

BAN CƠ YẾU CHÍNH PHỦ
HỌC VIỆN KỸ THUẬT MẬT MÃ



BÁO CÁO MÔN HỌC
CHUYÊN ĐỀ CHUYÊN SÂU

**NGHIÊN CỨU PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC
TRÙNG ĐỐI VỚI DỮ LIỆU LOGS TRONG PHÁT
HIỆN TẤN CÔNG**

Ngành: An toàn thông tin
Mã số: 7.48.02.02

Sinh viên thực hiện:

Đoàn Ngọc Hoàng Minh – AT180632

Giảng viên hướng dẫn:

Ths. Nguyễn Thị Thu Thủy

Khoa An toàn thông tin – Học viện Kỹ thuật mật mã

Hà Nội, 2026

BAN CƠ YẾU CHÍNH PHỦ
HỌC VIỆN KỸ THUẬT MẬT MÃ



BÁO CÁO MÔN HỌC
CHUYÊN ĐỀ CHUYÊN SÂU

**NGHIÊN CỨU PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC
TRÙNG ĐỐI VỚI DỮ LIỆU LOGS TRONG PHÁT
HIỆN TẤN CÔNG**

Ngành: An toàn thông tin
Mã số: 7.48.02.02

Sinh viên thực hiện:

Đoàn Ngọc Hoàng Minh – AT180632

Giảng viên hướng dẫn:

Ths. Nguyễn Thị Thu Thủy

Khoa An toàn thông tin – Học viện Kỹ thuật mật mã

Hà Nội, 2026

MỤC LỤC

MỤC LỤC	i
DANH MỤC VIẾT TẮT	iv
DANH MỤC HÌNH VẼ	vii
DANH MỤC BẢNG	viii
Lời nói đầu	1
Chương 1. TỔNG QUAN VỀ PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC TRƯNG DỮ LIỆU LOG VÀ THÁCH THỨC BẢO TOÀN NGŨ CẢNH AN TOÀN.....	4
1.1. Bài toán biểu diễn log trong phát hiện tấn công đa giai đoạn.....	4
1.1.1. <i>Không gian dữ liệu log doanh nghiệp: tốc độ cao, mất cân bằng cực đoan và phân phối biến đổi</i>	<i>4</i>
1.1.2. <i>Hành vi tấn công đa giai đoạn và ánh xạ đa nhãn MITRE ATT&CK</i>	<i>7</i>
1.1.3. <i>Các mức biểu diễn dữ liệu và Hợp đồng Biểu diễn</i>	<i>10</i>
1.2. Phân tích so sánh các nhóm phương pháp hiện đại	14
1.2.1. <i>Phương pháp thống kê và cú pháp: Event Count, Frequency, Entropy và Template Features</i>	<i>15</i>
1.2.2. <i>Phương pháp semantic-sequential: Embeddings, Self-Supervised Learning, Transformer và Parsing-Free....</i>	<i>17</i>
1.2.3. <i>Đồ thị nguồn gốc và Graph Representation Learning..</i>	<i>19</i>
1.3. Các khoảng trống nghiên cứu cốt lõi	23
1.3.1. <i>Khoảng trống 1: Mất mát ngữ nghĩa an ninh trong quá trình trừu tượng hóa tham số.....</i>	<i>23</i>
1.3.2. <i>Khoảng trống 2: Bất đồng bộ và suy thoái trong giống hàng biểu diễn đa góc nhìn</i>	<i>24</i>
1.3.3. <i>Khoảng trống 3: Rò rỉ thông tin quy trình, học đường tắt và trôi dạt biểu diễn</i>	<i>25</i>
1.3.4. <i>Khoảng trống 4: Gán nhãn mức thô, phân bổ bằng chứng yếu và nhiễu quản trị viên</i>	<i>26</i>
1.3.5. <i>Khoảng trống 5: Đánh đổi giữa bảo toàn liên kết an ninh và rủi ro quyền riêng tư.....</i>	<i>27</i>
Chương 2. PHƯƠNG PHÁP BIỂU DIỄN ĐẶC TRƯNG LOG ĐA GÓC NHÌN BẢO TOÀN NGŨ CẢNH AN TOÀN	29
2.1. Hình thức hóa bài toán và giới hạn xử lý dòng.....	29
2.1.1. <i>Biểu diễn đa góc nhìn và ranh giới Extractor-Detector</i>	<i>29</i>
2.1.2. <i>Độ phức tạp xử lý dòng với trạng thái hữu hạn (Yêu cầu kỹ thuật vận hành ER1)</i>	<i>33</i>
2.1.3. <i>Kiến trúc tổng thể và giao diện vào/ra.....</i>	<i>35</i>
2.2. Tiền xử lý và bảo vệ dynamic parameters	37
2.2.1. <i>Parsing, Typed Canonicalization, Entity Resolution và Security-aware Parameter Retention</i>	<i>37</i>

2.2.2.	<i>Mô hình đe dọa quyền riêng tư và Controlled Linkability</i>	42
2.2.3.	<i>Đồng bộ thời gian và cửa sổ ngữ cảnh đa tỷ lệ</i>	46
2.3.	Trích xuất đặc trưng đa góc nhìn	48
2.3.1.	<i>Bộ trích xuất tuần tự ngữ nghĩa Transformer</i>	48
2.3.2.	<i>Xây dựng đồ thị nguồn gốc phụ thuộc thời gian và đảm bảo độ chân thực đồ thị</i>	53
2.3.3.	<i>Bộ trích xuất đồ thị động Temporal GNN</i>	56
2.4.	Giống hàng và học biểu diễn thông nhất đa góc nhìn	61
2.4.1.	<i>Giống hàng đa góc nhìn dị thể</i>	61
2.4.2.	<i>Nhận thức hành vi quản trị viên và điều hòa rủi ro</i>	67
2.4.3.	<i>Hàm mục tiêu thống nhất và phân bổ bằng chứng yếu</i>	69
2.4.4.	<i>Biểu diễn thống nhất, giao diện đầu ra và độ phức tạp</i>	75
Chương 3. THỰC NGHIỆM, ĐÁNH GIÁ VÀ ỨNG DỤNG		79
3.1.	Thiết lập thực nghiệm và dữ liệu	79
3.1.1.	<i>Môi trường tính toán, tính tái lập và kiểm định độ bất định thống kê</i>	79
3.1.2.	<i>Khung dữ liệu đối chuẩn và giao thức phân chia theo dòng thời gian chống rò rỉ</i>	81
3.1.3.	<i>Hệ thống thang đo ba tầng và hàm mục tiêu huấn luyện</i>	83
3.2.	Kết quả tiền huấn luyện và đối sánh phương pháp luận	86
3.2.1.	<i>Kết quả huấn luyện Stage A2 trên 5 hạt ngẫu nhiên thực nghiệm</i>	86
3.2.2.	<i>Đối sánh đặc tính phương pháp luận so với các nghiên cứu cơ sở</i>	88
3.2.3.	<i>Đánh giá chuẩn hóa V3 hạ nguồn cho các mô hình xác nhận Sequence và Multi-View</i>	90
3.2.4.	<i>Kiểm chứng tái lập độc lập trên máy trạm</i>	93
3.3.	Phân tích động thái tối ưu hóa và trạng thái bằng chứng giả thuyết	95
3.3.1.	<i>Phân tích động thái tối ưu hóa và hiện tượng dừng sớm</i>	95
3.3.2.	<i>Đối chiếu trạng thái bằng chứng đối với các giả thuyết nghiên cứu</i>	96
3.3.3.	<i>Phân tích cơ chế và các giả thuyết giải thích kết quả âm tính H2</i>	101
3.4.	Khả năng ứng dụng thực tế, giới hạn và hướng phát triển	102
3.4.1.	<i>Khả năng tích hợp vận hành trong trung tâm điều hành an ninh mạng SOC</i>	102
3.4.2.	<i>Các giới hạn thực nghiệm và hướng nghiên cứu tiếp theo</i>	102
Kết luận		104

DANH MỤC VIẾT TẮT

Viết tắt	Tiếng Anh	Tiếng Việt
APT	Advanced Persistent Threat	Mối đe dọa tấn công có chủ đích kéo dài
ATT&CK	Adversarial Tactics, Techniques, and Common Knowledge	Cơ sở tri thức về chiến thuật, kỹ thuật và quy trình tấn công
BGL	Blue Gene/L	Bộ dữ liệu nhật ký siêu máy tính Blue Gene/L
CUDA	Compute Unified Device Architecture	Kiến trúc thiết bị tính toán hợp nhất của NVIDIA
DARPA	Defense Advanced Research Projects Agency	Cơ quan Chỉ đạo các Dự án Nghiên cứu Quốc phòng Tiên tiến Hoa Kỳ
DNS	Domain Name System	Hệ thống phân giải tên miền
DP	Differential Privacy	Quyền riêng tư vi sai
EDR	Endpoint Detection and Response	Giải pháp phát hiện và phản ứng tại điểm cuối
FastText	FastText	Mô hình biểu diễn nhúng từ ngữ nghĩa FastText
GCN	Graph Convolutional Network	Mạng nơ-ron tích chập đồ thị
GELU	Gaussian Error Linear Unit	Hàm kích hoạt phi tuyến sai số Gaussian
GNN	Graph Neural Network	Mạng nơ-ron đồ thị
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
GRU	Gated Recurrent Unit	Đơn vị tái phát có cổng
HDFS	Hadoop Distributed File System	Hệ thống tệp tin phân tán Hadoop
ID	Identifier	Mã định danh
InfoNCE	Information Noise-Contrastive Estimation	Ước lượng tương phản nhiễu thông tin
IP	Internet Protocol	Giao thức Internet

Viết tắt	Tiếng Anh	Tiếng Việt
LANL	Los Alamos National Laboratory	Phòng thí nghiệm Quốc gia Los Alamos
LogBERT	Log Bidirectional Encoder Representations from Transformers	Mô hình biểu diễn bộ mã hóa hai chiều từ Transformer cho dữ liệu nhật ký
LRU	Least Recently Used	Chính sách loại bỏ phần tử ít được sử dụng gần nhất
LSTM	Long Short-Term Memory	Mạng nơ-ron bộ nhớ ngắn hạn dài
MIA	Membership Inference Attack	Tấn công suy luận thành viên
MIL	Multiple Instance Learning	Học đa thể hiện
MITRE	MITRE Corporation	Tổ chức nghiên cứu và phát triển phi lợi nhuận MITRE
MLP	Multi-Layer Perceptron	Mạng nơ-ron perceptron đa tầng
MSE	Mean Squared Error	Sai số bình phương trung bình
NIST	National Institute of Standards and Technology	Viện Tiêu chuẩn và Công nghệ Quốc gia Hoa Kỳ
PCA	Principal Component Analysis	Phương pháp phân tích thành phần chính
PCGrad	Projecting Conflicting Gradients	Kỹ thuật chiếu trực giao triệt tiêu xung đột gradient
PID	Process Identifier	Mã định danh tiến trình
PIDS	Provenance-based Intrusion Detection System	Hệ thống phát hiện xâm nhập dựa trên đồ thị nguồn gốc
PII	Personally Identifiable Information	Thông tin định danh cá nhân
RAM	Random Access Memory	Bộ nhớ truy cập ngẫu nhiên
SIEM	Security Information and Event Management	Hệ thống quản lý thông tin và sự kiện an ninh mạng
SOC	Security Operations Center	Trung tâm điều hành an ninh mạng

Viết tắt	Tiếng Anh	Tiếng Việt
SSH	Secure Shell	Giao thức truyền thông mạng bảo mật
SSL	Self-Supervised Learning	Học tự giám sát
TC	Transparent Computing	Chương trình điện toán minh bạch DARPA
TF-IDF	Term Frequency - Inverse Document Frequency	Tần suất xuất hiện từ - Nghịch đảo tần suất xuất hiện trong văn bản
TTL	Time to Live	Thời gian sống của trạng thái thực thể
UTC	Coordinated Universal Time	Giờ phối hợp quốc tế
UUID	Universally Unique Identifier	Mã định danh duy nhất toàn cầu
VICReg	Variance-Invariance-Covariance Regularization	Kỹ thuật điều hòa Phương sai - Bất biến - Hiệp phương sai
VRAM	Video Random Access Memory	Bộ nhớ video truy cập ngẫu nhiên của GPU
WMI	Windows Management Instrumentation	Giao diện quản lý hệ thống Windows
Word2Vec	Word to Vector	Mô hình nhúng từ Word to Vector

DANH MỤC HÌNH VẼ

Hình 1.1: Phân cấp các đơn vị quan sát và sự đánh đổi giữa ngữ cảnh và chi phí tính toán trong biểu diễn dữ liệu log , nguồn tác giả tổng hợp	5
Hình 1.2: Mô hình Không gian Bằng chứng Hành vi Đa chiều MITRE ATT&CK và các đặc trưng phi tuyến tính trong tấn công APT , nguồn tác giả tổng hợp dựa trên MITRE ATT&CK [4] và Inam et al. [1]2 [6] [3]	9
Hình 1.3: Khung phân định ranh giới ba tầng phương pháp luận và vị trí trọng tâm của không gian vector biểu diễn z , nguồn tác giả đề xuất	13
Hình 1.4: Bản đồ đối chiếu ba nhóm phương pháp biểu diễn log và nguồn gốc hình thành năm khoảng trống nghiên cứu cốt lõi , nguồn tác giả tổng hợp.....	23
Hình 2.1: Kiến trúc hai mặt phẳng (Training Plane & Inference Plane) của khung biểu diễn đặc trưng log đa góc nhìn dòng, nguồn tác giả đề xuất.....	36
Hình 2.2: Kiến trúc Bộ trích xuất tuần tự ngữ nghĩa Transformer và cơ chế học tự giám sát trên cửa sổ ngắn hạn, nguồn tác giả đề xuất.....	52
Hình 2.3: Kiến trúc xây dựng đồ thị nguồn gốc phụ thuộc thời gian và Bộ trích xuất Temporal GNN, nguồn tác giả đề xuất	60
Hình 2.4: Sơ đồ kiến trúc Gióng hàng đa góc nhìn, Kiểm soát sụp đổ và Tổng hợp biểu diễn thống nhất, nguồn tác giả đề xuất.....	77

DANH MỤC BẢNG

Bảng 1.1: Phân cấp các đơn vị quan sát và mức độ hạt biểu diễn dữ liệu log.....	6
Bảng 1.2: Đặc tả Hợp đồng Biểu diễn cho vector đặc trưng z	11
Bảng 1.3: So sánh đối chiếu ba nhóm phương pháp biểu diễn đặc trưng log chủ đạo	22
Bảng 2.1: Chính sách RETAIN / NORMALIZE / PRIVACY-PROTECT / UNKNOWN-SAFE cho các trường của bộ sáu kiểu hóa	39
Bảng 2.2: Đặc tả kiến trúc và độ phức tạp tính toán của hai bộ trích xuất đặc trưng đa góc nhìn	60
Bảng 2.3: So sánh đối sánh các cơ chế tự giám sát đa góc nhìn trong bài toán an ninh mạng	63
Bảng 2.4: Kiểm toán toàn diện các khối tham số và đồ thị tối ưu hóa trong hệ thống	70
Bảng 3.1: Thông số kỹ thuật môi trường thực nghiệm và khóa xác thực mật mã	80
Bảng 3.2: Phân chia tập dữ liệu HDFS theo giao thức theo dòng thời gian chống rò rỉ2	82
Bảng 3.3: Kết quả huấn luyện Stage A2 trên 5 hạt ngẫu nhiên thực nghiệm	87
Bảng 3.4: Trạng thái hồ sơ và điều kiện kết thúc các đợt thực nghiệm Stage A2	87
Bảng 3.5: Đối sánh đặc tính phương pháp luận giữa khung biểu diễn đề xuất và các phương pháp cơ sở	89
Bảng 3.6: Kết quả đánh giá hạ nguồn V3 trên 100% tập Validation cho các mô hình Sequence và Multi-View	90
Bảng 3.7: Đối sánh hiệu năng cặp đôi Multi-View so với Sequence-Only và kiểm định biên không thua kém	91
Bảng 3.8: Kết quả kiểm thử cắt bỏ che tham số đầu vào trên Sequence-Only đóng băng	97

Bảng 3.9: Kiểm tra độ nhạy bỏ tham số đầu vào Sequence đối với hiệu năng phát hiện bất thường hạ nguồn.....	98
---	----

LỜI NÓI ĐẦU

Dữ liệu log là nguồn dấu vết phản ánh trực tiếp hoạt động của hệ thống thông tin. Các sự kiện như đăng nhập, tạo tiến trình, truy cập tệp, thay đổi quyền, thực hiện truy vấn hoặc thiết lập kết nối mạng đều có thể được ghi nhận bởi hệ điều hành, ứng dụng, thiết bị mạng, nền tảng đám mây và giải pháp bảo mật. Khi được thu thập và liên kết đúng cách, log cung cấp bằng chứng quan trọng cho giám sát an toàn thông tin, phát hiện tấn công, ứng cứu sự cố và điều tra số.

Tuy nhiên, giá trị của log không nằm ở số lượng bản ghi được lưu giữ mà ở khả năng chuyển chúng thành thông tin có thể phân tích. Một sự kiện đơn lẻ đôi khi đã chứa dấu hiệu nguy hiểm, chẳng hạn tiến trình PowerShell thực thi lệnh mã hóa hoặc tài khoản đặc quyền đăng nhập từ thiết bị chưa từng sử dụng. Trong nhiều trường hợp khác, từng sự kiện riêng biệt đều có vẻ hợp lệ nhưng khi kết hợp theo thời gian lại hình thành chuỗi hành vi của một cuộc tấn công, từ giành quyền truy cập, thực thi mã và duy trì hiện diện đến di chuyển ngang, điều khiển từ xa và đánh cắp dữ liệu.

Phân tích log tự động gặp nhiều khó khăn do sự khác biệt về nguồn phát sinh, cấu trúc, mức độ chi tiết và ngữ nghĩa. Log có thể tồn tại dưới dạng văn bản tự do, dữ liệu bán cấu trúc hoặc định dạng riêng của từng nền tảng. Khối lượng sự kiện thường rất lớn, trong khi tỷ lệ bản ghi liên quan đến tấn công rất nhỏ. Nhân dữ liệu có thể thiếu, sai hoặc chỉ được cung cấp ở mức phiên. Bên cạnh đó, sự thay đổi của phần mềm, cấu hình và hành vi người dùng liên tục tạo ra những mẫu log mới, làm suy giảm hiệu quả của các mô hình được huấn luyện trên dữ liệu cố định.

Trong pipeline phát hiện tấn công, trích xuất đặc trưng quyết định những tín hiệu mà mô hình có thể quan sát. Log thô cần được chuyển thành vector, chuỗi hoặc đồ thị trước khi đưa vào thuật toán học máy. Đặc trưng có thể phản ánh mã sự kiện, từ khóa, tần suất, độ hiếm, khoảng thời gian giữa các hoạt động, nội dung ngữ nghĩa hoặc quan hệ giữa người dùng, máy chủ, tiến trình, tệp và địa chỉ mạng. Một mô hình phức tạp vẫn khó đạt hiệu quả nếu quá trình tiền xử lý đã loại bỏ các tham số mang ý nghĩa an toàn hoặc không biểu diễn được ngữ cảnh của hành vi tấn công.

Các phương pháp truyền thống như Bag of Words, n-gram, TF-IDF và đặc trưng thống kê có ưu điểm về tốc độ, chi phí và khả năng giải thích, nhưng hạn chế trong việc xử lý biến thể cú pháp và quan hệ dài hạn [1], [2]. Các mô hình LSTM, GRU và Transformer được phát triển để học đặc trưng trình tự và ngữ nghĩa; mạng nơ-ron đồ thị giúp mô hình hóa quan hệ giữa nhiều thực thể; học tự giám sát hỗ trợ khai thác lượng lớn log chưa gán nhãn. Mô hình ngôn ngữ lớn mở thêm khả năng chuẩn hóa và diễn giải log, nhưng vẫn chịu hạn chế về chi phí, độ trễ, tính ổn định và bảo mật dữ liệu [2]. Vì vậy, không có một kiến trúc duy nhất phù hợp với mọi nguồn log và mọi loại tấn công.

Một thách thức kỹ thuật khác là sự phụ thuộc vào bước phân tích cú pháp. Việc chuyển log thành mẫu sự kiện giúp giảm nhiễu, nhưng có thể đồng thời loại bỏ tên tiến trình, tài khoản, địa chỉ mạng, đường dẫn hoặc đối số dòng lệnh có giá

trị phát hiện. Do đó, chất lượng của phương pháp trích xuất đặc trưng cần được đánh giá không chỉ qua khả năng khái quát hóa dữ liệu mà còn qua mức độ bảo toàn tín hiệu bảo mật và hiệu quả của tác vụ phát hiện phía sau.

Từ những vấn đề trên, đề tài “Nghiên cứu phương pháp trích xuất đặc trưng đối với dữ liệu log trong phát hiện tấn công” được thực hiện nhằm khảo sát, phân loại và đánh giá có hệ thống các phương pháp chuyển đổi log thành biểu diễn phục vụ phát hiện bất thường và tấn công mạng. Mục tiêu trọng tâm không chỉ là lựa chọn một mô hình phân loại, mà còn xác định những thông tin cần được bảo toàn, những thành phần có thể được tổng quát hóa và những quan hệ cần được mô hình hóa.

Đối tượng nghiên cứu gồm dữ liệu log từ hệ điều hành, ứng dụng, hệ thống xác thực, thiết bị mạng, giải pháp bảo mật và môi trường đám mây; các bước tiền xử lý; cùng những phương pháp hình thành đặc trưng dạng vector, chuỗi và đồ thị. Đề tài tập trung vào log dạng văn bản và dữ liệu sự kiện có cấu trúc hoặc bán cấu trúc, không đi sâu vào phân tích mã nhị phân, toàn bộ nội dung gói tin mạng hoặc xây dựng một nền tảng SIEM hoàn chỉnh.

Nghiên cứu hướng tới làm rõ vai trò của các nhóm đặc trưng thống kê, từ vựng, ngữ nghĩa, thời gian và đồ thị; ảnh hưởng của parsing, phân phiên và chia cửa sổ; khả năng xử lý mẫu sự kiện chưa từng xuất hiện; cũng như sự đánh đổi giữa độ chính xác, độ trễ, tài nguyên và khả năng giải thích. Giả thuyết được đặt ra là không một nhóm đặc trưng đơn lẻ nào có thể phản ánh đầy đủ bản chất của tấn công. Việc bảo toàn tham số có ý nghĩa an toàn và kết hợp có chọn lọc nhiều góc nhìn có khả năng tạo ra biểu diễn toàn diện và ổn định hơn.

Đề tài sử dụng phương pháp nghiên cứu tài liệu để thu thập và đối chiếu các công trình liên quan; phương pháp phân tích, tổng hợp để xây dựng hệ thống phân loại và xác định khoảng trống nghiên cứu; phương pháp mô hình hóa để biểu diễn pipeline xử lý log; cùng phương pháp thực nghiệm để so sánh các nhóm đặc trưng trong điều kiện kiểm soát. Khung đánh giá được thiết kế với các chỉ số dự kiến phù hợp với dữ liệu mất cân bằng, hướng tới xem xét cảnh báo sai, độ trễ, tài nguyên và khả năng giải thích cho các giai đoạn kiểm thử hạ nguồn tiếp theo.

Về phương diện khoa học, đề tài hướng tới thiết lập hệ thống phân loại đa chiều cho các phương pháp trích xuất đặc trưng, làm rõ ranh giới giữa phát hiện bất thường hệ thống và phát hiện tấn công, đồng thời xác định yêu cầu đối với một biểu diễn log có khả năng bảo toàn ngữ nghĩa, thời gian và quan hệ. Chuyên đề xác lập ranh giới phạm vi rõ ràng: trọng tâm nghiên cứu là bài toán trích xuất đặc trưng phục vụ phát hiện tấn công (feature extraction for attack detection); các kết quả thực nghiệm trong chuyên đề hiện thời cung cấp bằng chứng tiền huấn luyện tự giám sát (Stage A2) trên phân vùng Train/Validation, hoàn toàn phân định với việc đánh giá toàn diện năng lực phát hiện tấn công hạ nguồn (downstream attack detection) trên tập kiểm thử niêm phong khi có ủy quyền chính thức. Về khía cạnh thực tiễn, kết quả nghiên cứu hỗ trợ việc lựa chọn kỹ thuật phù hợp với từng nguồn dữ liệu và điều kiện triển khai, làm cơ sở xây dựng pipeline phân tích cho SIEM, SOC, EDR và hoạt động săn tìm mối đe dọa.

Báo cáo chuyên đề được cấu trúc thành ba chương trọng tâm:

Chương 1. Tổng quan về phương pháp trích xuất đặc trưng dữ liệu log và thách thức bảo toàn ngữ cảnh an toàn: Trình bày bài toán biểu diễn dữ liệu log doanh nghiệp, hành vi tấn công đa giai đoạn trên ma trận MITRE ATT&CK (Phiên bản Enterprise v19.1, 12/05/2026), khung Hợp đồng Biểu diễn, phân tích đối chiếu ba nhóm phương pháp hiện đại và xác lập 5 khoảng trống nghiên cứu cốt lõi tương ứng với 5 câu hỏi nghiên cứu từ RQ1 đến RQ5.

Chương 2. Đề xuất phương pháp trích xuất đặc trưng đa view bảo toàn ngữ cảnh và nhận thức quyền riêng tư: Trình bày kiến trúc biểu diễn đa góc nhìn kết hợp chuỗi sự kiện và đồ thị nguồn gốc, cơ chế giống hàng tiềm ẩn chống sụp đổ biểu diễn, phân bổ bằng chứng yếu cho nhiều quản trị viên và cơ chế bảo toàn liên kết có kiểm soát quyền riêng tư.

Chương 3. Thực nghiệm, đánh giá và ứng dụng: Mô tả thiết lập thực nghiệm, giao thức phân chia dữ liệu theo dòng thời gian chống rò rỉ và bồi cảnh các tập benchmark (DARPA TC, LANL, HDFS, BGL); báo cáo kết quả tiền huấn luyện tự giám sát Stage A2 trên tập Train/Validation (tập trung trên HDFS) qua các đợt chạy độc lập nhằm khảo sát động thái tối ưu hóa và kiểm toán thực nghiệm; đối chiếu trạng thái bằng chứng thực tế với năm giả thuyết nghiên cứu; định vị rõ khung đánh giá trôi dạt dữ liệu, rủi ro quyền riêng tư (MIA/Model Inversion) và phát hiện tấn công hạ nguồn là các giao thức đánh giá tiếp theo; thảo luận tiềm năng ứng dụng trong hệ thống SOC.

CHƯƠNG 1. TỔNG QUAN VỀ PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC TRƯNG DỮ LIỆU LOG VÀ THÁCH THỨC BẢO TOÀN NGỮ CẢNH AN TOÀN

1.1. Bài toán biểu diễn log trong phát hiện tấn công đa giai đoạn


Trong các trung tâm điều hành an ninh mạng (SOC), dữ liệu nhật ký hệ điều hành và nhật ký kiểm toán là nguồn bằng chứng trung tâm phục vụ phát hiện, điều tra và đối phó các cuộc tấn công có chủ đích kéo dài [3]. Khác với văn bản ngôn ngữ tự nhiên hay tín hiệu hình ảnh, dữ liệu nhật ký có cấu trúc bán cấu trúc, phụ thuộc thứ tự thời gian, phản ánh quan hệ phụ thuộc thực thi giữa các tiến trình và tài nguyên hệ thống, đồng thời mang ngữ nghĩa an ninh chuyên biệt [4], [5]. Mục 1.1 hình thức hóa bài toán biểu diễn đặc trưng nhật ký phục vụ phát hiện tấn công đa giai đoạn, phân tích đặc tính không gian dữ liệu doanh nghiệp, xác lập mô hình hành vi dựa trên ma trận MITRE ATT&CK [6] và thiết lập Hợp đồng Biểu diễn nhằm bảo toàn các ràng buộc an toàn cho không gian vector đặc trưng.

1.1.1. *Không gian dữ liệu log doanh nghiệp: tốc độ cao, mất cân bằng cực đoan và phân phối biến đổi*

Không gian dữ liệu nhật ký trong môi trường mạng doanh nghiệp được tổng hợp từ ba nhóm nguồn dữ liệu chính với cấu trúc và định dạng không đồng nhất [3], [7]. Nhóm thứ nhất là nhật ký kiểm toán máy chủ và viễn trức nguồn gốc. Trên các hệ thống Linux, các cơ chế thu thập viễn trức nguồn gốc và kiểm toán mức nhân, như Linux Auditd hoặc eBPF, ghi nhận các sự kiện lời gọi hệ thống, tiêu biểu như khởi tạo tiến trình `execve`, thao tác tệp tin `open`, `openat`, `unlink` và kết nối mạng `connect`, `accept`, để phục vụ điều tra số và xây dựng đồ thị quan hệ nhân quả [3], [4]. Trong khi đó, trên môi trường Windows, Microsoft Sysinternals Sysmon cung cấp viễn trức an ninh mức hệ điều hành thông qua các sự kiện định danh chuẩn hóa theo đặc tả kỹ thuật chính thức của Russinovich & Garnier [8], tiêu biểu gồm: khởi tạo tiến trình (`ProcessCreate` - Event ID 1), kết nối mạng (`NetworkConnect` - Event ID 3), nạp thư viện động (`ImageLoaded` -

Event ID 7), tạo tệp tin (FileCreate - Event ID 11), và thao tác cấu hình registry (RegistryEvent - Event ID 13). Nhóm thứ hai là nhật ký luồng mạng, được thu thập từ Zeek, Suricata hoặc NetFlow/IPFIX, cung cấp siêu dữ liệu kết nối giữa các nút mạng, giao dịch DNS, chứng chỉ TLS/SSL và thông lượng gói tin. Nhóm thứ ba là nhật ký ứng dụng và dịch vụ phân tán, phát sinh từ máy chủ web Apache, hệ thống tệp phân tán HDFS cùng các dịch vụ tính toán cụm thuộc bộ benchmark LogHub [9].

Tính dị thể sâu sắc của dữ liệu đặt ra bài toán khoa học về việc lựa chọn đơn vị quan sát phù hợp cho mô hình học biểu diễn, như được hệ thống hóa trực quan trong Hình 1.1 và chi tiết hóa trong Bảng 1.1:



Hình 1.1: Phân cấp các đơn vị quan sát và sự đánh đổi giữa ngữ cảnh và chi phí tính toán trong biểu diễn dữ liệu log , nguồn tác giả tổng hợp

Bảng 1.1: Phân cấp các đơn vị quan sát và mức độ hạt biểu diễn dữ liệu log

Mức độ hạt	Đơn vị quan sát	Dữ liệu đại diện	Ưu điểm cốt lõi	Thách thức và Mất mát ngữ nghĩa
Mức từ tố (Token)	Chuỗi con, từ khóa rời rạc	Từ khóa tĩnh, địa chỉ IP, mã lỗi hex	Dễ dàng vector hóa bằng kỹ thuật nhúng từ vụng	Mất liên kết cấu trúc cú pháp và quan hệ trường
Mức sự kiện (Event)	Một dòng log đơn lẻ	Bản ghi telemetry tại thời điểm t	Bảo toàn đầy đủ thuộc tính cục bộ tại thời điểm t	Thiếu ngữ cảnh chuỗi tuần tự và lịch sử tương tác
Mức chuỗi / Phiên (Session)	Cửa sổ trượt hoặc phiên tiến trình	Chuỗi sự kiện $[e_{t-k+1}, \dots, e_t]$ theo thời gian	Nắm bắt quan hệ phụ thuộc thứ tự thời gian	Nhạy cảm với nhiễu xen kẽ từ các luồng song song
Mức thực thể (Entity)	Định danh tác nhân (Host, User, Process)	Lịch sử tương tác gom cụm theo thực thể	Phân lập rõ ràng ranh giới hành vi chủ thể	Khó phát hiện hành vi tấn công vượt ranh giới
Mức đồ thị (Graph)	Đồ thị nguồn gốc (Provenance Graph)	Đồ thị luồng phụ thuộc di thể G	Mô hình hóa toàn diện quan hệ đa thực thể	Bùng nổ kích thước đồ thị và chi phí tính toán

Bên cạnh tính dị thể giữa các nguồn thu thập, dữ liệu nhật ký doanh nghiệp còn chịu áp lực lớn về mặt thông lượng và tỷ lệ phân bố nhãn [5], [10]. Hệ thống tiếp nhận luồng sự kiện liên tục với tốc độ cao, đòi hỏi cơ chế xử lý dòng trực tiếp như cách tiếp cận phác họa đồ thị của UNICORN [11], đồng thời đặt ra yêu cầu kiểm soát tài nguyên bộ nhớ khi theo dõi các đồ thị nguồn gốc kéo dài. Tỷ lệ các dòng nhật ký liên quan đến hành vi tấn công trong thực tế thường rất nhỏ so với

lưu lượng vận hành nền, tạo ra sự mất cân bằng dữ liệu sâu sắc khiến các thuật toán học máy thông thường có xu hướng bỏ qua nhóm thiểu số [10]. Bên cạnh đó, hiện tượng sụp đổ chiều biểu diễn có nguy cơ xuất hiện khi mô hình học biểu diễn tự giám sát trên luồng dữ liệu mất cân bằng không có cơ chế điều hòa phương sai và hiệp phương sai phù hợp để duy trì độ phong phú của các chiều vector [12], [13].

Dưới góc độ phân phối thời gian, dữ liệu nhật ký liên tục biến động trong quá trình vận hành dài hạn. Dựa trên bản chất không dừng của luồng dữ liệu và phương pháp luận đánh giá theo thời gian [10], bốn dạng trôi dạt dữ liệu được phân định như sau:

- Một là, trôi dạt khái niệm *Concept Drift*: Bản chất hành vi và mục tiêu tấn công thay đổi theo thời gian dù cấu trúc định dạng nhật ký không biến đổi: $P_t(Y | X) \neq P_{t+1}(Y | X)$.
- Hai là, trôi dạt mẫu định dạng *Template Drift*: Việc nâng cấp phần mềm, cập nhật bản vá hoặc thay đổi cấu hình làm biến đổi cấu trúc các chuỗi mẫu nhật ký: $P_t(X_{\text{template}}) \neq P_{t+1}(X_{\text{template}})$.
- Ba là, trôi dạt quần thể *Population Drift*: Lưu lượng người dùng, tần suất giao tác nghiệp vụ hoặc cơ cấu dịch vụ hệ thống biến động theo chu kỳ vận hành: $P_t(X) \neq P_{t+1}(X)$.
- Bốn là, trôi dạt không gian biểu diễn *Representation Drift*: Không gian vector tiềm ẩn z bị suy giảm năng lực phân tách do dữ liệu đầu vào trôi xa khỏi phân phối huấn luyện ban đầu: $P_t(z | X) \neq P_{t+1}(z | X)$.


1.1.2. Hành vi tấn công đa giai đoạn và ánh xạ đa nhãn MITRE ATT&CK

Trong lịch sử nghiên cứu phát hiện xâm nhập, các tiếp cận ban đầu thường dựa trên giả định chuỗi tấn công đơn tuyến (Cyber Kill Chain) hoặc các mô hình xích Markov tuyến tính để xâu chuỗi tuần tự các giai đoạn tấn công từ Thâm nhập ban đầu Initial Access, Thực thi Execution, Duy trì Persistence, Leo thang đặc quyền Privilege Escalation cho đến Đánh cắp dữ liệu Exfiltration.

Tuy nhiên, trên thực tế vận hành và theo khung phân loại chuẩn hóa của ma trận tri thức an ninh MITRE ATT&CK [6], các chiến dịch tấn công có chủ đích (APT) mang bản chất phi tuyến tính sâu sắc [3]. Cần lưu ý rằng MITRE khuyến nghị ATT&CK không phải là một danh mục kiểm tra đầy đủ khép kín; từ ontology ATT&CK và các quan sát về đồ thị nguồn gốc hệ thống [3], nghiên cứu tổng hợp ba cấu trúc phân tích đặc thù sau ; đây là cấu trúc phân loại do đề tài tự tổng hợp, không phải bảng phân loại chính thức của MITRE ATT&CK: *Một là*, cấu trúc nhảy cóc giai đoạn Step Skipping: Kẻ tấn công có thể khai thác trực tiếp lỗ hổng thực thi mã từ xa để trích xuất dữ liệu ra ngoài mà không cần thiết lập cơ chế duy trì hay di chuyển ngang; *Hai là*, cấu trúc lặp vòng kỹ thuật Tactic Looping & Interleaving: Kỹ thuật thu thập thông tin nội bộ Discovery thường được lặp lại nhiều lần xen kẽ giữa các bước leo thang đặc quyền và chiếm đoạt thông tin xác thực; *Ba là*, cấu trúc phân nhánh tiến trình song song Parallel Branching: Kẻ tấn công có thể khởi tạo đồng thời nhiều luồng tiến trình con độc lập trên các tiến trình hợp lệ khác nhau nhằm phân tán sự theo dõi của hệ thống phòng thủ.

Do đó, chuyên đề xác lập nguyên tắc: Ma trận MITRE ATT&CK được mô hình hóa thành một Không gian Bằng chứng Hành vi Đa chiều (Multi-label Behavioral Evidence Space), được minh họa trực quan trong Hình 1.2: Mô hình Không gian Bằng chứng Hành vi Đa chiều MITRE ATT&CK và các đặc trưng phi tuyến tính trong tấn công APT , nguồn tác giả tổng hợp dựa trên MITRE ATT&CK [4] và Inam et al. [1]2:

$$\mathcal{Y}_{\text{ATT\&CK}} = \mathcal{T}_{\text{tactics}} \times \mathcal{T}_{\text{techniques}}$$



Hình 1.2: Mô hình Không gian Bằng chứng Hành vi Đa chiều MITRE ATT&CK và các đặc trưng phi tuyến tính trong tấn công APT , nguồn tác giả tổng hợp dựa trên MITRE ATT&CK [4] và Inam et al. [1]2 [6] [3]

Trong đó mỗi chiến thuật Tactic đại diện cho mục tiêu chiến thuật của kẻ tấn công, trả lời câu hỏi “Tại sao”, và mỗi kỹ thuật Technique đại diện cho phương thức thực thi cụ thể, trả lời câu hỏi “Làm thế nào”; một chuỗi sự kiện hoặc cây tiến trình có thể đồng thời kích hoạt nhiều nhãn chiến thuật và kỹ thuật tại cùng một thời điểm quan sát [6].

Xét theo dữ liệu thực nghiệm, việc mô hình hóa hành vi tấn công đòi hỏi phải phân định chuẩn xác đặc tính gắn nhãn và mức độ hạt của từng bộ dữ liệu chuẩn [5]: *Một là*, bộ dữ liệu DARPA Transparent Computing Engagement #3 (TC E3, diễn ra tháng 4/2018) [14] và Engagement #5 (TC E5) [15] cung cấp dữ liệu kiểm toán hệ thống mức hạt nhân chi tiết, trong đó các kịch bản tấn công và diễn tập red-team trong các engagement của chương trình được gắn nhãn ở mức độ hạt tiến trình và luồng phụ thuộc; *Hai là*, bộ dữ liệu LANL Unified Host and Network Dataset [16] phản ánh môi trường mạng doanh nghiệp quy mô lớn với hàng tỷ sự kiện xác thực và luồng mạng, trong đó nhãn mặt đất thực nghiệm được xác lập từ tệp redteam.txt ghi nhận các sự kiện xác thực bị xâm nhập cụ thể của đội Red Team theo mốc thời gian và tài khoản/máy chủ xác định; *Ba là*, bộ dữ liệu HDFS của Xu et al. [17] và LogHub [9] được gắn nhãn bất thường theo vết

thực thi ở mức khối dữ liệu [17], phản ánh trạng thái bình thường hoặc bất thường của một phiên giao tác phân tán hoàn chỉnh; *Bốn là*, bộ dữ liệu BGL thuộc kho LogHub [9] đại diện cho nhật ký siêu máy tính với nhãn bất thường được xác lập ở mức dòng log đơn lẻ [9].

Đặc biệt, sự xuất hiện của hoạt động quản trị viên hệ thống là một thách thức vận hành thực tế. Các kỹ sư quản trị thường xuyên sử dụng các công cụ hợp lệ của hệ điều hành như PowerShell, SSH, WMI tương tự như công cụ kẻ tấn công khai thác; hiện tượng này đòi hỏi mô hình học sâu không dừng lại ở các mẫu cú pháp bề mặt mà phải nắm bắt được tương quan phụ thuộc cấu trúc và ngữ cảnh thực thi.

1.1.3. Các mức biểu diễn dữ liệu và Hợp đồng Biểu diễn

Khắc phục hạn chế của các nghiên cứu tiền nhiệm vốn thường đồng nhất việc trích xuất đặc trưng với thuật toán phân loại cụ thể, chuyên đề tiếp cận bài toán dưới góc nhìn của học biểu diễn sâu (Deep Representation Learning). Trong học sâu, mô hình thiết lập một ánh xạ hàm tham số chuyển đổi dữ liệu nhật ký hệ thống đa góc nhìn sang không gian vector tiềm ẩn. Điểm cốt lõi về mặt nhận thức luận là vector biểu diễn z chỉ phản ánh những thuộc tính và quy luật thống kê mà hàm mục tiêu tối ưu hóa khuyến khích lưu giữ, chứ không phải một bản sao toàn tri của mọi trạng thái hệ điều hành; những thông tin không xuất hiện trong dữ liệu quan sát hoặc không được objective thúc đẩy có thể không tồn tại trong z . Do đó, để định hình không gian biểu diễn phục vụ mục tiêu an ninh, chuyên đề đề xuất một khung khái niệm chính thức mang tên Hợp đồng Biểu diễn, ký hiệu là $\mathcal{C}_{\text{representation}}$, đóng vai trò như một bản đặc tả các ràng buộc toán học và ngữ nghĩa giữa dữ liệu thô và không gian vector tiềm ẩn z :

$$\mathcal{C}_{\text{representation}} = \langle \mathcal{P}_{\text{preserve}}, \mathcal{I}_{\text{invariant}}, \mathcal{E}_{\text{exclude}} \rangle$$

Khung Hợp đồng Biểu diễn thiết lập ba nhóm điều kiện ràng buộc bắt buộc mà không gian vector biểu diễn z phải đồng thời thỏa mãn:

Một là, nhóm Điều kiện Bảo toàn PRESERVE: Tập hợp các thuộc tính và tương quan an ninh bắt buộc phải được bảo toàn trong không gian vector biểu diễn, bao gồm ngữ nghĩa của các tham số dòng lệnh quan trọng, trật tự thời gian và quan hệ phụ thuộc thực thi giữa các tiến trình, tệp tin và kết nối mạng, cấu trúc cục bộ của đồ thị nguồn gốc cùng các đặc trưng nhận diện chiến thuật và kỹ thuật MITRE ATT&CK.

Hai là, nhóm Điều kiện Bất biến INVARIANT: Tập hợp các biến đổi hình thức mà không gian vector z phải duy trì tính bất biến, bao gồm sự thay đổi cú pháp vô hại của chuỗi nhật ký (định dạng thời gian, khoảng trắng, thứ tự các trường không mang nghĩa an ninh), sự ngẫu nhiên hóa mã định danh tiến trình (PID/PPID), tên tài khoản cục bộ không ảnh hưởng đến bản chất luồng thực thi và các biến động chu kỳ của lưu lượng nền.

Ba là, nhóm Điều kiện Triệt tiêu EXCLUDE: Tập hợp các thông tin giả tạo và biến số ngoài miền bắt buộc phải bị loại bỏ khỏi không gian vector z nhằm ngăn ngừa rủi ro học đường tắt [10]. Bao gồm các mẫu định dạng đặc thù của môi trường thử nghiệm lab, các biến số gây rò rỉ phân vùng và dấu thời gian tuyệt đối của máy thử nghiệm [10], cùng các tương quan ngẫu nhiên có thể khiến mô hình đạt điểm số ảo trên tập kiểm thử nhưng suy giảm năng lực khi vận hành thực tế.

Các đặc tả chi tiết của Hợp đồng Biểu diễn được hệ thống hóa trong Bảng 1.2:

Bảng 1.2: Đặc tả Hợp đồng Biểu diễn cho vector đặc trưng z


Thành phần hợp đồng	Mục tiêu ràng buộc	Đối tượng áp dụng cụ thể trong dữ liệu log	Cơ chế kiểm chứng thực nghiệm
PRESERVE (Bảo toàn)	Bảo tồn đầy đủ tín hiệu ngữ cảnh an ninh phân biệt	Ngữ nghĩa tham số động, trật tự thời gian và quan hệ phụ thuộc, tô-pô đồ thị, nhãn ATT&CK	Linear Probing, Mutual Information

Thành phần hợp đồng	Mục tiêu ràng buộc	Đối tượng áp dụng cụ thể trong dữ liệu log	Cơ chế kiểm chứng thực nghiệm
INVARIANT (Bất biến)	Duy trì bất biến trước biến đổi hình thức và trôi dạt vô hại	Định dạng timestamp, PID ngẫu nhiên, hoán vị cú pháp vô hại	Invariance Loss, Data Augmentation
EXCLUDE (Triệt tiêu)	Loại bỏ rò rỉ phân vùng và biến số học đường tắt	Artifacts môi trường lab, hostname cố định, thông tin định danh nhạy cảm (PII)	Snooping Test, Feature-leakage / Re-identification Audit

Nguyên tắc PRESERVE tập trung vào việc bảo toàn ngữ nghĩa an ninh động chứ không đồng nghĩa với việc giữ lại toàn bộ định danh thô của người dùng hay máy chủ. Về mặt bảo vệ quyền riêng tư, chuyên đề phân định rạch ròi bốn cấp độ an toàn thông tin và không đồng nhất khả năng phòng thủ giữa các cấp độ này: *Một là*, cơ chế giả danh hóa ẩn danh hóa thông qua việc ánh xạ các định danh nhạy cảm như tên người dùng, địa chỉ IP và tên máy chủ sang không gian mã băm hoặc chỉ số trừu tượng nhằm kiểm soát khả năng liên kết dữ liệu; *Hai là*, đề xuất quy trình đánh giá rủi ro trước tấn công suy luận thành viên (Membership Inference Attack – MIA) [18], được định vị là phép kiểm tra hạ nguồn nhằm đánh giá khả năng đối nghịch xác định một bản ghi nhật ký cụ thể có thuộc tập huấn luyện hay không; *Ba là*, đề xuất quy trình đánh giá rủi ro trước tấn công đảo ngược mô hình Model Inversion Attack [19], cũng được định vị là phép kiểm tra hạ nguồn nhằm đánh giá nguy cơ khôi phục thông tin cấu hình từ vector biểu diễn tiềm ẩn; *Bốn là*, định hướng khung bảo đảm toán học về quyền riêng tư vi sai (Differential Privacy – DP) theo hướng dẫn chuẩn mực của NIST SP 800-226 [20]. Cần khẳng định rằng vector biểu diễn tiềm ẩn không tự động an toàn về quyền riêng tư nếu không có cơ chế chứng minh toán học tường minh; các quy trình kiểm thử tấn công MIA hay Model Inversion được định vị là phép kiểm tra

hạ nguồn độc lập và chưa được thực thi trong phạm vi thực nghiệm hiện tại của chuyên đề [18], [19], kết hợp khung lý thuyết DP định hướng lượng hóa độ mất mát quyền riêng tư [20]. Tương tự, nguyên tắc EXCLUDE thiết lập các ràng buộc phủ định đối với các giả định đường tắt đã biết và các biến số gây rò rỉ phân vùng [10], thay vì giả định rằng mọi đường tắt đều có thể nhận biết trước khi thực nghiệm.

Đi đôi với Hợp đồng Biểu diễn được quy định trong Bảng 1.2, chuyên đề thiết lập nguyên tắc phân định ranh giới phương pháp luận ba tầng độc lập, được mô hình hóa tổng quát trong Hình 1.3:



Hình 1.3: Khung phân định ranh giới ba tầng phương pháp luận và vị trí trọng tâm của không gian vector biểu diễn z , nguồn tác giả đề xuất

Tầng 1 phụ trách trích xuất đặc trưng cơ sở: Đảm nhiệm tiền xử lý dữ liệu thô, phân tích cú pháp sơ bộ, chuẩn hóa kiểu dữ liệu trường và làm sạch dữ liệu ban đầu. Tầng này không gánh vác nhiệm vụ học biểu diễn ngữ cảnh an ninh sâu.

Tầng 2 học không gian biểu diễn tự giám sát: Thiết lập kiến trúc bộ mã hóa $f_\theta: \mathcal{X} \rightarrow z \in \mathbb{R}^d$ cùng các đầu chiếu phụ trợ để chuyển đổi chuỗi sự kiện và đồ thị

nguồn gốc sang không gian vector tiềm ẩn. Các hàm mất mát tự giám sát như dự đoán tham số bị che, dự đoán sự kiện tiếp theo, dự đoán quan hệ đồ thị và căn chỉnh thời gian đóng vai trò là các mục tiêu tối ưu hóa hình thức nhằm định hướng không gian vector z lưu giữ tín hiệu phục vụ các ràng buộc PRESERVE và INVARIANT; các hàm mục tiêu này là công cụ tối ưu hóa hình thức chứ không cấu thành bằng chứng trực tiếp chứng minh mô hình đã tự động hiểu bản chất an ninh hay nhân quả, và chất lượng biểu diễn bắt buộc phải được đánh giá qua các tác vụ hạ nguồn [12].

Tầng 3 thực hiện đánh giá phát hiện hạ nguồn: Đánh giá chất lượng của vector biểu diễn z thông qua giao thức đóng băng bộ mã hóa và huấn luyện bộ phân loại tuyến tính (Frozen Linear Probing theo chuẩn mực SimCLR [21]):

$$\hat{y} = \sigma(W^T z + b)$$

Trong đó tham số θ của bộ mã hóa Tầng 2 được giữ cố định hoàn toàn trong suốt quá trình đánh giá ở Tầng 3, chỉ có các tham số của bộ phân loại tuyến tính được huấn luyện để đo lường khả năng truy xuất tuyến tính của thông tin an ninh trong vector z . Giao thức đánh giá tuyến tính đóng băng (frozen linear probe) giữ bộ mã hóa cố định và chỉ huấn luyện một ánh xạ tuyến tính trên vector z , vì vậy phép đo cho biết lượng thông tin phục vụ tác vụ hạ nguồn có thể được truy xuất bằng một bộ phân loại tuyến tính mà không cho phép detector học lại biểu diễn, dù phương pháp này không đo lường toàn bộ thông tin phi tuyến có thể tồn tại trong z [10], [21].

1.2. Phân tích so sánh các nhóm phương pháp hiện đại

Phục vụ việc định vị chính xác các đóng góp kỹ thuật và cơ sở lý luận của chuyên đề, Mục 1.2 tiến hành khảo cứu, phân loại và phân tích đa chiều ba nhóm phương pháp biểu diễn đặc trưng log chủ đạo trong y văn hiện đại, bao gồm: nhóm phương pháp thống kê và cú pháp dựa trên mẫu log [1]; nhóm phương pháp biểu diễn ngữ nghĩa chuỗi thời gian [3]; cùng nhóm phương pháp học biểu diễn đồ thị nguồn gốc [7]. Mỗi nhóm phương pháp được mổ xẻ tường minh về cơ chế toán

học, độ phức tạp thuật toán, ưu điểm cốt lõi và các rào cản nền tảng khi triển khai trong môi trường phát hiện tấn công thực tế.

1.2.1. *Phương pháp thống kê và cú pháp: Event Count, Frequency, Entropy và Template Features*

Nhóm phương pháp thống kê và cú pháp đại diện cho thế hệ tiếp cận đầu tiên trong phân tích nhật ký tự động [1], [2]. Cơ chế hoạt động của nhóm này dựa trên quy trình hai giai đoạn tách rời: giai đoạn phân tách dòng log thô thành các mẫu định dạng tĩnh (Log Templates / Event IDs) thông qua bộ phân tích cú pháp, tiếp theo là giai đoạn lượng hóa các chuỗi sự kiện thành vector số học dựa trên các thước đo thống kê kinh điển.

Trong giai đoạn phân tích cú pháp, nhiều thuật toán tiêu biểu đã được phát triển nhằm tối ưu hóa tốc độ xử lý [1]: thứ nhất là Drain [1] sử dụng cấu trúc cây phân tích có độ sâu cố định để nhóm các dòng log dựa trên độ dài chuỗi và các từ khóa tiền tố, trong kết quả đo chuẩn thực nghiệm của Zhu et al., thời gian xử lý của Drain tăng gần tuyến tính theo kích thước tập dữ liệu log đối với luồng dữ liệu lớn; thứ hai là Spell [1] áp dụng thuật toán tìm chuỗi con chung dài nhất (LCS) theo cơ chế dòng để trích xuất động các thành phần tĩnh của thông điệp log; thứ ba là LenMa và AEL [1], [2] lần lượt khai thác chiều dài các từ tố và tần suất xuất hiện của từ khóa để phân cụm và tách biến số ra khỏi chuỗi mẫu.

Sau khi không gian log được rút gọn về tập M mẫu sự kiện cố định $\mathcal{E} = \{e_1, e_2, \dots, e_M\}$, các chuỗi sự kiện trong một cửa sổ thời gian hoặc phiên làm việc W được ánh xạ thành vector tần suất:

$$x = [c(e_1), c(e_2), \dots, c(e_M)]^T \in \mathbb{R}^M$$

Trong đó $c(e_i)$ là số lần xuất hiện của sự kiện e_i . Bên cạnh việc đếm tần suất đơn thuần, trọng số TF-IDF được vận dụng để điều chỉnh độ nổi bật của từng mẫu sự kiện trong không gian đặc trưng; trong đó thành phần tần suất sự kiện (TF) đo lường mức độ xuất hiện cục bộ trong một phiên phân tích, kết hợp cùng trọng số nghịch đảo chuỗi $\log\left(1 + \frac{N}{n(e_i)}\right)$ nhằm phạt giảm trọng số của các sự kiện

phổ biến trên toàn bộ kho dữ liệu, giúp khuếch đại các sự kiện xuất hiện tập trung trong phiên nhưng hiếm gặp trên diện rộng. Tuy nhiên, về mặt bản chất an ninh, sự kiện hiếm gặp không đồng nghĩa với hành vi tấn công độc hại bởi các tác vụ bảo trì định kỳ hoặc cấu hình quản trị ít dùng cũng tạo ra tần suất thấp, đồng thời kỹ thuật này hoàn toàn không phản ánh được trật tự thời gian, khoảng cách ngữ nghĩa hay quan hệ logic giữa các sự kiện kế tiếp. Độc lập với phép đánh trọng số từ vựng, độ hỗn loạn thông tin Shannon được xác định từ phân phối xác suất thực nghiệm để đo lường mức độ tập trung hoặc phân tán của phân bố sự kiện trong cửa sổ giám sát: khi luồng nhật ký chỉ tập trung vào một vài hành vi quen thuộc thì độ bất định nhận giá trị thấp, ngược lại khi các sự kiện phân tán trải đều trên nhiều nhóm trạng thái khác nhau thì độ bất định đạt mức cao, tạo tiền đề dẫn dắt sang các bước mô hình hóa chuỗi tiếp theo:

$$H(W) = - \sum_{i=1}^M p(e_i) \log_2(p(e_i))$$

Trên không gian vector tần suất này, các mô hình phát hiện bất thường kinh điển được triển khai rộng rãi, tiêu biểu là phân tích thành phần chính PCA (Xu et al., SOSP 2009) [17] thực hiện tâm hóa dữ liệu và tìm các phương chiều trực giao có phương sai lớn nhất nhằm phân rã không gian vector $\mathbb{R}^M$ thành không gian con chuẩn tắc $\mathcal{S}_n$ gồm các thành phần chính được giữ lại và không gian con phần dư $\mathcal{S}_r$; về mặt hình học, khi một vector quan sát nằm hoàn toàn trong không gian con giữ lại thì thành phần chiếu lên phần dư bằng 0, ngược lại một sự kiện được nhận diện là bất thường khi năng lượng chiếu lên phần dư vượt ngưỡng kiểm định thống kê, tuy nhiên phương có phương sai lớn trong dữ liệu không mặc nhiên là phương mang ý nghĩa an ninh do PCA tối ưu hóa tiêu chuẩn phương sai thống kê thay vì thuộc tính an ninh, vì vậy độ lớn phần dư thuần túy phản ánh độ lệch thống kê ngoài không gian chuẩn tắc chứ không tự chứng minh bản chất tấn công:

$$x_a = (I - PP^T)x, \|x_a\|^2 > \gamma_\alpha$$

Thứ hai, Invariant Mining (Lou et al., USENIX ATC 2010) [22] tự động khai phá các phương trình bất biến tuyến tính phản ánh mối quan hệ bảo toàn logic giữa các bước thực thi:

$$Ax = 0$$

Mặc dù sở hữu ưu thế về tốc độ xử lý trong thực tiễn, nhóm phương pháp thống kê và cú pháp bộc lộ hai điểm nghẽn phương pháp luận quan trọng [1], [4]: Một là, mất mát ngữ nghĩa an ninh do trừu tượng hóa tham số: các bộ log parser dựa trên biểu thức chính quy thường thay thế các tham số biến động như địa chỉ IP, đường dẫn tệp tin và tham số dòng lệnh bằng ký tự đại diện <*> khiến nhiều thông tin an ninh mang tính phân biệt cao bị lược bỏ; Hai là, lan truyền và khuếch đại sai số cú pháp Parser Error Propagation: khi gặp các định dạng log mới chưa từng xuất hiện, parser có thể phân tách không chính xác, dẫn đến hiện tượng sinh ra các mẫu sự kiện giả lập hoặc gộp nhầm các sự kiện khác biệt, làm xáo trộn cấu trúc không gian vector x.

1.2.2. *Phương pháp semantic-sequential: Embeddings, Self-Supervised Learning, Transformer và Parsing-Free*

Khắc phục sự cứng nhắc của các vector đếm tần suất và tận dụng trật tự xuất hiện của các sự kiện, nhóm phương pháp Semantic-Sequential mô hình hóa luồng log tương tự như các chuỗi ngôn ngữ tự nhiên, tích hợp các kỹ thuật nhúng từ và học tự giám sát (Self-Supervised Learning) để nắm bắt phụ thuộc ngữ cảnh dài hạn [23], [24], [25], [26], [27].

Khởi đầu cho hướng nghiên cứu này là mô hình DeepLog [23]. Nhằm khắc phục hạn chế mất mát thứ tự thời gian của các mô hình túi từ, DeepLog thiết lập cơ chế phát hiện bất thường chuỗi mẫu sự kiện (Log-Key Anomaly Detection): mô hình LSTM học trật tự thực thi bình thường thông qua phân phối có điều kiện $P(e_t | e_{t-k}, \dots, e_{t-1})$ trên cửa sổ trượt k sự kiện trước đó [23]:

$$\hat{e}_t = \operatorname{argtop} - g_{e \in \mathcal{E}} P(e | e_{t-k}, \dots, e_{t-1})$$

Song song với luồng sự kiện phân loại, DeepLog xây dựng mô hình LSTM thứ hai kết hợp phân phối chuẩn nhiều chiều để kiểm tra độ lệch bất thường của các tham số số học [23]; tuy nhiên, việc mô hình hóa dựa trên mạng hồi quy đòi hỏi thông tin trạng thái phải truyền tuần tự qua từng bước tính toán, khiến cơ chế cổng của LSTM gặp giới hạn khi truyền tải các phụ thuộc ngữ cảnh dài hạn và không cho phép các vị trí cách xa nhau tương tác trực tiếp với nhau.

Thứ nhất, để nâng cao năng lực biểu diễn ngữ nghĩa vượt khỏi hạn chế của vector tần suất, các công trình kế tiếp đã khai thác vector nhúng cho từng mẫu log: LogAnomaly [26] đề xuất Template2Vec dựa trên Word2Vec và FastText kết hợp trọng số d-IDF để trích xuất đặc trưng ngữ nghĩa từ vựng; trong khi đó, Logsy [27] áp dụng hàm mất mát phân loại ngoại lai trên dữ liệu log phụ trợ nhằm định hình biên giới phân tách cho lớp hành vi bình thường; Thứ hai, bước chuyển sang mô hình hóa chuỗi sâu sắc hơn được khởi xướng bởi LogBERT [24] dựa trên kiến trúc Transformer hai chiều và cơ chế chú ý tự thân (Self-Attention) của Vaswani et al. Trong kiến trúc Transformer [28], cơ chế chú ý tích vô hướng tỉ lệ ánh xạ đầu vào thành các bộ vector Query, Key và Value, tính điểm tương tác giữa các cặp Query-Key và chuẩn hóa qua hàm softmax để tạo phân phối trọng số tổng hợp các vector Value trong phạm vi của sổ quan sát; về mặt cơ chế, nếu các điểm tương tác tương đương nhau thì trọng số chú ý phân bố gần như đồng đều, còn khi một vị trí có điểm vượt trội thì trọng số tập trung vào vị trí đó, cho phép liên kết trực tiếp mọi cặp sự kiện mà không bị nghẽn qua các bước tuần tự, song trọng số chú ý thuần túy phản ánh mức độ liên đới ngữ cảnh được tính toán trong cửa sổ chứ không cấu thành bằng chứng giải thích nhân quả hay đồ thị phụ thuộc hệ thống. LogBERT áp dụng cơ chế này cho hai tác vụ tự giám sát gồm dự đoán sự kiện log bị che và dự đoán phân bố khối lượng log; song song đó, hướng tiếp cận không dùng parser như NeuralLog [25] trực tiếp mã hóa chuỗi văn bản thô thành các vector nhúng liên tục. Cuối cùng, trong các kiến trúc học tự giám sát trên chuỗi sự kiện, rủi ro phương pháp luận thường trực là hiện tượng sụp đổ biểu diễn, khi bộ mã hóa sinh ra các vector tầm thường giống nhau cho mọi đầu vào. Để kiểm soát hiện tượng này, kỹ thuật chính quy hóa VICReg [12] phân rã mục

tiêu điều chuẩn hình học thành ba thành phần: Phương sai duy trì độ phân tán theo chiều nhằm tránh co cụm về một điểm; Bất biến giống hàng biểu diễn giữa các góc nhìn khác nhau; và Hiệp phương sai phạt các phần tử ngoài đường chéo của ma trận hiệp phương sai nhằm giảm tương quan tuyến tính giữa các chiều đặc trưng, dù mức hiệp phương sai triệt tiêu không đồng nghĩa với tính độc lập thống kê hoàn toàn khi tồn tại phụ thuộc phi tuyến. Việc áp dụng VICReg trong chuyên đề đóng vai trò là một cơ chế chính quy hóa hình học không gian, trong khi hiệu quả giảm tỷ lệ cảnh báo sai hoặc bỏ sót trong viễn trắc an ninh là giả thuyết thích ứng của đề tài cần kiểm chứng thực nghiệm [12].

Mặc dù đạt kết quả tốt trên các tập dữ liệu phần mềm, nhóm phương pháp Semantic–Sequential đối mặt với ba rào cản khi áp dụng vào an ninh mạng [10], [5]: Một là, nguy cơ rò rỉ và thiên lệch từ dữ liệu tiền huấn luyện: các mô hình sử dụng Transformer tiền huấn luyện trên kho văn bản tổng quát có nguy cơ tận dụng tri thức ngoài miền; khi đánh giá trong điều kiện phân vùng nghiêm ngặt, năng lực phân tách thực tế cần được kiểm chứng cẩn trọng [10]; Hai là, chi phí tài nguyên tính toán: cơ chế Self-Attention trong Transformer [28] có độ phức tạp tính toán và bộ nhớ bậc hai theo độ dài chuỗi hoặc kích thước cửa sổ, đòi hỏi tài nguyên tính toán đáng kể khi triển khai trên luồng dữ liệu thời gian thực có lưu lượng lớn; Ba là, giới hạn phạm vi quan sát đơn luồng và thiếu nhận thức cấu trúc: cơ chế chú ý tự thân tính toán trọng số tương tác trực tiếp từ tích vô hướng Query-Key trong phạm vi cửa sổ chuỗi cục bộ và tự nó không chứng minh quan hệ nhân quả; trong khi đó, cấu trúc đồ thị nguồn gốc có thể cung cấp thêm tương tác đa thực thể giữa tiến trình - tệp tin - socket mạng và các liên kết phụ thuộc, nhưng bản thân tô-pô đồ thị cũng không tự biến quan hệ liên đới hay phụ thuộc cấu trúc thành suy diễn nhân quả an ninh nếu thiếu các thiết kế kiểm soát hoặc bằng chứng bổ sung phù hợp.

1.2.3. Đồ thị nguồn gốc và *Graph Representation Learning*

Để khắc phục hạn chế của mô hình chuỗi khi một sự kiện đơn lẻ không chứa đủ ngữ cảnh của cả chuỗi hành vi, hướng tiếp cận dựa trên đồ thị nguồn gốc

hệ thống mô hình hóa toàn bộ lịch sử thực thi và tương tác trong hệ điều hành dưới dạng một đồ thị có hướng, không đồng nhất và gán nhãn thời gian [3], [7]:

$$\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{T}_v, \mathcal{T}_e, \phi, \psi, \tau)$$

Trong đó $\mathcal{V}$ là tập các đỉnh đại diện cho các thực thể hệ thống thuộc tập kiểu $\mathcal{T}_v = \{\text{Process, File, Socket, Registry, User, Host}\}$; $\mathcal{E}$ là tập các cạnh có hướng mô tả các tương tác luồng phụ thuộc nằm trong tập kiểu $\mathcal{T}_e = \{\text{fork, execve, read, write, connect, bind, send, recv}\}$; và τ gán nhãn mốc thời gian xảy ra tương tác [3].

Các hệ thống phát hiện xâm nhập dựa trên đồ thị nguồn gốc (PIDS) tiêu biểu bao gồm [3], [7]: Thứ nhất, UNICORN [11] (NDSS 2020) xây dựng đồ thị nguồn gốc luồng thời gian thực, áp dụng thuật toán băm cây con Weisfeiler-Lehman để chuyển đổi đồ thị động thành vector đặc trưng đếm histogram; Thứ hai, KAIROS [29] (IEEE S&P 2024) tích hợp mạng nơ-ron đồ thị nhận biết thời gian mã hóa đồng thời thông tin cấu trúc và sự tiến triển thời gian của đồ thị nguồn gốc để chấm điểm bất thường và tái dựng dấu vết tấn công APT; Thứ ba, NODLINK [30] (NDSS 2024) mô hình hóa bài toán phát hiện thành cây Steiner trực tuyến kết hợp cơ chế bộ nhớ đệm để khôi phục đồ thị con tấn công nhỏ gọn; Thứ tư, MAGIC [31] (USENIX Security 2024) khai thác kiến trúc tự mã hóa đồ thị che kết hợp cơ chế thích ứng mô hình để học biểu diễn đa độ hạt và chống trôi dạt khái niệm; Thứ năm, ORTHRUS [32] (USENIX Security 2025) tích hợp cơ chế học biểu diễn nguồn gốc chống chịu kỹ thuật lẩn tránh. Mặc dù đạt nhiều bước tiến, nhóm phương pháp đồ thị đối mặt với ba thách thức lý thuyết và thực tiễn cốt lõi: Một là, hiện tượng bùng nổ phụ thuộc Dependency Explosion: các tiến trình hệ thống chạy dài hạn liên tục tương tác với nhiều tệp tin và socket, khiến đồ thị phát triển dày đặc và tạo ra nhiều liên kết phụ thuộc xa làm loãng tín hiệu bất thường [3], [33]; Hai là, ranh giới giữa quan hệ phụ thuộc cấu trúc và tác động nhân quả (Dependency $\neq$ Causal Effect): kết quả khảo sát thực nghiệm của Bilot et al. [34] (USENIX Security 2025) và Guerra et al. [35] chỉ ra rằng nhiều mô hình GNN phức tạp có nguy cơ khai thác các đặc trưng đường tắt thống kê

như phân bố bậc của nút hoặc tính mới của đường dẫn; trong đó Bilot et al. [34] chứng minh một mô hình mạng nơ-ron đơn giản đạt hiệu năng cạnh tranh vượt trội trên 5/7 tập dữ liệu DARPA, còn Guerra et al. [35] chỉ ra hiệu quả của các baseline danh sách cho phép / thống kê sự kiện, khẳng định một cạnh phụ thuộc trong đồ thị không đồng nghĩa với tác động nhân quả an ninh; Ba là, hai bệnh lý mạng nơ-ron đồ thị về mặt cấu trúc: khi tăng số lớp truyền tin, hiện tượng làm mịn quá mức (Over-smoothing), được Oono & Suzuki [36] chứng minh tại ICLR 2020 dưới các điều kiện phổ ma trận kề chuẩn hóa và hàm kích hoạt không âm trên kiến trúc GCN sâu, khiến biểu diễn các đỉnh hội tụ theo hàm mũ về một không gian con giới hạn và mất dần năng lực phân tách; trong khi đó, hiện tượng nghiền cổ chai thông tin (Over-squashing), được Alon & Yahav [37] phân tích tại ICLR 2021, xuất hiện khi kích thước vùng lân cận k-hop tăng nhanh và lượng thông tin từ nhiều nguồn phải truyền qua các nút cổ chai hoặc lát cắt hẹp để nén vào một vector trạng thái có kích thước cố định, khiến các tín hiệu bất thường quan trọng từ xa dễ bị hòa lẫn hoặc suy giảm. Hai hiện tượng này mang bản chất toán học độc lập và cần được xử lý bằng các cơ chế kiến trúc riêng biệt.


Tại Việt Nam, các nghiên cứu chuyên sâu của ThS. Nguyễn Thị Thu Thủy (Khoa An toàn thông tin, Học viện Kỹ thuật Mật mã) [38] cũng đã hệ thống hóa phương pháp luận ứng dụng Graph Learning và mạng nơ-ron đồ thị (Graph Neural Network, GNN) trên đồ thị nguồn gốc để phát hiện các chiến dịch tấn công APT đa giai đoạn; đồng thời phân tích sâu sắc các thách thức về hiện tượng bùng nổ phụ thuộc, tính đa góc nhìn và yêu cầu bảo toàn tính nhân quả khi phân tích luồng sự kiện kiểm toán hệ thống.

Bảng 1.3: So sánh đối chiếu ba nhóm phương pháp biểu diễn đặc trưng log chủ đạo

Tiêu chí đánh giá	Nhóm Thống kê / Cú pháp (Drain, PCA)	Nhóm Chuỗi Semantic (DeepLog, LogBERT)	Nhóm Đồ thị Nguồn gốc (UNICORN, MAGIC)
Cơ chế biểu diễn cốt lõi	Vector đếm tần suất Event ID trên cửa sổ trượt	Vector nhúng ngữ cảnh từ chuỗi sự kiện tuần tự	Vector nhúng cấu trúc đồ thị luồng phụ thuộc đệ thế
Độ phức tạp thời gian	$O(N)$: Tuyến tính theo số lượng sự kiện	$O(N \cdot L)$ đến $O(N \cdot L^2)$: Phụ thuộc độ dài cửa sổ L	Phụ thuộc $ E $, số tầng và chiều ẩn; chi phí lưu trữ đồ thị phụ thuộc $ V + E $
Bảo toàn tham số an ninh	Hạn chế (Tham số biến động thường bị thay thế bởi parser)	Trung bình (Tham số được rời rạc hóa hoặc nhúng từ)	Tốt (Lưu trữ trực tiếp trên thuộc tính của nút/cạnh)
Mô hình hóa chuỗi quan hệ	Không hỗ trợ	Cục bộ trên dòng thời gian tuần tự đơn luồng	Toàn diện trên quan hệ tương tác đa thực thể
Khả năng triển khai thực tế	Thuận lợi nhờ tính toán nhanh và tài nguyên thấp	Đòi hỏi tài nguyên GPU và thời gian suy luận lớn	Thách thức do đồ thị tăng trưởng và bùng nổ phụ thuộc
Điểm nghẽn phương pháp luận	Mất mát tham số động, nhạy cảm với sai số phân tách	Chi phí tính toán cao, hạn chế góc nhìn đa thực thể	Bùng nổ phụ thuộc, Over-smoothing, Over-squashing

Tổng kết lại, phân tích so sánh đối chiếu chỉ ra rằng mỗi nhóm phương pháp đều sở hữu những ưu thế và giới hạn riêng biệt tại Bảng 1.3. Mối quan hệ tương tác và sự chuyển tiếp từ các rào cản kỹ thuật của ba nhóm phương pháp tới năm

khoảng trống nghiên cứu trọng tâm được tổng hợp trực quan trên bản đồ quan hệ trong Hình 1.4: Bảng 1.3 Hình 1.4



Hình 1.4: Bản đồ đối chiếu ba nhóm phương pháp biểu diễn log và nguồn gốc hình thành năm khoảng trống nghiên cứu cốt lõi, nguồn tác giả tổng hợp

1.3. Các khoảng trống nghiên cứu cốt lõi

Kết quả khảo sát và phân tích đối chiếu ba nhóm phương pháp biểu diễn đặc trưng log tại Mục 1.2 cho thấy dù các kỹ thuật thống kê, mô hình chuỗi ngữ nghĩa và học biểu diễn đồ thị nguồn gốc đã giải quyết được từng khía cạnh phân tích riêng lẻ, việc triển khai chúng vào môi trường giám sát an ninh mạng doanh nghiệp thực tế vẫn bộc lộ các mâu thuẫn cơ bản về mặt biểu diễn [3], [5], [1], [10]. Để xác định phạm vi nghiên cứu và làm rõ cơ chế cần hoàn thiện, chuyên đề tổng hợp năm khoảng trống nghiên cứu kèm theo năm câu hỏi nghiên cứu tương ứng làm định hướng cho các đề xuất phương pháp luận tiếp theo:

1.3.1. Khoảng trống 1: Mất mát ngữ nghĩa an ninh trong quá trình trừu tượng hóa tham số

Dữ liệu thực nghiệm từ các nghiên cứu tiền nhiệm chỉ ra rằng các bộ phân tích cú pháp đóng vai trò giảm số chiều từ vựng bùng nổ của nhật ký hệ thống

bằng cách gom cụm văn bản thành các khuôn mẫu định dạng tĩnh [1], [2]. Tuy nhiên, cơ chế trừu tượng hóa tham số phụ thuộc vào từng thuật toán phân tích cú pháp; nhiều quy trình tiền xử lý thay thế các tham số biến động (như địa chỉ IP, tên tài khoản, đường dẫn tệp tin và tham số dòng lệnh) thành các ký tự đại diện nhằm tạo ra các mẫu log dùng chung.

Giới hạn quan trọng chưa được giải quyết là sự tương đương về mặt cú pháp mẫu nhật ký không đồng nghĩa với sự tương đương về mặt ngữ nghĩa an ninh [4], [5]. Một mẫu thông báo xác thực thất bại phát sinh từ tài khoản quản trị viên root trong mạng nội bộ mang ý nghĩa an ninh khác hoàn toàn so với cùng thông báo đó phát sinh từ tài khoản người dùng thông thường; tương tự, hai lệnh gọi powershell.exe thực thi bảo trì định kỳ và tải mã độc mã hóa base64 đều có thể bị ánh xạ về cùng một mã định danh sự kiện tiến trình.

Khoảng trống nghiên cứu này đặt ra thách thức: làm thế nào để thiết lập cơ chế trích xuất đặc trưng có khả năng lọc bỏ các nhiễu cú pháp vô hại nhưng vẫn bảo toàn các tham số động mang ngữ nghĩa an ninh trọng yếu dưới sự kiểm soát rò rỉ đường tắt và rủi ro quyền riêng tư trong không gian vector biểu diễn? Từ đó, câu hỏi nghiên cứu thứ nhất được xác lập:

- Câu hỏi nghiên cứu 1 RQ1 về độ trung thực biểu diễn: Có thể xây dựng representation loại bỏ nhiễu cú pháp nhưng vẫn bảo toàn các dynamic parameters có ý nghĩa an toàn quan trọng dưới sự kiểm soát rò rỉ và quyền riêng tư hay không?

1.3.2. *Khoảng trống 2: Bất đồng bộ và suy thoái trong giống hàng biểu diễn đa góc nhìn*

Hoạt động của một hệ thống có thể được quan sát qua nhiều lăng kính dữ liệu dị thể: góc nhìn thống kê tần suất phản ánh mật độ sự kiện [1], góc nhìn chuỗi sự kiện phản ánh trật tự thời gian cục bộ [23], [24], và góc nhìn đồ thị nguồn gốc phản ánh cấu trúc phụ thuộc thực thi giữa các thực thể $\mathcal{G}$ [3], [7], [11]. Việc kết hợp đồng thời các góc nhìn này hướng tới mục tiêu cung cấp đầy đủ ngữ cảnh về toàn bộ chuỗi hành vi tấn công.

Khi đưa các góc nhìn dị thể này vào không gian vector tiềm ẩn chung qua các hàm mất mát tự giám sát, mô hình đối mặt với nguy cơ sụp đổ chiều biểu diễn, tức xu hướng ánh xạ mọi đầu vào thành các vector hằng số tầm thường, vốn đòi hỏi cơ chế điều hòa phương sai và hiệp phương sai để duy trì độ đa dạng không gian [12], [13]; bên cạnh đó, việc giống hàng trong môi trường an ninh mạng còn gặp phải hai trở ngại thực tế: Một là, rủi ro chuyển giao tiêu cực, xảy ra khi nhiều từ chuỗi sự kiện lẫn át hoặc làm suy giảm tín hiệu cấu trúc phụ thuộc thực thi của đồ thị nguồn gốc; Hai là, hiện tượng dữ liệu bị khuyết hoặc tương ứng từng phần, phát sinh do độ trễ truyền thông, gói tin bị thất thoát hoặc thiếu liên kết 1–1 đồng thời giữa các luồng thu thập.

Khoảng trống nghiên cứu ở đây là: việc giống hàng đồng thời các góc nhìn dị thể đòi hỏi thiết lập cơ chế kiểm soát toán học phù hợp để vừa chống sụp đổ biểu diễn và hạn chế chuyển giao tiêu cực, đồng thời vẫn bảo tồn được các thông tin đặc thù hữu ích của từng góc nhìn riêng biệt. Do đó, câu hỏi nghiên cứu thứ hai được xác lập:

- Câu hỏi nghiên cứu 2 (RQ2, Cross-View Alignment): Có thể căn chỉnh các view dị thể mà không gây representation collapse, negative transfer, đồng thời vẫn bảo toàn thông tin hữu ích đặc thù của từng view hay không?

1.3.3. Khoảng trống 3: Rò rỉ thông tin quy trình, học đường tắt và trôi dạt biểu diễn

Công trình tổng kết của Arp et al. [10] và Liu et al. [5] đã cảnh báo sâu sắc về tình trạng sai lệch phương pháp luận trong nghiên cứu học máy áp dụng cho an ninh mạng. Trong bài toán trích xuất đặc trưng log, các mô hình rất dễ học phải các đặc trưng đường tắt giả định có tương quan ngẫu nhiên với nhãn độc hại trong tập huấn luyện nhưng không phản ánh bản chất tấn công thực tế.

Khảo sát thực nghiệm chỉ ra sáu kênh rò rỉ thông tin thường gặp trong quy trình đánh giá mô hình: Một là, rò rỉ từ vụng, xảy ra khi bộ phân tích cú pháp hoặc bộ tách từ được xây dựng trên toàn bộ dữ liệu bao gồm cả phần kiểm thử; Hai là, rò rỉ chuẩn hóa thống kê, khi các đại lượng trung bình, phương sai hoặc trọng số

tần suất được tính toán xuyên qua ranh giới giữa tập huấn luyện và kiểm thử; Ba là, rò rỉ thực thể máy chủ, khi dấu vết tấn công trên cùng một máy chủ hoặc địa chỉ IP xuất hiện đồng thời ở cả hai tập; Bốn là, rò rỉ điều chỉnh siêu tham số, khi ngưỡng quyết định được tinh chỉnh dựa trên dữ liệu đánh giá; Năm là, rò rỉ dữ liệu tiền huấn luyện ngoài miền, dẫn đến ước lượng sai lệch về khả năng khái quát hóa; và Sáu là, rò rỉ thời gian tương lai, khi mô hình sử dụng các sự kiện xảy ra sau để trích xuất biểu diễn cho các sự kiện xảy ra trước.

Khoảng trống nghiên cứu đặt ra là: làm thế nào để phân định rõ ràng giữa tín hiệu an ninh hợp lệ và các đặc trưng đường tắt nhân tạo, đồng thời duy trì năng lực phân tách của không gian vector khi dữ liệu thực tế trôi dạt phân phối theo thời gian. Chuyên đề xác lập câu hỏi nghiên cứu thứ ba:

- Câu hỏi nghiên cứu 3 RQ3 về tính hữu hiệu không phụ thuộc đường tắt: Representation có còn hữu ích sau khi loại bỏ shortcut của dataset và khi phân phối dữ liệu thay đổi hay không?

1.3.4. Khoảng trống 4: Gán nhãn mức thô, phân bổ bằng chứng yếu và nhiều quản trị viên

Trong thực tế giám sát an ninh mạng doanh nghiệp, dữ liệu nhãn thường chỉ được ghi nhận ở mức độ hạt rất thô, chẳng hạn như gán nhãn một phiên làm việc kéo dài nhiều giờ hoặc toàn bộ một máy chủ bị xâm nhập trong một khoảng thời gian [5], [14], [16]. Bên trong phiên làm việc đó, phần lớn các dòng nhật ký vẫn là các thao tác hệ thống bình thường, và chỉ có một số lượng rất nhỏ sự kiện thực sự phản ánh kỹ thuật tấn công.

Thách thức này càng trở nên phức tạp do sự xuất hiện liên tục của hành vi quản trị viên hệ thống [3], [5]. Các kỹ sư quản trị thường xuyên thực thi các lệnh bảo trì, chẩn đoán mạng hoặc sao lưu dữ liệu bằng các công cụ dòng lệnh hợp lệ của hệ điều hành như PowerShell, WMI hay SSH. Những hành vi này chia sẻ cùng cú pháp câu lệnh và quyền thực thi với các kỹ thuật tấn công lợi dụng công cụ sẵn có nhưng hoàn toàn mang mục đích vận hành hợp pháp. Một hành vi bất thường hoặc ít xuất hiện không tự thân đồng nghĩa với hành vi tấn công độc hại.

Khoảng trống nghiên cứu là: làm thế nào để phân bổ đúng bằng chứng tấn công từ nhãn mức thô xuống các sự kiện mẫu chốt mà không học nhầm các thao tác quản trị hợp pháp thành hành vi độc hại. Đây là cơ sở để xác lập câu hỏi nghiên cứu thứ tư:

- Câu hỏi nghiên cứu 4 RQ4 về phân bổ bằng chứng yếu: Có thể gán đúng attack evidence dưới coarse labels mà không học nhầm các hành vi quản trị hợp pháp thành malicious hay không?

1.3.5. Khoảng trống 5: Đánh đổi giữa bảo toàn liên kết an ninh và rủi ro quyền riêng tư

Nhiệm vụ phát hiện và điều tra các cuộc tấn công APT kéo dài đòi hỏi mô hình học biểu diễn phải duy trì khả năng liên kết có kiểm soát giữa các chuỗi hành vi của cùng một thực thể như người dùng, máy chủ và tiến trình qua nhiều mốc thời gian khác nhau [3], [7].

Tuy nhiên, việc lưu giữ khả năng liên kết này trong không gian vector biểu diễn trực tiếp làm nảy sinh các nguy cơ nghiêm trọng về quyền riêng tư và an toàn thông tin [18], [20], [19]. Các vector biểu diễn đặc trưng tiềm ẩn có nguy cơ bị kẻ tấn công khai thác thông qua các kỹ thuật tấn công suy luận thành viên (Membership Inference Attacks - MIA [18]) để xác định xem dữ liệu của một thực thể có nằm trong tập huấn luyện hay không. Về mặt lý thuyết nguồn gốc, nghiên cứu kinh điển của Fredrikson et al. [19] đã chứng minh tấn công nghịch đảo mô hình có thể khai thác thông tin đầu ra và độ tin cậy để suy diễn lại các đặc trưng nhạy cảm của dữ liệu đầu vào. Trong bối cảnh mô hình biểu diễn nhật ký của đề tài theo mô hình đe dọa thích ứng do nghiên cứu đề xuất, các định danh như tên người dùng, tên máy chủ và chuỗi đối số dòng lệnh là các thuộc tính nhạy cảm tiềm năng cần phải kiểm thử thực nghiệm trước nguy cơ bị khôi phục hoặc xấp xỉ từ không gian vector biểu diễn. Một mô hình được thiết kế có nhận thức về quyền riêng tư không tự động đồng nghĩa với việc đã đạt được khả năng bảo vệ quyền riêng tư ; các quy trình kiểm thử tấn công MIA và đảo ngược mô hình được

định vị là phép kiểm tra hạ nguồn và chưa được thực thi trong phạm vi thực nghiệm hiện tại [20].

Khoảng trống nghiên cứu này đòi hỏi phải phân tích mối quan hệ đánh đổi: Đây là điểm cân bằng giữa năng lực duy trì liên kết thực thể phục vụ phân tích an ninh và mức độ rò rỉ thông tin riêng tư của không gian vector đặc trưng? Từ đó, câu hỏi nghiên cứu thứ năm được xác lập:

- Câu hỏi nghiên cứu 5 (RQ5, Privacy-Security Trade-Off): Đây là sự cân bằng chấp nhận được giữa entity continuity và privacy leakage để representation vẫn hữu ích cho phân tích an toàn?

CHƯƠNG 2. PHƯƠNG PHÁP BIỂU DIỄN ĐẶC TRƯNG LOG ĐA GÓC NHÌN BẢO TOÀN NGŨ CẢNH AN TOÀN

2.1. Hình thức hóa bài toán và giới hạn xử lý dòng

2.1.1. Biểu diễn đa góc nhìn và ranh giới Extractor–Detector

Các hàm mất mát trong quá trình huấn luyện tự giám sát là những tín hiệu tối ưu hóa nội tại, không phải bằng chứng khoa học tự thân chứng minh năng lực an ninh trực tiếp. Việc giảm một hàm mất mát phụ trợ chỉ chứng minh mô hình tối ưu tốt hơn trên tác vụ đại diện và dữ liệu được quan sát; mọi kết luận về năng lực phát hiện xâm nhập downstream, tính vững chắc hay độ an toàn quyền riêng tư bắt buộc phải được thẩm định độc lập qua các phép đo thực nghiệm tương ứng.

Trên cơ sở các khoảng trống phương pháp luận được xác lập tại Chương 1, Chương 2 đề xuất khung phương pháp biểu diễn đặc trưng log đa góc nhìn bảo toàn ngũ cảnh an toàn, vận hành trực tuyến trong môi trường xử lý dòng trong môi trường xử lý dòng trực tuyến. Quá trình biểu diễn bắt đầu bằng việc hình thức hóa luồng nhật ký kiểm toán hệ thống thành một chuỗi sự kiện được gán nhãn thời gian: $\mathcal{L}_{1:t} = \langle e_1, e_2, \dots, e_t \rangle$, trong đó mỗi sự kiện $e_i = (t_i, \tau_i, v_i, o_i, a_i, p_i)$ tuân thủ thống nhất lược đồ bộ sáu kiểu hóa, được đặc tả chi tiết tại Mục 2.2.1, bao gồm mốc thời gian xuất hiện sự kiện $t_i \in \mathbb{R}_{\geq 0}$, định danh kiểu sự kiện $\tau_i \in \mathcal{T}$, thực thể tác nhân chủ động $v_i \in \mathcal{V}$, gồm tiến trình gốc hoặc tài khoản người dùng, thực thể đối tượng đích chịu tác động $o_i \in \mathcal{O} \cup \{\perp\}$, gồm tệp tin, cổng mạng hoặc tiến trình con, hành động/thao tác thực hiện $a_i \in \mathcal{A}$, như fork, execve, read, write, connect và registry_set, và tập hợp các tham số động có cấu trúc $p_i = \{(k_j, v_j)\}_{j=1}^m$ gồm đường dẫn tệp tin, tham số dòng lệnh thực thi, cổng mạng và địa chỉ IP kết nối [3].

Bài toán học biểu diễn đặc trưng log được phát biểu chính thức là việc tìm kiếm một ánh xạ tham số hóa f_θ biến đổi lịch sử sự kiện quan sát được $\mathcal{L}_{1:t}$ thành một vector biểu diễn tiềm ẩn liên tục $z_t \in \mathbb{R}^d$:

$$z_t = f_\theta(\mathcal{S}_t), \mathcal{S}_t = \text{Update}(\mathcal{S}_{t-1}, e_t)$$

Trong đó $\mathcal{S}_t$ là trạng thái bộ nhớ nội bộ hữu hạn tại thời điểm t , được cập nhật theo cơ chế đơn lượt theo chiều thời gian, không nhìn trước (Strictly Causal Single-pass Update) khi tiếp nhận sự kiện mới e_t . Quá trình học biểu diễn và đánh giá được tổ chức chặt chẽ theo ba giai đoạn giám sát độc lập :

Giai đoạn A (Stage A - Tiền huấn luyện tự giám sát ngoại tuyến): Huấn luyện bộ trích xuất f_θ hoàn toàn theo cơ chế tự giám sát trên dữ liệu nền tảng lịch sử $\mathcal{D}_{\text{train}}$ mà không tiếp cận bất kỳ nhãn tấn công hay tín hiệu phân loại hạ nguồn nào. Trong đó, Giai đoạn A gồm hai bước nối tiếp: Bước A1 : tiền huấn luyện đơn góc nhìn tối ưu hóa độc lập bộ trích xuất chuỗi và bộ trích xuất đồ thị qua các mục tiêu nội bộ như dự đoán sự kiện bị che hoặc dự đoán quan hệ cạnh nhằm hình thành các biểu trưng cấu trúc nền tảng; Bước A2 : giống hàng đa góc nhìn liên hợp kế thừa trọng số từ Bước A1 và tiến hành tối ưu hóa đồng thời qua hàm giống hàng kết hợp điều chuẩn phương sai và hiệp phương sai, nhằm hòa nhập hai góc nhìn vào không gian vector tiềm ẩn chung z mà không gây sụp đổ biểu diễn; việc chia tách này giúp ổn định quá trình tối ưu hóa và tránh hiện tượng trôi dạt đặc trưng.

Giai đoạn B (Stage B - Thích ứng bằng chứng yếu tùy chọn): Khi môi trường giám sát cung cấp các nhãn an ninh mức thô (như phiên làm việc hoặc máy chủ bị xâm nhập), mô hình kích hoạt đầu dự đoán bằng chứng yếu để hướng dẫn không gian vector tập trung vào các sự kiện mấu chốt cấu thành cuộc tấn công, hạn chế nguy cơ học nhầm các thao tác quản trị hợp pháp.

Giai đoạn C (Stage C - Đánh giá đóng băng hạ nguồn): Khóa cố định toàn bộ tham số θ^* của bộ trích xuất biểu diễn. Đánh giá chất lượng biểu diễn thông qua giao thức đóng băng tham số (Frozen Linear Probe: $\hat{y}_t = \sigma(W^\top z_t + b)$) phục vụ phân loại và quy kết chiến thuật/kỹ thuật theo phân loại MITRE ATT&CK [6], hoặc quy trình chấm điểm bất thường không giám sát tùy chọn (Optional Downstream Zero-Shot Anomaly Scoring Protocol). Trong đó, hàm tính điểm bất thường, phép đo khoảng cách/năng lượng, phân bố nền chuẩn, phương pháp hiệu

chuẩn và chính sách ngưỡng/ngân sách cảnh báo đều được thiết lập trước và khóa cố định trên phân vùng Train/Validation tại Chương 3 trước khi mở tập Test; do phân loại tuyến tính chỉ đo lường thông tin phân tách tuyến tính trực tiếp từ z , giao thức này không hàm ý khai thác toàn bộ các tương quan phi tuyến tiềm ẩn. Bộ trích xuất Extractor tuyệt đối độc lập và không phụ thuộc vào bất kỳ bộ dò Detector cụ thể nào.

Trên cơ sở định nghĩa bài toán và ranh giới phương pháp luận, chuyên đề xác lập ba đóng góp học thuật trọng tâm có thể bảo vệ được: thứ nhất (C1 - Đóng góp khái niệm và phương pháp luận), khung đặc tả Hợp đồng Biểu diễn nhận thức an ninh (Representation Contract) với các nguyên tắc tường minh PRESERVE / INVARIANT / EXCLUDE nhằm chuẩn hóa ranh giới tầng trích xuất đặc trưng (chuyên đề không tuyên bố đây là định lý hay bảo đảm hình thức toán học trừ khi có chứng minh); thứ hai (C2 - Đóng góp tích hợp kiến trúc), kiến trúc biểu diễn đa góc nhìn thời gian tích hợp chuỗi ngữ nghĩa Transformer, đồ thị nguồn gốc theo dòng thời gian liên tục TemporalGraphViewEncoder, cơ chế điều hòa giống hàng và cơ chế xử lý dòng trạng thái hữu hạn (chuyên đề không tuyên bố đây là thuật toán mới hoàn toàn do các khối nguyên thủy kế thừa từ các công bố nền tảng); và thứ ba (C3 - Đóng góp kỹ thuật thực nghiệm và tái lập), quy trình hiện thực hóa bộ trích xuất Stage A2, xây dựng cơ chế truy xuất nguồn gốc bằng chứng minh bạch, phân tích khách quan các sai lệch quy trình vận hành (procedural deviations) và khảo sát động thái tối ưu hóa trên dữ liệu phân chia theo dòng thời gian chống rò rỉ. Đóng góp của chuyên đề chủ yếu nằm ở khung đặc tả, tích hợp kiến trúc và quy trình thực nghiệm; chuyên đề không tuyên bố phát minh mới các thành phần Transformer, Temporal GNN, VICReg, PCGrad hay Attention-MIL. Đi kèm với ba đóng góp trên, chuyên đề hình thức hóa năm giả thuyết nghiên cứu từ H1 đến H5 làm định hướng khảo sát khoa học, cùng một yêu cầu kỹ thuật vận hành ER1:

Giả thuyết H1 (Parameter Semantic Fidelity): Biểu diễn nhận biết tham số X_{param} như chuỗi lệnh, đường dẫn tệp tin và địa chỉ IP vào không gian vector z

bảo tồn lượng thông tin tương hỗ về ngữ nghĩa an ninh tiềm ẩn Y_{sec} cao hơn có ý nghĩa so với biểu diễn chỉ dựa trên mẫu tính hoặc bị trừu tượng hóa tham số $X_{\text{abstracted}}$:

$$\mathcal{I}(z; Y_{\text{sec}}) > \mathcal{I}(z_{\text{abstracted}}; Y_{\text{sec}})$$

Trong đó Y_{sec} là biến ngẫu nhiên đại diện cho mục tiêu ngữ nghĩa an ninh tiềm ẩn như nhân hành vi độc hại, ý định thực thi tiến trình và phân loại quyền hạn truy cập; $\mathcal{I}(\cdot; \cdot)$ là thước đo thông tin tương hỗ, với bộ ước lượng và giao thức thực nghiệm đo lường thông tin tương hỗ được đề xuất cho các đánh giá hạ nguồn tiếp theo; giả thuyết chỉ kiểm tra tính trung thực ngữ nghĩa an ninh và không suy diễn tuyệt đối sang việc triệt tiêu sự sụp đổ biểu diễn.

Giả thuyết H2 (Multi-View Alignment & Negative Transfer Prevention): Cơ chế giống hàng có kiểm soát giữa góc nhìn chuỗi sự kiện $z^{(\text{seq})}$ và góc nhìn đồ thị nguồn gốc $z^{(\text{graph})}$ được kỳ vọng nâng cao hiệu năng biểu diễn tổng thể vượt trên các góc nhìn đơn lẻ, đồng thời thỏa mãn các điều kiện kiểm chứng định lượng:

$$\begin{aligned} \text{Utility}(z) &> \max(\text{Utility}(z^{(\text{seq})}), \text{Utility}(z^{(\text{graph})})) - \epsilon_{\text{margin}}, \text{Var}(z) \\ &\geq \tau_{\text{var}}, \mathcal{I}(z; X_{\text{view}}) \geq \tau_{\text{info}} \end{aligned}$$

Trong đó $\tau_{\text{var}} > 0$ là ngưỡng phương sai duy trì độ đa dạng không gian nhằm ngăn ngừa sự sụp đổ biểu diễn, τ_{info} là ngưỡng bảo toàn thông tin đặc thù từng góc nhìn, và mức độ suy giảm do chuyển giao tiêu cực được khống chế $\Delta_{\text{neg}} \leq \epsilon_{\text{neg}}$ theo các ngưỡng xác lập trước thực nghiệm (các kỹ thuật cụ thể như InfoNCE, VICReg hay Barlow Twins được xem xét là ứng viên kỹ thuật tại Mục 2.4).

Giả thuyết H3 (Anti-Drift & Shortcut Invariance Robustness): Lợi ích biểu diễn của không gian vector z duy trì tính ổn định sau khi loại bỏ các đặc trưng đường tắt giả định $S \in \mathcal{E}_{\text{exclude}}$ ($\mathcal{I}(z; S) \leq \epsilon_{\text{short}}$) và dưới sự biến động phân phối thực tế ($P_t(X, Y) \neq P_{t+1}(X, Y)$), đồng thời thỏa mãn ràng buộc ổn định khoảng cách hình học trước các biến đổi cú pháp vô hại $T \in \mathcal{T}_{\text{benign}}$:

$$\|z(T(X)) - z(X)\|_2 \leq \epsilon_{\text{inv}}, \mathcal{I}(z; S) \leq \epsilon_{\text{short}}$$

Giả thuyết H4 (Weak-Label Evidence Allocation & Administrator-Noise Robustness): Khi môi trường giám sát chỉ cung cấp các nhãn an ninh ở mức độ thô (coarse labels ở cấp phiên làm việc hoặc máy chủ bị xâm nhập), cơ chế phân bổ bằng chứng yếu (Weak-Label Evidence Allocation qua tầng Attention-MIL tại Stage B) được kỳ vọng tập trung trọng số kích hoạt vào tập con các sự kiện thuộc chuỗi hành vi tấn công, bảo đảm độ phân biệt của không gian vector z mà không gán nhầm các hành vi quản trị viên hợp pháp thành độc hại. Đi kèm với 5 giả thuyết nghiên cứu khoa học, chuyên đề xác lập Yêu cầu kỹ thuật vận hành ER1 (Bounded Operational Resource Feasibility) nhằm kiểm soát quá trình trích xuất và cập nhật biểu diễn dòng trong giới hạn ngân sách độ trễ và bộ nhớ xác định trước trên toàn bộ thời gian vận hành: $\Delta t(e_t) \leq T_{\text{budget}} \text{Mem}(\mathcal{S}_t) \leq M_{\text{max}}$

$$\Delta t(e_t) \leq T_{\text{budget}}, \text{Mem}(\mathcal{S}_t) \leq M_{\text{max}}, \forall t \geq 1$$

Giả thuyết H5 (Controlled Linkability & Utility–Privacy Frontier): Cơ chế duy trì liên kết có kiểm soát được kỳ vọng sẽ thiết lập sự vượt trội theo nghĩa Pareto so với các đường cơ sở giữ nguyên định danh thô hoặc ẩn danh hóa quá mức tại ít nhất một điểm vận hành thực tế dưới các thước đo hiệu năng an ninh và tổn thất quyền riêng tư đã định nghĩa trước:

$$\exists z: \text{Utility}(z) \geq \text{Utility}(z_{\text{baseline}}) \wedge \text{PrivacyLoss}(z) \leq \text{PrivacyLoss}(z_{\text{baseline}})$$

Trong đó lý thuyết Quyền riêng tư Vi sai (DP) đóng vai trò định lượng và chặn trên tổn thất lý thuyết (ϵ, δ) dưới các giả định toán học xác định, còn rủi ro thực tế được định vị là phép kiểm tra hạ nguồn cần đánh giá thực nghiệm độc lập thông qua các quy trình kiểm thử tấn công suy luận thành viên (MIA) [18], [20] và tấn công nghịch đảo/tái định danh thực thể [19].

2.1.2. ***Độ phức tạp xử lý dòng với trạng thái hữu hạn (Yêu cầu kỹ thuật vận hành ER1)***

Trong môi trường giám sát an ninh SOC thời gian thực, luồng telemetry liên tục đổ về với lưu lượng rất lớn. Việc duy trì toàn bộ lịch sử tương tác của hệ thống trên bộ nhớ là bất khả thi về mặt tài nguyên. Do đó, chuyên đề thiết lập hợp

đồng xử lý dòng với trạng thái hữu hạn (Bounded-State Streaming Contract), được quy định bởi ngân sách bộ nhớ trần $M_{\max}$ và tập thực thể hoạt động $\mathcal{V}_{\text{active}}(t)$:

$$\mathcal{V}_{\text{active}}(t) = \{v \in \mathcal{V} \mid t - t_{\text{last}}(v) \leq \tau_{\text{TTL}}, |\mathcal{S}_t| \leq M_{\max}\}$$

Trong đó τ_{TTL} là ngưỡng thời gian sống (Time-To-Live). Một thực thể v (tiền trình, socket, tệp tin) không phát sinh bất kỳ tương tác nào trong khoảng thời gian τ_{TTL} sẽ hết hạn và đủ điều kiện loại bỏ khỏi bộ đệm trạng thái $\mathcal{S}_t$. Khi kích thước trạng thái tiếp cận ngưỡng ngân sách $M_{\max}$, hệ thống kích hoạt yêu cầu thu dọn và nén tóm tắt dữ liệu. Để hiện thực hóa hợp đồng này, các kỹ thuật như chính sách Least Recently Updated LRU, cấu trúc phác thảo Count-Min Sketch và hàm suy giảm trọng số cạnh theo hàm mũ $\omega(e_{uv}, t) = \exp(-\lambda(t - t_{uv}))$ được đề xuất như các ứng viên kỹ thuật hiện thực hóa có thể thay thế hoặc tùy biến linh hoạt.

Xử lý hiện tượng sự kiện đến muộn hoặc xáo trộn thứ tự (Out-of-Order Events) phát sinh từ độ trễ mạng thu thập telemetry [3], [30], chuyên đề đề xuất nguyên tắc xử lý theo thời gian sự kiện kết hợp cơ chế mốc ngắt thời gian (Event-Time Watermark):

$$t_{\text{wm}} = \max_{1 \leq i \leq t} (t_{\text{event}}(e_i)) - \delta_{\text{delay}}$$

Mốc thời gian t_{wm} xác lập ranh giới trễ cho phép δ_{delay} ; các sự kiện đến muộn trong phạm vi δ_{delay} được tự động điều hòa vào trạng thái dòng. Các sự kiện đến trễ hơn δ_{delay} được chuyển tiếp vào bộ đệm tái điều chỉnh Reconciliation Buffer theo giao thức ghi nhận thất thoát thông tin xác định (Explicit Information-Loss Protocol) mà không làm gián đoạn luồng suy luận thời gian thực.


Khi hệ thống gặp hiện tượng đột biến lưu lượng Traffic Spike, cơ chế kiểm soát áp lực ngược Backpressure Control dựa trên thuật toán Token-Bucket điều tiết tốc độ nạp dữ liệu. Nếu lưu lượng vượt quá giới hạn chịu tải tối đa, việc loại bỏ gói tin (Shedding) được thực hiện hoàn toàn độc lập với kết quả phát hiện của mô hình (dựa trên hạn ngạch băng thông nguồn thu thập hoặc mức độ ưu tiên của phân vùng telemetry, tuyệt đối không dựa vào điểm số an ninh chưa kiểm chứng)

nhằm tránh rủi ro rò rỉ vòng lặp Detector Leakage và loại bỏ nhằm các bằng chứng APT yếu thừa thớt.

Xét theo lý thuyết tính toán, mô hình dòng thiết lập hợp đồng ngân sách độ phức tạp cho từng thành phần xử lý ký hiệu tổng quát: $\mathcal{C}_{\text{step}} = \mathcal{C}_{\text{seq}}(L, d, \text{arch}) + \mathcal{C}_{\text{graph}}(\text{card}(\mathcal{V}_{\text{active}}), \text{card}(\mathcal{E}_{\text{window}}), \text{arch}) + \mathcal{C}_{\text{state}}(\text{idx}, M_{\text{max}}) + \mathcal{C}_{\text{align}}$. Trong đó các hàm chi phí phụ thuộc vào kiến trúc và cấu trúc dữ liệu cụ thể (ví dụ chi phí tự chú ý $\approx \mathcal{O}(L^2 \cdot d)$ nếu dùng Transformer chuẩn hoặc $\mathcal{O}(L \cdot d)$ nếu dùng biến thể tuyến tính, chi phí truyền tin đồ thị lân cận phụ thuộc số lớp và bậc đỉnh $\mathcal{O}(\text{deg}_{\text{max}} \cdot d)$, chi phí cập nhật chỉ mục trạng thái $\mathcal{O}(\log \text{card}(\mathcal{V}_{\text{active}}))$ nếu sử dụng cây cân bằng). Các mức chặn Big-O cụ thể được đặc tả chặt chẽ cho từng nhánh tại Mục 2.3, Mục 2.4 và tổng hợp tại Bảng 2.2 và Bảng 2.4. Chuyên đề chỉ rõ bản chất đánh đổi cốt lõi (Long-Horizon Context Trade-off): các chiến dịch APT kéo dài nhiều tuần đòi hỏi duy trì ngữ cảnh tương tác sâu, trong khi bộ nhớ thực tế bị giới hạn bởi M_{max} , và thiết kế dòng giải quyết mâu thuẫn này bằng cơ chế nén ngữ cảnh có kiểm soát thay vì lưu trữ toàn bộ dữ liệu thô.

2.1.3. *Kiến trúc tổng thể và giao diện vào/ra*

Kiến trúc tổng thể của khung biểu diễn đặc trưng log đa góc nhìn dòng được thiết kế theo nguyên tắc phân tách độc lập giữa hai mặt phẳng vận hành: Mặt phẳng Huấn luyện (Training Plane) và Mặt phẳng Suy luận Dòng (Streaming Inference Plane), được minh họa chi tiết trong Hình 2.1:



Hình 2.1: Kiến trúc hai mặt phẳng (Training Plane & Inference Plane) của khung biểu diễn đặc trưng log đa góc nhìn dòng, nguồn tác giả đề xuất

Một là, *mặt phẳng huấn luyện ngoại tuyến*: Vận hành trên kho dữ liệu telemetry lịch sử $\mathcal{D}_{\text{train}}$. Mặt phẳng này thực hiện trích xuất song song hai góc nhìn gồm chuỗi sự kiện và đồ thị nguồn gốc, tối ưu hóa hàm mất mát giống hàng đa góc nhìn kết hợp các số hạng điều hòa bất biến để tìm kiếm bộ trọng số tối ưu θ^* tại Giai đoạn A, đồng thời hỗ trợ pha thích ứng bằng chứng yếu Giai đoạn B khi có nhãn mức thô. Quá trình tiền huấn luyện hoàn toàn không sử dụng nhãn tấn công và không can thiệp vào luồng vận hành thời gian thực.

Hai là, *mặt phẳng suy luận dòng trực tuyến*: Vận hành trên luồng sự kiện đang diễn ra $e_t \in \mathcal{L}_{1:t}$. Mặt phẳng này tiếp nhận trọng số đã đóng băng hoàn toàn θ^* , cập nhật trạng thái bộ nhớ hữu hạn S_t theo các chính sách TTL, loại bỏ và đánh dấu thời gian, sau đó trích xuất vector đóng gói $z_t = f_{\theta^*}(S_t) \in \mathbb{R}^d$ theo cơ chế đơn lượt đơn hướng không nhìn trước thời gian tuân thủ nguyên tắc nhân quả thời gian nghiêm ngặt, cung cấp đầu vào tức thời cho các bộ dò tuyến tính đóng băng Giai đoạn C phục vụ phát hiện và quy kết chiến thuật/kỹ thuật MITRE ATT&CK.

2.2. Tiền xử lý và bảo vệ dynamic parameters

Mục 2.2 xác lập cơ sở tiền xử lý phục vụ toàn bộ pipeline trích xuất đặc trưng đa góc nhìn: từ luồng nhật ký thô đến các sự kiện đã được chuẩn hóa, phân loại tham số an ninh và bảo vệ quyền riêng tư có kiểm soát; tất cả đều tuân thủ nghiêm ngặt ranh giới Extractor–Detector và hợp đồng biểu diễn đã thiết lập tại Mục 2.1. Ba thành phần cốt lõi được trình bày theo thứ tự phụ thuộc logic: Một là, parsing và chuẩn hóa có nhận thức an ninh tại Mục 2.2.1; Hai là, mô hình đe dọa quyền riêng tư và cơ chế liên kết có kiểm soát tại Mục 2.2.2; Ba là, đồng bộ thời gian và cửa sổ ngữ cảnh đa tỷ lệ tại Mục 2.2.3.

2.2.1. *Parsing, Typed Canonicalization, Entity Resolution và Security-aware Parameter Retention*

Điểm khởi đầu của pipeline là luồng nhật ký thô không đồng nhất từ nhiều nguồn thu thập: nhật ký kiểm toán hệ điều hành (auditd, Windows Event Log, Sysmon), nhật ký mạng, nhật ký xác thực. Mỗi nguồn sử dụng định dạng cú pháp riêng và ký pháp tham số đặc thù. Mục tiêu của giai đoạn tiền xử lý là ánh xạ tất cả sự kiện về một lược đồ bộ sáu có kiểu hóa (Typed Six-tuple Schema) trong khi bảo toàn mọi thông tin có giá trị an ninh nằm trong các tham số động.

2.2.1.1. Lược đồ kiểu hóa và bảo toàn tham số có nhận thức an ninh

Mỗi sự kiện thô sau khi qua bước parsing được biểu diễn dưới dạng bộ sáu có kiểu hóa (Typed Six-tuple) như sau:

$$\tilde{e}_i = (t_i, \tau_i, v_i, o_i, a_i, p_i)$$

Trong đó: $t_i \in \mathbb{R}_{\geq 0}$ là mốc thời gian sự kiện theo đồng hồ hệ thống nguồn; $\tau_i \in \mathcal{T}$ là kiểu hành vi kiểm toán như syscall, registry op, network op hoặc auth op; $v_i \in \mathcal{V}$ là thực thể chủ thể gồm tiến trình, người dùng, dịch vụ; $o_i \in \mathcal{O}$ là thực thể đối tượng gồm tệp tin, socket, registry key, tiến trình con; $a_i \in \mathcal{A}$ là hành động cụ thể như read, write, execute, connect, create hoặc delete; $p_i = \{(k_j, v_j)\}_{j=1}^{m_i}$ là tập các tham số động có kiểu hóa cụ thể: đường dẫn tệp tin, địa

chỉ IP và cổng đích, chuỗi đối số dòng lệnh, giá trị registry, tên người dùng đích, mã trả về, đáp ứng đúng yêu cầu của Hợp đồng Biểu diễn yêu cầu bảo toàn.

Tập kiểu sự kiện $\mathcal{T}$ và tập hành động $\mathcal{A}$ được định nghĩa tĩnh theo đặc tả nguồn thu thập như bảng syscall của Auditd, taxonomy Windows Event ID và các kiểu sự kiện Sysmon và không phụ thuộc vào dữ liệu huấn luyện, do đó không phát sinh rủi ro rò rỉ vocabulary từ tập kiểm tra (CTRL-LEAK-001). Ngược lại, từ vựng tham số động đặc biệt là chuỗi đường dẫn tệp tin và đối số lệnh, phụ thuộc vào môi trường và được học hoàn toàn trên phân vùng huấn luyện $\mathcal{D}_{\text{train}}$ theo cơ chế fit-only: mọi thống kê, ánh xạ từ vựng và bảng chuẩn hóa đều được fit trên $\mathcal{D}_{\text{train}}$ và áp dụng ở trạng thái đóng băng lên phân vùng Validation và Test ; quá trình fit chỉ thực thi trên phân vùng huấn luyện nhằm tránh đưa thông tin từ tập kiểm tra và tập kiểm định vào bước fit.

2.2.1.2. Chuẩn hóa kiểu hóa và phân giải thực thể

Hạt nhân của giai đoạn chuẩn hóa là hai vị từ ngữ nghĩa bổ sung cho nhau, được áp dụng lên từng trường của bộ sáu kiểu hóa:

$$\text{Retain}(x) = \mathbf{1}[\text{Type}(x) \in \mathcal{T}_{\text{security}} \vee x \text{thỏa đặc tả an ninh tiền nghiệm}]$$

$$\text{Normalize}(x) = \phi(x) \text{ với } \phi \text{ loại bỏ biến thể định dạng, giữ nguyên ngữ nghĩa}$$

Vị từ $\text{Retain}(\cdot)$ được xác lập dựa trên kiểu ngữ nghĩa trường và tính phù hợp an ninh xác định tiền nghiệm hoặc được cấu hình độc quyền trên phân vùng $\mathcal{D}_{\text{train}}/\mathcal{D}_{\text{val}}$ theo đặc tả miền, tuyệt đối không phụ thuộc vào nhãn tấn công hay thống kê tập kiểm tra nhằm ngăn ngừa rủi ro test leakage trên các trường được kiểm toán. Cụ thể, $\text{Retain}(\cdot)$ đánh giá $\mathbf{1} = \text{True}$ đối với các trường mang thông tin tương tác hệ thống trọng yếu: địa chỉ IP và cổng mạng, đường dẫn tệp tin thực thi/cấu hình, chuỗi đối số dòng lệnh, khóa registry, định danh tiến trình cha và con và tài khoản người dùng đích. Các quy tắc như kiểm tra dải IP mạng, khóa registry khởi động, hay cờ đặc quyền nếu được áp dụng chỉ đóng vai trò là các đặc trưng chính sách miền tùy chọn hỗ trợ chuẩn hóa biểu diễn, tuyệt đối không phải là bộ phán quyết tiên tri để phân biệt hành vi độc hại; ranh giới Extractor-Detector được duy trì nghiêm ngặt , tức Extractor không phải là bộ phát hiện dựa

trên luật. Ngược lại, các trường metadata môi trường cục bộ không mang ngữ nghĩa an ninh như PID tạm thời, timestamp mili-giây nội bộ không phải Event-Time và số sequence kernel được phân loại là KNOWN EXCLUDE FIELD và bị loại bỏ trước khi đưa vào Extractor. Đối với các tham số chưa từng thấy hoặc chưa rõ ngữ nghĩa (UNSEEN / UNCERTAIN), hệ thống áp dụng chính sách UNKNOWN-SAFE bảo toàn nhãn kiểu trường và cấu trúc, gán typed placeholder, không thực hiện loại bỏ mặc định.

Hàm chuẩn hóa $\phi(\cdot)$ Áp dụng các phép biến đổi định dạng tường minh: chuẩn hóa đường dẫn, các ký hiệu separator, junction thừa, chuẩn hóa phân cách; chuẩn hóa địa chỉ IP về dạng chính tắc (loại bỏ zero-padding, khai triển IPv6 viết tắt); chuẩn hóa timestamp về UTC epoch; lower-casing không phân biệt hoa thường với tên lệnh trên Windows. Quan trọng là hàm $\phi(\cdot)$ không được phép loại bỏ thông tin ngữ nghĩa an ninh dưới danh nghĩa “nhiều cú pháp”: ví dụ, khoảng trắng trong đối số lệnh không được thu gọn nếu điều đó phá vỡ khả năng tái tạo ý định lệnh. Ranh giới giữa nhiều định dạng và tham số an ninh được ghi nhận tường minh và không thay đổi trong suốt quá trình thực nghiệm.

Bảng 2.1 tóm tắt chính sách xử lý cho từng trường của bộ sáu kiểu hóa:

Bảng 2.1: Chính sách RETAIN / NORMALIZE / PRIVACY-PROTECT / UNKNOWN-SAFE cho các trường của bộ sáu kiểu hóa

Trường	Vai trò ngữ nghĩa	Chính sách giữ/chuẩn hóa	Xử lý quyền riêng tư và An toàn
t_i	Event-Time	NORMALIZE → UTC epoch	Quasi-ID khi kết hợp dữ liệu ngoài; đánh giá theo CTRL-PRIV-001
τ_i	Kiểu hành vi kiểm toán	RETAIN (tĩnh, không học)	Kiểu thấp, không PII trực tiếp
v_i	Thực thể chủ thể (Actor)	PRIVACY-PROTECT → $\pi_\psi(v_i)$	Direct identifier; bắt buộc pseudonymize

Trường	Vai trò ngữ nghĩa	Chính sách giữ/chuẩn hóa	Xử lý quyền riêng tư và An toàn
o_i	Thực thể đối tượng	PRIVACY-PROTECT $\rightarrow \pi_\psi(o_i)$	Direct/quasi-ID; bắt buộc pseudonymize
a_i	Hành động	RETAIN (tĩnh)	Kiểu thấp
p_i (Retain=1)	Tham số an ninh được xác nhận	RETAIN + NORMALIZE $\rightarrow$ tokenize	Tokenize trên từ vựng $\mathcal{D}_{\text{train}}$; OOV $\rightarrow$ UNKNOWN-SAFE
p_i (KNOWN EXCLUDE)	Trường xác định không mang ngữ nghĩa an ninh (PID, timestamp cục bộ, sequence kernel)	DROP trước Extractor	Loại bỏ hoàn toàn trước khi đưa vào f_θ
p_i (UNSEEN / UNCERTAIN)	Tham số ngoài từ vựng $\mathcal{D}_{\text{train}}$ hoặc chưa rõ an ninh	UNKNOWN-SAFE (bảo toàn cấu trúc cú pháp)	Giữ nguyên field-type tag (PATH, IP, CMD, REG, USER) và vị trí cấu trúc; thay giá trị chuỗi bằng typed placeholder (<UNK-PATH>, <UNK-IP>, <UNK-CMD>)

```

elif self.mode == "PRIVACY_AWARE_PARAMETERIZED":
    # Security-aware multi-tier tokenization:
    # Categorize dynamic parameters into invariant security parameter classes
    def classify_ip(m):
        ip_str = m.group(0)
        if self._is_private_ip(ip_str):
            return f"<IP_INTERNAL:{self._pseudonymize(ip_str)}>"
        return f"<IP_EXTERNAL:{self._pseudonymize(ip_str)}>"

    text = re.sub(r"\b\d{1,3}\.\d{1,3}\.\d{1,3}\.\d{1,3}\b", classify_ip, text)
    text = re.sub(r"blk_-\d+", lambda m: f"<BLK:{self._pseudonymize(m.group(0))}>", text)

    # Security-critical path classification
    text = re.sub(r"/etc/[a-zA-Z0-9_\.\\-]+", "<PATH_CONFIG>", text)
    text = re.sub(r"/tmp/[a-zA-Z0-9_\.\\-]+", "<PATH_STAGING>", text)
    text = re.sub(r"/var/log/[a-zA-Z0-9_\.\\-]+", "<PATH_LOG>", text)
    text = re.sub(r"/[a-zA-Z0-9_\.\\-]+", "<PATH_GENERIC>", text)

    text = re.sub(r"0x[0-9a-fA-F]+", "<HEX>", text)
    text = re.sub(r"\b\d+\b", "<NUM>", text)
    return text

```

Đoạn mã 2.1: Logic phân loại và ẩn danh hóa tham số có nhận thức an ninh trong *PrivacyAwareLogTokenizer*.

Phương thức `tokenize_line` ở chế độ `PRIVACY_AWARE_PARAMETERIZED` thực hiện phân loại tham số động thành các lớp trừu tượng có ý nghĩa an ninh (như phân biệt IP nội bộ và ngoại vi, định danh khối dữ liệu, đường dẫn cấu hình nhạy cảm và giá trị số). Cơ chế giả danh hóa cục bộ bảo toàn khả năng liên kết sự kiện trong cùng phiên mà vẫn ngăn ngừa rò rỉ thông tin định danh nhạy cảm.

2.2.1.3. Tiềm xử lý an toàn chống rò rỉ thông tin

Tất cả các thành phần tiềm xử lý có trạng thái học được (bao gồm từ vựng tokenizer tham số động, bảng chuẩn hóa tên tiến trình theo môi trường, thống kê tần suất sự kiện phục vụ outlier filtering, và ngưỡng phân ngưỡng tham số) đều được fit độc quyền trên phân vùng huấn luyện $\mathcal{D}_{\text{train}}$ theo thứ tự nhân quả thời gian theo trật tự nhân quả thời gian, tức là chỉ sử dụng dữ liệu quan sát trước thời điểm phân cắt huấn luyện. Phân vùng Validation và Test chỉ nhận các phép biến đổi từ trạng thái đóng băng đã fit, không có bất kỳ thông tin thống kê nào từ Val/Test được đưa trở lại (CTRL-LEAK-001: Anti-Leakage Temporal Split). Cụ thể:

Một là, phân vùng thời gian tuyến tính theo Event-Time: $\mathcal{D}_{\text{train}} < \mathcal{D}_{\text{val}} < \mathcal{D}_{\text{test}}$ trong đó ký hiệu $<$ biểu thị quan hệ xảy ra trước nghiêm ngặt theo thứ tự thời gian. Không có xáo trộn ngẫu nhiên theo thời gian ở bất kỳ giai đoạn nào.

Hai là, tất cả preprocessor như tokenizer, normalizer, entity resolver và vocabulary builder đều có trạng thái fit-freeze: quá trình fit chỉ chạy một lần trên $\mathcal{D}_{\text{train}}$.

Ba là, chính sách xử lý tham số chưa xác định tuân thủ nghiêm ngặt nguyên tắc an toàn UNKNOWN-SAFE: tuyệt đối không áp dụng quy tắc mặc định hủy bỏ, không thực hiện loại bỏ mặc định UNCONFIRMED $\rightarrow$ DROP. Hệ thống phân định rạch ròi: Thứ nhất, các trường KNOWN EXCLUDE FIELD gồm metadata môi trường như PID, timestamp cục bộ mili-giây và số sequence nội bộ được loại bỏ hoàn toàn trước khi đưa vào Extractor; Thứ hai, các tham số UNSEEN hoặc chưa xác định rõ ngữ nghĩa an ninh xuất hiện trong tập Validation hoặc Test được giữ nguyên nhãn kiểu trường gồm các thẻ PATH, IP, CMD, REG, USER và bảo toàn vị trí cấu trúc của tham số trong bộ sáu, đồng thời thay thế giá trị chuỗi cụ thể bằng typed placeholder tương ứng (<UNK-PATH>, <UNK-IP>, <UNK-CMD>). Cơ chế này được thiết kế để giảm nguy cơ sụp đổ thông tin cấu trúc cú pháp cần thiết cho Extractor và hạn chế rò rỉ từ vựng từ tập kiểm tra.

Bốn là, ranh giới leakage-safe được kiểm tra tự động trong pipeline thực nghiệm: mọi phép fit nào truy cập dữ liệu ngoài $\mathcal{D}_{\text{train}}$ đều bị phát hiện và báo lỗi trước khi chạy thực nghiệm (xem CTRL-LEAK-001).

2.2.2. *Mô hình đe dọa quyền riêng tư và Controlled Linkability*

Các vector biểu diễn đặc trưng z_t và các sự kiện đã được chuẩn hóa $\tilde{e}_i$ tất yếu mang thông tin nhận dạng thực thể, xem đây là điều kiện cần thiết để duy trì ngữ cảnh hành vi và phục vụ phân tích tấn công đa giai đoạn (kế thừa H5 từ Mục 2.1). Tuy nhiên, việc lưu giữ thông tin nhận dạng thô trong không gian vector tạo ra bề mặt tấn công quyền riêng tư không cần thiết. Mục 2.2.2 hình thức hóa mô hình đe dọa và xác lập cơ chế liên kết có kiểm soát như một hợp đồng kỹ thuật. Cơ chế này được kỳ vọng thiết lập sự vượt trội Pareto theo H5 nhưng cần được kiểm chứng thực nghiệm ở các mô hình hạ nguồn (BOUNDARY-06: Privacy Claim Requires Attack-Based Empirical Evaluation; chưa thực thi trong phạm vi Stage A hiện tại).

2.2.2.1. Đối nghịch dữ liệu và thực thể

Lớp đe dọa thứ nhất là đối nghịch dữ liệu/thực thể (Data/Entity Adversary). Đối nghịch này có quyền truy cập trực tiếp hoặc gián tiếp vào các sự kiện đã chuẩn hóa $\tilde{e}_i$ hoặc các trạng thái trung gian trong pipeline tiền xử lý. Hai mối đe dọa chính:

Tấn công liên kết thực thể Entity Linkage Attack: đối nghịch sử dụng các trường nhận dạng thô như tên người dùng, PID và hostname để liên kết sự kiện giữa các phân đoạn thời gian, các hệ thống, hoặc giữa log nguồn và dữ liệu bên ngoài nhằm xác định danh tính cá nhân.

Tấn công tái định danh (Re-identification Attack): đối nghịch sử dụng các đặc trưng hành vi đặc trưng (pattern thao tác tệp tin, chuỗi lệnh đặc thù) kết hợp với thông tin bên ngoài để tái định danh thực thể đã bị ẩn danh hóa.

2.2.2.2. Đối nghịch mô hình

Lớp đe dọa thứ hai là đối nghịch mô hình Model Adversary. Đối nghịch này không truy cập trực tiếp dữ liệu thô mà tương tác với mô hình đã được triển khai hoặc với các vector biểu diễn z_t đã xuất ra. Hai mối đe dọa chính:

Tấn công suy luận thành viên Membership Inference Attack (MIA): đối nghịch xác định xem một bản ghi dữ liệu cụ thể của một thực thể có nằm trong tập huấn luyện của mô hình hay không, thông qua quan sát hành vi đầu ra hoặc các đặc trưng của vector z ([18]).

Tấn công nghịch đảo biểu diễn Representation/Model Inversion Attack: Về mặt nguyên lý, Fredrikson et al. [19] chứng minh tấn công nghịch đảo có thể khai thác thông tin đầu ra/độ tin cậy để tái cấu trúc thuộc tính dữ liệu; trong mô hình đe dọa thích ứng của đề tài (Threat-Model Adaptation), đối nghịch cố gắng khôi phục hoặc xấp xỉ các thuộc tính nhạy cảm tiềm năng như tên người dùng, hostname và chuỗi lệnh từ vector nhúng z .

Lưu ý quan trọng: sự tồn tại của hai lớp đe dọa trên không đồng nghĩa với việc mọi thiết kế đều bị tổn thương ở mức độ như nhau. Mức độ tổn thương thực tế phụ thuộc vào kiến trúc cụ thể của f_θ và cơ chế liên kết được chọn; mức độ này

được xác định qua kiểm thử tấn công thực nghiệm tại Chương 3 (CTRL-PRIV-001).

2.2.2.3. Hợp đồng cơ chế liên kết có kiểm soát

Trước hai lớp đe dọa nêu trên trong khi vẫn bảo toàn ngữ cảnh hành vi cần thiết cho phân tích tấn công, chuyên đề xác lập Cơ chế Liên kết Có Kiểm soát như một hợp đồng kỹ thuật với ba thành phần:

Một là, cơ chế pseudonymization thực thể theo phiên Session-scoped Pseudonymization: mỗi thực thể thực sự $v \in \mathcal{V}$ được ánh xạ về một mã định danh giả danh $\hat{v} = \pi_\psi(v)$ thông qua hàm ánh xạ xác định có kiểm soát $\pi_\psi: \mathcal{V} \rightarrow \hat{\mathcal{V}}$. Hàm π_ψ bảo toàn quan hệ đồng nhất thực thể (tức là $v_i = v_j \Rightarrow \pi_\psi(v_i) = \pi_\psi(v_j)$) để cho phép liên kết hành vi theo thời gian, đây là điều kiện cần để phát hiện APT đa giai đoạn, nhưng không giữ lại thông tin nhận dạng thô v không cần thiết cho mục đích phát hiện.

Hai là, cơ chế tokenization tham số động có chọn lọc Security-selective Parameter Tokenization: các tham số động đã được $\text{Retain}(\cdot)$ xác nhận là mang ngữ nghĩa an ninh được tokenize thành các đơn vị học được theo kho từ vựng fit trên $\mathcal{D}_{\text{train}}$. Các trường KNOWN EXCLUDE FIELD được loại bỏ hoàn toàn trước khi đưa vào f_θ ; trong khi các tham số UNSEEN / UNCERTAIN được xử lý theo chính sách UNKNOWN-SAFE với mục tiêu bảo toàn nhãn kiểu trường và vị trí cấu trúc, đồng thời gán typed placeholder, không bị loại bỏ tùy tiện.

Ba là, về phạm vi liên kết và rotation Linkability Scope: hàm π_ψ xác lập bốn ranh giới tường minh: thứ nhất, Linkable within scope: trong cùng phiên, π_ψ nhất quán để hành vi đa giai đoạn của cùng thực thể vẫn liên kết được; thứ hai, Unlinkable across rotation boundary: khi rotation xảy ra, cùng thực thể nhận mã giả danh mới, làm gián đoạn cross-session linkage; thứ ba, Remains linkable: kiểu hành vi, thời gian tương đối và tham số an ninh giúp duy trì behavioral fingerprint; thứ tư, Becomes unlinkable: tên thực sự v , o và các direct identifier. Rotation boundary phải được xác lập theo predefined operational policy hoặc được lựa chọn dựa trên tập Train/Validation, tuyệt đối không sử dụng thông tin từ true Test

attack/campaign duration nhằm loại trừ rủi ro test leakage. Về mặt phương pháp luận, chuyên đề đề xuất hướng đánh giá nhiều mốc rotation horizon cố định để xây dựng đường biên Utility–Privacy frontier ở các giai đoạn thực nghiệm tiếp theo. Trường hợp rotation horizon quá ngắn so với thời lượng chiến dịch APT thực tế sẽ dẫn tới việc cùng một thực thể nhận các mã giả danh khác nhau qua từng giai đoạn, làm phân mảnh khả năng liên kết chuỗi hành vi cross-phase nếu không có cơ chế tái liên kết an toàn; đây là failure case tường minh cần được định lượng trong đánh giá thực nghiệm. Thiết kế phạm vi cụ thể giữa cấp độ phiên và cấp độ toàn cục là quyết định thực nghiệm phụ thuộc vào đánh đổi này.

Hợp đồng kỹ thuật tổng quát của cơ chế Controlled Linkability được phát biểu như sau: với mọi sự kiện đã được chuẩn hóa $\tilde{e}_i$, sự kiện được biến đổi quyền riêng tư $\tilde{e}_i^{\text{priv}}$ được tạo ra bằng cách thay thế các trường nhận dạng thực thể bằng mã giả danh và áp dụng toán tử bảo vệ tham số an toàn $\text{ParamProtect}(p_i)$ tuân thủ nguyên tắc: thứ nhất, các trường KNOWN EXCLUDE FIELD bị loại bỏ hoàn toàn; thứ hai, các tham số được $\text{Retain}(\cdot)$ xác nhận được tokenize trên $\mathcal{D}_{\text{train}}$; thứ ba, các tham số UNSEEN / UNCERTAIN được xử lý theo chính sách UNKNOWN-SAFE :

$$\tilde{e}_i^{\text{priv}} = (t_i, \tau_i, \pi_\psi(v_i), \pi_\psi(o_i), a_i, \text{ParamProtect}(p_i))$$

Lưu ý rằng các tham số thời gian và kiểu hành vi được bảo toàn nguyên vẹn vì chúng không phải direct identifier, tuy nhiên các tham số này có thể hoạt động như quasi-identifier khi kết hợp với dữ liệu bên ngoài; rủi ro liên kết tương ứng cần được đánh giá theo CTRL-PRIV-001. Cơ chế này được kỳ vọng thiết lập sự vượt trội Pareto theo nghĩa của H5 so với hai đường cơ sở: thứ nhất, giữ nguyên định danh thô không có pseudonymization; và thứ hai, ẩn danh hóa quá mức xóa bỏ cả liên kết thực thể cần thiết cho phân tích hành vi. Tuy nhiên, khẳng định sự vượt trội này là một giả thuyết nghiên cứu yêu cầu kiểm thử thực nghiệm tường minh ở các mô hình hạ nguồn thông qua giao thức CTRL-PRIV-001, bao gồm đánh giá MIA [18], tấn công nghịch đảo theo nguyên lý Fredrikson et al. [19] áp

dụng cho các thuộc tính nhạy cảm của log, cùng tấn công tái định danh; chưa được thực thi trong phạm vi thực nghiệm của chuyên đề hiện tại.

2.2.3. *Đồng bộ thời gian và cửa sổ ngữ cảnh đa tỷ lệ*

Sau khi các sự kiện được chuẩn hóa và bảo vệ quyền riêng tư theo Mục 2.2.1–2.2.2, bước tiếp theo là tổ chức chúng thành các đơn vị ngữ cảnh phục vụ các bộ trích xuất đặc trưng hạ nguồn tại Mục 2.3. Mục 2.2.3 giải quyết hai vấn đề liên quan chặt chẽ: thứ nhất là đảm bảo tính nhất quán Event-Time khi sự kiện đến từ nhiều nguồn có đồng hồ không đồng bộ; và thứ hai là xây dựng cấu trúc cửa sổ ngữ cảnh đa tỷ lệ phù hợp với bản chất đa giai đoạn của chiến dịch APT. Cơ chế móc ngắt thời gian và tham số δ_{delay} đã được xác lập tại Mục 2.1.2; Mục 2.2.3 kế thừa và áp dụng các định nghĩa đó mà không tái định nghĩa lại.

2.2.3.1. Thời gian sự kiện, lệch pha đồng hồ, cơ chế watermark và sự kiện đến trễ

Môi trường SOC thực tế thu thập log từ nhiều nguồn có đồng hồ hệ thống khác nhau, phát sinh hiện tượng lệch pha đồng hồ Clock Skew. Lệch pha đồng hồ khiến các bản ghi telemetry tương ứng của cùng một sự kiện/tương tác quan sát được lại mang nhãn thời gian không nhất quán khi so sánh xuyên nguồn, làm xáo trộn thứ tự thời gian sự kiện dùng để xây dựng chuỗi và đồ thị hạ nguồn (lưu ý nguyên lý bất biến: quan hệ phụ thuộc ghi nhận trong log không đồng nhất với quan hệ nhân quả (nguyên lý: dependency $\neq$ causal effect)). Giai đoạn đồng bộ thời gian áp dụng một chuỗi bước xử lý có thứ tự:

Thứ nhất, chuẩn hóa múi giờ: tất cả nhãn thời gian được chuyển về UTC epoch trước khi so sánh xuyên nguồn.

Thứ hai, ước lượng và hiệu chỉnh lệch pha đồng hồ: với mỗi cặp nguồn có thể quan sát được sự kiện chung (ví dụ: cùng một kết nối mạng được ghi nhận bởi cả endpoint log và network log), offset lệch pha Δ_{skew} được ước lượng và hiệu chỉnh. Phương pháp ước lượng cụ thể (crystal-synced event matching, NTP-based correction,...) là quyết định triển khai phụ thuộc môi trường và không ảnh hưởng đến hợp đồng tiền xử lý.

Thứ ba, áp dụng cơ chế Watermark kế thừa từ Mục 2.1.2: tham số δ_{delay} xác lập cửa sổ dung sai cho sự kiện đến muộn sau đồng bộ thời gian. Các sự kiện đến trong cửa sổ $[t_{\text{wm}}, t_{\text{wm}} + \delta_{\text{delay}}]$ được tích hợp vào trạng thái dòng; các sự kiện đến trễ hơn được chuyển vào Reconciliation Buffer theo Explicit Information-Loss Protocol.

2.2.3.2. Cửa sổ ngữ cảnh đa tỷ lệ

Đặc điểm của chiến dịch APT là hoạt động trải dài nhiều tỷ lệ thời gian khác nhau đồng thời: hành động tức thời từ mili-giây đến giây, chuỗi hành vi ngắn hạn từ phút đến giờ, và chiến dịch dài hạn từ ngày đến tuần. Một cửa sổ ngữ cảnh duy nhất không thể bao phủ đầy đủ tất cả tỷ lệ này mà không vi phạm ràng buộc bộ nhớ hữu hạn M_{max} từ Mục 2.1.2. Chuyên đề đề xuất cấu trúc cửa sổ ngữ cảnh ba tỷ lệ như một giải pháp phân cấp:

$$\mathcal{W} = \{W_s, W_m, W_L\}$$

Cửa sổ ngắn hạn W_s Short-term Window: bao phủ chuỗi sự kiện gần nhất trong phạm vi thời gian ngắn (hyperparameter, ví dụ: vài phút đến hàng chục phút; khóa bằng Validation/operational budget tại Mục 2.3), cung cấp ngữ cảnh thực thi tức thời cho một tiến trình hoặc phiên làm việc. Cửa sổ này cung cấp dữ liệu đầu vào chính cho Bộ trích xuất tuần tự tại Mục 2.3. Kích thước $\text{card}(W_s)$ bị chặn trên bởi độ dài chuỗi tối đa L_{max} của kiến trúc encoder, với giá trị cụ thể sẽ được xác lập tại Mục 2.3 khi kiến trúc được khóa.

Cửa sổ trung hạn W_m Medium-term Window: bao phủ lịch sử hành vi của thực thể trong phạm vi thời gian trung (hyperparameter, ví dụ: vài giờ đến một ngày; khóa bằng Validation budget), phản ánh các pattern hành vi đặc trưng của người dùng/tiến trình và cung cấp ngữ cảnh phát hiện leo thang đặc quyền hoặc lateral movement. Cửa sổ này được duy trì trong trạng thái hữu hạn $\mathcal{S}_t$ thông qua cơ chế nén trạng thái (state summary/sketch) đã xác lập tại Mục 2.1.2.

Cửa sổ dài hạn/Tóm tắt trạng thái W_L Long-term State Summary: thay vì lưu trữ toàn bộ lịch sử thô (vi phạm M_{max}), trạng thái dài hạn được duy trì dưới dạng các sketch thống kê nén gọn (ví dụ: Count-Min Sketch về tần suất hành vi

loại sự kiện, hàm suy giảm trọng số cạnh theo thời gian). Đây chính là đánh đổi cốt lõi Long-Horizon Context Trade-off đã được xác lập tại Mục 2.1.2: chi phí tính toán và bộ nhớ cụ thể của W_L phụ thuộc vào lựa chọn cấu trúc sketch tại Mục 2.3–2.4.

Ba cửa sổ W_s, W_m, W_L không độc lập mà có quan hệ phân cấp: $W_s \subset W_m$ theo thứ tự thời gian, và W_L là tóm tắt nén của lịch sử trước W_m . Phân cấp này đảm bảo cùng một evidence có thể xuất hiện ở nhiều scale gồm W_s, W_m và W_L dưới dạng bài biểu diễn khác nhau, nhưng không có thông tin tương lai nào bị nạp vào cửa sổ hiện tại (nguyên lý Strictly Causal / Zero Lookahead từ Mục 2.1.3). Sơ đồ phân cấp cụ thể và giao diện đầu ra từ $\mathcal{W}$ sang các bộ trích xuất tại Mục 2.3 sẽ được hình thức hóa khi kiến trúc được xác lập.

2.3. Trích xuất đặc trưng đa góc nhìn

Sau giai đoạn tiền xử lý và đồng bộ thời gian tại Mục 2.2, luồng sự kiện kiểu hóa $\tilde{e}_i^{\text{priv}}$ được đưa vào hai bộ trích xuất đặc trưng song song nhằm khai thác hai góc nhìn bổ trợ cho nhau: góc nhìn tuần tự ngữ nghĩa (Semantic-Sequential View) và góc nhìn cấu trúc phụ thuộc (Dependency-Temporal Graph View). Mỗi bộ trích xuất hoạt động độc lập trên không gian đầu vào tương ứng và xuất ra một vector biểu diễn đặc trưng riêng biệt: $z_{\text{seq}} \in \mathbb{R}^{d_{\text{seq}}}$ và $z_{\text{graph}} \in \mathbb{R}^{d_{\text{graph}}}$. Hai vector này là đầu vào của tầng giống hàng và học biểu diễn thống nhất tại Mục 2.4.

2.3.1. Bộ trích xuất tuần tự ngữ nghĩa Transformer

Bộ trích xuất tuần tự ngữ nghĩa tiếp nhận chuỗi các sự kiện kiểu hóa trong cửa sổ ngắn hạn W_s gồm $L \leq L_{\text{max}}$ sự kiện liên tiếp, kế thừa kiến trúc Self-Attention tiêu chuẩn [28]. Nhiệm vụ của bộ trích xuất là mô hình hóa các phụ thuộc ngữ cảnh cục bộ, thứ tự gọi hàm hệ thống và tương tác tham số động mà không dựa trên bất kỳ nhãn phân loại tấn công nào ở hạ nguồn.

2.3.1.1. Biểu diễn sự kiện kiểu hóa và mã hóa ngữ cảnh

Mỗi sự kiện kiểu hóa $\tilde{e}_i^{\text{priv}} = (t_i, \tau_i, \pi_\psi(v_i), \pi_\psi(o_i), a_i, \text{ParamProtect}(p_i))$ được chiếu vào không gian vector liên tục $\mathbb{R}^{d_{\text{model}}}$ thông qua hàm nhúng kết hợp các thành phần thông tin theo cấu trúc:

$$\begin{aligned} x_i = & e_\tau(\tau_i) + e_a(a_i) + e_v(\pi_\psi(v_i)) + e_o(\pi_\psi(o_i)) \\ & + \sum_{(k_j, v_j) \in p_i^{\text{priv}}} e_p(k_j, v_j) + e_{\text{time}}(t_i) + e_{\text{pos}}(i) \end{aligned}$$

Trong đó: e_τ, e_a là các ma trận nhúng kiểu sự kiện và hành động tĩnh; e_v, e_o là nhúng thực thể chủ thể và đối tượng theo không gian giả danh có kiểm soát; e_p là nhúng các token tham số an ninh được giữ lại; $e_{\text{pos}}(i)$ là mã hóa vị trí rời rạc; và $e_{\text{time}}(t_i)$ là hàm mã hóa thời gian liên tục điều hòa (Harmonic Time Encoding) dạng $e_{\text{time}}(t_i) = [\cos(\omega_1 t_i + \phi_1), \dots, \cos(\omega_k t_i + \phi_k)]^\top$, kế thừa nguyên lý mã hóa thời gian liên tục trên đồ thị động [39], mã hóa trực tiếp khoảng trễ liên tục Δt giữa các hành vi liên tiếp nhằm tránh việc rời rạc hóa thô thành các time-bin cố định, cho phép mô hình biểu diễn và phân biệt các nhịp thời gian khác nhau trong phạm vi thiết kế (như sự khác biệt giữa hai hành vi diễn ra cách nhau 10 mili-giây trong một đoạn mã tự động so với cách nhau 10 giờ trong hoạt động thông thường), song phép chiếu điều hòa này không hàm ý một ánh xạ một-một hay bảo toàn tuyệt đối mọi giá trị khoảng trễ thực tế. Toàn bộ các siêu tham số cấu trúc như số tầng encoder N_{layers} , số đầu chú ý N_{heads} , số chiều ẩn d_{model} , số chiều lan truyền d_{ff} và tỷ lệ dropout p_{drop} đều được xác lập dựa trên tập huấn luyện và kiểm định (Train/Validation), không sử dụng nhân kiểm tra.

2.3.1.2. Mục tiêu huấn luyện tự giám sát

Quy trình huấn luyện bộ trích xuất tuần tự mà không gây rò rỉ nhãn tấn công hay phụ thuộc vào tri thức chuyên gia định trước được tối ưu hóa qua ba mục tiêu tự giám sát với đầu dự đoán phụ trợ và tiêu chuẩn tối ưu hóa rõ ràng:

1. Tác vụ dự đoán sự kiện bị che (Masked Event Prediction, $\mathcal{L}_{\text{MEP}}$): Thích ứng từ phương pháp LogBERT [24], che ngẫu nhiên tập chỉ số sự kiện $\mathcal{M}_{\text{event}} \subset$

$\{1, \dots, L\}$ theo tỷ lệ che $r_{\text{mask}}^{\text{event}} \in (0,1)$ (trong đó đề tài lựa chọn giá trị 15% làm điểm khởi tạo tham chiếu và được khóa cố định trên tập Train/Validation trước khi đánh giá trên tập Test). Đầu dự đoán phụ trợ $\phi_{\text{seq}}^{\text{event}}: \mathbb{R}^{d_{\text{model}}} \rightarrow \mathbb{R}^{\text{card}(\mathcal{V}_{\text{event}})}$ ánh xạ trạng thái ẩn h_i sang không gian xác suất kiểu sự kiện. Mục tiêu (target) là nhãn kiểu sự kiện và hành động thực tế $y_i^{\text{event}} \in \{1, \dots, \text{card}(\mathcal{V}_{\text{event}})\}$, tối ưu hóa qua hàm mất mát Categorical Cross-Entropy trung bình trên tập bị che, cung cấp gradient cập nhật trực tiếp cho θ_{seq} và $\phi_{\text{seq}}^{\text{event}}$:

$$\mathcal{L}_{\text{MEP}} = -\frac{1}{\text{card}(\mathcal{M}_{\text{event}})} \sum_{i \in \mathcal{M}_{\text{event}}} \log[\text{softmax}(\phi_{\text{seq}}^{\text{event}}(\mathbf{h}_i^{\text{seq}}))]_{\tau_i}$$

2. Tác vụ dự đoán tham số an ninh bị che (Masked Parameter Prediction, $\mathcal{L}_{\text{MPP}}$): Thiết kế đóng góp riêng của chuyên đề nhằm che ngẫu nhiên tập tham số bảo toàn an ninh $\mathcal{M}_{\text{param}} \subset \{1, \dots, L\}$ theo tỷ lệ $r_{\text{mask}}^{\text{param}} \in (0,1)$ (khởi tạo tham chiếu 15% và được khóa cố định trên tập Validation trước khi thử nghiệm). Đầu dự đoán phụ trợ $\phi_{\text{seq}}^{\text{param}}: \mathbb{R}^{d_{\text{model}}} \rightarrow \mathbb{R}^{\text{card}(\mathcal{V}_{\text{param}})}$ dự đoán token tham số mục tiêu y_i^{param} . Mục tiêu tái dựng được định nghĩa chuẩn xác là token đã qua chuẩn hóa và biến đổi bảo vệ quyền riêng tư π_{ψ} tại Mục 2.2 (gồm token thực thể giả danh hóa, token tham số an ninh chuẩn hóa hoặc token kiểu hóa UNKNOWN-SAFE), tuyệt đối không đặt mục tiêu là chuỗi nhạy cảm thô. Hàm mất mát Categorical Cross-Entropy tính trung bình trên $\mathcal{M}_{\text{param}}$, truyền gradient cho θ_{seq} và $\phi_{\text{seq}}^{\text{param}}$:

$$\begin{aligned} \mathcal{L}_{\text{MPP}} \\ = \frac{1}{\text{card}(\mathcal{M}_{\text{param}})} \sum_{i \in \mathcal{M}_{\text{param}}} \sum_{(k_j, v_j) \in \mathbf{p}_i^{\text{priv}}} \mathcal{L}_{\text{param}}(\phi_{\text{seq}}^{\text{param}}(\mathbf{h}_i^{\text{seq}}), (k_j, v_j)) \end{aligned}$$

```

elif true_param_targets.dim() == 3:
    # 3D multi-slot target [B, T, K]
    mpp_logits = self.mpp_head(features).view(batch_size, seq_len, self.max_param_slots,
self.param_vocab_size)
    if mpp_mask is None:
        # Target only active non-padding parameter slots (<PAD_PARAM> = 1 excluded)
        mpp_mask = (true_param_targets != 1) & (~padding_mask.unsqueeze(-1))
    else:
        # Ensure <PAD_PARAM> = 1 is NEVER a target
        mpp_mask = mpp_mask & (true_param_targets != 1)

    if mpp_mask.any():
        # Flatten to [N_masked, param_vocab_size] and [N_masked]
        selected_logits = mpp_logits[mpp_mask]
        selected_targets = true_param_targets[mpp_mask]
        l_mpp = F.cross_entropy(selected_logits, selected_targets)
    else:
        l_mpp = torch.tensor(0.0, device=masked_events.device, requires_grad=True)
    losses["L_MPP"] = l_mpp

```

Đoạn mã 2.2: Tính toán hàm mất mát Masked Parameter Prediction (L_MPP) trên mục tiêu đa khe 3D.

Đoạn mã triển khai hàm mất mát L_MPP đối với tensor mục tiêu tham số ba chiều biểu diễn đa khe (multi-slot). Mặt nạ mpp_mask cô lập chính xác các khe tham số đang hoạt động và loại trừ token đệm <PAD_PARAM>, sau đó tính toán Cross Entropy trên các vị trí che giấu nhằm thúc đẩy mô hình học đặc trưng biểu diễn tham số có nhận thức an ninh.

3. Tác vụ dự đoán khoảng thời gian tương đối (Relative Time Gap Prediction, $\mathcal{L}_{\text{time}}$): Thiết kế đóng góp riêng của chuyên đề nhằm dự đoán khoảng cách thời gian giữa hai sự kiện kề nhau $\Delta t_{i,i+1} = t_{i+1} - t_i \geq 0$. Đầu hồi quy phụ trợ $\phi_{\text{seq}}^{\text{time}}: \mathbb{R}^{2d_{\text{model}}} \rightarrow \mathbb{R}$ tiếp nhận vector ghép $[h_i; h_{i+1}]$ để dự đoán giá trị logarit $\log(1 + \Delta t_{i,i+1})$. Tiêu chuẩn tối ưu hóa là hàm Smooth L1 (Huber criterion, $\delta = 1.0$) trung bình trên toàn bộ $L - 1$ cặp sự kiện liền kề, truyền gradient cho θ_{seq} và $\phi_{\text{seq}}^{\text{time}}$:

$$\mathcal{L}_{\text{time}} = \frac{1}{\text{card}(\mathcal{M}_{\text{time}})} \sum_{i \in \mathcal{M}_{\text{time}}} \mathcal{L}_{\delta}(\phi_{\text{seq}}^{\text{time}}(\mathbf{h}_i^{\text{seq}}), \log(1 + \Delta t_i))$$

Hàm mất mát tổng thể của Bộ trích xuất tuần tự trong Giai đoạn A1 là tổng kết hợp có trọng số: $\mathcal{L}_{\text{seq}}^{\text{self}} = \alpha_1 \mathcal{L}_{\text{MEP}} + \alpha_2 \mathcal{L}_{\text{MPP}} + \alpha_3 \mathcal{L}_{\text{time}}$, trong đó các hệ số $\alpha_1, \alpha_2, \alpha_3 > 0$ được tinh chỉnh trên tập Validation.


2.3.1.3. Giao diện đầu ra của bộ trích xuất tuần tự

Sau khi đi qua N_{layers} khối Transformer Encoder, chuỗi biểu diễn ẩn $H_{\text{seq}} = [h_1, \dots, h_L] \in \mathbb{R}^{L \times d_{\text{model}}}$ được tổng hợp thành vector biểu diễn ngữ cảnh tuần tự z_{seq} thông qua toán tử tổng hợp có trọng số chú ý (Attention-weighted Readout):

$$\alpha_i = \text{softmax} \left(\frac{w_{\text{seq}}^T h_i}{\sqrt{d_{\text{model}}}} \right)$$

$$z_{\text{seq}} = \sum_{i=1}^L \alpha_i W_{\text{proj}} h_i \in \mathbb{R}^{d_{\text{seq}}}$$

Đầu ra của Bộ trích xuất tuần tự là một gói biểu diễn chuẩn hóa mang vector $z_{\text{seq}} \in \mathbb{R}^{d_{\text{seq}}}$ đại diện cho toàn bộ chuỗi hành vi trong cửa sổ ngắn hạn W_s , kèm theo siêu dữ liệu tương ứng bao gồm: khoảng thời gian sự kiện $[t_{\text{start}}, t_{\text{end}}]$, phạm vi thực thể hoặc phiên tương ứng, mặt nạ sẵn sàng của góc nhìn $m_{\text{seq}} \in \{0,1\}$, và định danh cửa sổ. Giao diện này cung cấp đầy đủ thông tin để Tầng giống hàng tại Mục 2.4 xác định quan hệ tương ứng giữa các góc nhìn mà không thực hiện dung hợp sớm hay sử dụng nhãn kiểm tra. Giả định kiến trúc gồm N_{layers} tầng Transformer Encoder, độ dài chuỗi đầu vào L , số chiều mô hình d_{model} và số chiều tầng truyền thẳng d_{ff} , độ phức tạp tính toán của bộ trích xuất tuần tự là $C_{\text{seq}} = \mathcal{O}(N_{\text{layers}} \cdot (L^2 \cdot d_{\text{model}} + L \cdot d_{\text{model}} \cdot d_{\text{ff}}))$, trong đó số hạng bậc hai phản ánh chi phí tính toán ma trận chú ý theo độ dài chuỗi.



Hình 2.2: Kiến trúc Bộ trích xuất tuần tự ngữ nghĩa Transformer và cơ chế học tự giám sát trên cửa sổ ngắn hạn, nguồn tác giả đề xuất

2.3.2. *Xây dựng đồ thị nguồn gốc phụ thuộc thời gian và đảm bảo độ chân thực đồ thị*

Song song với bộ trích xuất tuần tự, luồng sự kiện được chuyển hóa thành đồ thị nguồn gốc phụ thuộc thời gian (Dependency-Temporal Provenance Graph). Đồ thị này biểu diễn các quan hệ tương tác và luồng thông tin cấu trúc giữa các thực thể hệ thống. Quá trình xây dựng đồ thị tuân thủ quy trình ba bước: tiếp nhận sự kiện kiểu hóa, áp dụng các cơ chế ứng viên kiểm soát độ chân thực đồ thị (Graph-Fidelity Candidates), và nạp cấu trúc đã tinh lọc vào mô hình Temporal GNN.

2.3.2.1. **Định kiểu hóa, cạnh có hướng và thuộc tính thời gian**

Đồ thị nguồn gốc phụ thuộc thời gian tại thời điểm t được hình thức hóa dưới dạng đồ thị dị thể động $\mathcal{G}_t = (\mathcal{V}_t, \mathcal{E}_t, \phi_V, \phi_E, \tau_E)$, trong đó:

- Tập đỉnh kiểu hóa $\mathcal{V}_t$: phân loại thông qua hàm ánh xạ kiểu $\phi_V: \mathcal{V}_t \rightarrow \{\text{Process, File, Socket, User, Host}\}$, phân định ranh giới ngữ nghĩa giữa các loại tài nguyên hệ thống.
- Tập cạnh có hướng $\mathcal{E}_t$: mỗi cạnh $e = (u, v, r, t_e) \in \mathcal{E}_t$ thể hiện một tương tác quan sát được với kiểu quan hệ $r = \phi_E(e) \in \{\text{fork, exec, read, write, connect, bind}\}$ và mốc thời gian sự kiện $t_e = \tau_E(e)$.
- Thuộc tính cạnh: tích hợp các tham số an ninh đã được chuẩn hóa và bảo vệ quyền riêng tư như số byte truyền nhận, cờ truy cập và mã trạng thái, gắn kèm vector thuộc tính $x_e \in \mathbb{R}^{d_{\text{edge}}}$.

Nguyên tắc cốt lõi: cạnh chỉ được tạo ra khi có sự kiện nhật ký kiểm toán ghi nhận tường minh tương tác giữa hai thực thể. Hệ thống không tự ý tạo cạnh nối chỉ dựa trên sự gần nhau về mặt thời gian giữa hai sự kiện rời rạc.

2.3.2.2. **Quan hệ phụ thuộc quan sát được và ranh giới với quan hệ nhân quả**

Một ranh giới phương pháp luận căn bản cần được duy trì xuyên suốt chuyên đề là sự phân định giữa quan hệ phụ thuộc quan sát được và quan hệ nhân quả thực sự. Các cạnh trong đồ thị nguồn gốc phản ánh luồng dữ liệu và quan hệ

kiểm toán do hệ điều hành ghi lại, biểu thị khả năng có sự truyền dẫn thông tin. Tuy nhiên, việc một tiến trình đọc tệp tin A rồi sau đó ghi vào tệp tin B không khẳng định một cách chắc chắn rằng nội dung trong B bị chi phối nhân quả bởi A (nguyên lý bất biến: dependency $\neq$ causal effect). Chuyên đề không sử dụng thuật ngữ đồ thị nhân quả trừ khi các giả định nhận dạng nhân quả chặt chẽ được thỏa mãn, tránh các suy diễn sai lầm trong việc truy vết nguồn gốc tấn công.

2.3.2.3. Các cơ chế ứng viên kiểm soát độ chân thực đồ thị và bùng nổ phụ thuộc

Trong môi trường thực tế, đồ thị nguồn gốc thường đối mặt với hiện tượng bùng nổ phụ thuộc và ô nhiễm liên kết từ các thực thể tồn tại lâu (Long-lived Entities như dịch vụ hệ thống, tiến trình nền). Để xử lý các thách thức này trước khi nạp đồ thị vào mô hình học máy, chuyên đề đề xuất bốn cơ chế ứng viên kiểm soát độ chân thực đồ thị (Proposed Graph-Fidelity Candidates) hoạt động độc lập với bộ phát hiện:

1. Phân rã thực thể theo đơn vị công việc (Unit-of-work Node Splitting): các tiến trình hệ thống chạy dài ngày được phân tách thành các đỉnh phiên dựa trên luồng thực thi thread hoặc ranh giới phiên xử lý, nhằm hạn chế việc một tiến trình duy nhất tạo liên kết ảo giữa các tác vụ không liên quan.
2. Hàm suy giảm trọng số cạnh theo thời gian : trọng số ảnh hưởng của cạnh suy giảm theo hàm mũ $w(e) = \exp(-\lambda(t - t_e))$, trong đó $\lambda > 0$ là hệ số suy giảm được xác định theo ngân sách trạng thái tại Mục 2.1.2, làm giảm độ ưu tiên của các tương tác cũ.
3. $t_{\text{first}}t_{\text{last}}$ Khi áp dụng mạng nơ-ron đồ thị trên đồ thị nguồn gốc có đường kính lớn, hai rủi ro kiến trúc phổ biến là hiện tượng làm mịn quá mức (Over-smoothing, Oono & Suzuki [36]) khiến biểu diễn các đỉnh hội tụ về các vector khó phân biệt, và hiện tượng nghẽn cổ chai thông tin (Over-squashing, Alon & Yahav [37]) khi lượng thông tin từ vùng lân cận mở rộng nhanh chóng phải truyền qua một số ít cạnh trung gian để nén vào một vector kích thước cố định. Chuyên đề đề xuất hai cơ chế ứng viên giảm thiểu :

4. Tính độc lập và đánh giá thực nghiệm: các cơ chế trên hoàn toàn dựa trên quy tắc cấu trúc và thời gian, không sử dụng điểm số tấn công hay nhân kiểm tra để quyết định giữ hay xóa cạnh. Mức độ đóng góp và hiệu quả thực tế của từng cơ chế ứng viên được đánh giá định lượng thông qua phân tích triệt tiêu tại Chương 3.

2.3.2.4. Xử lý thực thể khởi động lạnh và thực thể mới

Hệ thống log thường xuyên xuất hiện các thực thể mới như tiến trình mới tạo, kết nối mạng tạm thời và máy chủ mới kết nối chưa có lịch sử tương tác trong đồ thị, dẫn đến thách thức khởi động lạnh (Cold-start). Để xử lý hiện tượng này trong không gian biểu diễn:

- Khởi tạo vector trạng thái dựa trên kiểu thực thể: đỉnh mới v được khởi tạo vector đặc trưng ban đầu thông qua hàm nhúng kiểu thực thể học được (Entity-type-conditioned learnable initialization): $h_v^{(0)} = e_{\text{type}}(\phi_V(v))$. Cơ chế kế thừa ngữ cảnh từ tiến trình cha chỉ được kích hoạt như một tùy chọn hỗ trợ khi quan hệ cha con thực sự quan sát được trong luồng nhật ký kiểm toán và thỏa mãn hợp đồng riêng tư, tuyệt đối không sử dụng thông tin nhân kiểm tra hay giả định mở rộng miền định danh.
- Toán tử tự kết nối điều hòa (Self-loop Regularization): nhằm hỗ trợ việc truyền thông điệp khi cấu trúc lân cận thưa thớt, mạng GNN có thể áp dụng toán tử tự kết nối điều hòa trong đồ thị tính toán của mô hình. Toán tử này chỉ tồn tại trong quá trình thực thi lan truyền thông điệp và không được ghi nhận vào đồ thị nguồn gốc $\mathcal{G}_t$ như một quan hệ quan sát được.

```
def reset_node_states(self):
    """Inductive Split Reset: Clears all dynamic node memory and interaction states."""
    self.node_memory.clear()
    self.node_last_ts.clear()
    self.node_in_degrees.clear()
    self.node_out_degrees.clear()
    self.node_history_buffers.clear()
```

Đoạn mã 2.3: Cơ chế đặt lại trạng thái nút động (*reset_node_states*) phục vụ đánh giá quy nạp.

Khi chuyển tiếp giữa các phân vùng dữ liệu Train, Validation và Test, phương thức `reset_node_states` làm trống toàn bộ bộ nhớ nút, mốc thời gian gần nhất, bậc vào/ra và bộ đệm lịch sử tương tác của mạng đồ thị thời gian. Thao tác này bảo đảm tính quy nạp

thuần túy (strictly inductive evaluation) và ngăn chặn việc mang trạng thái ẩn của các thực thể từ tập huấn luyện sang các tập đánh giá tiếp theo.

2.3.3. Bộ trích xuất đồ thị động Temporal GNN

Sau khi đồ thị nguồn gốc được xây dựng và áp dụng các cơ chế ứng viên kiểm soát độ chân thực, cấu trúc đồ thị động được đưa vào Bộ trích xuất Temporal GNN. Kế thừa khung xử lý bộ nhớ và truyền thông điệp thời gian động [40] cùng các nguyên lý thiết kế từ các hệ thống đồ thị nguồn gốc tiêu biểu [29], [30], [31], [32], chuyên đề hình thức hóa cơ chế truyền thông điệp thời gian có kiểu hóa (Typed Temporal Message Passing) phù hợp với dữ liệu log bảo toàn ngữ cảnh an ninh.

2.3.3.1. Truyền thông điệp thời gian có kiểu hóa

Tại mỗi sự kiện tương tác $e = (v, u, r, t)$, thông điệp truyền từ đỉnh nguồn v sang đỉnh đích u được tính toán dựa trên trạng thái bộ nhớ của các đỉnh ngay trước mốc thời gian sự kiện, khoảng thời gian tương đối, vector nhúng kiểu quan hệ và thuộc tính cạnh an toàn:

$$m_{v \rightarrow u}(t) = \text{Msg}(h_{v,pre}, h_{u,pre}, \delta_v(t), e_r, x_e)$$

Trong đó $h_{v,pre}$ và $h_{u,pre}$ là trạng thái bộ nhớ của v và u ngay trước event-time t ; e_r là vector nhúng của loại quan hệ r ; x_e là vector thuộc tính cạnh; $\delta_v(t) = t - t_{last}(v)$ là độ lệch thời gian so với tương tác gần nhất của v . Các thông điệp gửi đến đỉnh u trong cùng bước thời gian được tổng hợp qua hàm gom cụm:

$$m_{u,agg}(t) = \text{Agg}(\{m_{v \rightarrow u}(t) : (v, u) \in N_t(u)\})$$

Trạng thái bộ nhớ của thực thể u được cập nhật qua tế bào hồi quy như GRU Cell từ trạng thái trước đó và thông điệp tổng hợp:

$$h_u(t) = \text{Update}(h_{u,pre}, m_{u,agg}(t))$$

2.3.3.2. Học biểu diễn tự giám sát trên đồ thị nguồn gốc động

Mục tiêu tối ưu hóa các tham số θ_{graph} của mạng Temporal GNN trong Giai đoạn A1 mà không sử dụng nhãn tấn công hay thông tin tương lai, chuyên đề thiết

lập hàm mục tiêu tự giám sát đồ thị động $\mathcal{L}_{\text{graph}}^{\text{self}}$. Kế thừa cảm hứng từ mô hình MAGIC [31] về học biểu diễn qua cơ chế che giấu (Masked Graph Representation Learning) và mở rộng cho đồ thị nguồn gốc động theo thời gian (Adapted / Ours), hàm mục tiêu tự giám sát đồ thị được cấu thành từ ba tác vụ phụ trợ với đầu dự đoán riêng biệt:

$$\mathcal{L}_{\text{graph}}^{\text{self}} = \beta_1 \mathcal{L}_{\text{mask-node}} + \beta_2 \mathcal{L}_{\text{mask-edge}} + \beta_3 \mathcal{L}_{\text{time-gap}}$$

- Tác vụ tái tạo thuộc tính thực thể bị che (Masked Node Attribute Reconstruction, $\mathcal{L}_{\text{mask-node}}$): Che ngẫu nhiên một tỷ lệ $r_{\text{mask-node}} \in (0,1)$ thuộc tính kiểu hóa của các thực thể hoạt động $\mathcal{V}_{\text{mask}} \subset \mathcal{V}_{\text{active}}$, trong đó $r_{\text{mask-node}}$ là siêu tham số được kiểm soát, tinh chỉnh và khóa cố định trên tập Validation. Đầu giải mã phụ trợ $\phi_{\text{graph}}^{\text{node}}: \mathbb{R}^{d_{\text{GNN}}} \rightarrow \mathbb{R}^{d_{\text{node-attr}}}$ tái tạo lại vector thuộc tính an toàn quyền riêng tư x_v^{priv} từ trạng thái ẩn $h_v(t)$ theo tiêu chuẩn hồi quy Mean Squared Error (MSE). Mục tiêu tái dựng được khóa chuẩn xác là x_v^{priv} , tức vector đặc trưng đỉnh kiểu hóa thu được SAU KHI đã áp dụng toàn diện quy trình chuẩn hóa, kiểm soát liên kết danh tính / giả danh hóa và chính sách UNKNOWN-SAFE tại Mục 2.2; tuyệt đối không đặt mục tiêu là tên người dùng thô, tên máy chủ thô, mã tiến trình thô, định danh đối tượng thô hay bất kỳ giá trị nhạy cảm nào trước biến đổi, bảo đảm tác vụ tự giám sát đồ thị tuân thủ nghiêm ngặt cùng hợp đồng bảo vệ quyền riêng tư như tác vụ MPP của chuỗi; truyền gradient cập nhật cho θ_{graph} và $\phi_{\text{graph}}^{\text{node}}$:

$$\mathcal{L}_{\text{mask-node}} = \frac{1}{\text{card}(\mathcal{V}_{\text{mask}})} \sum_{v \in \mathcal{V}_{\text{mask}}} \|\phi_{\text{graph}}^{\text{node}}(\mathbf{h}_v(t)) - \mathbf{x}_v^{\text{priv}}\|_2^2$$

- Tác vụ dự đoán kiểu quan hệ cạnh bị che (Masked Edge Relation Prediction, $\mathcal{L}_{\text{mask-edge}}$): Che nhãn quan hệ tương tác trên tập cạnh $\mathcal{E}_{\text{mask}} \subset \mathcal{E}$ theo tỷ lệ $r_{\text{mask-edge}} \in (0,1)$ (siêu tham số được kiểm soát, tinh chỉnh và khóa cố định trên tập Validation trước khi đánh giá Test). Đầu phân loại phụ trợ $\phi_{\text{graph}}^{\text{edge}}: \mathbb{R}^{2d_{\text{GNN}}} \rightarrow \mathbb{R}^{\text{card}(\mathcal{R})}$ tiếp nhận vector ghép $[h_v(t); h_u(t)]$ và

tối ưu hóa hàm Categorical Cross-Entropy đối với nhãn quan hệ thực tế $r_{(v,u)} \in \{1, \dots, \text{card}(\mathcal{R})\}$, truyền gradient cho θ_{graph} và $\phi_{\text{graph}}^{\text{edge}}$:

$$\mathcal{L}_{\text{mask-edge}} = -\frac{1}{\text{card}(\mathcal{E}_{\text{mask}})} \sum_{(v,u) \in \mathcal{E}_{\text{mask}}} \log[\text{softmax}(\phi_{\text{graph}}^{\text{edge}}([\mathbf{h}_v(t); \mathbf{h}_u(t)])_{r_{(v,u)}}]$$

- Tác vụ dự đoán khoảng cách thời gian tương đối (Relative Temporal Gap Prediction, $\mathcal{L}_{\text{time-gap}}$): Dự đoán độ lệch thời gian tương tác $\Delta t_{v,u} = |t_v - t_u|$ giữa các cặp đỉnh tương tác trong tập cạnh hoạt động $\mathcal{E}_{\text{active}}$. Đầu hồi quy phụ trợ $\phi_{\text{graph}}^{\text{time}}: \mathbb{R}^{2d_{\text{GNN}}} \rightarrow \mathbb{R}$ tiếp nhận $[\mathbf{h}_v(t); \mathbf{h}_u(t)]$ và tối ưu hóa hàm Smooth L1 $\delta = 1.0$) đối với đích $\log(1 + \Delta t_{v,u})$, truyền gradient cho θ_{graph} và $\phi_{\text{graph}}^{\text{time}}$ (giúp mô hình học cấu trúc thứ tự và khoảng thời gian quan sát được giữa các sự kiện mà không hàm ý tác động nhân quả, tuân thủ nguyên tắc temporal order != causal effect và dependency != causal effect):

$$\mathcal{L}_{\text{time-gap}} = \frac{1}{\text{card}(\mathcal{E}_{\text{active}})} \sum_{(v,u) \in \mathcal{E}_{\text{active}}} \mathcal{L}_{\delta}(\phi_{\text{graph}}^{\text{time}}([\mathbf{h}_v(t); \mathbf{h}_u(t)]), \log(1 + \Delta t_{v,u}))$$

Các trọng số $\beta_1, \beta_2, \beta_3 > 0$ là các siêu tham số cân bằng giữa các tác vụ phụ trợ. Hàm mục tiêu $\mathcal{L}_{\text{graph}}^{\text{self}}$ trực tiếp tối ưu hóa tập tham số θ_{graph} cùng các đầu phụ trợ trong Giai đoạn A1 và trở thành cấu phần bảo toàn cấu trúc đồ thị trong hàm $\mathcal{L}_{\text{preserv}}$ tại Mục 2.4.

2.3.3.3. Kiểm soát hiện tượng làm mịn quá mức và nghẽn cổ chai thông tin

Khi áp dụng mạng nơ-ron đồ thị trên đồ thị nguồn gốc có đường kính lớn, hai rủi ro kiến trúc phổ biến là hiện tượng làm mịn quá mức (Over-smoothing, Oono & Suzuki [36]) khiến biểu diễn các đỉnh hội tụ về các vector khó phân biệt, và hiện tượng nghẽn cổ chai thông tin (Over-squashing, Alon & Yahav [37]) khi

thông tin từ vùng lân cận mở rộng theo hàm mũ bị ép vào một vector kích thước cố định. Chuyên đề đề xuất hai cơ chế ứng viên giảm thiểu :

- Giảm thiểu Over-smoothing: giới hạn số lớp truyền thông điệp ở mức thấp ($K \leq 2$) kết hợp cơ chế kết nối tắt phần dư (Residual Skip-connections): $h_u^{(l)}(t) = h_u^{(l-1)}(t) + \text{GNN}(h_u^{(l-1)}(t), \dots)$, hỗ trợ duy trì tính phân biệt giữa các thực thể.
- Giảm thiểu Over-squashing: áp dụng cơ chế lấy mẫu lân cận có chọn lọc theo trọng số thời gian Top-k Temporal Attention Sampling, ưu tiên tổng hợp thông điệp từ các đỉnh lân cận có hoạt động gần nhất thay vì mở rộng toàn bộ cây phụ thuộc nhiều bước. Cơ chế này được thiết kế để đánh giá đối sánh với các chính sách lấy mẫu toàn bộ lân cận Full Neighborhood và lấy mẫu theo độ mới Recency Sampling tại Chương 3, nhằm kiểm tra thực nghiệm liệu chính sách sampling có gây mất mát các bằng chứng APT dài hạn hay không.

2.3.3.4. Giao diện đầu ra của bộ trích xuất đồ thị

Vector biểu diễn đặc trưng đồ thị $\mathbf{z}_{\text{graph}}$ trên cửa sổ trung hạn W_m được tạo ra bằng cách tổng hợp trạng thái của tất cả các thực thể đang hoạt động trong cửa sổ:

$$\begin{aligned} \mathbf{z}_{\text{graph}} &= \text{Readout}_{\text{graph}}(\{\mathbf{h}_u(t) : u \in \mathcal{V}_{\text{active}}(W_m)\}) \\ &= \sum_{u \in \mathcal{V}_{\text{active}}} \text{softmax}\left(\frac{\mathbf{w}_{\text{graph}}^T \mathbf{h}_u(t)}{\sqrt{d_{\text{GNN}}}}\right) \mathbf{w}_{\text{proj}} \mathbf{h}_u(t) \in \mathbb{R}^{d_{\text{graph}}} \end{aligned}$$

Đầu ra của Bộ trích xuất đồ thị là một gói biểu diễn mang vector $\mathbf{z}_{\text{graph}} \in \mathbb{R}^{d_{\text{graph}}}$ tóm tắt cấu trúc đồ thị và sự lan truyền thông tin qua lại giữa các thực thể trong cửa sổ trung hạn W_m , đi kèm siêu dữ liệu tương ứng: khoảng thời gian $[t_{\text{start}}, t_{\text{end}}]$, tập thực thể hoạt động $\mathcal{V}_{\text{active}}$, mặt nạ sẵn sàng $m_{\text{graph}} \in \{0,1\}$, và định danh đồ thị con. Về mặt khung đa tỷ lệ, cửa sổ dài hạn W_L đã thiết lập tại Mục 2.2.3.2 đóng vai trò cung cấp ngữ cảnh trạng thái dài hạn có chặn (Bounded Long-term Context Summary) cho hệ thống mà không làm phát sinh bộ trích xuất thứ

ba độc lập. Chi phí tính toán của nhánh đồ thị được phân lập giữa chi phí xây dựng cửa sổ và chi phí xử lý gia số theo từng sự kiện: xây dựng đồ thị $\mathcal{C}_{\text{build}} = \mathcal{O}(\text{card}(\mathcal{E}_W))$, tạo thông điệp $\mathcal{C}_{\text{msg}} = \mathcal{O}(\text{card}(\mathcal{E}_W) \cdot (d_{\text{GNN}} \cdot d_{\text{msg}} + d_{\text{attr}}))$, cập nhật trạng thái bộ nhớ với tập đỉnh nhận thông điệp $\mathcal{V}_{\text{upd}}(t) \subseteq \mathcal{V}_t$ là $\mathcal{C}_{\text{update}} = \mathcal{O}(\text{card}(\mathcal{V}_{\text{upd}}) \cdot d_{\text{GNN}}^2)$, và tổng hợp đầu ra $\mathcal{C}_{\text{readout}} = \mathcal{O}(\text{card}(\mathcal{V}_{\text{active}}) \cdot d_{\text{GNN}} + d_{\text{GNN}} \cdot d_{\text{graph}})$.



Hình 2.3: Kiến trúc xây dựng đồ thị nguồn gốc phụ thuộc thời gian và Bộ trích xuất Temporal GNN, nguồn tác giả đề xuất

Bảng 2.2: Đặc tả kiến trúc và độ phức tạp tính toán của hai bộ trích xuất đặc trưng đa góc nhìn

Thành phần trích xuất	Góc nhìn biểu diễn	Cấu trúc đầu vào	Mục tiêu biểu diễn	Độ phức tạp tính toán
Bộ trích xuất tuần tự (Transformer)	Tuần tự ngữ nghĩa	Cửa sổ ngắn W_s (L sự kiện)	Tự giám sát (MEP, MPP, Time Gap)	$\mathcal{O}(N_{\text{layers}} \cdot (L^2 \cdot d + L \cdot d \cdot d_{\text{ff}}))$
Xây dựng đồ thị nguồn gốc	Cấu trúc phụ thuộc	Luồng sự kiện $\tilde{e}_i^{\text{priv}}$	Độ chân thực đồ thị (Fidelity candidates)	$\mathcal{O}(\text{card}(\mathcal{E}_W))$
Bộ trích xuất đồ thị (Temporal GNN)	Đồ thị động	Đồ thị dị thể $\mathcal{G}_t$	Tự giám sát động (L_{graph})	$\mathcal{O}(\text{card}(\mathcal{E}_W) \cdot d + \text{card}(\mathcal{V}_{\text{upd}}) \cdot d^2)$

Thành phần trích xuất	Góc nhìn biểu diễn	Cấu trúc đầu vào	Mục tiêu biểu diễn	Độ phức tạp tính toán
Giao diện biểu diễn đầu ra	Không gian ẩn đa góc nhìn	Vector z_{seq} & z_{graph}	Đầu vào cho tầng giống hàng (Mục 2.4)	$\mathcal{O}(d_{\text{seq}} + d_{\text{graph}})$

2.4. Giống hàng và học biểu diễn thống nhất đa góc nhìn

Sau khi hai bộ trích xuất độc lập tại Mục 2.3 sản sinh hai vector đặc trưng ẩn $z_{\text{seq}} \in \mathbb{R}^{d_{\text{seq}}}$, nắm bắt thứ tự vi mô, tham số an ninh và nhịp điệu thời gian trên cửa sổ ngắn hạn W_s , và $z_{\text{graph}} \in \mathbb{R}^{d_{\text{graph}}}$, nắm bắt cấu trúc phụ thuộc quan sát được, luồng truyền lan thông tin và quan hệ phụ thuộc cấu trúc, thời gian trên cửa sổ trung hạn W_m , thách thức khoa học trung tâm là làm thế nào để dung hợp và giống hàng hai nguồn thông tin dị thể này thành một vector biểu diễn thống nhất canonical $z_{\text{mv}} \in \mathbb{R}^{d_{\text{mv}}}$. Tầng giống hàng đa góc nhìn xây dựng cơ chế phương pháp luận giải quyết câu hỏi nghiên cứu RQ2 và RQ4, thiết lập nền tảng kỹ thuật nhằm phục vụ kiểm định giả thuyết H2 và H4 tại Chương 3. Để đạt được mục tiêu này, chuyên đề thiết lập một quy trình tối ưu hóa đa tầng chặt chẽ: thứ nhất, thiết lập không gian ngữ nghĩa chung mà không gây sụp đổ biểu diễn; thứ hai, bảo toàn đối xứng thông tin đặc thù nội góc nhìn; thứ ba, kiểm soát nhiễu đặc quyền và hành vi quản trị viên thông qua ngữ cảnh hóa đa chiều; thứ tư, cung cấp cơ chế phân bổ bằng chứng yếu qua mô hình học đa thể hiện MIL tùy chọn; và thứ năm, thích ứng linh hoạt với hiện tượng khuyết góc nhìn trong môi trường phân tán mà không vi phạm nguyên tắc nhân quả thời gian.

2.4.1. Giống hàng đa góc nhìn dị thể

Mục 2.4.1 thiết lập Hợp đồng Tương ứng, phân định ranh giới giữa Không gian Biểu diễn và Không gian Chiếu, cùng các cơ chế điều hòa chống sụp đổ biểu diễn.

2.4.1.1. Hợp đồng tương ứng ngữ cảnh và siêu dữ liệu liên kết

Một cặp biểu diễn đa góc nhìn ($z_{\text{seq}}, z_{\text{graph}}$) được xem là một cặp tương ứng hợp lệ nếu và chỉ nếu chúng thỏa mãn Hợp đồng Tương ứng dựa trên bộ siêu dữ liệu liên kết $\mathcal{M} = \langle [t_{\text{start}}, t_{\text{end}}], \mathcal{E}_{\text{scope}}, m_{\text{seq}}, m_{\text{graph}} \rangle$ đã thiết lập tại Mục 2.3:

- Giao thoa khoảng thời gian quan sát Temporal Interval Overlap: Khoảng thời gian hiệu lực của cửa sổ chuỗi ngắn hạn $[t_{\text{start}}^{\text{seq}}, t_{\text{end}}^{\text{seq}}]$ phải là tập con hoặc có giao thoa thực dương với khoảng thời gian của cửa sổ đồ thị trung hạn $[t_{\text{start}}^{\text{graph}}, t_{\text{end}}^{\text{graph}}]$, tức $[t_{\text{start}}^{\text{seq}}, t_{\text{end}}^{\text{seq}}] \cap [t_{\text{start}}^{\text{graph}}, t_{\text{end}}^{\text{graph}}] \neq \emptyset$.
- Giao thoa phạm vi thực thể Entity Scope Overlap: Tập các thực thể hệ thống quan sát trong chuỗi $\mathcal{E}_{\text{scope}}^{\text{seq}}$ như tiến trình, người dùng và tài nguyên phải chia sẻ ít nhất một đỉnh thực thể chung với tập đỉnh đồ thị $\mathcal{E}_{\text{scope}}^{\text{graph}} = \mathcal{V}_{\text{active}}(W_m)$, tức $\mathcal{E}_{\text{scope}}^{\text{seq}} \cap \mathcal{E}_{\text{scope}}^{\text{graph}} \neq \emptyset$.
- Tính đầy đủ của mặt nạ khả dụng Availability Mask Completeness: Cả hai góc nhìn đều tồn tại dữ liệu đo kiểm thực tế trong khoảng quan sát, biểu thị bởi $m_{\text{seq}} = 1$ và $m_{\text{graph}} = 1$.

Tuyệt đối không sử dụng nhãn tấn công hay bất kỳ tín hiệu từ tập kiểm thử nào để định nghĩa cặp tương ứng trong Stage A. Các cặp tương ứng được hình thành hoàn toàn tự nhiên từ tiến trình vận hành hệ thống thực tế. Các trường hợp chỉ giao thoa một phần thực thể hoặc thời gian được xếp vào nhóm Tương ứng Cục bộ, trong khi các trường hợp thiếu hụt một trong hai nguồn được xử lý qua cơ chế Góc nhìn Khuyết.

2.4.1.2. Phân tách không gian biểu diễn và không gian chiếu

Tránh hiện tượng mất mát thông tin cấu trúc đặc thù khi ép hai vector biểu diễn gốc z_{seq} và z_{graph} phải hội tụ về cùng một điểm, chuyên đề áp dụng nguyên lý phân tách không gian theo SimCLR [21] và VICReg [12]. Chúng ta đưa mỗi vector biểu diễn qua một đầu chiếu phi tuyến riêng biệt (Non-linear Projection Heads):

$$p_{\text{seq}} = g_{\text{seq}}(z_{\text{seq}}) = W_{p2} \cdot \text{GELU}(\text{LayerNorm}(W_{p1} z_{\text{seq}})) \in \mathbb{R}^{d_{\text{proj}}}$$

$$p_{\text{graph}} = g_{\text{graph}}(z_{\text{graph}}) = W_{g2} \cdot \text{GELU}(\text{LayerNorm}(W_{g1} z_{\text{graph}})) \in \mathbb{R}^{d_{\text{proj}}}$$

Trong đó g_{seq} và g_{graph} là các mạng MLP hai tầng có chuẩn hóa LayerNorm và hàm kích hoạt phi tuyến GELU; d_{proj} là số chiều của Không gian Chiếu. Việc phân tách này thiết lập một ranh giới phương pháp luận nghiêm ngặt: Không gian Chiếu $\mathbb{R}^{d_{\text{proj}}}$ chỉ phục vụ việc tính toán các hàm mất mát giống hàng tự giám sát và sẽ bị loại bỏ sau khi kết thúc Stage A; trong khi Không gian Biểu diễn $\mathbb{R}^{d_{\text{seq}}}$, $\mathbb{R}^{d_{\text{graph}}}$ và không gian biểu diễn thống nhất $\mathbb{R}^{d_{\text{mv}}}$ được bảo toàn nguyên vẹn để cung cấp đặc trưng cho các tác vụ hạ nguồn ở Stage C.

2.4.1.3. Phân tích đối sánh các cơ chế tự giám sát đa góc nhìn

Trong học biểu diễn tự giám sát, ba hướng tiếp cận tiêu biểu bao gồm: InfoNCE / Contrastive Learning [41], [21], Barlow Twins [13], và VICReg [12]. Bảng 2.3 phân tích đối sánh chi tiết các đặc tính lý thuyết từ các công bố gốc và các giả thuyết nghiên cứu của chuyên đề đối với dữ liệu telemetry an ninh:

Bảng 2.3: So sánh đối sánh các cơ chế tự giám sát đa góc nhìn trong bài toán an ninh mạng

Tiêu chí phương pháp luận	InfoNCE / Contrastive	Barlow Twins	VICReg (Ứng viên đề xuất)
Cơ chế điều hòa chống sụp đổ	Sử dụng phân bố mẫu âm (Negative pairs) để đẩy xa các phiên khác nhau [41], [21]	Ép ma trận tương quan chéo giữa hai view về ma trận đơn vị I [13]	Phân tách độc lập: Duy trì phương sai từng chiều + Phạt hiệp phương sai [12]
Yêu cầu mẫu âm (Negative pairs)	Bắt buộc (phụ thuộc vào cơ chế lấy mẫu âm trong batch)	Không yêu cầu mẫu âm tường minh	Không yêu cầu mẫu âm tường minh
Đặc tính phân tích trên telemetry	Rủi ro False Negatives tiềm tàng khi phạt các phiên bình thường độc lập có hành vi tương đồng (Phân tích lý thuyết phương pháp luận)	Độ ổn định phụ thuộc vào việc ước lượng tương quan chéo; rủi ro nhạy cảm thang đo chuỗi và đồ thị (Phân tích lý thuyết phương pháp luận)	Điều hòa độc lập phương sai và hiệp phương sai; kỳ vọng duy trì cấu trúc phân phối telemetry an ninh (Phân tích lý thuyết phương pháp luận)

Tiêu chí phương pháp luận	InfoNCE / Contrastive	Barlow Twins	VICReg (Ứng viên đề xuất)
Đặc tính phụ thuộc kích thước lô	Hiệu năng thường hưởng lợi khi kích thước lô đủ lớn để bao quát phân bố mẫu âm	Độ ổn định phụ thuộc vào việc ước lượng ma trận tương quan chéo trên batch	Ước lượng phương sai và hiệp phương sai trực tiếp trên phân bố lô huấn luyện
Vai trò trong đề tài	Cơ chế đối sánh lý thuyết (Theoretical baseline)	Cơ chế đối sánh lý thuyết (Theoretical baseline)	Khung hàm mất mát tự giám sát chính thức trong thiết kế kiến trúc

Từ phân tích phương pháp luận trên, chuyên đề lựa chọn VICReg (Variance-Invariance-Covariance Regularization) [12] làm ứng viên giống hàng cốt lõi. Theo Bardes et al. [12], VICReg thiết lập cơ chế tự giám sát không tương phản dựa trên điều hòa phương sai và hiệp phương sai để ngăn ngừa sụp đổ biểu diễn mà không cần khai thác các cặp mẫu âm. Dựa trên đặc tính lý thuyết này của công bố gốc, nghiên cứu đề xuất giả thuyết thích nghi (Author Adaptation Hypothesis): việc loại bỏ nhu cầu lấy mẫu âm tường minh trong không gian telemetry log sẽ giúp giảm thiểu rủi ro âm tính giả, hạn chế việc ép các phiên telemetry bình thường độc lập nhưng có đặc trưng tương đồng ra xa nhau một cách nhân tạo. Giả thuyết này được đề xuất làm cơ sở kiến trúc cho khung giống hàng đa góc nhìn, trong khi việc đối sánh triệt tiêu định lượng với InfoNCE [38], [37] và Barlow Twins [11] được định vị cho các chiến dịch thực nghiệm hạ nguồn tiếp theo. [41] [21] [13]

2.4.1.4. Hàm mục tiêu giống hàng VICReg trên không gian chiếu

Hàm mục tiêu giống hàng VICReg trên một lô huấn luyện kích thước B gồm các cặp chiếu hợp lệ $\{(p_{seq}^{(i)}, p_{graph}^{(i)})\}_{i=1}^B$ được phân rã thành ba thành phần điều hòa tường minh:

- Số hạng Bất biến (Invariance Term, $\mathcal{L}_{inv}$): Đo lường khoảng cách sai số toàn phương trung bình giữa hai góc nhìn biểu diễn của cùng một thực thể hoặc khoảng thời gian:

$$\mathcal{L}_{inv}(\mathbf{P}_{seq}, \mathbf{P}_{graph}) = \frac{1}{B} \sum_{i=1}^B \|\mathbf{p}_{seq}^{(i)} - \mathbf{p}_{graph}^{(i)}\|_2^2$$

- Số hạng Phương sai (Variance Regularization, $\mathcal{L}_{var}$): Sử dụng hàm bản lề để duy trì độ lệch chuẩn của từng chiều đặc trưng trên toàn bộ lô huấn luyện lớn hơn một ngưỡng tối thiểu $\gamma > 0$ (giá trị khởi tạo tham chiếu $\gamma = 1$, được tối ưu hóa trên tập xác thực), kiểm soát nguy cơ sụp đổ điểm (Point Collapse):

$$\mathcal{L}_{var}(\mathbf{P}) = \frac{1}{d_{proj}} \sum_{j=1}^{d_{proj}} \max\left(0, \gamma - \sqrt{\text{Var}(\mathbf{p}_{:,j})} + \epsilon\right)$$

Trong đó công thức phương sai mẫu từng chiều đặc trưng $\text{Var}(\mathbf{p}_{:,j})$ và hằng số ổn định số học $\epsilon = 10^{-4}$ được xác định tường minh:

$$\text{Var}(\mathbf{p}_{:,j}) = \frac{1}{B-1} \sum_{i=1}^B (p_{i,j} - \bar{p}_j)^2$$

- Số hạng Hiệp phương sai (Covariance Regularization, $\mathcal{L}_{cov}$): Phạt tổng bình phương các phần tử nằm ngoài đường chéo chính của ma trận hiệp phương sai $\mathbf{C}(\mathbf{P}) \in \mathbb{R}^{d_{proj} \times d_{proj}}$, điều hòa các chiều đặc trưng theo hướng giảm tương quan tuyến tính giữa các chiều và giảm tính dư thừa thông tin (Redundancy Reduction), hạn chế hiện tượng sụp đổ số chiều (Dimensional Collapse):

$$\mathbf{C}(\mathbf{P}) = \frac{1}{B-1} \sum_{i=1}^B (\mathbf{p}^{(i)} - \bar{\mathbf{p}})(\mathbf{p}^{(i)} - \bar{\mathbf{p}})^T$$

$$\mathbf{C}_{off}(\mathbf{P}) = \mathbf{C}(\mathbf{P}) - \text{Diag}\left(\text{diag}(\mathbf{C}(\mathbf{P}))\right)$$

$$\mathcal{L}_{cov}(\mathbf{P}) = \left(\frac{1}{d_{proj}}\right) \|\mathbf{C}_{off}(\mathbf{P})\|_F^2$$

Trong đó $\mathbf{C}_{off}(\mathbf{P})$ là ma trận hiệp phương sai $\mathbf{C}(\mathbf{P})$ sau khi đặt toàn bộ phần tử đường chéo chính bằng 0.

2.4.1.5. Cơ chế thích ứng góc nhìn khuyết và tương ứng từng phần

Trong thực tế giám sát an ninh phân tán, các cảm biến thu thập telemetry có thể gặp sự cố cục bộ, gây ra hiện tượng khuyết góc nhìn (Missing-View,

Incomplete Telemetry). Chuyên đề xử lý vấn đề này theo khung tiếp cận của CPM-Nets [42] kết hợp cơ chế mặt nạ khả dụng và suy thoái duyên dáng do chuyên đề đề xuất:

- Trường hợp đầy đủ hai góc nhìn ($m_{\text{seq}} = 1, m_{\text{graph}} = 1$): Hệ thống kích hoạt toàn bộ luồng huấn luyện giống hàng và dung hợp đa góc nhìn.
- Trường hợp chỉ có chuỗi sự kiện ($m_{\text{seq}} = 1, m_{\text{graph}} = 0$): Vô hiệu hóa số hạng $\mathcal{L}_{\text{inv}}$ và các thành phần liên quan đến đồ thị; biểu diễn thống nhất tự động suy thoái duyên dáng về nhánh chuỗi thông qua phép chiếu thích ứng: $z_{\text{mv}} = f_{\text{adapt}}^{\text{seq}}(z_{\text{seq}}) = \text{LayerNorm}(W_{\text{out}}^{\text{seq}} z_{\text{seq}})$.
- Trường hợp chỉ có đồ thị nguồn gốc ($m_{\text{seq}} = 0, m_{\text{graph}} = 1$): Tương tự, hệ thống vô hiệu hóa $\mathcal{L}_{\text{inv}}$ và chuyển hướng biểu diễn thống nhất về nhánh đồ thị: $z_{\text{mv}} = f_{\text{adapt}}^{\text{graph}}(z_{\text{graph}}) = \text{LayerNorm}(W_{\text{out}}^{\text{graph}} z_{\text{graph}})$.
- Trường hợp tương ứng cục bộ: Khi hai góc nhìn chỉ giao nhau một phần về thời gian hoặc thực thể, hệ thống tính toán hệ số giao thoa Jaccard $0 < \rho_{\text{overlap}} \leq 1$ và điều tiết trọng số giống hàng tương thích: $\mathcal{L}_{\text{inv}}^{\text{partial}} = \rho_{\text{overlap}} \cdot \mathcal{L}_{\text{inv}}$.

Nguyên tắc bất biến: Hệ thống tuyệt đối không tự bịa đặt dữ liệu (Data Hallucination) cho góc nhìn bị thiếu, không sử dụng dữ liệu tương lai để nội suy và không sử dụng nhãn tấn công để bù đắp, tuân thủ nguyên tắc nhân quả thời gian của mặt phẳng suy luận dòng.

Lưu ý phương pháp luận về tính nhân quả: Khái niệm “Strictly Causal / Zero Lookahead” được định nghĩa chính xác theo nghĩa: hệ thống chỉ sử dụng dữ liệu đo kiểm trong quá khứ và ở thời điểm hiện tại khi suy luận dòng, tuyệt đối không sử dụng thông tin tương lai hay nhãn kiểm thử; khái niệm này KHÔNG hàm ý suy diễn quan hệ nhân quả (Causal-effect Inference) theo nghĩa thống kê can thiệp. Trong an ninh mạng, sự phụ thuộc quan sát được không đồng nhất với tác động nhân quả.

2.4.2. Nhận thức hành vi quản trị viên và điều hòa rủi ro

Một yếu tố gây nhiễu quan trọng trong giám sát an ninh là sự chồng lấn giữa hoạt động quản trị hợp thức và hành vi tấn công. Mục 2.4.2 thiết lập khung phương pháp luận nhận thức hành vi quản trị (Risk-aware Administrative Behavior) và các cơ chế kiểm soát nhiễu đặc quyền (Admin-Noise Controls, Đề xuất của đề tài / Ours) nhằm giải quyết trực tiếp câu hỏi nghiên cứu RQ4.

2.4.2.1. Nguyên tắc bất biến: Bất thường không đồng nhất với Độc hại

Trong môi trường vận hành công nghệ thông tin thực tế, các hoạt động quản trị viên (System Administration), ví dụ như cài đặt bản vá hàng loạt, sao lưu cơ sở dữ liệu định kỳ, bảo trì từ xa thông qua PowerShell, SSH, WMI, PsExec hay các kịch bản script tự động hóa phức tạp, thường xuyên tạo ra các chuỗi sự kiện có tần suất cao đột biến, quyền hạn cao Privileged Execution và cấu trúc lệnh khác lạ so với người dùng thông thường. Tuy nhiên, các hoạt động này hoàn toàn hợp thức. Chuyên đề xác lập nguyên tắc khoa học cốt lõi: Hành vi bất thường không đồng nhất với hành vi độc hại (Unusual $\neq$ Malicious).

Bộ trích xuất đa góc nhìn không đóng vai trò bộ phân loại dựa trên luật (Rule-based Detector) để gán nhãn cứng hoạt động quản trị là an toàn hay độc hại. Thay vào đó, bộ trích xuất có nhiệm vụ mã hóa toàn diện các đặc trưng ngữ cảnh quan sát được vào không gian vector biểu diễn liên tục z_{mv} dựa trên 4 chiều thông tin an ninh:

- Ngữ cảnh đặc quyền (Privilege Context): Định lượng mức độ leo thang và phân cấp đặc quyền hệ thống theo thang đo liên tục, phản ánh đúng quyền hạn thực thi tại thời điểm quan sát mà không xem quyền hạn cao mặc định là mối đe dọa.
- Ngữ cảnh công cụ và tham số (Tool & Parameter Structure): Biểu diễn cấu trúc cú pháp câu lệnh, tham số thực thi động và trạng thái chữ ký số (Signed/Unsigned State nếu quan sát được), phản ánh trung thực bản chất công cụ thực thi vào không gian vector.

- Ngữ cảnh thời gian và chu kỳ (Temporal & Cadence Regularity): Mô hình hóa tính chu kỳ của các tác vụ tự động (Cronjobs, Scheduled Tasks, Maintenance Windows) thông qua hàm phân phối nhịp điệu thời gian Δt , mã hóa các hoạt động định kỳ theo lịch trình và các hành vi tương tác thủ công vào biểu diễn thời gian.
- Ngữ cảnh lan truyền thực thể (Entity Footprint & Neighborhood Breadth): Biểu diễn luồng kết nối quản trị diện rộng và cấu trúc phân nhánh lân cận của đồ thị nguồn gốc trung hạn, tạo cơ sở cho các mô hình hạ nguồn phân biệt hành vi quản trị thông thường với các chuỗi lây lan ngang .

Toàn bộ các đặc trưng trên chỉ được mã hóa vào vector biểu diễn. Việc đưa ra quyết định độc hại hay an toàn (Malicious-vs-Benign Decision) được bàn giao hoàn toàn cho các mô hình đánh giá hạ nguồn ở Stage C và các kịch bản thực nghiệm đánh giá hạ nguồn.

2.4.2.2. Kiểm soát biên gây nhiễu và ngăn chặn học đường tắt

Nhằm hạn chế rủi ro trôi dạt và tăng tính ổn định cho không gian vector biểu diễn, chuyên đề thiết lập các cơ chế kiểm soát biên gây nhiễu :

- Cấm học đường tắt định danh (No Identity / Role Shortcuts): Hệ thống tuyệt đối không sử dụng tên người dùng thô hoặc chuỗi ký tự chức danh làm đặc trưng đầu vào trực tiếp. Mọi định danh thực thể đều được chuẩn hóa và bảo vệ qua cơ chế Kiểm soát Liên kết Danh tính (Controlled Linkability, Mục 2.2.2), ngăn chặn mô hình học mối liên hệ giả tạo rằng “tài khoản Admin luôn an toàn” hoặc “tài khoản Guest luôn đáng ngờ”.
- Cấm rò rỉ nhân kiểm thử và đặc quyền giám sát (No Privileged Test Knowledge): Trong toàn bộ quá trình tiền xử lý và huấn luyện tự giám sát, hệ thống tuyệt đối không sử dụng bất kỳ thông tin nào về nhân tấn công tương lai hay danh sách phân loại tĩnh từ tập kiểm thử, ngăn rò rỉ thông tin kiểm thử qua các kênh đã định nghĩa .

2.4.3. *Hàm mục tiêu thống nhất và phân bổ bằng chứng yếu*

Mục 2.4.3 tổng hợp toàn bộ đồ thị tối ưu hóa của chuyên đề, thiết lập hàm mục tiêu tự giám sát thống nhất trong Stage A, đóng kín các luồng gradient cho toàn bộ tập tham số, và tích hợp mô đun Phân bổ Bằng chứng Yếu qua mô hình học đa thể hiện (MIL) tùy chọn trong Stage B.

2.4.3.1. **Đóng kín đồ thị tối ưu hóa và kiểm toán tham số huấn luyện**

Theo nguyên tắc kiểm toán tham số có gradient (Zero Orphan Parameters), Bảng 2.4 tổng hợp toàn bộ tập tham số huấn luyện của hệ thống, xác định rõ giai đoạn huấn luyện, hàm mục tiêu sinh gradient, thời điểm đóng băng và vai trò khi suy luận trực tuyến:

Bảng 2.4: Kiểm toán toàn diện các khối tham số và đồ thị tối ưu hóa trong hệ thống

Khối tham số	Giai đoạn	Hàm mục tiêu sinh Gradient	Thời điểm đồng băng / Vòng đời	Dùng khi suy luận?
θ_{seq} (Transformer Encoder)	Stage A1 (Chuỗi)	$\mathcal{L}_{\text{seq}}^{\text{self}} = \alpha_1 \mathcal{L}_{\text{MEP}} + \alpha_2 \mathcal{L}_{\text{MPP}} + \alpha_3 \mathcal{L}_{\text{time}}$	Đồng băng sau A1; Tinh chỉnh ở A2	CÓ (Trích $\mathbf{Z}_{\text{seq}}$)
$\phi_{\text{seq}}^{\text{event}}, \phi_{\text{seq}}^{\text{param}}, \phi_{\text{seq}}^{\text{time}}$	Stage A1 (Chuỗi)	$\mathcal{L}_{\text{MEP}}, \mathcal{L}_{\text{MPP}}, \mathcal{L}_{\text{time}}$	Duy trì ở A2 cho $\mathcal{L}_{\text{preserv}}$; Hủy sau A2	KHÔNG (Ngắt bỏ)
θ_{graph} (Temporal GNN)	Stage A1 (Đồ thị)	$\mathcal{L}_{\text{graph}}^{\text{self}} = \beta_1 \mathcal{L}_{\text{mask-node}} + \beta_2 \mathcal{L}_{\text{mask-edge}} + \beta_3 \mathcal{L}_{\text{time-gap}}$	Đồng băng sau A1; Tinh chỉnh ở A2	CÓ (Trích $\mathbf{Z}_{\text{graph}}$)
$\phi_{\text{graph}}^{\text{node}}, \phi_{\text{graph}}^{\text{edge}}, \phi_{\text{graph}}^{\text{time}}$	Stage A1 (Đồ thị)	$\mathcal{L}_{\text{mask-node}}, \mathcal{L}_{\text{mask-edge}}, \mathcal{L}_{\text{time-gap}}$	Duy trì ở A2 cho $\mathcal{L}_{\text{preserv}}$; Hủy sau A2	KHÔNG (Ngắt bỏ)
$\mathcal{G}_{\text{seq}}, \mathcal{G}_{\text{graph}}$ (Projection Heads)	Stage A2 (Giống hàng)	$\mathcal{L}_{\text{align}} = \mathcal{L}_{\text{VICReg}}(P_{\text{seq}}, P_{\text{graph}})$	Đồng băng & Hủy sau Stage A2	KHÔNG (Ngắt bỏ)
w_r, b_r, w_g, b_g (Gating Weights)	Stage A2 (Dung hợp)	$\mathcal{L}_{\text{fuse-rec}}$ (Tái tạo tự giám sát)	Đồng băng sau Stage A2	CÓ (Tính $\mathbf{W}_{\text{rel}}$)
$P_{\text{fuse}}^{\text{seq}}, P_{\text{fuse}}^{\text{graph}}$ (Cross Proj)	Stage A2 (Dung hợp)	$\mathcal{L}_{\text{fuse-rec}}$ (Tái tạo tự giám sát)	Đồng băng sau Stage A2	CÓ (Chiều $\mathbb{R}^{d_{\text{cross}}}$)
$W_{\text{out}}^{\text{seq}}, W_{\text{out}}^{\text{graph}}, W_{\text{out}}^{\text{cross}}$	Stage A2 (Dung hợp)	$\mathcal{L}_{\text{fuse-rec}}$ (Tái tạo tự giám sát)	Đồng băng sau Stage A2	CÓ (Gộp $\mathbf{Z}_{\text{mv}}$)
$D_{\text{seq}}, D_{\text{graph}}$ (Linear Decoders)	Stage A2 (Dung hợp)	$\mathcal{L}_{\text{fuse-rec}}$ (Tái tạo tự giám sát)	Đồng băng & Hủy sau Stage A2	KHÔNG (Ngắt bỏ)
$w_{\text{mil}}, V_{\text{mil}}, U_{\text{mil}}, W_{\text{mil}}^{\text{cls}}, b_{\text{mil}}^{\text{cls}}$	Stage B (Tùy chọn)	$\mathcal{L}_{\text{MIL}}$ (Coarse Bag BCE)	Đồng băng sau Stage B (chỉ bản mở rộng)	TÙY CHỌN (Bản MIL)

2.4.3.2. Hàm mục tiêu tự giám sát thống nhất Stage A và Bảo toàn Đối xứng

Trong Stage A, chuyên đề áp dụng chiến lược Bảo toàn Đối xứng kết hợp hàm mất mát tái tạo dung hợp tự giám sát (Self-Supervised Fusion Reconstruction). Hàm mất mát bảo toàn đối xứng duy trì năng lực biểu diễn nội góc nhìn cho cả chuỗi và đồ thị thông qua việc tái sử dụng các mục tiêu tự giám sát nội tại:

$$\mathcal{L}_{\text{preserv}} = \mathcal{L}_{\text{seq}}^{\text{self}}(\mathbf{z}_{\text{seq}}) + \mathcal{L}_{\text{graph}}^{\text{self}}(\mathbf{z}_{\text{graph}})$$

Vòng đời và vai trò của các đầu dự đoán phụ trợ Auxiliary SSL Heads Lifecycle: Trong Stage A1, các đầu phụ trợ $\phi_{\text{seq}}^{\text{event}}, \phi_{\text{seq}}^{\text{param}}, \phi_{\text{seq}}^{\text{time}}$ và $\phi_{\text{graph}}^{\text{node}}, \phi_{\text{graph}}^{\text{edge}}, \phi_{\text{graph}}^{\text{time}}$ được tối ưu hóa đồng thời cùng backbone tương ứng. Trong Stage A2, để tính toán hàm mất mát bảo toàn đối xứng $\mathcal{L}_{\text{preserv}} = \mathcal{L}_{\text{seq}}^{\text{self}} + \mathcal{L}_{\text{graph}}^{\text{self}}$ được thiết kế nhằm hạn chế nguy cơ trôi dạt biểu diễn và quên thảm họa trong khi giống hàng đa góc nhìn với việc đánh giá định lượng hiệu quả thực tế được định vị cho các giai đoạn hạ nguồn, các đầu phụ trợ này tiếp tục được duy trì để cung cấp gradient điều hòa. Ngay sau khi Stage A2 kết thúc, toàn bộ các đầu phụ trợ này cùng 2 đầu chiếu phi tuyến $g_{\text{seq}}, g_{\text{graph}}$ và 2 bộ giải mã tái tạo $D_{\text{seq}}, D_{\text{graph}}$ đều bị ngắt bỏ; các projection và prediction heads chỉ phục vụ huấn luyện tự giám sát và không được nạp trong Stage C. Tại thời điểm suy luận dòng, chỉ các backbone $\theta_{\text{seq}}, \theta_{\text{graph}}$ và các ma trận dung hợp chuẩn tắc được nạp để tính toán vector $\mathbf{z}_{\text{mv}}$; nhờ đó, số thành phần mô hình phải duy trì khi suy luận được giảm đáng kể so với đồ thị huấn luyện đầy đủ mà không để lại tham số mồ côi, tuân thủ nguyên tắc Zero Orphan Parameters.

Cung cấp tín hiệu học trực tiếp cho các ma trận dung hợp $P_{\text{fuse}}^{\dots}, W_{\text{out}}^{\dots}$, vector trọng số gating w_r, w_g và các ma trận giải mã tuyến tính $D_{\text{seq}} \in \mathbb{R}^{d_{\text{seq}} \times d_{\text{mv}}}, D_{\text{graph}} \in \mathbb{R}^{d_{\text{graph}} \times d_{\text{mv}}}$, chuyên đề thiết lập hàm mất mát tái tạo đa góc nhìn tự giám sát $\mathcal{L}_{\text{fuse-rec}}$:

$$\begin{aligned} \mathcal{L}_{\text{fuse-rec}} = & \left\| \mathbf{D}_{\text{seq}} \mathbf{z}_{\text{mv}} - \text{stopgrad}(\mathbf{z}_{\text{seq}}) \right\|_2^2 \\ & + \left\| \mathbf{D}_{\text{graph}} \mathbf{z}_{\text{mv}} - \text{stopgrad}(\mathbf{z}_{\text{graph}}) \right\|_2^2 \end{aligned}$$

Định tuyến luồng gradient: Để ngăn chặn hiện tượng co-adaptation không kiểm soát khiến vector đích tự trôi dạt, chuyên đề thiết lập toán tử chặn gradient tường minh $\mathbf{z}_{\text{seq}}^{\text{target}} = \text{stopgrad}(\mathbf{z}_{\text{seq}})$ và $\mathbf{z}_{\text{graph}}^{\text{target}} = \text{stopgrad}(\mathbf{z}_{\text{graph}})$. Khi lan truyền, chiều xuôi vẫn tính vector đích cho $\mathcal{L}_{\text{fuse-rec}}$, còn chiều ngược áp đặt triệt tiêu đạo hàm riêng $\left. \frac{\partial \mathcal{L}_{\text{fuse-rec}}}{\partial \theta_{\text{seq}}} \right|_{\text{target}} = \left. \frac{\partial \mathcal{L}_{\text{fuse-rec}}}{\partial \theta_{\text{graph}}} \right|_{\text{target}} = 0$. Do đó, $\mathcal{L}_{\text{fuse-rec}}$ chỉ truyền gradient cập nhật các tham số dung hợp và giải mã

$(w_r, b_r, w_g, b_g, P_{\text{fuse}}, W_{\text{out}}, D_{\text{seq}}, D_{\text{graph}})$, hoàn toàn không cập nhật ngược về θ_{seq} , θ_{graph} . Hai backbone chỉ nhận gradient duy nhất từ $\mathcal{L}_{\text{align}}$ và $\mathcal{L}_{\text{preserv}}$; ràng buộc kiến trúc này định hướng tối ưu hóa cục bộ chứ không bảo chứng chất lượng downstream tối ưu.

Hàm mục tiêu tối ưu hóa thống nhất toàn bộ Stage A được xác lập:

$$\begin{aligned} \mathcal{L}_{\text{Stage-A}} = & \lambda_{\text{inv}} \mathcal{L}_{\text{inv}} + \lambda_{\text{var}} \left(\mathcal{L}_{\text{var}}(\mathbf{P}_{\text{seq}}) + \mathcal{L}_{\text{var}}(\mathbf{P}_{\text{graph}}) \right) \\ & + \lambda_{\text{cov}} \left(\mathcal{L}_{\text{cov}}(\mathbf{P}_{\text{seq}}) + \mathcal{L}_{\text{cov}}(\mathbf{P}_{\text{graph}}) \right) + \lambda_{\text{spec}} \mathcal{L}_{\text{preserv}} \\ & + \lambda_{\text{rec}} \mathcal{L}_{\text{fuse-rec}} \end{aligned}$$

Các hệ số siêu tham số $\lambda_{\text{inv}}, \lambda_{\text{var}}, \lambda_{\text{cov}}, \lambda_{\text{spec}}, \lambda_{\text{rec}}$ là các trọng số điều hòa được thiết lập giá trị khởi tạo tham chiếu $\{25.0, 25.0, 1.0, 1.0, 1.0\}$ và được đề xuất kiểm định độ nhạy thực nghiệm trong các chiến dịch đánh giá mở rộng tiếp theo.

2.4.3.3. Công độ tin cậy động và Phẫu thuật Gradient PCGrad

Đánh giá chất lượng góc nhìn và điều hòa xung đột gradient trong quá trình tối ưu hóa Stage A, hệ thống tích hợp vector chất lượng đo kiểm quan sát được q_{seq} và q_{graph} :

$$\begin{aligned} \mathbf{q}_{\text{seq}} &= [m_{\text{seq}}, \text{Cov}_{\text{event}}, \Delta t_{\text{span}}]^T \in \mathbb{R}^3, \mathbf{q}_{\text{graph}} \\ &= [m_{\text{graph}}, \text{Cov}_{\text{graph}}, \text{Density}_{\text{edge}}]^T \in \mathbb{R}^3 \\ s_{\text{seq}} &= w_r^T [z_{\text{seq}}; \mathbf{q}_{\text{seq}}] + b_r, s_{\text{graph}} = w_g^T [z_{\text{graph}}; \mathbf{q}_{\text{graph}}] + b_g \\ w_{\text{rel}}^{\text{seq}} &= \tau + (1 - 2\tau) \frac{\exp(s_{\text{seq}})}{\exp(s_{\text{seq}}) + \exp(s_{\text{graph}})}, w_{\text{rel}}^{\text{graph}} = 1 - w_{\text{rel}}^{\text{seq}} \end{aligned}$$

Trong đó $\tau = 0.05$ là siêu tham số ngưỡng chặn dưới an toàn, ngăn ngừa việc hạ trọng số về 0 (tính nhạy cảm của được đề xuất khảo sát trong các thực nghiệm hạ nguồn mở rộng) τ . Khi tối ưu hóa liên hợp, chuyên đề đề xuất áp dụng kỹ thuật phẫu thuật gradient PCGrad [43] trên tập tham số nhận đồng thời hai luồng gradient:

$$\Theta_{\text{PCGrad}} = \text{dom}(\nabla \mathcal{L}_{\text{align}}) \cap \text{dom}(\nabla \mathcal{L}_{\text{preserv}})$$

Trong đó $\mathbf{g}_{\text{align}} = \nabla_{\theta_{\text{PCGrad}}} \mathcal{L}_{\text{align}}$ và $\mathbf{g}_{\text{preserv}} = \nabla_{\theta_{\text{PCGrad}}} \mathcal{L}_{\text{preserv}}$. Các gradient từ hàm tái tạo $\mathcal{L}_{\text{fuse-rec}}$ không tham gia vào phép chiếu PCGrad vì chúng chỉ cập nhật độc lập các tham số tầng dung hợp. Khi xảy ra xung đột hướng $\langle \mathbf{g}_{\text{align}}, \mathbf{g}_{\text{preserv}} \rangle < 0$, gradient giống hàng được chiếu vuông góc:

$$\mathbf{g}_{\text{align}} \leftarrow \mathbf{g}_{\text{align}} - \frac{\langle \mathbf{g}_{\text{align}}, \mathbf{g}_{\text{preserv}} \rangle}{\|\mathbf{g}_{\text{preserv}}\|_2^2} \mathbf{g}_{\text{preserv}}$$

Kỹ thuật chiếu trực giao PCGrad giải quyết xung đột hình học cục bộ: tích vô hướng âm $\langle \mathbf{g}_{\text{align}}, \mathbf{g}_{\text{preserv}} \rangle < 0$ phản ánh góc tù ($> 90^\circ$), khiến bước cập nhật theo $\mathbf{g}_{\text{align}}$ ở xấp xỉ Taylor bậc nhất làm tăng $\mathcal{L}_{\text{preserv}}$. Chiếu lên siêu phẳng pháp tuyến triệt tiêu thành phần đối kháng, tạo vector $\mathbf{g}_{\text{align}}^{\text{proj}}$ thỏa mãn $\langle \mathbf{g}_{\text{align}}^{\text{proj}}, \mathbf{g}_{\text{preserv}} \rangle = 0$ nhằm không làm suy giảm $\mathcal{L}_{\text{preserv}}$. Phép chiếu chỉ xử lý xung đột gradient vi mô tức thời (bậc nhất Taylor), không thay thế đồng thuận toàn cục; việc giảm chuyên giao tiêu cực là mục tiêu kiến trúc cần đánh giá hạ nguồn riêng và chưa kiểm chứng tại Chương 3.

2.4.3.4. Stage B tùy chọn: Phân bổ bằng chứng yếu qua Attention-MIL

Trong các kịch bản an ninh thực tế, nhãn tấn công thường chỉ sẵn có ở mức độ thô, ví dụ: một phiên làm việc, một máy chủ, hoặc một cửa sổ chiến dịch kéo dài được xác định là bị xâm nhập (nhãn túi $Y_{\text{bag}} \in \{0,1\}$), nhưng không thể xác định chính xác sự kiện log đơn lẻ nào là hành vi tấn công. Để giải quyết thách thức này, chuyên đề thiết lập mô đun Phân bổ Bằng chứng Yếu tùy chọn ở Stage B dựa trên khung tiếp cận Học Đa Thể Hiện.

Chuyên đề áp dụng cơ chế Attention-based Deep MIL của Ilse et al. [44], nhưng thiết kế cơ chế ánh xạ Túi, Thực thể đặc thù cho bài toán an ninh mạng (Cybersecurity Bag-Instance Mapping, Đề xuất của đề tài / Ours):

- Định nghĩa Túi quan sát ($\text{Bag}, \mathcal{X}_{\text{bag}} = \{z_{\text{mv}}^{(1)}, z_{\text{mv}}^{(2)}, \dots, z_{\text{mv}}^{(K)}\}$): Một túi gồm K vector biểu diễn đa góc nhìn liên tiếp tương ứng với một phiên làm việc hoặc một cửa sổ giám sát của máy chủ.

- Định nghĩa Thực thể thành phần (Instance, $z_{mv}^{(i)}$): Mỗi vector biểu diễn đa góc nhìn tại thời điểm t_i đóng vai trò là một thể hiện bên trong túi.

Cơ chế Gated Attention-MIL với không gian chú ý kích thước d_{att} tính toán trọng số chú ý thích ứng $a_i \in [0,1]$ cho từng thể hiện:

$$a_i = \frac{\exp\left(\mathbf{w}_{mil}^T \left(\tanh\left(\mathbf{V}_{mil}\mathbf{z}_{mv}^{(i)}\right) \odot \sigma\left(\mathbf{U}_{mil}\mathbf{z}_{mv}^{(i)}\right)\right)\right)}{\sum_{j=1}^K \exp\left(\mathbf{w}_{mil}^T \left(\tanh\left(\mathbf{V}_{mil}\mathbf{z}_{mv}^{(j)}\right) \odot \sigma\left(\mathbf{U}_{mil}\mathbf{z}_{mv}^{(j)}\right)\right)\right)}$$

$$\mathbf{z}_{bag} = \sum_{i=1}^K a_i \mathbf{z}_{mv}^{(i)}$$

$$\hat{Y}_{bag} = \sigma(W_{mil_cls}\mathbf{z}_{bag} + b_{mil_cls})$$

$$\mathcal{L}_{MIL} = -Y_{bag} \log(\hat{Y}_{bag}) - (1 - Y_{bag}) \log(1 - \hat{Y}_{bag})$$

Phân định ranh giới giữa Khung trích xuất chuẩn tắc và Đầu phân lớp phụ trợ MIL: Cơ chế Gated Attention-MIL trang bị một đầu phân lớp túi phụ trợ W_{mil_cls}, b_{mil_cls} . Trong quy trình chuẩn hóa của chuyên đề:

- Giai đoạn Stage B: Chỉ sử dụng nhãn thô trên tập Huấn luyện và Xác thực (Train/Validation only) để huấn luyện đầu phân lớp phụ trợ và tùy chọn tinh chỉnh nhẹ không gian vector đặc trưng.
- Giai đoạn Stage C chuẩn tắc: Hệ thống hoàn toàn loại bỏ đầu phân lớp W_{mil_cls}, b_{mil_cls} cùng cấu trúc phân loại túi, đóng băng bộ trích xuất đặc trưng thuần túy để chỉ xuất gói biểu diễn chuẩn tắc $\mathcal{B}_{mv}$ chứa vector canonical $\mathbf{z}_{mv}$ cho các mô hình hạ nguồn độc lập.
- Biên thể tùy chọn hỗ trợ MIL: Nếu kịch bản triển khai thực tế có nhu cầu giám sát trực quan điểm bằng chứng a_i , hệ thống định nghĩa riêng một biến thể hỗ trợ MIL, hoàn toàn phân định với Extractor chuẩn tắc. Việc so sánh thực nghiệm giữa ba cấu hình: SSL thuần túy, SSL kết hợp thích ứng MIL,

và Biến thể hỗ trợ MIL được định vị cho giai đoạn đánh giá hạ nguồn khi bài toán giám sát an ninh yêu cầu trực quan hóa bằng chứng tui.

Ý nghĩa phương pháp luận của trọng số chú ý a_i : Trọng số a_i phản ánh mức độ đóng góp bằng chứng yếu của cửa sổ quan sát thứ i đối với trạng thái bất thường chung của toàn bộ tui. Chuyên đề nhấn mạnh ranh giới khoa học: Trọng số a_i là tín hiệu gợi ý điều tra, TUYỆT ĐỐI KHÔNG PHẢI là xác suất tấn công độc hại và KHÔNG PHẢI là bằng chứng giải thích nhân quả.

2.4.4. *Biểu diễn thống nhất, giao diện đầu ra và độ phức tạp*

Mục 2.4.4 xác lập công thức tổng hợp biểu diễn thống nhất canonical, định nghĩa giao diện chuẩn cho các mô hình hạ nguồn ở Stage C và phân tích chi phí tính toán.

2.4.4.1. **Vector biểu diễn thống nhất canonical z_{mv} và giao diện Extractor**

Kết hợp sức mạnh biểu diễn vi mô từ chuỗi và quan hệ cấu trúc vĩ mô từ đồ thị mà không áp đặt giả định đồng nhất số chiều tùy tiện, chuyên đề thiết lập các ánh xạ tuyến tính chuẩn hóa sang không gian tương tác chung $\mathbb{R}^{d_{cross}}$:

$$u_{seq} = P_{fuse}^{seq} z_{seq} \in \mathbb{R}^{d_{cross}}, u_{graph} = P_{fuse}^{graph} z_{graph} \in \mathbb{R}^{d_{cross}}$$

$$u_{cross} = u_{seq} \odot u_{graph} \in \mathbb{R}^{d_{cross}}$$

Trong đó $P_{fuse}^{seq} \in \mathbb{R}^{d_{cross} \times d_{seq}}$ và $P_{fuse}^{graph} \in \mathbb{R}^{d_{cross} \times d_{graph}}$ là các ma trận chiếu tuyến tính phục vụ dung hợp; ký hiệu $\odot$ biểu thị tích Hadamard trên không gian cùng số chiều $\mathbb{R}^{d_{cross}}$ nhằm nắm bắt tương tác phi tuyến bậc hai giữa hai góc nhìn. Vector biểu diễn thống nhất canonical $z_{mv} \in \mathbb{R}^{d_{mv}}$ được tổng hợp thông qua cơ chế Dung hợp có Cổng thích ứng:

```

def __init__(self, embed_dim: int):
    super().__init__()
    self.gate_net = nn.Sequential(
        nn.Linear(embed_dim * 2, embed_dim),
        nn.GELU(),
        nn.Linear(embed_dim, embed_dim),
        nn.Sigmoid()
    )

def forward(self, z_seq: torch.Tensor, z_graph: torch.Tensor) -> Tuple[torch.Tensor, torch.Tensor]:
    concat = torch.cat([z_seq, z_graph], dim=-1)
    alpha = self.gate_net(concat)
    z_mv = alpha * z_seq + (1.0 - alpha) * z_graph
    return z_mv, alpha

```

Đoạn mã 2.4: Cơ chế trộn có cổng thích ứng (GatedMultiViewFusion) giữa biểu diễn chuỗi và đồ thị.


Lớp GatedMultiViewFusion ghép nối vector biểu diễn chuỗi z_{seq} và vector đồ thị z_{graph} , sau đó truyền qua mạng nơ-ron phi tuyến với hàm kích hoạt Sigmoid để suy ra trọng số cổng động α . Vector biểu diễn đa góc nhìn hợp nhất z_{mv} được tính bằng tổ hợp lồi có trọng số, cho phép mô hình cân bằng đóng góp thông tin giữa hai góc nhìn một cách thích ứng.

$$\mathbf{z}_{mv} = LayerNorm(m_{seq} \mathbf{w}_{rel}^{seq} \mathbf{W}_{out}^{seq} \mathbf{z}_{seq} + m_{graph} \mathbf{w}_{rel}^{graph} \mathbf{W}_{out}^{graph} \mathbf{z}_{graph} + m_{seq} m_{graph} \mathbf{W}_{out}^{cross} \mathbf{u}_{cross}) \in \mathbb{R}^{d_{mv}}$$

Trong đó $\mathbf{W}_{out}^{seq} \in \mathbb{R}^{d_{mv} \times d_{seq}}$, $\mathbf{W}_{out}^{graph} \in \mathbb{R}^{d_{mv} \times d_{graph}}$, $\mathbf{W}_{out}^{cross} \in \mathbb{R}^{d_{mv} \times d_{cross}}$ là các ma trận trọng số đầu ra. Gói biểu diễn đầu ra đa góc nhìn được đóng gói chuẩn mực:

$$\mathcal{B}_{mv} = \langle \mathbf{z}_{mv}, [t_{start}, t_{end}], \mathcal{E}_{scope}, m_{seq}, m_{graph}, \mathbf{w}_{rel} \rangle$$

Gói biểu diễn $\mathcal{B}_{mv}$ tạo thành giao diện đầu ra duy nhất của toàn bộ Khung Trích xuất Đặc trưng Đa góc nhìn. Phù hợp với ranh giới phân định tầng tại Mục 1.1.3, Extractor tuyệt đối không chứa logic phát hiện bất thường hay ngưỡng phân lớp an ninh. Gói biểu diễn được bàn giao nguyên vẹn sang Stage C phục vụ các đầu dò tuyến tính đồng bằng và quy trình chấm điểm bất thường không giám sát tùy chọn (Optional Downstream Zero-Shot Anomaly Scoring Protocol, được định nghĩa cho giai đoạn đánh giá hạ nguồn trên tập kiểm thử niêm phong khi có ủy quyền chính thức).



Hình 2.4: Sơ đồ kiến trúc Giống hàng đa góc nhìn, Kiểm soát sụp đổ và Tổng hợp biểu diễn thống nhất, nguồn tác giả đề xuất

2.4.4.2. Phân tích độ phức tạp tính toán và ngân sách streaming

Chi phí tính toán của Tầng Giống hàng và Biểu diễn Thống nhất được phân định rõ ràng giữa giai đoạn huấn luyện tự giám sát và giai đoạn suy luận trực tuyến:

- Chi phí huấn luyện giống hàng và tái tạo dung hợp: Trong mỗi bước huấn luyện lô B , chi phí chiếu phi tuyến qua MLP là $\mathcal{O}(B \cdot (d_{seq} + d_{graph})d_{proj})$. Chi phí tính toán hàm mất mát VICReg trên không gian chiếu là $\mathcal{O}(B \cdot d_{proj}^2)$, hàm tái tạo dung hợp là $\mathcal{O}(B \cdot (d_{seq} + d_{graph} + d_{cross})d_{mv})$, và chi phí phẫu thuật gradient PCGrad bổ sung trên tập tham số chia sẻ Θ_{PCGrad} sau khi đã tính các gradient thành phần là $\mathcal{O}(\text{card}(\Theta_{PCGrad}))$. Nếu kích hoạt mô đun Attention-MIL ở Stage B với không gian ẩn chú ý d_{att} , chi phí tính toán cho mỗi túi kích thước K bao gồm chi phí chiếu cộng chú ý $\mathcal{O}(K \cdot d_{mv} \cdot d_{att})$ và chi phí phân lớp túi $\mathcal{O}(K \cdot d_{att} + d_{mv})$, cho chi phí tổng thể mỗi túi là $\mathcal{O}(K \cdot d_{mv} \cdot d_{att} + d_{mv})$ (tuyến tính theo quy mô túi $\mathcal{O}(K)$ khi các tham số chiều được cố định). Toàn bộ chi phí này chỉ phát sinh trong quá trình huấn luyện ngoại tuyến.
- Chi phí suy luận trực tuyến: Trong giai đoạn vận hành dòng, các đầu chiếu g_{seq}, g_{graph} và các mô đun mất mát được ngắt bỏ hoàn toàn. Chi phí dung hợp và tổng hợp đầu ra đa góc nhìn tăng thêm (Incremental Fusion/Readout

Cost), sau khi đã có z_{seq} và z_{graph} , chỉ bao gồm các phép nhân ma trận, vector tuyến tính và cổng gating.

$$C_{fusion} = O(d_{seq}d_{cross} + d_{graph}d_{cross} + d_{seq}d_{mv} + d_{graph}d_{mv} + d_{cross}d_{mv})$$

Với kích thước các không gian vector đặc trưng được cố định, chi phí dung hợp cục bộ này không phụ thuộc vào độ dài toàn bộ luồng telemetry hoặc kích thước toàn đồ thị. Nhận định này chỉ áp dụng cho incremental fusion/readout sau khi z_{seq} và z_{graph} đã được tạo; không phải End-to-End Budget.

Chi phí tính toán toàn trình của toàn bộ hệ thống bao gồm: tiền xử lý sự kiện thô, trích xuất chuỗi ngắn hạn, cập nhật đồ thị động, lan truyền thông điệp Temporal GNN, quản lý trạng thái bộ nhớ hữu hạn và tổng hợp dung hợp đa góc nhìn. Trong khuôn khổ Stage A2 hiện tại, chuyên đề ghi nhận quan sát bước đầu về mức tiêu thụ VRAM GPU trong quá trình tiền huấn luyện; các chỉ số đo kiểm vận hành toàn trình còn lại (thông lượng sự kiện/giây, độ trễ p50/p95, dung lượng RAM và kích thước trạng thái trên mỗi thực thể) được đề xuất đo lường chi tiết khi triển khai thử nghiệm trên hệ thống SOC thực tế. *H4*

CHƯƠNG 3. THỰC NGHIỆM, ĐÁNH GIÁ VÀ ỨNG DỤNG

Chương này trình bày chi tiết công tác thực nghiệm, phương pháp luận đánh giá và các kết quả định lượng thu được nhằm kiểm chứng mô hình biểu diễn đồ thị sự kiện theo dòng thời gian liên tục (Temporal Graph View Encoder) đã đề xuất tại Chương 2. Mọi quy trình thực nghiệm đều tuân thủ các nguyên tắc kiểm toán độc lập: môi trường phần cứng và phần mềm được ghi nhận chính xác theo khóa môi trường, dữ liệu phân tách nhân quả chống rò rỉ thông tin, và kết quả được đối soát nguồn gốc độc lập trên từng hạt giống ngẫu nhiên. Toàn bộ các phân tích trong chương này được dẫn xuất trực tiếp từ các bằng chứng thực nghiệm máy đọc được, phân định rõ ràng giữa kết quả quan sát thực tế, suy diễn khoa học và các giới hạn kỹ thuật nội tại.

3.1. Thiết lập thực nghiệm và dữ liệu

3.1.1. *Môi trường tính toán, tính tái lập và kiểm định độ bất định thống kê*

Bảo đảm tính minh bạch và khả năng tái lập thực nghiệm, toàn bộ quá trình tiền huấn luyện được thực thi trên môi trường máy trạm độc lập với thông số kỹ thuật được xác định theo đúng khóa môi trường thực thi STAGE-A2-LOCAL-EXECUTION-ENVIRONMENT-V1.5.json. Hệ thống phần cứng trang bị card đồ họa NVIDIA GeForce RTX 3050 Ti Laptop GPU (dung lượng bộ nhớ 4.0 GB, Compute Capability 8.6, phiên bản driver 595.95, mã định danh UUID: GPU-3f4d825d-63ad-0695-1b32-466308a00b8c). Bộ xử lý trung tâm là Intel Core i5-12500H (12 Cores / 16 Threads) với bộ nhớ RAM hệ thống ghi nhận 15.71 GB.

Môi trường phần mềm vận hành trên nền tảng hệ điều hành Windows-11-10.0.26200-SP0, phiên bản Python 3.12.8, thư viện PyTorch 2.6.0+cu124 với CUDA runtime 12.4. Nhằm kiểm soát tối đa tính ngẫu nhiên của các phép toán trên nhân GPU, hệ thống cấu hình biến môi trường CUBLAS_WORKSPACE_CONFIG=:4096:8 và kích hoạt chế độ tính toán xác định torch.use_deterministic_algorithms(True). Đặc tả môi trường được niêm phong trong tệp bằng chứng experiments/evidence/stage-a2/preexecution/STAGE-A2-LOCAL-

EXECUTION-ENVIRONMENT-V1.5.json với mã băm SHA-256: 81d3ca4865a95c75cc2345695091265f948ad58e705865a3f8f780a9bf09f362.

Bảng 3.1: Thông số kỹ thuật môi trường thực nghiệm và khóa xác thực mật mã

Thành phần	Thông số kỹ thuật phần cứng / phần mềm	Khóa xác thực mật mã / Ghi chú
GPU phần cứng	NVIDIA GeForce RTX 3050 Ti Laptop GPU (4.0 GB, CC 8.6)	UUID: GPU-3f4d825d-63ad-0695-1...
Driver GPU	NVIDIA Display Driver 595.95	Khóa phiên bản cố định
Bộ vi xử lý	Intel Core i5-12500H (12 Cores / 16 Threads)	12 nhân vật lý, 16 luồng
Bộ nhớ hệ thống	RAM 15.71 GB	Ghi nhận từ môi trường lock
Hệ điều hành	Windows-11-10.0.26200-SP0	Nền tảng thực thi cục bộ
Phần mềm tính toán	Python 3.12.8, PyTorch 2.6.0+cu124, CUDA 12.4	cuBLAS :4096:8
Mã băm môi trường	STAGE-A2-LOCAL-EXECUTION-ENVIRONMENT-V1.5.json	SHA256: 81d3ca4865a95c75cc234569...

```
def compute_file_sha256(file_path: Path | str, chunk_size: int = 65536) -> str:
    """Compute SHA-256 hash of a local file."""
    p = Path(file_path)
    if not p.exists() or not p.is_file():
        raise FileNotFoundError(f"File not found for hash computation: {file_path}")

    hasher = hashlib.sha256()
    with open(p, "rb") as f:
        while chunk := f.read(chunk_size):
            hasher.update(chunk)
    return hasher.hexdigest()
```

Đoạn mã 3.4: Hàm tính toán mã băm SHA-256 theo khối nhị phân phục vụ kiểm toán toàn vẹn tệp tin.

Hàm `compute_file_sha256` đọc tệp tin dưới dạng nhị phân theo từng khối 64 KB nhằm tối ưu bộ nhớ máy trạm khi xử lý các tệp nhật ký và checkpoint trọng lượng lớn. Mã băm SHA-256 thu được cung cấp chữ ký toàn vẹn không thể bác bỏ, phục vụ công tác kiểm toán nguồn gốc thực nghiệm và khóa môi trường.

3.1.2. *Khung dữ liệu đối chuẩn và giao thức phân chia theo dòng thời gian chống rò rỉ*

Trong khuôn khổ nghiên cứu chuyên đề, thực nghiệm Stage A2 tập trung đánh giá trên tập dữ liệu chuẩn HDFS (Hadoop Distributed File System). Tập dữ liệu gốc HDFS_1.tar.gz, dung lượng 44.7 GB chưa nén, chứa tổng cộng 11,175,629 sự kiện log hệ thống được phân nhóm thành 575,061 phiên khối Block Session ID, có mã băm toàn vẹn SHA-256: 6ca6c5bc2671c66afecee9369a2fdac606bf33997a2494ac66aa411fe3e95169.

Khác với các phương pháp xáo trộn ngẫu nhiên truyền thống có nguy cơ rò rỉ thông tin thời gian, nghiên cứu đề xuất và áp dụng quy trình phân chia dữ liệu theo thứ tự dòng thời gian không nhìn trước (leakage-safe chronological split), tuân thủ khuyến nghị tránh rò rỉ thời gian (temporal snooping) của Arp et al. [8]. Khung đối chuẩn nghiên cứu bao quát 4 tập dữ liệu đại diện cho các miền viễn trắc an ninh khác nhau (DARPA TC E3 [12], LANL [13], HDFS [18], BGL [42]); trong đó, tập dữ liệu HDFS đóng vai trò là môi trường thực thi chính thức cho chiến dịch tiền huấn luyện Stage A2 hiện hành, còn các tập dữ liệu quy mô lớn còn lại định vị bối cảnh mở rộng cho các giai đoạn tiếp theo. Toàn bộ các phân vùng dữ liệu được phân định theo thứ tự thời gian và xác thực bằng chữ ký mật mã: [10]

Một là, phân vùng huấn luyện: Bao gồm đúng 35.000 phiên khối đầu tiên theo dòng thời gian thực tế, tương ứng với 586.577 sự kiện log, được tổ chức thành 2.292 cửa sổ ngữ cảnh (độ dài $W = 256$ sự kiện). Danh sách thành viên phiên khối huấn luyện có mã băm xác thực: 65b76694b0a3cf5c6d684a26899b1e5dca634cfd0985560149feddc12ca8ccfc.

Hai là, phân vùng kiểm định: Gồm 7.500 phiên khối tiếp theo trên trục thời gian, tương ứng 119.531 sự kiện log, tổ chức thành 467 cửa sổ ngữ cảnh ($W = 256$). Mã băm xác thực danh sách phiên khối kiểm định: 14cf689f9682a354e104463b9f02806629a683dfdf36d72d88daf5b407b0609a.

Ba là, phân vùng kiểm thử độc lập: Được bảo vệ thông qua cơ chế Tường lửa Dữ liệu Kiểm thử (SEALED-TEST-DATA-FIREWALL). Toàn bộ quá trình tối ưu hóa trọng số và kích hoạt điều kiện dừng sớm chỉ được thực hiện trên tập Train và Validation; các biến kiểm soát chiến dịch ghi nhận test_opened = false với 0 lượt truy cập (test_reads = 0), các manifest thực nghiệm được lưu không ghi nhận lượt đọc Test cho đến giai đoạn đánh giá hạ nguồn.

Bảng 3.2: Phân chia tập dữ liệu HDFS theo giao thức theo dòng thời gian chống rò rỉ

Phân vùng dữ liệu	Số phiên khối (Sessions)	Số sự kiện log (Events)	Số cửa sổ ngữ cảnh (W=256)	Mã băm tập hợp (Membership SHA-256)
Train Split	35,000	586,577	2,292	65b76694b0a3cf5c6d68...
Validation Split	7,500	119,531	467	14cf689f9682a354e104...
Sealed Test Split	Niêm phong cách ly	Niêm phong cách ly	Niêm phong cách ly	e07999decc7164e639a7...
Toàn bộ ngữ liệu	575,061	11,175,629	43,654	6ca6c5bc2671c66afece...

```
# Invariant checks
assert train_max_end < val_min_start, "Train-Val boundary causal violation!"
assert val_max_end < test_min_start, "Val-Test boundary causal violation!"
assert train_block_ids.isdisjoint(val_block_ids), "Train and Val block IDs overlap!"
assert train_block_ids.isdisjoint(test_block_ids), "Train and Test block IDs overlap!"
assert val_block_ids.isdisjoint(test_block_ids), "Val and Test block IDs overlap!"
assert purged_train_val_ids.isdisjoint(train_block_ids), "Purged sessions leaked into Train!"
assert purged_val_test_ids.isdisjoint(val_block_ids), "Purged sessions leaked into Val!"

# Causal budget selection (Earliest 35,000 Train sessions, Earliest 7,500 Val sessions)
selected_train_block_ids = sorted(
    train_block_ids,
    key=lambda b: (session_intervals[b][0], b)
)[:self.max_train_sessions]

selected_val_block_ids = sorted(
    val_block_ids,
    key=lambda b: (session_intervals[b][0], b)
)[:self.max_val_sessions]
```

Đoạn mã 3.1: Kiểm tra bất biến phân chia nhân quả và lựa chọn ngân sách phiên trong compute_and_cache_split.

Đoạn mã thực thi các điều kiện bất biến thời gian nghiêm ngặt thông qua các lệnh assert, bảo đảm thời điểm kết thúc của tập Huấn luyện xảy ra trước thời điểm bắt đầu của tập Kiểm định, đồng thời ngăn chặn mọi sự chồng lấn định danh phiên (block ID)

hoặc rò rỉ các phiên bị loại bỏ (purged). Tiếp đó, ngân sách phiên được chọn lọc theo thứ tự thời gian sớm nhất nhằm bảo toàn tính nhân quả chặt chẽ của giao thức thực nghiệm.

3.1.3. *Hệ thống thang đo ba tầng và hàm mục tiêu huấn luyện*

Theo khung đánh giá của chuyên đề, năng lực của vector biểu diễn đặc trưng log được kiểm chứng qua hệ thống thang đo ba tầng: thứ nhất là thang đo bản chất đo lường sai số dự đoán và độ phân kỳ phân phối trên không gian tự giám sát; thứ hai là thang đo đầu dò đánh giá năng lực phân tách tuyến tính các thuộc tính an ninh; và thứ ba là thang đo vận hành kiểm tra hiệu năng tính toán, độ trễ cùng thông lượng dòng sự kiện.

Đặc biệt, ở Thang đo Đầu dò (Probe Metrics), nhằm thực hiện đánh giá độc lập và khách quan chất lượng biểu diễn của các mạng nơ-ron nền tảng mà không làm thay đổi trọng số đã học, nghiên cứu chuẩn hóa Giao thức Đầu dò Tuyến tính Đóng băng V3 (TRAIN_FIT_FULL_FIXED_VALIDATION_EVALUATE). Trong giao thức này, toàn bộ các trọng số của backbone được đóng băng hoàn toàn (freeze). Bộ phân loại tuyến tính mỏng $W \in \mathbb{R}^{128 \times 1}$ được huấn luyện độc lập trên 100% biểu diễn của phân vùng Huấn luyện (35.000 phiên Train, khóa hạt giống ngẫu nhiên 10007, tối ưu hóa AdamW tốc độ học 10^{-2} , suy giảm trọng số 10^{-4} , kích thước lô 256 trong 50 epochs, tương ứng 6.850 bước tối ưu). Sau đó, mô hình probe được đánh giá cố định trên toàn bộ 100% phân vùng Kiểm định (7.500 phiên Validation cố định, 119.531 sự kiện). Hai thước đo an ninh chính thức được sử dụng là Average Precision (AP) và Diện tích dưới đường cong đặc trưng hoạt động máy thu (ROC-AUC). Tuyệt đối không có bất kỳ bước tối ưu hóa nào chạm vào nhãn kiểm định, và các biến kiểm soát chiến dịch ghi nhận tập dữ liệu Kiểm thử (Test split) chưa từng được truy cập (`test_opened = false`, `test_reads = 0`).

```

probe = nn.Linear(128, 1).to(self.dev)
optimizer = torch.optim.AdamW(probe.parameters(), lr=1e-2, weight_decay=1e-4)
criterion = nn.BCEWithLogitsLoss()

probe.train()
batch_size = 256
n_train = len(y_train)
optimizer_steps = 0

# Epoch loop
for epoch in range(50):
    # Deterministic permutation for this epoch
    g = torch.Generator().manual_seed(PROBE_FIXED_SEED + epoch)
    perm = torch.randperm(n_train, generator=g)
    for b_start in range(0, n_train, batch_size):
        b_idx = perm[b_start:b_start + batch_size]
        optimizer.zero_grad()
        logits = probe(z_tr[b_idx]).squeeze(-1)
        loss = criterion(logits, y_tr[b_idx])
        loss.backward()
        optimizer.step()
        optimizer_steps += 1

```

Đoạn mã 3.2: Vòng lặp huấn luyện bộ phân loại tuyến tính đóng băng (Frozen Linear Probe) trong `fit_linear_probe`.

Quy trình huấn luyện bộ dò tuyến tính sử dụng tầng tuyến tính duy nhất `nn.Linear(128, 1)` với hàm mất mát `BCEWithLogitsLoss` trên biểu diễn ẩn đóng băng. Mỗi epoch được xáo trộn xác định thông qua bộ sinh số ngẫu nhiên có seed cố định, bảo đảm tính công bằng tuyệt đối khi đo lường khả năng tách biệt thông tin an ninh của biểu diễn tự giám sát.

```

def compute_ap_and_roc_auc(scores: np.ndarray, y_true: np.ndarray) -> Tuple[float, float]:
    """
    Computes Average Precision (AP) and ROC-AUC with standard tie handling.
    Validates binary classes (must contain both 0 and 1).
    Uses standard scikit-learn metrics for consistent ranking.
    """
    scores = np.asarray(scores, dtype=np.float64)
    y_true = np.asarray(y_true, dtype=np.int64)

    classes = np.unique(y_true)
    if len(classes) != 2 or not np.array_equal(np.sort(classes), [0, 1]):
        raise ValueError(
            f"Binary classification requires exactly two classes [0, 1]. "
            f"Found unique classes: {classes.tolist()}"
        )

    from sklearn.metrics import average_precision_score, roc_auc_score
    ap = float(average_precision_score(y_true, scores))
    auc = float(roc_auc_score(y_true, scores))
    return ap, auc

```

Đoạn mã 3.3: Hàm tính toán AP và ROC-AUC xử lý đồng hạng (ties) chuẩn hóa qua scikit-learn.

Đoạn mã thể hiện nhánh tính toán chuẩn hóa cốt lõi của hàm `compute_ap_and_roc_auc`, tiến hành kiểm tra nghiêm ngặt tính nhị phân của nhãn mục tiêu và tính toán các chỉ số AP cùng ROC-AUC thông qua thư viện `scikit-learn`. Phép đo này xử lý nhất quán các trường hợp đồng hạng (ties), loại bỏ hoàn toàn các sai số do tính toán thứ hạng thô và thiết lập tiêu chuẩn đối chuẩn khách quan giữa các kiến trúc.

Kiến trúc thực nghiệm trong Stage A2 là mô hình TemporalGraphView Encoder, bao gồm: bộ nhớ trạng thái thực thể động dựa trên tế bào GRUCell ($d_{\text{mem}} = 128$), cơ chế chú ý thời gian đa đầu (Multi-Head Temporal Attention over causal event window), và phép chiếu thời gian liên tục điều hòa (Continuous Sinusoidal Time Projection $\phi(\Delta t)$). Mô hình xử lý đồ thị dị thể với 4 loại nút thực thể và 8 loại quan hệ cạnh. Mô hình được tối ưu hóa bằng thuật toán AdamW ($lr = 5 \times 10^{-4}$, $\text{betas}=(0.9, 0.98)$, $\epsilon = 10^{-8}$, $\text{weight_decay} = 0.01$) kết hợp bộ lập lịch Linear Warmup với 343 bước + Cosine Annealing to min $_lr = 10^{-5}$. Kích thước lô hiệu dụng là 1.024 events tương đương 4 cửa sổ nhân 256 sự kiện trên mỗi bước tối ưu hóa, tương ứng 573 bước cập nhật trọng số trên mỗi epoch, với tổng số bước tối ưu hóa tối đa là 6.876 bước trên 12 epochs, trong đó giai đoạn khởi động kéo dài 343 bước.

Mục tiêu huấn luyện tự giám sát đa nhiệm (Multi-task Self-supervised Objective) trong Stage A2 được xây dựng từ ba thành phần tổn thất cục bộ:

- Mất mát Dự đoán Quan hệ Che giấu (Masked Relation Prediction Loss, L_{rel}): Đo lường sai số phân loại quan hệ cạnh giữa các thực thể dựa trên hàm mất mát cross-entropy:

$$\mathcal{L}_{\text{mask-edge}} = -\frac{1}{\text{card}(\mathcal{E}_{\text{mask}})} \sum_{(v,u) \in \mathcal{E}_{\text{mask}}} \log[\text{softmax}(\varphi_{\text{graph}}^{\text{edge}}([\mathbf{h}_v(t); \mathbf{h}_u(t)])_{r(v,u)})]$$

- Mất mát Tái cấu trúc Đặc trưng Nút (Masked Node Attribute Reconstruction Loss, L_{node}): Sử dụng sai số toàn phương trung bình để khôi phục vector thuộc tính nút bị che giấu:

$$\mathcal{L}_{\text{mask-node}} = \frac{1}{\text{card}(\mathcal{V}_{\text{mask}})} \sum_{v \in \mathcal{V}_{\text{mask}}} \|\varphi_{\text{graph}}^{\text{node}}(\mathbf{h}_v(t)) - \mathbf{x}_v^{\text{priv}}\|_2^2$$

- Mất mát Hồi quy Khoảng thời gian Sự kiện (Continuous Time Interval Regression Loss, L_{time}): Hồi quy độ lệch thời gian liên tục $\log(1 + \Delta t)$ bằng hàm mất mát Smooth L1:

$$\mathcal{L}_{time-gap} = \frac{1}{card(\mathcal{E}_{active})} \sum_{(v,u) \in \mathcal{E}_{active}} \mathcal{L}_{\delta}(\varphi_{graph}^{time}([\mathbf{h}_v(t); \mathbf{h}_u(t)]), \log(1 + \Delta t_{v,u}))$$

Hàm mất mát đồ thị tổng hợp Stage A2 (L_{graph}) là tổ hợp tuyến tính có định giữa ba thành phần trên:

$$L_{graph} = 1.0 L_{rel} + 1.0 L_{node} + 0.1 L_{time}$$

3.2. Kết quả tiền huấn luyện và đối sánh phương pháp luận

3.2.1. Kết quả huấn luyện Stage A2 trên 5 hạt ngẫu nhiên thực nghiệm

Khảo sát động thái hội tụ và kiểm toán tính nhất quán thực nghiệm, chiến dịch tiền huấn luyện được tiến hành trên 5 đợt chạy thực nghiệm (run instances) với các giá trị khởi tạo hạt ngẫu nhiên khác nhau: 999, 42, 7, 1337, và 2024. Sự biến thiên quan sát được giữa các đợt chạy phản ánh tổng hòa giữa khởi tạo ngẫu nhiên, các yếu tố gây nhiễu từ bộ lập lịch và giao thức (scheduler/protocol confounding) cùng các sai lệch thủ tục thực thi, không cấu thành phép đo phương sai thuần túy qua seed (seed-only variance). Dựa trên cấu hình Stage A2 chính thức hiện hành theo văn bản thẩm quyền experiments/plans/STAGE-A2-FINAL-12-EPOCH-AUTHORITY.json, trên 12 epochs, 6.876 bước tối ưu hóa, 343 bước khởi động tuyến tính, kết hợp kiểm toán nguồn gốc thực thi độc lập từ nhật ký Git và các tệp bằng chứng máy đọc được, các đợt chạy được phân loại khoa học và minh bạch như sau: nhóm Lệnh Giao thức (Protocol Deviation), gồm Seed 999 hoàn thành 12 epochs với mất mát kiểm định 0,6095 nhưng có sai lệch giao thức tiền thi hành khi văn bản ủy quyền commit 244e81a5 ràng buộc kế hoạch chứa 573 bước khởi động trong khi mã nguồn thực thi sử dụng 343 bước, Seed 42 chạy theo quỹ đạo của bộ lập lịch cũ và dừng sớm tại Epoch 4 theo quy tắc dừng sớm xác lập trước (patience = 3/3), và Seed 7 khớp lịch trình 12 epochs nhưng tệp ủy quyền chỉ được commit lên Git sau thời điểm khởi chạy; và nhóm Đợt chạy Không chuẩn (Noncanonical), gồm Seed 1337 chạy theo lịch trình cũ, dừng tại Epoch 12 và thiếu các tệp biên bản thực thi bắt buộc METRICS.json, RUN-

MANIFEST.json, TEST-FIREWALL.json, cùng Seed 2024 chứa sai lệch mã băm commit và điều chỉnh lịch học giữa chừng. Bảng 3.3 tổng hợp chi tiết số liệu đo đạc thực tế trên từng hạt giống từ các tệp nhật ký thực thi được xác minh; Bảng 3.4 ghi nhận trạng thái hồ sơ và điều kiện kết thúc từng đợt chạy.

Bảng 3.3: Kết quả huấn luyện Stage A2 trên 5 hạt ngẫu nhiên thực nghiệm

Hạt giống	Epo ch	Số bước	Train loss	Best epoch	Best val loss	Val loss cuối	L_{rel}	L_{node}	L_{time}
Seed 999	12	6,876	0.1590	12	0.609500	0.609500	0.1943	0.4063	0.088 ₇
Seed 42	4	2,292	0.3083	1	6.081352	7.150944	4.9266	2.1803	0.440 ₇
Seed 7	12	6,876	0.1609	12	0.550259	0.550259	0.1833	0.3584	0.085 ₇
Seed 1337	12	6,876	0.1848	10	0.917827	1.205658	0.3063	0.8317	0.677 ₁
Seed 2024	12	6,876	0.1671	12	0.553257	0.553257	0.1974	0.3472	0.086 ₇
TB lệch thủ tục (3 seed)	-	-	0.2094	-	2.413704	2.770234	1.7681	0.9817	0.205 ₀

Ghi chú: Các trạng thái hồ sơ phản ánh mức độ tuân thủ quy trình ủy quyền, cấu hình và khả năng truy vết của từng đợt thực nghiệm; chúng không đồng nghĩa với lỗi tính toán hoặc checkpoint không sử dụng được. Các đợt có sai lệch được giữ lại để báo cáo minh bạch và được tách biệt khi tổng hợp kết quả chuẩn. Chi tiết trạng thái hồ sơ và điều kiện kết thúc từng đợt chạy được ghi nhận tại Bảng 3.4. Các chỉ số trung bình của nhóm lệch thủ tục mang tính chất tóm tắt mô tả (descriptive summary only), không đại diện cho hiệu năng chuẩn tắc hay độ bền vững của mô hình.

Bảng 3.4: Trạng thái hồ sơ và điều kiện kết thúc các đợt thực nghiệm Stage A2

Hạt giống	Trạng thái hồ sơ	Lý do kết thúc
Seed 999	Có sai lệch thủ tục	Đạt trần epoch
Seed 42	Có sai lệch thủ tục	Dừng sớm

Hạt giống	Trạng thái hồ sơ	Lý do kết thúc
Seed 7	Có sai lệch thủ tục	Đạt trần epoch
Seed 1337	Ngoài tập chuẩn	Dừng giữa chừng
Seed 2024	Ngoài tập chuẩn	Đạt trần epoch
TB lệch thủ tục (3 seed)	Có sai lệch thủ tục	-

Từ kết quả Bảng 3.3, toàn bộ 5 hạt giống thực nghiệm được bóc tách và đối soát nguồn gốc độc lập. Trong khuôn khổ kiểm toán hợp đồng tiền thi hành nghiêm ngặt, không có đợt chạy nào thỏa mãn đầy đủ các điều kiện đạt chuẩn (Canonical) do xuất hiện độ lệch giao thức giữa kế hoạch tiền thi hành và quá trình thực thi thực tế; độ lệch này là yêu cầu kiểm toán thủ tục, không đồng nhất với lỗi hỏng huấn luyện. Đối với nhóm quan sát lệch thủ tục gồm Seed 999, Seed 42 và Seed 7, mức mất mát kiểm định tốt nhất ghi nhận trung bình tóm tắt mô tả (descriptive summary only) là 2.413704 và mất mát kiểm định cuối trung bình đạt 2.770234; các giá trị trung bình này không dùng để suy diễn hiệu năng chuẩn tắc. Trong đó, Seed 999 hoàn thành 12 epochs với mất mát kiểm định 0,609500 nhưng mang sai lệch về số bước khởi động so với văn bản ủy quyền; Seed 7 đạt mức mất mát kiểm định tốt nhất 0,550259 nhưng văn bản ủy quyền được commit sau khi khởi chạy; Seed 42 dừng sớm tại Epoch 4 theo quy tắc dừng sớm xác lập trước (patience = 3/3). Các thành phần mất mát kiểm định cuối (L_{rel} , L_{node} , L_{time}) tuân thủ chặt chẽ công thức phân rã thành phần L_{graph} cho từng đợt chạy. Việc công khai các sai lệch nguồn gốc và duy trì trạng thái niêm phong của tập kiểm thử giúp tăng tính minh bạch và khả năng kiểm toán của quy trình thực nghiệm.

3.2.2. *Đối sánh đặc tính phương pháp luận so với các nghiên cứu cơ sở*

Làm rõ vị trí đóng góp học thuật của khung biểu diễn đề xuất, Bảng 3.5 tiến hành đối sánh định tính về đặc tính phương pháp luận giữa mô hình của chuyên đề và các phương pháp trích xuất đặc trưng log tiêu biểu được công bố trên các diễn đàn bảo mật quốc tế. Đối chiếu này dựa trên phân tích thiết kế kiến trúc lý thuyết và thực nghiệm tiền huấn luyện Stage A2, không cấu thành tuyên bố thực

thực nghiệm so sánh hơn về độ chính xác phát hiện bất thường downstream khi chưa tiến hành đánh giá end-to-end có sẵn nhãn.

Bảng 3.5: Đối sánh đặc tính phương pháp luận giữa khung biểu diễn đề xuất và các phương pháp cơ sở

Phương pháp cơ sở	Mô hình biểu diễn	Xử lý tham số & thời gian	Đặc tính cấu trúc & Phân tích khoảng trống
DeepLog (Du et al., CCS 2017) [23]	Mô hình chuỗi LSTM trên mã định danh mẫu (Template ID)	Mô hình hóa chuỗi log key và vector giá trị tham số qua các LSTM tách rời; thời gian chỉ phản ánh qua thứ tự bước rời rạc	Nhận xét trong phạm vi đối sánh của nghiên cứu: Trong cấu hình công bố gốc, mô hình tập trung vào chuỗi log key đơn luồng, không thiết kế cơ chế biểu diễn liên kết đồ thị giữa các thực thể hệ thống; nhạy cảm với các mẫu log ngoài từ điển tiền xử lý
LogBERT (Guo et al., IJCNN 2021) [24]	Mô hình ngôn ngữ tự chú ý Transformer 2 chiều	Mô hình hóa chuỗi mã mẫu; trong cấu hình công bố, không mô tả cơ chế bảo toàn trường minh ngữ nghĩa số học của tham số dòng lệnh	Nhận xét trong phạm vi đối sánh của nghiên cứu: Trọng tâm công bố khai thác chuỗi ngữ cảnh tuần tự, không khai thác cấu trúc đồ thị tương tác đa thực thể; chi phí tính toán self-attention bậc hai theo độ dài chuỗi
UNICORN (Han et al., NDSS 2020) [11]	Đồ thị nguồn gốc tĩnh với cấu trúc phức tạp đồ thị động (Graph Sketching)	Thời gian được rời rạc hóa qua cơ chế chia khoảng (Histogram/Bucketing); cấu hình công bố không mô tả cơ chế nhúng thời gian liên tục cục bộ cho tham số	Nhận xét trong phạm vi đối sánh của nghiên cứu: Sử dụng cấu trúc phức tạp đồ thị (Graph Sketching) cho đồ thị nguồn gốc hệ thống; trong các kịch bản tiến trình dài ngày, bài báo ghi nhận thách thức quản lý bùng nổ phụ thuộc (Dependency Explosion)
KAIROS (Cheng et al., IEEE S&P 2024) [29]	Mạng đồ thị nguồn gốc theo thời gian (Temporal Provenance Graph)	Sử dụng khoảng thời gian rời rạc giữa các sự kiện kiểm toán kernel	Nhận xét trong phạm vi đối sánh của nghiên cứu: Thiết kế chuyên biệt cho luồng nhật ký kernel cấp thấp; cấu hình theo vết toàn bộ dòng dữ liệu đòi hỏi quản lý bộ nhớ cần trọng khi mở rộng quy mô
MAGIC (Jia et al., USENIX Security 2024) [31]	Mô hình tự mã hóa đồ thị có mặt nạ (Masked Graph Autoencoder)	Phân chia cửa sổ sự kiện tĩnh; cấu hình công bố không mô tả cơ chế biểu diễn hàm thời gian liên tục $\phi(\Delta t)$ giữa các sự kiện vi mô	Nhận xét trong phạm vi đối sánh của nghiên cứu: Kiến trúc Masked Graph Autoencoder tối ưu hóa theo lô ngoại tuyến (offline); việc thích ứng cho kịch bản streaming thời gian thực đòi hỏi thiết kế thêm cơ chế quản lý trạng thái động

Phương pháp cơ sở	Mô hình biểu diễn	Xử lý tham số & thời gian	Đặc tính cấu trúc & Phân tích khoảng trống
Khung nghiên cứu đề xuất (Temporal Graph View)	TemporalGraphViewEncoder kết hợp bộ nhớ GRU động và Temporal Attention	Áp dụng hàm nhúng thời gian liên tục $\phi(\Delta t)$ nhằm nắm bắt khoảng trễ giữa các sự kiện liên tiếp	Mô hình hóa quan hệ đồ thị dị thể (4 loại nút, 8 loại quan hệ) kết hợp cơ chế tự giám sát đa nhiệm trong khuôn khổ huấn luyện

3.2.3. Đánh giá chuẩn hóa V3 hạ nguồn cho các mô hình xác nhận Sequence và Multi-View

Thực hiện chiến lược bằng chứng tối ưu hóa chi phí (Cost-Optimized Evidence Strategy) theo kế hoạch NINEPLUS-EXPERIMENT-CAMPAIGN-V3, nghiên cứu tiến hành đánh giá chuẩn hóa V3 trên toàn bộ 6 mô hình nền tảng thuộc bộ ba xác nhận triển vọng: 3 hạt giống đơn chuỗi SEQUENCE_ONLY (42, 7, 999) và 3 hạt giống đa góc nhìn liên kết MULTI_VIEW_ALIGNED_VICREG (42, 7, 999). Tất cả 6 mô hình đều được huấn luyện trên cùng giao thức phân chia nhân quả chống rò rỉ của tập dữ liệu HDFS và được đánh giá hạ nguồn bằng bộ phân loại tuyến tính đóng băng trên 100% tập Kiểm định cố định (7.500 phiên). Bảng 3.6 tổng hợp kết quả chi tiết của 6 đợt thực nghiệm V3, bao gồm chỉ số AP, ROC-AUC và phương sai biểu diễn ẩn $\text{Var}(z)$.

Bảng 3.6: Kết quả đánh giá hạ nguồn V3 trên 100% tập Validation cho các mô hình Sequence và Multi-View

Kiến trúc	Seed	Checkpoint nguồn	AP	ROC-AUC	Var(z)	Trạng thái nghiệm thu
SEQUENCE_ONLY	42	CONF_SEQUENCE_ONLY_seed42	1.0000	1.0000	0.004535	Đạt chuẩn
SEQUENCE_ONLY	7	CONF_SEQUENCE_ONLY_seed7	1.0000	1.0000	0.005755	Đạt chuẩn
SEQUENCE_ONLY	999	CONF_SEQUENCE_ONLY_seed999	1.0000	1.0000	0.006097	Đạt chuẩn

Kiến trúc	Seed	Checkpoint nguồn	AP	ROC-AUC	Var(z)	Trạng thái nghiệm thu
TB Sequence (3 seed)	-	-	1.0000	1.0000	0.005462	Đạt chuẩn V3
MULTI_VIEW_ALIGNED	42	CONF_MULTI_VIEW_seed42	0.7604	0.9946	0.005513	Đạt chuẩn
MULTI_VIEW_ALIGNED	7	CONF_MULTI_VIEW_seed7	0.6309	0.8081	0.004682	Đạt chuẩn
MULTI_VIEW_ALIGNED	999	CONF_MULTI_VIEW_seed999	0.5911	0.7693	0.008013	Lệch thủ tục
TB Multi-View (3 seed)	-	-	0.6608	0.8573	0.006069	Đạt chuẩn V3

Nhằm kiểm định chặt chẽ Giả thuyết H2 về tính không thua kém của mô hình đa góc nhìn so với nhánh đơn chuỗi, Bảng 3.7 tổng hợp độ lệch hiệu năng cặp đôi (Paired Deltas: Δ = Multi-View – Sequence) trên từng hạt giống tương ứng. Biên không thua kém thực tiễn được nhóm tác giả tiền đăng ký trước thực nghiệm là $\delta \geq -0.02$ (-2.0% AP).

Bảng 3.7: Đối sánh hiệu năng cặp đôi Multi-View so với Sequence-Only và kiểm định biên không thua kém

Cặp hạt giống	Sequence AP	Multi-View AP	Δ AP	Δ ROC-AUC	Biên $\delta \geq -0.02$
Seed 42	1.0000	0.7604	-0.2396	-0.0054	Vi phạm (-23.96%)
Seed 7	1.0000	0.6309	-0.3691	-0.1919	Vi phạm (-36.91%)
Seed 999	1.0000	0.5911	-0.4089	-0.2307	Vi phạm (-40.89%)
Trung bình cặp	1.0000	0.6608	-0.3392	-0.1427	Không thỏa mãn

Từ kết quả Bảng 3.7, trên toàn bộ ba hạt giống ghép cặp thực nghiệm, hiệu năng phát hiện bất thường của mô hình đa góc nhìn đều thấp hơn mô hình đơn

chuỗi (độ suy giảm ΔAP lần lượt là -0.2396, -0.3691 và -0.4089; trung bình $\Delta AP = -0.3392 \pm 0.0885$, độ lệch chuẩn mẫu). Toàn bộ ba hạt giống đều vi phạm rõ rệt biên không thua kém tiền đăng ký $\delta \geq -0.02$. Do đó, trong phạm vi đối chứng trực tiếp với Sequence-Only trên tập HDFS, kết quả thực nghiệm không hỗ trợ giả thuyết H2 về tính không thua kém của biểu diễn đa góc nhìn (H2_CONFIRMATORY_STATUS = NOT_SUPPORTED_WITHIN_SEQUENCE_COMPARATOR_SCOPE).

Về nhánh đơn đồ thị (GRAPH_ONLY): Do hạn chế nghiêm ngặt về chi phí tính toán phần cứng máy trạm, bộ ba xác nhận triển vọng GRAPH_ONLY_FRESH đã không được triển khai huấn luyện (thực nghiệm pilot ghi nhận tốc độ huấn luyện nhánh đồ thị lên tới ~ 190 phút/epoch, tương đương xấp xỉ 38 giờ GPU danh định cho một đợt chạy 12 epochs; trần danh định cho bộ ba hạt giống đạt tới ~ 114 giờ GPU). Do đó, các kết quả của mô hình đồ thị lịch sử (AP trung bình xấp xỉ 0.6694 ± 0.0468 ; ROC-AUC trung bình xấp xỉ 0.8142 ± 0.0675 , độ lệch chuẩn mẫu) thuần túy được giữ lại với vai trò tham chiếu khảo sát lịch sử (HISTORICAL_EXPLORATORY_REFERENCE_ONLY) nhằm phân tích thiết kế kiến trúc, tuyệt đối không được đối chiếu như mô hình đối chứng chuẩn hóa V3.

Về kế toán bước tối ưu hóa (Optimizer Accounting): Trong toàn bộ giai đoạn đánh giá chuẩn hóa V3 và các kiểm toán vi mô, không có bất kỳ bước tối ưu hóa nào được thực hiện trên các mạng nơ-ron nền tảng (NEW_BACKBONE_OPTIMIZER_STEPS_THIS_PHASE = 0). Tổng cộng 82.200 bước tối ưu hóa đã được thực thi độc lập trên các bộ phân loại tuyến tính mỏng ($W \in \mathbb{R}^{128 \times 1}$), bao gồm: 41.100 bước tối ưu probe đánh giá bất thường V3 (6 mô hình x 6.850 bước); 20.550 bước tối ưu probe bất thường phục vụ kiểm thử che đầu vào H1 (3 mô hình x 6.850 bước); và 20.550 bước tối ưu probe bất thường phục vụ kiểm tra độ nhạy bỏ tham số Sequence H2 (3 mô hình x 6.850 bước). Không có quá trình huấn luyện probe trực tiếp nào cho danh mục tham số H1 diễn ra.

3.2.4. *Kiểm chứng tái lập độc lập trên máy trạm*

Nhằm xác thực tính độc lập, khách quan và năng lực tái lập thực tế của hệ thống mã nguồn mà không phụ thuộc vào giao diện tương tác hay luồng tự động hóa của trợ lý AI, sinh viên đã trực tiếp thực thi kịch bản kiểm chứng `manual_reproduction/run_manual_sequence42.ps1` ngoài môi trường PowerShell độc lập (với cờ lệnh `-ExecutionPolicy Bypass`). Quy trình thực thi này được neo chặt trực tiếp vào commit mã nguồn đã được kiểm toán toàn diện tại HEAD (commit SHA: `14e04d73c64de315806bd862fb73b2a812f1f50b` trên nhánh làm việc `fix/thesis-apply-edits`). Trước khi bước vào chu trình huấn luyện, kịch bản tự động kích hoạt kiểm thử tiền kiểm phần cứng và môi trường (`scripts/gpu_smoke_test.py`), ghi nhận và xác thực chính xác các thông số môi trường thực tế: Python 3.12.8, PyTorch 2.6.0+cu124, CUDA 12.4, PyG 2.6.1 trên máy trạm trang bị card đồ họa NVIDIA GeForce RTX 3050 Ti Laptop GPU (tổng dung lượng VRAM thực tế 4.095,5 MB). Tại thời điểm khởi chạy, nhật ký ghi nhận 9 tệp chưa theo dõi/sửa đổi cục bộ (thuộc các thư mục lưu vết thực nghiệm confirmatory của các seed khác và các kịch bản điều phối tạm thời), hoàn toàn không can thiệp hay làm biến đổi tính toàn vẹn của mã nguồn nghiên cứu.

Đợt chạy thực nghiệm độc lập (với định danh Run ID `CONF_SEQUENCE_ONLY_seed42_1789724929`, kiến trúc `SEQUENCE_ONLY`, khởi tạo ngẫu nhiên Seed 42) đã hoàn thành tổng cộng 6 epochs và kích hoạt cơ chế dừng sớm (Early Stopping) tại Epoch 6 do mất mát kiểm định không cải thiện so với Epoch 3 (thỏa mãn điều kiện kiên nhẫn `patience = 3/3 epochs`). Checkpoint tối ưu được hệ thống tự động lưu vết tại Epoch 3 với giá trị mất mát kiểm định tốt nhất đạt 0.009218 và phương sai không gian ẩn đạt 0.093496. Mức tiêu thụ bộ nhớ GPU đỉnh đo đặc nội bộ trong `RUN-MANIFEST.json` là 170.45 MB VRAM (cùng 1.678,2 MB RAM hệ thống), khẳng định khả năng vận hành hoàn toàn nằm trong giới hạn tài nguyên khả thi của máy trạm cá nhân. Trọng số mô hình được niêm phong toàn vẹn với mã băm xác thực SHA-256 mang giá trị `926b32512577ac66d8adc29bd145bf45868d176c440c733fb7e074c6470621cc` (đối chiếu tại Bảng 3.7b).

Đánh giá hạ nguồn nội bộ sau huấn luyện theo giao thức `POST_TRAINING_INTERNAL_VAL_80_20_PROBE` ghi nhận chỉ số AP đạt 0.899385 và ROC-AUC đạt 0.997263. Phép đo này được thực thi hoàn toàn độc lập sau khi quá trình huấn luyện backbone hoàn tất và mô hình tối ưu được nạp lại; toàn bộ trọng số trích xuất đặc trưng được đóng băng cố định. Tập biểu diễn ẩn gồm 7.500 mẫu của tập Validation được chia tách phân tầng theo tỷ lệ 80/20, trong đó bộ phân loại tuyến tính (linear probe) chỉ được tối ưu trên 80% số mẫu và được đánh giá khách quan trên 20% số mẫu holdout còn lại; đây không phải là phép đo trên từng mini-batch trong lúc

huấn luyện và không phải luồng dữ liệu trực tuyến. Đối với giao thức đánh giá đóng băng chuẩn hóa V3 (V3_FROZEN_PROBE), bộ phân loại tuyến tính được tối ưu trên biểu diễn đóng băng của toàn bộ 35.000 mẫu Train và đo lường trên toàn bộ 7.500 mẫu Validation, đạt $AP = 1.0000$ và $ROC-AUC = 1.0000$ như công bố tại Bảng 3.6. Đợt chạy tái lập độc lập này đã tái hiện chính xác quỹ đạo hội tụ, cơ chế dừng sớm và các chỉ số kiểm toán của đợt chạy xác nhận Seed 42, khẳng định tính xác định và độ tin cậy thực nghiệm của pipeline nghiên cứu.

Bảng 3.7b: Thông số kỹ thuật và kết quả đo đạc từ đợt chạy kiểm chứng độc lập Sequence-Only (Seed 42)

Chỉ tiêu / Thông số thực nghiệm	Giá trị đo đạc thực tế
Git Commit SHA thực thi	14e04d73c64de315806bd862fb73b2a812f1f50b (nhánh fix/thesis-apply-edits)
Run ID thực thi	CONF_SEQUENCE_ONLY_seed42_1789724929
Mô hình kiến trúc & Seed	SEQUENCE_ONLY, Seed 42
Môi trường phần mềm	Python 3.12.8, PyTorch 2.6.0+cu124, CUDA 12.4, PyG 2.6.1
Phần cứng GPU thực tế	NVIDIA GeForce RTX 3050 Ti Laptop GPU (4.095,5 MB VRAM)
Tổng số epoch thực thi	6 epochs (kích hoạt Early Stopping tại Epoch 6)
Điều kiện dừng sớm	patience = 3/3 epochs không cải thiện mất mát kiểm định so với Epoch 3
Checkpoint tối ưu (Best Epoch)	Epoch 3 (lưu vết tự động)
Mất mát kiểm định tốt nhất (Val Loss)	0.00921815038938671
Phương sai không gian ẩn (Latent Var)	0.09349559992551804
Bộ nhớ GPU đỉnh (Peak VRAM)	170.4453125 MB (ghi nhận trong RUN-MANIFEST.json; RAM: 1.678,2 MB)
Post-Training Internal Val 80/20 Probe AP	0.8993850472022873 (đánh giá sau huấn luyện trên tập Validation 80/20)
Post-Training Internal Val 80/20 Probe ROC-AUC	0.9972634577897737 (đánh giá sau huấn luyện trên tập Validation 80/20)
Mã băm Checkpoint SHA-256	926b32512577ac66d8adc29bd145bf45868d176c440c733fb7e074c6470621cc

```

and will change in the near future. We recommend specifying layout=torch.jagged when constructing a nested tensor, as this layout receives active developmen
t, has better operator coverage, and works with torch.compile. (Triggered internally at C:\actions-runner_work\pytorch\pytorch\aten\src\ATen\Nested
TensorImpl.cpp:182.)
output = torch._nested_tensor_from_mask(
[CONF_SEQUENCE_ONLY_seed42_1789724929] Epoch 1/12 | Train: 1.13m | Val: 0.05m | Val Loss: 0.0294
[CONF_SEQUENCE_ONLY_seed42_1789724929] * New best validation loss: 0.0294 (Saved best_checkpoint.pt)
[CONF_SEQUENCE_ONLY_seed42_1789724929] Epoch 2/12 | Train: 1.37m | Val: 0.19m | Val Loss: 0.0107
[CONF_SEQUENCE_ONLY_seed42_1789724929] * New best validation loss: 0.0107 (Saved best_checkpoint.pt)
[CONF_SEQUENCE_ONLY_seed42_1789724929] Epoch 3/12 | Train: 1.91m | Val: 0.05m | Val Loss: 0.0092
[CONF_SEQUENCE_ONLY_seed42_1789724929] * New best validation loss: 0.0092 (Saved best_checkpoint.pt)
[CONF_SEQUENCE_ONLY_seed42_1789724929] Epoch 4/12 | Train: 1.50m | Val: 0.17m | Val Loss: 0.0136
[CONF_SEQUENCE_ONLY_seed42_1789724929] Patience counter: 1/3
[CONF_SEQUENCE_ONLY_seed42_1789724929] Epoch 5/12 | Train: 1.65m | Val: 0.05m | Val Loss: 0.0102
[CONF_SEQUENCE_ONLY_seed42_1789724929] Patience counter: 2/3
[CONF_SEQUENCE_ONLY_seed42_1789724929] Epoch 6/12 | Train: 1.64m | Val: 0.19m | Val Loss: 0.0098
[CONF_SEQUENCE_ONLY_seed42_1789724929] Patience counter: 3/3
[CONF_SEQUENCE_ONLY_seed42_1789724929] Early stopping triggered at epoch 6 (patience=3)
[CONF_SEQUENCE_ONLY_seed42_1789724929] CONFIRMATORY_SEQUENCE_ONLY COMPLETE. Probe AP: 0.8994 | ROC-AUC: 0.9973

=====
CONFIRMATORY EXECUTION BATCH FINISHED SUCCESSFULLY!
=====
- sequence_only_seed42: CONF_SEQUENCE_ONLY_seed42_1789724929 | Best Val Loss: 0.0092 (Epoch 3) | Probe AP: 0.8994

>>> [BƯỚC 4/6] NHẬN DIỆN THỦ MỤC KẾT QUẢ MỚI...
Thủ mục mới: D:\Research\experiments\nineplus\confirmatory\CONF_SEQUENCE_ONLY_seed42_1789724929

>>> [BƯỚC 5/6] KIỂM ĐỊNH BẰNG CHỨNG RUN-MANIFEST MỚI...

>>> [BƯỚC 6/6] GHI BÁO CÁO TÓM TẮT MANUAL_RUN_SUMMARY.txt...
Đã ghi tóm tắt: D:\Research>manual_reproduction\runs\1789724927\MANUAL_RUN_SUMMARY.txt
Transcript stopped, output file is D:\Research>manual_reproduction\runs\1789724927\transcript.log

=====
HOÀN TẤT PHIÊN TẢI LẬP THỰC NGHIỆM ĐỘC LẬP!
Vui lòng xem chi tiết tại: D:\Research>manual_reproduction\runs\1789724927\MANUAL_RUN_SUMMARY.txt
=====
PS D:\Research>

```

Hình 3.1: Giao diện PowerShell khi chạy kiểm chứng độc lập Sequence-Only (Seed 42), thể hiện tiến trình 6 epoch, kích hoạt early stopping tại epoch 6 (checkpoint tối ưu tại epoch 3) và hoàn tất lưu vết thực nghiệm.

Hình 3.1 ghi nhận nhật ký console trực quan trong quá trình sinh viên thực thi kịch bản `run_manual_sequence42.ps1` trên máy trạm ngoài môi trường trợ lý AI. Hình ảnh thể hiện rõ sự suy giảm của hàm mất mát huấn luyện và mất mát kiểm định từ Epoch 1 đến Epoch 3, tiếp theo là sự kích hoạt cơ chế dừng sớm khi giá trị mất mát kiểm định không tiếp tục cải thiện ở các Epoch 4, 5 và 6 (bộ đếm patience đạt 3/3). Sau khi kích hoạt dừng sớm, hệ thống tự động tải lại checkpoint tối ưu của Epoch 3, thực thi bộ dò nội bộ sau huấn luyện và hoàn tất quy trình lưu vết thực nghiệm an toàn.

3.3. Phân tích động thái tối ưu hóa và trạng thái bằng chứng giả thuyết

3.3.1. Phân tích động thái tối ưu hóa và hiện tượng dừng sớm

Kết quả thực nghiệm trong chiến dịch huấn luyện Stage A2 ghi nhận sự phân hóa rõ nét giữa các quỹ đạo hội tụ. Trong khi Seed 7 và Seed 999 đạt được mức mất mát kiểm định thấp quanh 0,550–0,609 sau 12 epochs, thì Seed 42 đã kích hoạt cơ chế dừng sớm (Early Stopping) ngay tại Epoch 4 với giá trị mất mát kiểm định ghi nhận ở mức 6.081352 (do thỏa mãn điều kiện kiên nhẫn $\text{patience} = 3/3$ epochs không cải thiện so với Epoch 1).

Phân tích nhật ký huấn luyện từ tệp `TRAIN-LOG.jsonl` ghi nhận tại Epoch 1, Seed 42 có mất mát kiểm định ban đầu là 6.081352. Sau đó, mất mát trên tập kiểm định không tiếp tục giảm mà tăng lên 6.3761 ở Epoch 2, duy trì ở mức cao,

lần lượt là 7.0354 tại Epoch 3 và 7.1509 tại Epoch 4. Dữ liệu thực nghiệm hiện có không cho phép phân tách rạch ròi tác động của trạng thái khởi tạo trọng số ngẫu nhiên ban đầu khỏi các khác biệt về bộ lập lịch và giao thức thực thi (scheduler/protocol confounding). Hiện tượng dừng sớm tại Seed 42 là chỉ dấu gợi ý về tính nhạy cảm và sự bất ổn định trong quá trình tối ưu hóa mô hình đồ thị thời gian liên tục, đòi hỏi các nghiên cứu sâu hơn về cơ chế khởi tạo và kỹ thuật khởi động thích nghi.

Việc báo cáo trung thực kết quả của Seed 42 thể hiện sự tuân thủ nghiêm túc quy trình nghiên cứu khoa học: mọi quan sát thực tế đều được ghi nhận đầy đủ, không thực hiện hành vi loại bỏ kết quả bất lợi để làm đẹp số liệu. Đồng thời, sự biến thiên giữa các đợt chạy khẳng định tính phức tạp của bề mặt tối ưu và sự cần thiết của việc kiểm toán thực nghiệm đa đợt chạy trước khi đưa ra các kết luận khái quát.

3.3.2. *Đối chiếu trạng thái bằng chứng đối với các giả thuyết nghiên cứu*

Dựa trên toàn bộ dữ liệu thực nghiệm đã kiểm toán độc lập từ chiến dịch tiền huấn luyện Stage A2 và chiến dịch đánh giá chuẩn hóa V3 Nineplus, nghiên cứu tiến hành đối chiếu khách quan, có trách nhiệm giải trình khoa học đối với năm giả thuyết nghiên cứu (H1 - H5) và một yêu cầu kỹ thuật vận hành (ER1):

Thứ nhất, về Giả thuyết H1 (Parameter Semantic Fidelity) - Trạng thái: CHƯA THỂ ĐÁNH GIÁ TRỰC TIẾP VỚI BIỂU DIỄN CẤP PHIÊN HIỆN TẠI (H1_DIRECT_STATUS = NOT_DIRECTLY_EVALUABLE_WITH_CURRENT_SESSION_REPRESENTATION). Kiểm toán nguồn gốc nhãn cho thấy mục tiêu tham số trong dữ liệu tiền huấn luyện hdfs_ssl_train.pt được định dạng ở cấp độ token và khe tham số $[L_i, 4]$ (token/event-level). Trong khi đó, vector biểu diễn trích xuất phục vụ đánh giá an ninh hạ nguồn lại là vector gộp cấp độ phiên $z_{\text{session}} \in \mathbb{R}^{128}$. Khi thực hiện ánh xạ sang nhãn xuất hiện đa danh mục ở cấp phiên (session-level presence), phân phối nhãn bị thoái hóa thống kê: hai danh mục tham số (địa chỉ IP và chuỗi ký tự chung) xuất hiện trong 100% số phiên (phương sai bằng 0), năm danh mục xuất hiện trong trên 98% số phiên, và

có tới 18 trên 25 danh mục hoàn toàn có 0 mẫu dương trong phân vùng Kiểm định. Do đó, bài toán probe phân loại trực tiếp danh mục tham số H1 chưa thể thực thi do độ mịn mục tiêu không tương thích ($H1_TARGET_ALIGNMENT = TOKEN_LEVEL_REQUIRES_TOKEN_REPRESENTATION$).

Để thu thập bằng chứng định lượng gián tiếp, nghiên cứu thực hiện kiểm thử cắt bỏ che đầu vào đóng băng ($FROZEN_INPUT_MASKING_ABLATION$) trên ba mô hình $SEQUENCE_ONLY$: trích xuất biểu diễn khi mở toàn bộ tham số động ($param_slots = params$) so với khi che hoàn toàn tham số ($param_slots = None$). Các bộ phân loại tuyến tính mỏng phát hiện bất thường hạ nguồn có dung lượng tương đương được huấn luyện độc lập trên biểu diễn Train đóng băng của từng hạt giống. Bảng 3.8 tổng hợp kết quả kiểm thử cắt bỏ che đầu vào tham số đối với vector biểu diễn z .

Bảng 3.8: Kết quả kiểm thử cắt bỏ che tham số đầu vào trên Sequence-Only đóng băng

Hạt giống	Độ tương đồng Cosine	Khoảng cách Euclid (L2)	AP có tham số	AP che tham số	Độ lệch ΔAP
Seed 42	0.9581	3.2742	1.0000	1.0000	+0.0000
Seed 7	0.8201	6.7778	1.0000	1.0000	+0.0000
Seed 999	0.9546	3.4056	1.0000	1.0000	+0.0000
Trung bình	0.9109	4.4859	1.0000	1.0000	+0.0000

Kết quả Bảng 3.8 xác nhận trạng thái $H1_MASKING_ABLATION_STATUS = AUXILIARY_OBSERVATION_ONLY$. Về suy diễn được phép: Khi loại bỏ đầu vào parameter slots trên cùng mô hình Sequence đóng băng (kiểm thử cắt bỏ che đầu vào), vector biểu diễn phiên z ghi nhận sự thay đổi đo lường được về độ tương đồng cosine (0.8201 - 0.9581) và khoảng cách Euclid (3.27 - 6.78). Điều này xác lập độ nhạy của biểu diễn đóng băng đối với các đầu vào này dưới can thiệp che tham số cụ thể; đồng thời trên bài toán phát hiện bất thường HDFS, việc che tham số không làm suy giảm AP hạ nguồn (duy trì 1.0000). Về

suy diễn bị cấm: Nghiên cứu tuyệt đối không tuyên bố đây là bằng chứng chứng minh mô hình có hiểu biết ngữ nghĩa sâu xa, không tuyên bố giả thuyết H1 đã được xác nhận, và không suy diễn về tính tối ưu lý thuyết thông tin hay sự cần thiết của tham số đối với bài toán hạ nguồn này.

Thứ hai, về Giả thuyết H2 (Multi-View Alignment & Negative Transfer Prevention) - Trạng thái: KHÔNG ĐƯỢC HỖ TRỢ TRONG PHẠM VI ĐỐI CHỨNG VỚI SEQUENCE-ONLY (H2_CONFIRMATORY_STATUS = NOT_SUPPORTED_WITHIN_SEQUENCE_COMPARATOR_SCOPE). Dưới giao thức đầu dò tuyến tính đồng bằng V3, mô hình đơn chuỗi ghi nhận $AP = 1.0000$ và $ROC-AUC = 1.0000$ trên tập Kiểm định cố định trên cả ba hạt giống. Ngược lại, mô hình đa góc nhìn đạt AP trung bình 0.6608 ± 0.0885 và $ROC-AUC$ trung bình 0.8573 ± 0.1204 (độ lệch chuẩn mẫu). Độ suy giảm hiệu năng cặp đôi bình quân đạt $\Delta AP = -0.3392 \pm 0.0885$, vi phạm biên không thua kém $\delta \geq -0.02$ trên toàn bộ ba hạt giống.

Để loại trừ khả năng ưu thế của nhánh đơn chuỗi chỉ là hệ quả thiên lệch từ việc nhánh Sequence tiếp nhận trực tiếp các khe tham số động trong khi hàm `extract_representation()` của Multi-View xử lý tham số ẩn, nghiên cứu đã tiến hành kiểm tra độ nhạy bỏ tham số Sequence (H2_SEQUENCE_NOPARAM_SENSITIVITY). Trong bài kiểm tra này, toàn bộ 35.000 biểu diễn Train và 7.500 biểu diễn Validation của mô hình Sequence đều bị che hoàn toàn tham số (`param_slots = None`); một bộ probe mới được huấn luyện và đánh giá trên các vector che này. Bảng 3.9 tổng hợp kết quả phân tích độ nhạy.

Bảng 3.9: Kiểm tra độ nhạy bỏ tham số đầu vào Sequence đối với hiệu năng phát hiện bất thường hạ nguồn

Hạt giống	Sequence No-Param AP	Multi-View AP	ΔAP	Phương sai $Var(z)$	Biên $\delta \geq -0.02$
Seed 42	1.0000	0.7604	-0.2396	0.006487	Vi phạm
Seed 7	1.0000	0.6309	-0.3691	0.008236	Vi phạm

Hạt giống	Sequence No-Param AP	Multi-View AP	ΔAP	Phương sai $\text{Var}(z)$	Biên $\delta \geq -0.02$
Seed 999	1.0000	0.5911	-0.4089	0.007036	Vi phạm
Trung bình cặp	1.0000	0.6608	-0.3392	0.007253	Không thỏa mãn

Kết quả Bảng 3.9 khẳng định: H2_NEGATIVE_RESULT_ROBUST_TO_THIS_PARAMETER_INPUT_REMOVAL_CHECK. Kết quả H2 không thay đổi trong kiểm tra độ nhạy cụ thể khi loại bỏ đầu vào parameter slots khỏi Sequence-only: mô hình Sequence-Only vẫn duy trì AP 1.0000 trên cả ba hạt giống. Điều này cho thấy độ lệch hiệu năng quan sát được không bắt nguồn từ sự hiện diện của các khe tham số đầu vào ở nhánh Sequence trong kiểm tra này. Nghiên cứu không khái quát hóa kết quả này thành tính vững chắc phổ quát trước mọi trôi dạt phân phối hay thay đổi kiến trúc. Theo chuẩn mực phương pháp luận, với cỡ mẫu $N = 3$ cặp hạt giống, nghiên cứu không đưa ra các tuyên bố về ý nghĩa thống kê suy diễn (unsupported statistical-significance claim) và không suy diễn nhân quả chưa qua kiểm chứng.

Thứ ba, về Giả thuyết H3 (Anti-Drift & Shortcut Invariance Robustness) - Trạng thái: CHƯA THỰC HIỆN KIỂM CHỨNG (NOT_TESTED). Chiến dịch thực nghiệm V3 tập trung đánh giá hiệu năng biểu diễn trên phân vùng cố định của tập HDFS, chưa thực thi các bài kiểm thử loại bỏ đặc trưng đường tắt hoặc đánh giá dưới sự trôi dạt phân phối theo thời gian thực.

Thứ tư, về Giả thuyết H4 (Weak-Label Evidence Allocation & Administrator-Noise Robustness) - Trạng thái: CHƯA THỰC HIỆN KIỂM CHỨNG (NOT_TESTED). Mô hình Attention-MIL (Stage B) đã được định nghĩa về mặt kiến trúc lý thuyết nhưng chưa tiến hành huấn luyện thực nghiệm với nhân giám sát mức thô.

Thứ năm, về Giả thuyết H5 (Controlled Linkability & Utility-Privacy Frontier) - Trạng thái: CHƯA THỰC HIỆN KIỂM CHỨNG (NOT_TESTED).

Cơ chế mã giả danh theo phiên được cài đặt tại tầng tiền xử lý, nhưng các kiểm nghiệm tấn công suy luận thành viên (MIA) và xác lập đường biên Pareto quyền riêng tư chưa được đo kiểm thực nghiệm.

Thứ sáu, về Yêu cầu kỹ thuật vận hành ER1 (Bounded Operational Resource Feasibility) - Trạng thái: QUAN SÁT BỘ NHỚ CỤC BỘ MỘT PHẦN (PARTIAL_PRELIMINARY_MEMORY_EVIDENCE). Mức tiêu thụ bộ nhớ GPU VRAM duy trì ổn định dưới 550 MB trong toàn bộ các đợt thực nghiệm; các chỉ tiêu về thông lượng dòng và độ trễ xử lý streaming thuộc phạm vi triển khai mở rộng.

Kiểm toán tính thao tác hóa ngưỡng phương sai chống sụp đổ: Các giá trị phương sai biểu diễn ẩn $\text{Var}(z)$ ghi nhận trong Bảng 3.6 (trung bình Sequence: 0.005462; trung bình Multi-View: 0.006069) nằm dưới ngưỡng 0.01000 ban đầu. Tuy nhiên, kiểm toán phương pháp luận xác nhận: ANTI_COLLAPSE_OPERATIONALIZATION = AMBIGUOUS_ACROSS_LEGACY_AND_V3_EXTRACTION. Nguyên nhân là do phương sai trong tài liệu tiền đăng ký cũ được đo lường dưới đường dẫn chèn ngẫu nhiên mã <MASK>, trong khi giao thức V3 đo lường trên các vector biểu diễn sạch không bị che. Nghiên cứu báo cáo minh bạch các giá trị phương sai thực tế dưới góc độ mô tả định lượng và không sử dụng ngưỡng 0.01000 cũ làm tiêu chí phán quyết độc lập về hiện tượng sụp đổ biểu diễn.

Kiểm toán tính toàn vẹn khôi phục huấn luyện Seed 999: Đợt chạy Seed 999 của mô hình Multi-View trải qua hai lần tạm dừng an toàn và tiếp tục huấn luyện từ checkpoint lưu trữ. Kiểm toán xác nhận: SEED999_RESUME_INTEGRITY = PARTIAL_STATE_RESUME_WITH_DETERMINISTIC_RNG_RECONSTRUCTION. Toàn bộ trọng số mô hình (model_state_dict), trạng thái bộ tối ưu (optimizer_state_dict), bộ điều phối tốc độ học (scheduler_state_dict), bước tối ưu toàn cục (global_step) và trạng thái dừng sớm đều được nạp lại đầy đủ 100%. Yếu tố 'partial-state' thuần túy bắt nguồn từ việc trạng thái RNG của PyTorch không được tuần tự hóa trong checkpoint mà được tái tạo xác định

qua generator. Nghiên cứu phân loại Seed 999 là SEED999_CONFIRMATORY_STATUS = CONFIRMATORY_WITH_DOCUMENTED_PROTOCOL_DEVIATION, công khai minh bạch sai lệch thủ tục này thay vì tuyên bố là khôi phục toàn phần (full-state resume).

3.3.3. *Phân tích cơ chế và các giả thuyết giải thích kết quả âm tính H2*

Trong nghiên cứu khoa học thực nghiệm, kết quả âm tính (negative result) mang giá trị tri thức học thuật quan trọng, giúp làm sáng tỏ ranh giới ứng dụng của các cơ chế lý thuyết. Việc mô hình đa góc nhìn không vượt trội hơn mô hình đơn chuỗi trên tập dữ liệu HDFS mở ra ba giả thuyết giải thích cơ chế cần được kiểm chứng trong các nghiên cứu tiếp theo:

- **1.** Giả thuyết 1: Đặc tính phân tách của chuỗi mẫu sự kiện HDFS. Dưới giao thức thực nghiệm hiện tại, nhánh Transformer đơn chuỗi đã khai thác hiệu quả tín hiệu phân tách từ các chuỗi định danh sự kiện (Event Templates) và đạt AP = 1.0000 trên tập Kiểm định cố định. Đây là giả thuyết giải thích về đặc tính dữ liệu, cần được kiểm chứng thêm qua các bài kiểm thử độ phức tạp trên các tập dữ liệu khác.
- **2.** Giả thuyết 2: Sự đánh đổi điều hòa đa góc nhìn (Multi-view Regularization Trade-off). Hàm mất mát giống hàng VICReg trên không gian chiếu đồng thời tối ưu ba mục tiêu: bất biến khoảng cách, duy trì phương sai và phi tương quan hiệp phương sai. Cơ chế điều hòa phức tạp này có thể đã tạo ra áp lực nén không gian biểu diễn, làm giảm độ sắc nét của các đặc trưng phân loại an ninh so với khi nhánh chuỗi được tối ưu hóa tự do.
- **3.** Giả thuyết 3: Tính dị thể và giới hạn thông tin bổ sung của đồ thị HDFS. Các sự kiện trong cùng một phiên khối HDFS chủ yếu xoay quanh các thao tác đọc/ghi luồng khối dữ liệu tiêu chuẩn. Cấu trúc đồ thị thời gian của các phiên này có thể không cung cấp nhiều thông tin quan hệ trực giao (orthogonal signal) mới so với thứ tự xuất hiện của chuỗi sự kiện.

Nghiên cứu nhấn mạnh: ba luận điểm trên thuần túy là các giả thuyết khoa học mở đường cho các thực nghiệm cắt bỏ (ablation) trong tương lai, tuyệt đối không được xem là các kết luận nhân quả đã được chứng minh.

3.4. Khả năng ứng dụng thực tế, giới hạn và hướng phát triển

3.4.1. Khả năng tích hợp vận hành trong trung tâm điều hành an ninh mạng SOC

Mô hình biểu diễn đồ thị thời gian mở ra hai tiềm năng ứng dụng cụ thể trong công tác giám sát an ninh mạng:

Thứ nhất, hỗ trợ giảm tải cảnh báo. Việc biểu diễn các thực thể hệ thống theo chuỗi tương tác thời gian liên tục mở ra khả năng thiết lập các cụm sự kiện cảnh báo đơn lẻ có liên đới phụ thuộc thực thi theo thời gian, hỗ trợ chuyên viên phân tích theo dõi ngữ cảnh sự cố theo đồ thị tương tác.

Thứ hai, hỗ trợ truy vết sự cố. Vector biểu diễn trạng thái động của các nút thực thể có thể được sử dụng để đối chiếu thứ tự tương tác theo thời gian, hỗ trợ công tác truy vết nguồn gốc trong các tình huống phân tích điều tra số.

3.4.2. Các giới hạn thực nghiệm và hướng nghiên cứu tiếp theo

Nghiên cứu ghi nhận một cách trung thực và đầy đủ tám ranh giới giới hạn thực nghiệm cốt lõi của công trình:

- **1. Quy mô hạt giống xác nhận:** Chiến dịch xác nhận triển vọng V3 được thực hiện trên 3 cặp hạt giống ngẫu nhiên ($N = 3$: Seeds 42, 7, 999). Cỡ mẫu này đủ để xác định sự vi phạm biên không thua kém đã tiền đăng ký trong phạm vi đối chứng, nhưng chưa cho phép thực hiện các phép kiểm định suy diễn thống kê quy mô lớn.
- **2. Giới hạn nhánh đơn đồ thị (Graph-Only):** Bộ ba mô hình đồ thị xác nhận triển vọng chưa được huấn luyện do rào cản chi phí tính toán phần cứng (~114 giờ GPU danh định). Các đối chiếu với nhánh đồ thị chỉ mang giá trị tham chiếu khảo sát lịch sử.

- **3. Trạng thái tập Kiểm thử (Sealed Test):** Các biến kiểm soát chiến dịch ghi nhận $\text{test_opened} = \text{false}$ và $\text{test_reads} = 0$, cho thấy tập Kiểm thử chưa từng được truy cập trong chiến dịch này. Toàn bộ các chỉ số hiệu năng trong báo cáo được đo đạc trên tập Kiểm định (Validation split).
- **4. Bất tương thích độ mịn mục tiêu H1:** Độ mịn nhãn tham số ở cấp token $[L_i, 4]$ không tương thích với biểu diễn gộp cấp phiên $z \in \mathbb{R}^{128}$, khiến giả thuyết H1 chưa được kiểm định trực tiếp theo phát biểu ban đầu.
- **5. Nhập nhằng thao tác hóa ngưỡng chống sụp đổ:** Ngưỡng phương sai $\text{Var}(z) = 0.01000$ ban đầu được đo lường dưới cơ chế che ngẫu nhiên $\langle \text{MASK} \rangle$ cũ, không tương thích trực tiếp với quy trình trích xuất biểu diễn sạch của giao thức V3.
- **6. Sai lệch giao thức khôi phục Seed 999:** Toàn bộ trọng số mô hình và trạng thái tối ưu được nạp lại đầy đủ; sai lệch thủ tục bắt nguồn từ việc thiếu trạng thái RNG tuần tự hóa và phải tái tạo xác định qua generator.
- **7. Phạm vi thực nghiệm trên tập dữ liệu HDFS:** Toàn bộ kết luận định lượng thuộc về tập dữ liệu chuẩn HDFS với các đặc trưng cấu trúc riêng biệt; nghiên cứu không đưa ra bất kỳ tuyên bố tổng quát hóa nào sang các tập dữ liệu khác như DARPA TC hay LANL khi chưa có thực nghiệm trực tiếp.
- **8. Các cơ chế chưa kiểm chứng thực nghiệm:** Các thành phần lý thuyết như Attention-MIL (Stage B), kiểm chuẩn tấn công quyền riêng tư (MIA, Model Inversion) và đánh giá trôi dạt phân phối (H3, H4, H5) mới dừng ở mức thiết kế kiến trúc, chưa có dữ liệu đo đạc thực tế.

KẾT LUẬN

Báo cáo chuyên đề chuyên sâu đã hoàn thành việc thiết lập khung phương pháp luận, xây dựng hạ tầng thực nghiệm và hoàn tất quy trình đánh giá chuẩn hóa V3 đóng băng hạ nguồn cho mô hình biểu diễn đặc trưng log đa góc nhìn kết hợp chuỗi thời gian và đồ thị nguồn gốc. Công trình tuân thủ nghiêm cần các nguyên tắc liên chính học thuật: phân định rõ ràng giữa kết quả quan sát trực tiếp và suy diễn khoa học, công khai minh bạch các kết quả âm tính và các sai lệch giao thức thực nghiệm.

Các kết quả chính và trạng thái khoa học của công trình được tổng hợp như sau:

- **1.** Về phương pháp luận và tích hợp kiến trúc: Chuyên đề đã đề xuất khung đặc tả Hợp đồng Biểu diễn (Representation Contract) phân định ranh giới chặt chẽ giữa tầng trích xuất đặc trưng và tầng phát hiện an ninh hạ nguồn; thiết kế kiến trúc tích hợp giữa chuỗi ngữ nghĩa Transformer và đồ thị phụ thuộc thời gian liên tục TemporalGraphViewEncoder kết hợp cơ chế giống hàng tự giám sát VICReg.
- **2.** Về kết quả thực nghiệm chuẩn hóa V3: Dưới giao thức đầu dò tuyến tính đóng băng trên tập Kiểm định cố định (7.500 phiên HDFS), mô hình đơn chuỗi SEQUENCE_ONLY đạt $AP = 1.0000$ và $ROC-AUC = 1.0000$ trên cả 3 hạt giống; mô hình đa góc nhìn MULTI_VIEW_ALIGNED đạt AP trung bình 0.6608 ± 0.0885 và $ROC-AUC$ trung bình 0.8573 ± 0.1204 (độ lệch chuẩn mẫu).
- **3.** Về trạng thái kiểm chứng các giả thuyết khoa học: Giả thuyết H2 không được hỗ trợ trong phạm vi đối chứng trực tiếp với Sequence-Only trên tập HDFS (độ suy giảm hiệu năng trung bình $\Delta AP = -0.3392$, vi phạm biên không thua kém tiền đăng ký $\delta \geq -0.02$ trên toàn bộ 3 cặp hạt giống); kiểm tra độ nhạy xác nhận kết quả H2 không thay đổi khi che tham số đầu vào của Sequence trong bài kiểm tra này. Giả thuyết H1 chưa thể đánh giá

trực tiếp do bất tương thích độ mịn giữa mục tiêu tham số cấp token và biểu diễn gộp cấp phiên, trong khi kiểm thử che đầu vào đóng băng ghi nhận độ nhạy dịch chuyển vector biểu diễn z nhưng không làm giảm AP hạ nguồn trên tập HDFS. Các kết quả của nhánh đơn đồ thị được bảo lưu dưới vai trò tham chiếu khảo sát lịch sử; các giả thuyết H3, H4, H5 được bảo lưu cho các giai đoạn nghiên cứu tiếp theo.

- **4.** Về quản trị dữ liệu và quy trình: Các biến kiểm soát chiến dịch ghi nhận trạng thái chưa truy cập của tập Kiểm thử (`test_opened = false`, `test_reads = 0`); toàn bộ các bước tối ưu hóa được kế toán minh bạch (82.200 bước probe, 0 bước backbone); sai lệch giao thức khôi phục Seed 999 do thiếu trạng thái RNG tuần tự hóa được công bố chi tiết.

Trên cơ sở các bằng chứng thu được, ba định hướng nghiên cứu tiếp theo bao gồm: (1) Thiết kế cơ chế biểu diễn tham số ở cấp độ mịn phù hợp (token-level representation probing) để kiểm chứng trực tiếp giả thuyết H1; (2) Khảo sát các kỹ thuật điều hòa đa góc nhìn thích nghi nhằm kiểm soát hiện tượng nén biểu diễn và đánh giá trên các tập dữ liệu có cấu trúc đồ thị phức tạp hơn như DARPA TC; và (3) Đánh giá trên tập kiểm thử chưa mở khi có sự đồng thuận phương pháp luận trong các nghiên cứu tương lai.

Tài liệu tham khảo

- [1] J. Zhu, S. He, J. Liu, P. He, Q. Xie, Z. Zheng and M. R. Lyu, "Tools and Benchmarks for Automated Log Parsing," in *2019 IEEE/ACM 41st International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP)*, Montreal, QC, Canada, 2019.
- [2] Z. Jiang, J. Liu, J. Huang, Y. Li, Y. Huo, J. Gu, Z. Chen, J. Zhu and M. R. Lyu, "A Large-Scale Evaluation for Log Parsing Techniques: How Far Are We?," in *Proceedings of the 33rd ACM SIGSOFT International Symposium on Software Testing and Analysis (ISSTA 2024)*, Vienna, Austria, 2024.
- [3] M. A. Inam, Y. Chen, A. Goyal, J. Liu, J. Mink, N. Michael, S. Gaur, A. Bates and W. U. Hassan, "SoK: History is a Vast Early Warning System: Auditing the Provenance of System Intrusions," in *2023 IEEE Symposium on Security and Privacy (SP)*, San Francisco, CA, USA, 2023.

- [4] N. Michael, J. Mink, J. Liu, S. Gaur, W. U. Hassan and A. Bates, "On the Forensic Validity of Approximated Audit Logs," in *Proceedings of the 36th Annual Computer Security Applications Conference (ACSAC 2020)*, Austin, TX, USA, 2020.
- [5] J. Liu, M. A. Inam, A. Goyal, A. Riddle, K. Westfall and A. Bates, "What We Talk About When We Talk About Logs: Understanding the Effects of Dataset Quality on Endpoint Threat Detection Research," in *2025 IEEE Symposium on Security and Privacy (SP)*, San Francisco, CA, USA, 2025.
- [6] MITRE Corporation, "MITRE ATT&CK: Enterprise Tactics and Techniques Matrix (v19.1)," 2026.
- [7] M. Zipperle, F. Gottwalt, E. Chang and T. S. Dillon, "Provenance-based Intrusion Detection Systems: A Survey," vol. 55, no. 7, pp. 1-36, 2023.
- [8] M. Russinovich and T. Garnier, "Sysmon (System Monitor) - Sysinternals," 2026.
- [9] J. Zhu, S. He, P. He, J. Liu and M. R. Lyu, "Loghub: A Large Collection of System Log Datasets for AI-driven Log Analytics," in *2023 IEEE 34th International Symposium on Software Reliability Engineering (ISSRE)*, Florence, Italy, 2023.
- [10] D. Arp, E. Quiring, F. Pendlebury, A. Warnecke, F. Pierazzi, C. Wressnegger, L. Cavallaro and K. Rieck, "Dos and Don'ts of Machine Learning in Computer Security," in *Proceedings of the 31st USENIX Security Symposium*, Boston, MA, USA, 2022.
- [11] X. Han, T. Pasquier, A. Bates, J. Mickens and M. Seltzer, "UNICORN: Runtime Provenance-Based Detector for Advanced Persistent Threats," in *Proceedings of the Network and Distributed System Security Symposium (NDSS 2020)*, San Diego, CA, USA, 2020.
- [12] A. Bardes, J. Ponce and Y. LeCun, "VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning," in *Proceedings of the 10th International Conference on Learning Representations (ICLR 2022)*, 2022.
- [13] J. Zbontar, L. Jing, I. Misra, Y. LeCun and S. Deny, "Barlow Twins: Self-Supervised Learning via Redundancy Reduction," in *Proceedings of the 38th International Conference on Machine Learning (ICML 2021)*, 2021.
- [14] D. A. R. P. A. DARPA/I2O, "Transparent Computing Engagement 3 Data Release," 2018.
- [15] D. A. R. P. A. DARPA/I2O, "Transparent Computing Engagement 5 Data Release," 2020.
- [16] A. D. Kent, "Comprehensive, Multi-Source Cyber-Security Events," 2015.
- [17] W. Xu, L. Huang, A. Fox, D. Patterson and M. I. Jordan, "Detecting Large-Scale System Problems by Mining Console Logs," in *Proceedings of the ACM SIGOPS 22nd Symposium on Operating Systems Principles (SOSP '09)*, Big Sky, MT, USA, 2009.

- [18] R. Shokri, M. Stronati, C. Song and V. Shmatikov, "Membership Inference Attacks Against Machine Learning Models," in *Proceedings of the 38th IEEE Symposium on Security and Privacy (S&P 2017)*, San Jose, CA, USA, 2017.
- [19] M. Fredrikson, S. Jha and T. Ristenpart, "Model Inversion Attacks that Exploit Confidence Information and Basic Countermeasures," in *Proceedings of the 22nd ACM SIGSAC Conference on Computer and Communications Security (CCS '15)*, Denver, CO, USA, 2015.
- [20] J. P. Near, D. Darais, N. Lefkovitz and G. S. Howarth, "Guidelines for Evaluating Differential Privacy Guarantees," 2025.
- [21] T. Chen, S. Kornblith, M. Norouzi and G. Hinton, "A Simple Framework for Contrastive Learning of Visual Representations," in *Proceedings of the 37th International Conference on Machine Learning (ICML 2020)*, 2020.
- [22] J.-G. Lou, Q. Fu, S. Yang, Y. Xu and J. Li, "Mining Invariants from Console Logs for System Problem Detection," in *Proceedings of the 2010 USENIX Annual Technical Conference (USENIX ATC 10)*, Boston, MA, USA, 2010.
- [23] M. Du, F. Li, G. Zheng and V. Srikumar, "DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning," in *Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS '17)*, Dallas, TX, USA, 2017.
- [24] H. Guo, S. Yuan and X. Wu, "LogBERT: Log Anomaly Detection via BERT," in *Proceedings of the International Joint Conference on Neural Networks (IJCNN 2021)*, Shenzhen, China, 2021.
- [25] V.-H. Le and H. Zhang, "Log-based Anomaly Detection Without Log Parsing," in *Proceedings of the 36th IEEE/ACM International Conference on Automated Software Engineering (ASE 2021)*, Melbourne, Australia, 2021.
- [26] W. Meng, Y. Liu, Y. Zhu, S. Zhang, D. Pei, Y. Liu, Y. Chen, R. Zhang, S. Tao, P. Sun and R. Zhou, "LogAnomaly: Unsupervised Detection of Sequential and Quantitative Anomalies in Unstructured Logs," in *Proceedings of the 28th International Joint Conference on Artificial Intelligence (IJCAI 2019)*, Macao, China, 2019.
- [27] S. Nedelkoski, J. Bogatinovski, A. Acker, J. Cardoso and O. Kao, "Self-Attentive Classification-Based Anomaly Detection in Unstructured Logs," in *Proceedings of the 2020 IEEE International Conference on Data Mining (ICDM 2020)*, Sorrento, Italy, 2020.
- [28] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser and I. Polosukhin, "Attention Is All You Need," in *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 2017.
- [29] Z. Cheng, Q. Lv, J. Liang, Y. Wang, D. Sun, T. Pasquier and X. Han, "KAiOS: Practical Intrusion Detection and Investigation using Whole-

- system Provenance," in *Proceedings of the 45th IEEE Symposium on Security and Privacy (S&P 2024)*, San Francisco, CA, USA, 2024.
- [30] S. Li, F. Dong, X. Xiao, H. Wang, F. Shao, J. Chen, Y. Guo, X. Chen and D. Li, "NODLINK: An Online System for Fine-Grained APT Attack Detection and Investigation," in *Proceedings of the Network and Distributed System Security Symposium (NDSS 2024)*, San Diego, CA, USA, 2024.
- [31] Z. Jia, Y. Xiong, Y. Nan, Y. Zhang, J. Zhao and M. Wen, "MAGIC: Detecting Advanced Persistent Threats via Masked Graph Representation Learning," in *Proceedings of the 33rd USENIX Security Symposium*, Philadelphia, PA, USA, 2024.
- [32] B. Jiang, T. Bilot, N. E. Madhoun, K. A. Agha, A. Zouaoui, S. Iqbal, X. Han and T. Pasquier, "ORTHRUS: Achieving High Quality of Attribution in Provenance-based Intrusion Detection Systems," in *Proceedings of the 34th USENIX Security Symposium*, Seattle, WA, USA, 2025.
- [33] J. Zeng, C. Zhang and Z. Liang, "PalanTír: Optimizing Attack Provenance with Hardware-enhanced System Observability," in *Proceedings of the 2022 ACM SIGSAC Conference on Computer and Communications Security (CCS '22)*, Los Angeles, CA, USA, 2022.
- [34] T. Bilot, B. Jiang, Z. Li, N. E. Madhoun, K. A. Agha, A. Zouaoui and T. Pasquier, "Sometimes Simpler is Better: A Comprehensive Analysis of State-of-the-Art Provenance-Based Intrusion Detection Systems," in *Proceedings of the 34th USENIX Security Symposium*, Seattle, WA, USA, 2025.
- [35] L. Guerra, T. Chapuis, G. Duc, P. Mozharovskiy and V.-T. Nguyen, "How Benchmarks and Evaluation Protocols Shape Conclusions in Provenance-Based Intrusion Detection," 2026.
- [36] K. Oono and T. Suzuki, "Graph Neural Networks Exponentially Lose Expressive Power for Node Classification," in *8th International Conference on Learning Representations (ICLR 2020)*, 2020.
- [37] U. Alon and E. Yahav, "On the Bottleneck of Graph Neural Networks and its Practical Implications," in *Proceedings of the 9th International Conference on Learning Representations (ICLR 2021)*, 2021.
- [38] T. T. T. Nguyễn, "Phát hiện tấn công APT dựa trên Graph Learning (Phần 2)," 2026.
- [39] D. Xu, C. Ruan, E. Korpeoglu, S. Kumar and K. Achan, "Inductive Representation Learning on Temporal Graphs," in *Proceedings of the 8th International Conference on Learning Representations (ICLR 2020)*, 2020.
- [40] E. Rossi, B. Chamberlain, F. Frasca, D. Eynard, F. Monti and M. Bronstein, "Temporal Graph Networks for Deep Learning on Dynamic Graphs," in *ICML 2020 Workshop on Graph Representation Learning / arXiv:2006.10637*, 2020.

- [41] A. van den Oord, Y. Li and O. Vinyals, "Representation Learning with Contrastive Predictive Coding," 2018.
- [42] C. Zhang, Z. Han, Y. Cui, H. Fu, J. T. Zhou and Q. Hu, "CPM-Nets: Cross Partial Multi-View Networks," in *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*, 2019.
- [43] T. Yu, S. Kumar, A. Gupta, S. Levine, K. Hausman and C. Finn, "Gradient Surgery for Multi-Task Learning," in *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 2020.
- [44] M. Ilse, J. M. Tomczak and M. Welling, "Attention-based Deep Multiple Instance Learning," in *Proceedings of the 35th International Conference on Machine Learning (ICML 2018)*, Stockholm, Sweden, 2018.