

BAN CƠ YẾU CHÍNH PHỦ
HỌC VIỆN KỸ THUẬT MẬT MÃ



BÁO CÁO MÔN HỌC
CHUYÊN ĐỀ CHUYÊN SÂU

**NGHIÊN CỨU PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC
TRÙNG ĐỐI VỚI DỮ LIỆU LOGS TRONG PHÁT
HIỆN TẤN CÔNG**

Ngành: An toàn thông tin
Mã số: 7.48.02.02

Sinh viên thực hiện:

Đoàn Ngọc Hoàng Minh – AT180632

Giảng viên hướng dẫn:

Ths. Nguyễn Thị Thu Thủy

Khoa An toàn thông tin – Học viện Kỹ thuật mật mã

Hà Nội, 2026

BAN CƠ YẾU CHÍNH PHỦ
HỌC VIỆN KỸ THUẬT MẬT MÃ



BÁO CÁO MÔN HỌC
CHUYÊN ĐỀ CHUYÊN SÂU

**NGHIÊN CỨU PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC
TRUNG ĐỐI VỚI DỮ LIỆU LOGS TRONG PHÁT
HIỆN TẤN CÔNG**

Ngành: An toàn thông tin
Mã số: 7.48.02.02

Sinh viên thực hiện:

Đoàn Ngọc Hoàng Minh – AT180632

Giảng viên hướng dẫn:

Ths. Nguyễn Thị Thu Thủy

Khoa An toàn thông tin – Học viện Kỹ thuật mật mã

Hà Nội, 2026

MỤC LỤC

MỤC LỤC.....	4
DANH MỤC HÌNH VẼ	6
DANH MỤC BẢNG.....	7
Lời nói đầu.....	8
Chương 1. TỔNG QUAN VỀ PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC TRƯNG DỮ LIỆU LOG VÀ THÁCH THỨC BẢO TOÀN NGŨ CẢNH AN TOÀN	11
1.1. Bài toán biểu diễn log trong phát hiện tấn công đa giai đoạn	11
1.1.1. <i>Không gian dữ liệu log doanh nghiệp: tốc độ cao, mất cân bằng cực đoạn và phân phối biến đổi.....</i>	<i>11</i>
1.1.2. <i>Hành vi tấn công đa giai đoạn và ánh xạ đa nhãn MITRE ATT&CK.....</i>	<i>14</i>
1.1.3. <i>Các mức biểu diễn dữ liệu và Hợp đồng Biểu diễn (Representation Contract)</i>	<i>17</i>
1.2. Phân tích so sánh các nhóm phương pháp hiện đại	21
1.2.1. <i>Phương pháp thống kê và cú pháp: Event Count, Frequency, Entropy và Template Features.....</i>	<i>22</i>
1.2.2. <i>Phương pháp semantic-sequential: Embeddings, Self-Supervised Learning, Transformer và Parsing-Free.....</i>	<i>24</i>
1.2.3. <i>Đồ thị nguồn gốc và Graph Representation Learning</i>	<i>26</i>
1.3. Các khoảng trống nghiên cứu cốt lõi	29
1.3.1. <i>Khoảng trống 1: Mất mát ngữ nghĩa an ninh trong quá trình trừu tượng hóa tham số.....</i>	<i>29</i>
1.3.2. <i>Khoảng trống 2: Bất đồng bộ và suy thoái trong giống hàng biểu diễn đa góc nhìn</i>	<i>30</i>
1.3.3. <i>Khoảng trống 3: Rò rỉ thông tin quy trình, học đường tắt và trôi dạt biểu diễn.....</i>	<i>31</i>
1.3.4. <i>Khoảng trống 4: Gán nhãn mức thô, phân bổ bằng chứng yếu và nhiễu quản trị viên.....</i>	<i>32</i>
1.3.5. <i>Khoảng trống 5: Đánh đổi giữa bảo toàn liên kết an ninh và rủi ro quyền riêng tư</i>	<i>33</i>
Chương 2. PHƯƠNG PHÁP BIỂU DIỄN ĐẶC TRƯNG LOG ĐA GÓC NHÌN BẢO TOÀN NGŨ CẢNH AN TOÀN	35
2.1. Hình thức hóa bài toán và giới hạn xử lý dòng.....	35
2.1.1. <i>Biểu diễn đa góc nhìn và ranh giới Extractor–Detector</i>	<i>35</i>
2.1.2. <i>Độ phức tạp xử lý dòng với trạng thái hữu hạn</i>	<i>38</i>
2.1.3. <i>Kiến trúc tổng thể và giao diện vào/ra.....</i>	<i>40</i>
2.2. Tiền xử lý và bảo vệ dynamic parameters	42
2.2.1. <i>Parsing, Typed Canonicalization, Entity Resolution và Security-aware Parameter Retention.....</i>	<i>42</i>

2.2.2.	<i>Mô hình đe dọa quyền riêng tư và Controlled Linkability</i>	47
2.2.3.	<i>Đồng bộ thời gian và cửa sổ ngữ cảnh đa tỷ lệ</i>	50
2.3.	Trích xuất đặc trưng đa góc nhìn	53
2.3.1.	<i>Bộ trích xuất tuần tự ngữ nghĩa Transformer</i>	53
2.3.2.	<i>Xây dựng đồ thị nguồn gốc phụ thuộc thời gian và đảm bảo độ chân thực đồ thị</i>	57
2.3.3.	<i>Bộ trích xuất đồ thị động Temporal GNN</i>	60
2.4.	Giống hàng và học biểu diễn thống nhất đa góc nhìn	66
2.4.1.	<i>Giống hàng đa góc nhìn dị thể</i>	66
2.4.2.	<i>Nhận thức hành vi quản trị viên và điều hòa rủi ro</i>	72
2.4.3.	<i>Hàm mục tiêu thống nhất và phân bổ bằng chứng yếu</i>	74
2.4.4.	<i>Biểu diễn thống nhất, giao diện đầu ra và độ phức tạp</i>	80
Chương 3.	THỰC NGHIỆM, ĐÁNH GIÁ VÀ ỨNG DỤNG	83
3.1.	Thiết lập thực nghiệm và dữ liệu	83
3.1.1.	<i>Môi trường tính toán, tính tái lập và kiểm định độ bất định thống kê</i>	83
3.1.2.	<i>Hai tầng benchmark và giao thức phân chia nhân quả chống rò rỉ</i>	84
3.1.3.	<i>Hệ thống thang đo ba tầng và hàm mục tiêu huấn luyện</i>	86
3.2.	Kết quả thực nghiệm và benchmarking	87
3.2.1.	<i>Kết quả huấn luyện Stage A2 trên 5 hạt ngẫu nhiên thực nghiệm</i>	87
3.2.2.	<i>Đối sánh đặc tính phương pháp luận so với các nghiên cứu cơ sở</i>	90
3.3.	Phân tích triệt tiêu, động thái tối ưu hóa và kiểm chứng giả thuyết	91
3.3.1.	<i>Phân tích động thái tối ưu hóa và hiện tượng dừng sớm</i>	91
3.3.2.	<i>Kiểm chứng các giả thuyết khoa học tiền đăng ký</i>	91
3.4.	Khả năng ứng dụng thực tế, giới hạn và hướng phát triển	92
3.4.1.	<i>Khả năng tích hợp vận hành trong trung tâm điều hành an ninh mạng SOC</i>	92
3.4.2.	<i>Các giới hạn thực nghiệm và hướng nghiên cứu tiếp theo</i>	93
	Kết luận	94
	Tài liệu tham khảo	96

DANH MỤC HÌNH VẼ

Hình 1.1: Phân cấp các đơn vị quan sát và sự đánh đổi giữa ngữ cảnh và chi phí tính toán trong biểu diễn dữ liệu log (Nguồn: Tác giả tổng hợp)	12
Hình 1.2: Mô hình Không gian Bằng chứng Hành vi Đa chiều MITRE ATT&CK và các đặc trưng phi tuyến tính trong tấn công APT (Nguồn: Tác giả tổng hợp dựa trên MITRE ATT&CK [4] và Inam et al. [1])	15
Hình 1.3: Khung phân định ranh giới ba tầng phương pháp luận và vị trí trọng tâm của không gian vector biểu diễn z (Nguồn: Tác giả đề xuất).....	20
Hình 1.4: Bản đồ đối chiếu ba nhóm phương pháp biểu diễn log và nguồn gốc hình thành năm khoảng trống nghiên cứu cốt lõi (Nguồn: Tác giả tổng hợp)	29
Hình 2.1: Kiến trúc hai mặt phẳng (Training Plane & Inference Plane) của khung biểu diễn đặc trưng log đa góc nhìn dòng (Nguồn: Tác giả đề xuất)	41
Hình 2.2: Kiến trúc Bộ trích xuất tuần tự ngữ nghĩa Transformer và cơ chế học tự giám sát trên cửa sổ ngắn hạn (Nguồn: Tác giả đề xuất).....	57
Hình 2.3: Kiến trúc xây dựng đồ thị nguồn gốc phụ thuộc thời gian và Bộ trích xuất Temporal GNN (Nguồn: Tác giả đề xuất)	65
Hình 2.4: Sơ đồ kiến trúc Gióng hàng đa góc nhìn, Kiểm soát sụp đổ và Tổng hợp biểu diễn thống nhất (Nguồn: Tác giả đề xuất)	81

DANH MỤC BẢNG

Bảng 1.1: Phân cấp các đơn vị quan sát và mức độ hạt biểu diễn dữ liệu log	13
Bảng 1.2: Đặc tả Hợp đồng Biểu diễn (Representation Contract) cho vector đặc trưng z	19
Bảng 1.3: So sánh đối chiếu ba nhóm phương pháp biểu diễn đặc trưng log chủ đạo	28
Bảng 2.1: Chính sách RETAIN / NORMALIZE / PRIVACY-PROTECT / UNKNOWN-SAFE cho các trường của bộ sáu kiểu hóa.....	44
Bảng 2.2: Đặc tả kiến trúc và độ phức tạp tính toán của hai bộ trích xuất đặc trưng đa góc nhìn.....	65
Bảng 2.3: So sánh đối sánh các cơ chế tự giám sát đa góc nhìn trong bài toán an ninh mạng.....	68
Bảng 2.4: Kiểm toán toàn diện các khối tham số và đồ thị tối ưu hóa trong hệ thống	75

LỜI NÓI ĐẦU

Dữ liệu log là nguồn dấu vết phản ánh trực tiếp hoạt động của hệ thống thông tin. Các sự kiện như đăng nhập, tạo tiến trình, truy cập tệp, thay đổi quyền, thực hiện truy vấn hoặc thiết lập kết nối mạng đều có thể được ghi nhận bởi hệ điều hành, ứng dụng, thiết bị mạng, nền tảng đám mây và giải pháp bảo mật. Khi được thu thập và liên kết đúng cách, log cung cấp bằng chứng quan trọng cho giám sát an toàn thông tin, phát hiện tấn công, ứng cứu sự cố và điều tra số.

Tuy nhiên, giá trị của log không nằm ở số lượng bản ghi được lưu giữ mà ở khả năng chuyển chúng thành thông tin có thể phân tích. Một sự kiện đơn lẻ đôi khi đã chứa dấu hiệu nguy hiểm, chẳng hạn tiến trình PowerShell thực thi lệnh mã hóa hoặc tài khoản đặc quyền đăng nhập từ thiết bị chưa từng sử dụng. Trong nhiều trường hợp khác, từng sự kiện riêng biệt đều có vẻ hợp lệ nhưng khi kết hợp theo thời gian lại hình thành chuỗi hành vi của một cuộc tấn công, từ giành quyền truy cập, thực thi mã và duy trì hiện diện đến di chuyển ngang, điều khiển từ xa và đánh cắp dữ liệu.

Phân tích log tự động gặp nhiều khó khăn do sự khác biệt về nguồn phát sinh, cấu trúc, mức độ chi tiết và ngữ nghĩa. Log có thể tồn tại dưới dạng văn bản tự do, dữ liệu bán cấu trúc hoặc định dạng riêng của từng nền tảng. Khối lượng sự kiện thường rất lớn, trong khi tỷ lệ bản ghi liên quan đến tấn công rất nhỏ. Nhãn dữ liệu có thể thiếu, sai hoặc chỉ được cung cấp ở mức phiên. Bên cạnh đó, sự thay đổi của phần mềm, cấu hình và hành vi người dùng liên tục tạo ra những mẫu log mới, làm suy giảm hiệu quả của các mô hình được huấn luyện trên dữ liệu cố định.

Trong pipeline phát hiện tấn công, trích xuất đặc trưng quyết định những tín hiệu mà mô hình có thể quan sát. Log thô cần được chuyển thành vector, chuỗi hoặc đồ thị trước khi đưa vào thuật toán học máy. Đặc trưng có thể phản ánh mã sự kiện, từ khóa, tần suất, độ hiếm, khoảng thời gian giữa các hoạt động, nội dung ngữ nghĩa hoặc quan hệ giữa người dùng, máy chủ, tiến trình, tệp và địa chỉ mạng. Một mô hình phức tạp vẫn khó đạt hiệu quả nếu quá trình tiền xử lý đã loại bỏ các tham số mang ý nghĩa an toàn hoặc không biểu diễn được ngữ cảnh của hành vi tấn công.

Các phương pháp truyền thống như Bag of Words, n-gram, TF-IDF và đặc trưng thống kê có ưu điểm về tốc độ, chi phí và khả năng giải thích, nhưng hạn chế trong việc xử lý biến thể cú pháp và quan hệ dài hạn. Các mô hình LSTM, GRU và Transformer được phát triển để học đặc trưng trình tự và ngữ nghĩa; mạng nơ-ron đồ thị giúp mô hình hóa quan hệ giữa nhiều thực thể; học tự giám sát hỗ trợ khai thác lượng lớn log chưa gán nhãn. Mô hình ngôn ngữ lớn mở thêm khả năng chuẩn hóa và diễn giải log, nhưng vẫn chịu hạn chế về chi phí, độ trễ, tính ổn định và bảo mật dữ liệu. Vì vậy, không có một kiến trúc duy nhất phù hợp với mọi nguồn log và mọi loại tấn công.

Một thách thức kỹ thuật khác là sự phụ thuộc vào bước phân tích cú pháp. Việc chuyển log thành mẫu sự kiện giúp giảm nhiễu, nhưng có thể đồng thời loại bỏ tên tiến trình, tài khoản, địa chỉ mạng, đường dẫn hoặc đối số dòng lệnh có giá trị phát hiện. Do đó, chất lượng của phương pháp trích xuất đặc trưng cần được đánh giá không chỉ

qua khả năng khái quát hóa dữ liệu mà còn qua mức độ bảo toàn tín hiệu bảo mật và hiệu quả của tác vụ phát hiện phía sau.

Từ những vấn đề trên, đề tài “Nghiên cứu phương pháp trích xuất đặc trưng đối với dữ liệu log trong phát hiện tấn công” được thực hiện nhằm khảo sát, phân loại và đánh giá có hệ thống các phương pháp chuyển đổi log thành biểu diễn phục vụ phát hiện bất thường và tấn công mạng. Mục tiêu trọng tâm không chỉ là lựa chọn một mô hình phân loại, mà còn xác định những thông tin cần được bảo toàn, những thành phần có thể được tổng quát hóa và những quan hệ cần được mô hình hóa.

Đối tượng nghiên cứu gồm dữ liệu log từ hệ điều hành, ứng dụng, hệ thống xác thực, thiết bị mạng, giải pháp bảo mật và môi trường đám mây; các bước tiền xử lý; cùng những phương pháp hình thành đặc trưng dạng vector, chuỗi và đồ thị. Đề tài tập trung vào log dạng văn bản và dữ liệu sự kiện có cấu trúc hoặc bán cấu trúc, không đi sâu vào phân tích mã nhị phân, toàn bộ nội dung gói tin mạng hoặc xây dựng một nền tảng SIEM hoàn chỉnh.

Nghiên cứu hướng tới làm rõ vai trò của các nhóm đặc trưng thống kê, từ vựng, ngữ nghĩa, thời gian và đồ thị; ảnh hưởng của parsing, phân phiên và chia cửa sổ; khả năng xử lý mẫu sự kiện chưa từng xuất hiện; cũng như sự đánh đổi giữa độ chính xác, độ trễ, tài nguyên và khả năng giải thích. Giả thuyết được đặt ra là không một nhóm đặc trưng đơn lẻ nào có thể phản ánh đầy đủ bản chất của tấn công. Việc bảo toàn tham số có ý nghĩa an toàn và kết hợp có chọn lọc nhiều góc nhìn có khả năng tạo ra biểu diễn toàn diện và ổn định hơn.

Đề tài sử dụng phương pháp nghiên cứu tài liệu để thu thập và đối chiếu các công trình liên quan; phương pháp phân tích, tổng hợp để xây dựng hệ thống phân loại và xác định khoảng trống nghiên cứu; phương pháp mô hình hóa để biểu diễn pipeline xử lý log; cùng phương pháp thực nghiệm để so sánh các nhóm đặc trưng trong điều kiện kiểm soát. Hiệu quả được đánh giá bằng các chỉ số phù hợp với dữ liệu mất cân bằng, đồng thời xem xét cảnh báo sai, độ trễ, tài nguyên và khả năng giải thích.

Về phương diện khoa học, đề tài hướng tới thiết lập hệ thống phân loại đa chiều cho các phương pháp trích xuất đặc trưng, làm rõ ranh giới giữa phát hiện bất thường hệ thống và phát hiện tấn công, đồng thời xác định yêu cầu đối với một biểu diễn log có khả năng bảo toàn ngữ nghĩa, thời gian và quan hệ. Về khía cạnh thực tiễn, kết quả nghiên cứu hỗ trợ việc lựa chọn kỹ thuật phù hợp với từng nguồn dữ liệu và điều kiện triển khai, làm cơ sở xây dựng pipeline phân tích cho SIEM, SOC, EDR và hoạt động săn tìm mối đe dọa.

Báo cáo chuyên đề được cấu trúc thành ba chương trọng tâm:

Chương 1. Tổng quan về phương pháp trích xuất đặc trưng dữ liệu log và thách thức bảo toàn ngữ cảnh an toàn: Trình bày bài toán biểu diễn dữ liệu log doanh nghiệp, hành vi tấn công đa giai đoạn trên ma trận MITRE ATT&CK (Phiên bản Enterprise v19.1, 12/05/2026), khung Hợp đồng Biểu diễn (Representation Contract), phân tích

đối chiếu ba nhóm phương pháp hiện đại và xác lập 5 khoảng trống nghiên cứu cốt lõi tương ứng với 5 câu hỏi nghiên cứu (RQ1–RQ5).

Chương 2. Đề xuất phương pháp trích xuất đặc trưng đa view bảo toàn ngữ cảnh và nhận thức quyền riêng tư: Trình bày kiến trúc biểu diễn đa góc nhìn kết hợp chuỗi sự kiện và đồ thị nguồn gốc, cơ chế giống hàng tiềm ẩn chống sụp đổ biểu diễn, phân bổ bằng chứng yếu cho nhiều quản trị viên và cơ chế bảo toàn liên kết có kiểm soát quyền riêng tư.

Chương 3. Thực nghiệm, đánh giá và ứng dụng: Mô tả thiết lập thực nghiệm trên các bộ dữ liệu benchmark chuẩn (DARPA TC, LANL, HDFS, BGL), đánh giá định lượng hiệu năng phát hiện, phân tích độ bền vững trước trôi dạt dữ liệu, kiểm chứng khả năng phòng chống tấn công suy luận quyền riêng tư và thảo luận khả năng tích hợp trong hệ thống SOC.

CHƯƠNG 1. TỔNG QUAN VỀ PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC TRƯNG DỮ LIỆU LOG VÀ THÁCH THỨC BẢO TOÀN NGỮ CẢNH AN TOÀN

1.1. Bài toán biểu diễn log trong phát hiện tấn công đa giai đoạn


Trong các Trung tâm Điều hành An ninh mạng (Security Operations Center, SOC) hiện đại, dữ liệu nhật ký hệ thống và nhật ký kiểm toán đóng vai trò là nguồn bằng chứng trung tâm phục vụ phát hiện, điều tra và ứng phó các chiến dịch tấn công có chủ đích (Advanced Persistent Threats, APT) [1]. Khác với văn bản ngôn ngữ tự nhiên thông thường hoặc tín hiệu thị giác máy tính, dữ liệu log sở hữu cấu trúc bán cấu trúc, mang tính phụ thuộc thời gian nghiêm ngặt, phản ánh các quan hệ phụ thuộc thực thi giữa các tiến trình và tài nguyên hệ điều hành, đồng thời chứa đựng các ngữ nghĩa an ninh đặc thù [2], [3]. Mục 1.1 tập trung hình thức hóa bài toán biểu diễn đặc trưng log phục vụ phát hiện tấn công đa giai đoạn, phân tích bản chất không gian dữ liệu doanh nghiệp, xác lập mô hình hành vi phi tuyến tính trên ma trận MITRE ATT&CK [4] và thiết lập khung Hợp đồng Biểu diễn nhằm bảo toàn các bất biến an toàn cho không gian vector đặc trưng.

1.1.1. Không gian dữ liệu log doanh nghiệp: tốc độ cao, mất cân bằng cực đoan và phân phối biến đổi

Không gian dữ liệu nhật ký trong môi trường mạng doanh nghiệp được tổng hợp từ ba nhóm nguồn telemetry chính với cấu trúc và định dạng không đồng nhất [1], [5]. Nhóm thứ nhất là nhật ký kiểm toán máy chủ và viễn trắc nguồn gốc (Host Audit & Provenance Telemetry). Trên các hệ thống Linux, các cơ chế thu thập viễn trắc nguồn gốc và kiểm toán mức nhân (như Linux Auditd hoặc eBPF) ghi nhận các sự kiện lời gọi hệ thống (system calls) — tiêu biểu như khởi tạo tiến trình (execve), thao tác tệp tin (open, openat, unlink) và kết nối socket mạng (connect, accept) — để phục vụ điều tra số và xây dựng đồ thị quan hệ nhân quả [2], [1]. Trong khi đó, trên môi trường Windows, Microsoft Sysinternals Sysmon cung cấp viễn trắc an ninh mức hệ điều hành

thông qua các sự kiện định danh chuẩn hóa theo đặc tả kỹ thuật chính thức của Russinovich & Garnier [41], tiêu biểu gồm: khởi tạo tiến trình (ProcessCreate - Event ID 1), kết nối mạng (NetworkConnect - Event ID 3), nạp thư viện động (ImageLoaded - Event ID 7), tạo tệp tin (FileCreate - Event ID 11), và thao tác cấu hình registry (RegistryEvent - Event ID 13). Nhóm thứ hai là nhật ký luồng mạng (Network Flow & Protocol Logs), được thu thập từ Zeek, Suricata hoặc NetFlow/IPFIX, cung cấp siêu dữ liệu kết nối giữa các nút mạng, giao dịch DNS, chứng chỉ TLS/SSL và thông lượng gói tin. Nhóm thứ ba là nhật ký ứng dụng và dịch vụ phân tán (Application & Distributed System Logs), phát sinh từ máy chủ web (Apache), hệ thống tệp phân tán (HDFS) cùng các dịch vụ tính toán cụm thuộc bộ benchmark LogHub [6], [7].

Tính dị thể sâu sắc của dữ liệu đặt ra bài toán khoa học về việc lựa chọn đơn vị quan sát (Unit of Observation) phù hợp cho mô hình học biểu diễn, như được hệ thống hóa trực quan trong Hình 1.1 và chi tiết hóa trong Bảng 1.1:



Hình 1.1: Phân cấp các đơn vị quan sát và sự đánh đổi giữa ngữ cảnh và chi phí tính toán trong biểu diễn dữ liệu log (Nguồn: Tác giả tổng hợp)

Bảng 1.1: Phân cấp các đơn vị quan sát và mức độ hạt biểu diễn dữ liệu log

Mức độ hạt	Đơn vị quan sát	Dữ liệu đại diện	Ưu điểm cốt lõi	Thách thức và Mất mát ngữ nghĩa
Mức từ tố (Token)	Chuỗi con, từ khóa rời rạc	Từ khóa tĩnh, địa chỉ IP, mã lỗi hex	Dễ dàng vector hóa bằng kỹ thuật nhúng từ vụng	Mất liên kết cấu trúc cú pháp và quan hệ trường
Mức sự kiện (Event)	Một dòng log đơn lẻ	Bản ghi telemetry tại thời điểm t	Bảo toàn đầy đủ thuộc tính cục bộ tại thời điểm t	Thiếu ngữ cảnh chuỗi tuần tự và lịch sử tương tác
Mức chuỗi / Phiên (Session)	Cửa sổ trượt hoặc phiên tiến trình	Chuỗi sự kiện $[e_{t-k+1}, \dots, e_t]$ theo thời gian	Nắm bắt quan hệ phụ thuộc thứ tự thời gian	Nhạy cảm với nhiễu xen kẽ từ các luồng song song
Mức thực thể (Entity)	Định danh tác nhân (Host, User, Process)	Lịch sử tương tác gom cụm theo thực thể	Phân lập rõ ràng ranh giới hành vi chủ thể	Khó phát hiện hành vi tấn công vượt ranh giới
Mức đồ thị (Graph)	Đồ thị nguồn gốc (Provenance Graph)	Đồ thị luồng phụ thuộc di thể G	Mô hình hóa toàn diện quan hệ đa thực thể	Bùng nổ kích thước đồ thị và chi phí tính toán

Bên cạnh tính dị thể, dữ liệu log doanh nghiệp chịu áp lực vận hành về mặt thông lượng và tỷ lệ phân bố nhần [8], [3]. Trong các môi trường mạng lớn, hệ thống tiếp nhận luồng sự kiện liên tục với tốc độ cao, đặt ra yêu cầu giám sát theo cơ chế thời gian thực (runtime streaming) như cách tiếp cận phác họa đồ thị của UNICORN [9], đồng thời đối mặt với thách thức kiểm soát tài nguyên bộ nhớ khi xử lý các đồ thị

nguồn gốc kéo dài. Đồng thời, tỷ lệ các dòng log liên quan đến hành vi tấn công trong thực tế thường rất nhỏ so với lưu lượng thông thường, tạo ra sự mất cân bằng nhãn sâu sắc khiến các hàm mất mát học máy thông thường có xu hướng xem nhẹ nhóm thiểu số [8]. Trong khi đó, việc suy thoái không gian vector (sụp đổ chiều biểu diễn) nảy sinh khi các mô hình tự giám sát không áp dụng các cơ chế điều hòa phương sai và hiệp phương sai phù hợp để duy trì tính đa dạng của các chiều đặc trưng [10], [11].

Dưới góc độ phân phối thời gian, dữ liệu log liên tục biến đổi trong môi trường vận hành dài hạn. Dựa trên các vấn đề không dừng (non-stationarity) và phương pháp luận đánh giá theo thời gian được thảo luận trong tài liệu liên quan [8], nghiên cứu tổng hợp bốn dạng trôi dạt dữ liệu (Drift Taxonomy) phục vụ khung phân tích của chuyên đề (Tác giả tổng hợp):

- Concept Drift: Bản chất hành vi và mục đích tấn công thay đổi theo thời gian mặc dù cấu trúc định dạng log không đổi: $P_t(Y | X) \neq P_{t+1}(Y | X)$.
- Template Drift: Việc nâng cấp phần mềm, cập nhật bản vá hoặc thay đổi cấu hình làm biến đổi cấu trúc chuỗi mẫu log: $P_t(X_{\text{template}}) \neq P_{t+1}(X_{\text{template}})$.
- Population Drift: Lưu lượng người dùng, tần suất giao tác nghiệp vụ hoặc cơ cấu dịch vụ hệ thống biến động theo chu kỳ: $P_t(X) \neq P_{t+1}(X)$.
- Representation Drift: Không gian vector tiềm ẩn z bị suy giảm năng lực phân tách do dữ liệu đầu vào trôi dạt khỏi vùng phân phối huấn luyện ban đầu: $P_t(z | X) \neq P_{t+1}(z | X)$.


1.1.2. Hành vi tấn công đa giai đoạn và ánh xạ đa nhãn MITRE ATT&CK

Trong lịch sử nghiên cứu phát hiện xâm nhập, các tiếp cận ban đầu thường dựa trên giả định chuỗi tấn công đơn tuyến (Cyber Kill Chain) hoặc các mô hình xích Markov tuyến tính để xâu chuỗi tuần tự các giai đoạn tấn công từ Thâm nhập ban đầu (Initial Access), Thực thi (Execution), Duy trì (Persistence), Leo thang đặc quyền (Privilege Escalation) cho đến Đánh cắp dữ liệu (Exfiltration).

Tuy nhiên, trên thực tế vận hành và theo khung phân loại chuẩn hóa của ma trận tri thức an ninh MITRE ATT&CK [4], các chiến dịch tấn công có chủ đích (APT) mang bản chất phi tuyến tính sâu sắc [1]. Cần lưu ý rằng MITRE khuyến nghị ATT&CK không phải là một danh mục kiểm tra đầy đủ (checklist) khép kín; từ ontology ATT&CK và các quan sát về đồ thị nguồn gốc hệ thống [1], nghiên cứu tổng hợp ba cấu trúc phân tích đặc thù sau (đây là cấu trúc phân loại do đề tài tự tổng hợp, không phải taxonomy chính thức của MITRE ATT&CK): *Một là*, cấu trúc nhảy cóc giai đoạn (Step Skipping): Kẻ tấn công có thể khai thác trực tiếp lỗ hổng thực thi mã từ xa để trích xuất dữ liệu ra ngoài mà không cần thiết lập cơ chế duy trì hay di chuyển ngang; *Hai là*, cấu trúc lặp vòng kỹ thuật (Tactic Looping & Interleaving): Kỹ thuật thu thập thông tin nội bộ (Discovery) thường được lặp lại nhiều lần xen kẽ giữa các bước leo thang đặc quyền và chiếm đoạt thông tin xác thực; *Ba là*, cấu trúc phân nhánh tiến trình song song (Parallel Branching): Kẻ tấn công có thể khởi tạo đồng thời nhiều luồng tiến trình con độc lập trên các tiến trình hợp lệ khác nhau nhằm phân tán sự theo dõi của hệ thống phòng thủ.

Do đó, chuyên đề xác lập nguyên tắc: Ma trận MITRE ATT&CK được mô hình hóa thành một Không gian Bằng chứng Hành vi Đa chiều (Multi-label Behavioral Evidence Space), được minh họa trực quan trong Hình 1.2:

$$\mathcal{Y}_{\text{ATT\&CK}} = \mathcal{T}_{\text{tactics}} \times \mathcal{T}_{\text{techniques}}$$



Hình 1.2: Mô hình Không gian Bằng chứng Hành vi Đa chiều MITRE ATT&CK và các đặc trưng phi tuyến tính trong tấn công APT (Nguồn: Tác giả tổng hợp dựa trên MITRE ATT&CK [4] và Inam et al. [1])

Trong đó mỗi chiến thuật (Tactic) đại diện cho mục tiêu chiến thuật của kẻ tấn công (trả lời câu hỏi “Tại sao”) và mỗi kỹ thuật (Technique) đại diện cho phương thức thực thi cụ thể (trả lời câu hỏi “Làm thế nào”); một chuỗi sự kiện hoặc cây tiến trình có thể đồng thời kích hoạt nhiều nhãn chiến thuật và kỹ thuật tại cùng một thời điểm quan sát [4].

Xét theo dữ liệu thực nghiệm, việc mô hình hóa hành vi tấn công đòi hỏi phải phân định chuẩn xác đặc tính gắn nhãn và mức độ hạt (Label Granularity) của từng bộ dữ liệu chuẩn [3]: *Một là*, bộ dữ liệu DARPA Transparent Computing Engagement #3 (TC E3, diễn ra vào tháng 4/2018) [12] và Engagement #5 (TC E5) [43] cung cấp dữ liệu kiểm toán hệ thống mức hạt nhân chi tiết, trong đó các kịch bản tấn công và diễn tập red-team trong các engagement của chương trình được gắn nhãn ở mức độ hạt tiến trình/luồng phụ thuộc (Fine-grained Ground Truth); *Hai là*, bộ dữ liệu LANL Unified Host and Network Dataset (Kent, 2015) [13] phản ánh môi trường mạng doanh nghiệp quy mô lớn với hàng tỷ sự kiện xác thực và luồng mạng, trong đó nhãn mặt đất thực nghiệm được xác lập từ tệp redteam.txt ghi nhận các sự kiện xác thực bị xâm nhập cụ

thể của đội Red Team (Authentication Compromise Events) theo mốc thời gian và tài khoản/máy chủ xác định; *Ba là*, bộ dữ liệu HDFS (Xu et al. [18], LogHub [42]) được gán nhãn bất thường theo vết thực thi ở mức khối dữ liệu (Block-level trace labels [18]), phản ánh trạng thái bình thường hoặc bất thường của một phiên giao tác phân tán hoàn chỉnh; *Bốn là*, bộ dữ liệu BGL (LogHub [42]) đại diện cho nhật ký siêu máy tính với nhãn bất thường được xác lập ở mức dòng log đơn lẻ (Line-level alert/non-alert labels [42]).

Đặc biệt, sự xuất hiện của nhiễu từ hành vi quản trị viên (Admin-Noise) là một thách thức vận hành thực tế. Các quản trị viên hệ thống thường xuyên sử dụng các công cụ hợp lệ như PowerShell, SSH, WMI và các lệnh nội bộ tương tự như kỹ thuật kẻ tấn công sử dụng; hiện tượng này được đề tài xác lập dưới dạng một giả thuyết nghiên cứu cần kiểm thử thực nghiệm trong không gian đặc trưng hành vi, đòi hỏi mô hình học sâu không dừng lại ở các mẫu cú pháp bề mặt mà phải nắm bắt được tương quan phụ thuộc cấu trúc và ngữ cảnh thực thi sâu.

1.1.3. Các mức biểu diễn dữ liệu và Hợp đồng Biểu diễn (Representation Contract)

Khắc phục hạn chế của các nghiên cứu tiền nhiệm vốn thường đồng nhất việc trích xuất đặc trưng với thuật toán phân loại cụ thể, chuyên đề tiếp cận bài toán dưới góc nhìn của học biểu diễn sâu (Deep Representation Learning). Trong học sâu, mô hình thiết lập một ánh xạ hàm tham số chuyển đổi dữ liệu nhật ký hệ thống đa góc nhìn sang không gian vector tiềm ẩn. Điểm cốt lõi về mặt nhận thức luận là vector biểu diễn z chỉ phản ánh những thuộc tính và quy luật thống kê mà hàm mục tiêu tối ưu hóa (optimization objective) khuyến khích lưu giữ, chứ không phải một bản sao toàn tri của mọi trạng thái hệ điều hành; những thông tin không xuất hiện trong dữ liệu quan sát hoặc không được objective thúc đẩy có thể không tồn tại trong z . Do đó, để định hình không gian biểu diễn phục vụ mục tiêu an ninh, chuyên đề đề xuất một khung khái niệm chính thức mang tên Hợp đồng Biểu diễn (Representation Contract), ký hiệu là $\mathcal{C}_{\text{representation}}$, đóng vai trò như một bản đặc tả các ràng buộc toán học và ngữ nghĩa giữa dữ liệu thô và không gian vector tiềm ẩn z :

$$\mathcal{C}_{\text{representation}} = \langle \mathcal{P}_{\text{preserve}}, \mathcal{I}_{\text{invariant}}, \mathcal{E}_{\text{exclude}} \rangle$$

Khung Hợp đồng Biểu diễn thiết lập ba nhóm điều kiện ràng buộc bắt buộc mà không gian vector biểu diễn z phải đồng thời thỏa mãn:

Một là, nhóm Điều kiện Bảo toàn (PRESERVE, $\mathcal{P}_{\text{preserve}}$): Tập hợp các thuộc tính và tương quan an ninh bắt buộc phải được bảo toàn nguyên vẹn trong không gian vector biểu diễn. Bao gồm: ngữ nghĩa sâu của các tham số dòng lệnh quan trọng, trật tự thời gian và mối quan hệ phụ thuộc thực thi giữa các thực thể hệ thống (Process-File-Socket), cấu trúc tô-pô cục bộ của đồ thị nguồn gốc và các đặc trưng nhận diện chiến thuật/kỹ thuật MITRE ATT&CK.

Hai là, nhóm Điều kiện Bất biến (INVARIANT, $\mathcal{I}_{\text{invariant}}$): Tập hợp các biến đổi hình thức hoặc biến động môi trường mà không gian vector z phải duy trì tính bất biến. Bao gồm: sự biến đổi cú pháp vô hại của các chuỗi văn bản log (định dạng dấu thời gian, khoảng trắng, thứ tự các trường không mang nghĩa an ninh), sự xáo trộn mã định danh tiến trình ngẫu nhiên (PID/PPID), tên tài khoản người dùng hoặc địa chỉ IP cục bộ không ảnh hưởng đến bản chất luồng thực thi, và các biến động định kỳ về khối lượng lưu lượng nền (Workload fluctuations).

Ba là, nhóm Điều kiện Triệt tiêu (EXCLUDE, $\mathcal{E}_{\text{exclude}}$): Tập hợp các thông tin giả tạo và biến số ngoài miền bắt buộc phải bị loại bỏ/triệt tiêu khỏi không gian vector z nhằm ngăn ngừa rủi ro học đường tắt (Shortcut Learning) [8]. Bao gồm: các mẫu định dạng đặc thù của môi trường thử nghiệm (Testbed-specific artifacts), các biến số gây rò rỉ phân vùng dữ liệu và đánh cắp thời gian (Partition-leakage and temporal snooping variables như dấu thời gian tuyệt đối của máy thí nghiệm, hostname cố định của môi trường lab) [8], và các đặc trưng tương quan giả (Spurious correlations) có thể khiến mô hình đạt độ chính xác ảo trên tập kiểm thử nhưng thất bại khi triển khai thực tế.

Các đặc tả chi tiết của Hợp đồng Biểu diễn được hệ thống hóa trong Bảng 1.2:


Bảng 1.2: Đặc tả Hợp đồng Biểu diễn (Representation Contract) cho vector đặc trưng z

Thành phần hợp đồng	Mục tiêu ràng buộc	Đối tượng áp dụng cụ thể trong dữ liệu log	Cơ chế kiểm chứng thực nghiệm
PRESERVE (Bảo toàn)	Bảo tồn đầy đủ tín hiệu ngữ cảnh an ninh phân biệt	Ngữ nghĩa tham số động, trật tự thời gian và quan hệ phụ thuộc, tô-pô đồ thị, nhãn ATT&CK	Linear Probing, Mutual Information
INVARIANT (Bất biến)	Duy trì bất biến trước biến đổi hình thức và trôi dạt vô hại	Định dạng timestamp, PID ngẫu nhiên, hoán vị cú pháp vô hại	Invariance Loss, Data Augmentation
EXCLUDE (Triệt tiêu)	Loại bỏ rò rỉ phân vùng và biến số học đường tắt	Artifacts môi trường lab, hostname cố định, thông tin định danh nhạy cảm (PII)	Snooping Test, Feature-leakage / Re-identification Audit

Nguyên tắc PRESERVE tập trung vào việc bảo toàn ngữ nghĩa an ninh động chứ không đồng nghĩa với việc giữ lại toàn bộ định danh thô của người dùng hay máy chủ. Về mặt bảo vệ quyền riêng tư, chuyên đề phân định rạch ròi bốn cấp độ an toàn thông tin và không đồng nhất khả năng phòng thủ giữa các cấp độ này: *Một là*, cơ chế giả danh hóa (Pseudonymization) thông qua việc ánh xạ các định danh nhạy cảm (như username, IP, hostname) sang không gian mã băm hoặc chỉ số trừu tượng nhằm kiểm soát khả năng liên kết (controlled linkability); *Hai là*, đề xuất quy trình đánh giá khả năng chống tấn công suy luận thành viên (Membership Inference Attack - MIA) [16] nhằm đánh giá xem kẻ tấn công có thể xác định một bản ghi nhật ký cụ thể có thuộc tập huấn luyện hay không; *Ba là*, đề xuất quy trình đánh giá khả năng chống tấn công đảo ngược mô hình (Model Inversion Attack) [33] nhằm đánh giá rủi ro khôi phục thông tin cấu hình từ vector biểu diễn tiềm ẩn; *Bốn là*, khung bảo đảm toán học về quyền riêng tư vi sai (Differential Privacy - DP) theo hướng dẫn chuẩn mực của NIST

SP 800-226 [17]. Cần khẳng định rằng vector biểu diễn tiềm ẩn không tự động an toàn về quyền riêng tư nếu không có cơ chế chứng minh toán học tường minh; chuyên đề đề xuất khung đánh giá an toàn thông tin bao gồm các thử nghiệm MIA hay Model Inversion được định vị cho giai đoạn đánh giá mô hình hạ nguồn [16], [33], kết hợp khung lý thuyết DP định hướng lượng hóa độ mất mát quyền riêng tư [17]. Tương tự, nguyên tắc EXCLUDE thiết lập các ràng buộc phủ định đối với các giả định đường tắt đã biết và các biến số gây rò rỉ phân vùng [8], thay vì giả định rằng mọi đường tắt đều có thể nhận biết trước khi thực nghiệm.

Đi đôi với Hợp đồng Biểu diễn được quy định trong Bảng 1.2, chuyên đề thiết lập nguyên tắc phân định ranh giới phương pháp luận ba tầng độc lập, được mô hình hóa tổng quát trong Hình 1.3:



Hình 1.3: Khung phân định ranh giới ba tầng phương pháp luận và vị trí trọng tâm của không gian vector biểu diễn z (Nguồn: Tác giả đề xuất)

1. Tầng 1 phụ trách trích xuất đặc trưng cơ sở: Đảm nhiệm tiền xử lý dữ liệu thô, phân tích cú pháp sơ bộ, chuẩn hóa kiểu dữ liệu trường và làm sạch dữ liệu. Tầng này không gánh vác nhiệm vụ học biểu diễn ngữ cảnh an ninh sâu.

2. Tầng 2 tập trung học không gian biểu diễn, giữ vai trò trọng tâm của Chuyên đề: Thiết lập kiến trúc encoder $f_\theta: \mathcal{X} \rightarrow z \in \mathbb{R}^d$ và các đầu chiếu/dự đoán phụ trợ (projection/prediction heads) để chuyển đổi cấu trúc chuỗi sự kiện và đồ thị nguồn gốc sang không gian vector tiềm ẩn. Các hàm mất mát tự giám sát (như dự đoán tham số bị che, dự đoán sự kiện tiếp theo, dự đoán quan hệ đồ thị và căn chỉnh thời gian) được thiết kế như các mục tiêu tối ưu hóa (optimization objectives) cụ thể để khuyến khích không gian biểu diễn z lưu giữ những tín hiệu phục vụ các ràng buộc PRESERVE và INVARIANT; chúng không phải là bằng chứng khoa học trực tiếp chứng minh mô hình đã tự động hiểu an ninh hay nhân quả, và mức độ đạt được bắt buộc phải được kiểm chứng downstream [10].

3. Tầng 3 thực hiện phát hiện và phân loại hạ nguồn (Downstream Detection): Đánh giá chất lượng của vector biểu diễn z thông qua giao thức đóng băng encoder và huấn luyện đầu phân loại tuyến tính (Frozen Linear Probing theo chuẩn mực SimCLR [37]):

$$\hat{y} = \sigma(W^\top z + b)$$

Trong đó tham số θ của bộ mã hóa Tầng 2 được giữ cố định hoàn toàn trong suốt quá trình đánh giá ở Tầng 3, chỉ có các tham số của bộ phân loại tuyến tính được huấn luyện để đo lường khả năng truy xuất tuyến tính (linear accessibility) của thông tin an ninh trong vector z . Quy tắc này bảo đảm bộ phân loại hạ nguồn không làm thay nhiệm vụ trích xuất đặc trưng của Tầng 2 và phản ánh trung thực năng lực của không gian biểu diễn [8], [37].

1.2. Phân tích so sánh các nhóm phương pháp hiện đại

Phục vụ việc định vị chính xác các đóng góp kỹ thuật và cơ sở lý luận của chuyên đề, Mục 1.2 tiến hành khảo cứu, phân loại và phân tích đa chiều ba nhóm phương pháp

biểu diễn đặc trưng log chủ đạo trong y văn hiện đại [6], [1], [5]: (1) Nhóm phương pháp thống kê và cú pháp dựa trên mẫu log (Statistical & Syntactic Parsing-Based); (2) Nhóm phương pháp biểu diễn ngữ nghĩa chuỗi thời gian (Semantic-Sequential & Transformer-Based); và (3) Nhóm phương pháp học biểu diễn đồ thị nguồn gốc (Provenance Graph Representation Learning). Mỗi nhóm phương pháp được mô tả về cơ chế toán học, độ phức tạp thuật toán, ưu điểm cốt lõi và các rào cản nền tảng khi triển khai trong môi trường phát hiện tấn công thực tế.

1.2.1. Phương pháp thống kê và cú pháp: Event Count, Frequency, Entropy và Template Features

Nhóm phương pháp thống kê và cú pháp đại diện cho thế hệ tiếp cận đầu tiên trong phân tích nhật ký tự động [6], [7]. Cơ chế hoạt động của nhóm này dựa trên quy trình hai giai đoạn tách rời: giai đoạn phân tách dòng log thô thành các mẫu định dạng tĩnh (Log Templates / Event IDs) thông qua bộ phân tích cú pháp, tiếp theo là giai đoạn lượng hóa các chuỗi sự kiện thành vector số học dựa trên các thước đo thống kê kinh điển.

Trong giai đoạn phân tích cú pháp, nhiều thuật toán tiêu biểu đã được phát triển nhằm tối ưu hóa tốc độ xử lý [6]: (1) Drain [6] sử dụng cấu trúc cây phân tích có độ sâu cố định (Fixed-Depth Parse Tree) để nhóm các dòng log dựa trên độ dài chuỗi và các từ khóa tiền tố, trong kết quả đo chuẩn thực nghiệm của Zhu et al., thời gian xử lý của Drain tăng gần tuyến tính theo kích thước tập dữ liệu log đối với luồng dữ liệu lớn; (2) Spell [6] áp dụng thuật toán tìm chuỗi con chung dài nhất (Longest Common Subsequence - LCS) theo cơ chế dòng để trích xuất động các thành phần tĩnh của thông điệp log; (3) LenMa và AEL [6], [7] lần lượt khai thác chiều dài các từ tố và tần suất xuất hiện của từ khóa để phân cụm và tách biến số ra khỏi chuỗi mẫu.

Sau khi không gian log được rút gọn về tập M mẫu sự kiện cố định $\mathcal{E} = \{e_1, e_2, \dots, e_M\}$, các chuỗi sự kiện trong một cửa sổ thời gian hoặc phiên làm việc W được ánh xạ thành vector tần suất:

$$x = [c(e_1), c(e_2), \dots, c(e_M)]^T \in \mathbb{R}^M$$

Trong đó $c(e_i)$ là số lần xuất hiện của sự kiện e_i . Bên cạnh đếm tần suất đơn thuần, trong các phương pháp tiếp cận thống kê truyền thống, trọng số TF-IDF (Term Frequency - Inverse Document Frequency) hoặc độ hỗn loạn thông tin Shannon (Information Entropy) thường được vận dụng nhằm cân bằng và nhấn mạnh các sự kiện hiếm gặp:

$$H(W) = - \sum_{i=1}^M p(e_i) \log_2(p(e_i))$$

Trên không gian vector tần suất này, các mô hình phát hiện bất thường kinh điển được triển khai rộng rãi: (1) Principal Component Analysis (PCA) (Xu et al., SOSP 2009) [18] phân rã không gian vector $\mathbb{R}^M$ thành không gian con chuẩn tắc $\mathcal{S}_n$ và không gian con phần dư $\mathcal{S}_r$, nhận diện bất thường khi năng lượng chiếu lên phần dư vượt ngưỡng kiểm định:

$$x_a = (I - PP^T)x, \|x_a\|^2 > \gamma_\alpha$$

(2) Invariant Mining (Lou et al., USENIX ATC 2010) [19] tự động khai phá các phương trình bất biến tuyến tính phản ánh mối quan hệ bảo toàn logic giữa các bước thực thi:

$$Ax = \mathbf{0}$$

Mặc dù sở hữu ưu thế về tốc độ xử lý trong thực tiễn, nhóm phương pháp thống kê và cú pháp bộc lộ hai điểm nghẽn phương pháp luận quan trọng [6], [2]: (1) Mất mát ngữ nghĩa an ninh do trừu tượng hóa tham số: các bộ log parser dựa trên biểu thức chính quy thường thay thế các tham số biến động (địa chỉ IP, đường dẫn tệp tin, tham số dòng lệnh) bằng ký tự đại diện $\langle * \rangle$ khiến nhiều thông tin an ninh mang tính phân biệt cao bị lược bỏ; (2) Lan truyền và khuếch đại sai số cú pháp (Parser Error Propagation): khi gặp các định dạng log mới chưa từng xuất hiện (unseen logs), parser có thể phân tách không chính xác, dẫn đến hiện tượng sinh ra các mẫu sự kiện giả lập hoặc gộp nhầm các sự kiện khác biệt, làm xáo trộn cấu trúc không gian vector x .

1.2.2. *Phương pháp semantic–sequential: Embeddings, Self-Supervised Learning, Transformer và Parsing-Free*

Khắc phục sự cứng nhắc của các vector đếm tần suất và tận dụng trật tự xuất hiện của các sự kiện, nhóm phương pháp Semantic–Sequential mô hình hóa luồng log tương tự như các chuỗi ngôn ngữ tự nhiên, tích hợp các kỹ thuật nhúng từ và học tự giám sát (Self-Supervised Learning) để nắm bắt phụ thuộc ngữ cảnh dài hạn [14], [20], [21], [22], [23].

Khởi đầu cho hướng nghiên cứu này là mô hình DeepLog [14]. DeepLog không chỉ phân tích chuỗi mã sự kiện log mà còn là một khung làm việc toàn diện gồm hai thành phần mô hình hóa: *Một là*, mô hình LSTM thứ nhất học biểu diễn chuỗi các mẫu log (Log-Key Anomaly Detection) nhằm phát hiện các sự kiện sai lệch khỏi trật tự thực thi bình thường theo phân phối có điều kiện $P(e_t | e_{t-k}, \dots, e_{t-1})$; *Hai là*, mô hình LSTM thứ hai kết hợp phân phối chuẩn nhiều chiều để kiểm tra sự bất thường về giá trị tham số số học (Parameter Value Anomaly Detection) [14].

$$\hat{e}_t = \operatorname{argtop} - g_{e \in \mathcal{E}} P(e | e_{t-k}, \dots, e_{t-1})$$

Song song đó, DeepLog xây dựng mô hình LSTM thứ hai dựa trên phân phối chuẩn nhiều chiều để kiểm tra sự bất thường về giá trị tham số số học (Parameter Value Anomaly) [14].

Các công trình kế tiếp đã nâng cấp cơ chế biểu diễn ngữ nghĩa: (1) LogAnomaly (Meng et al., IJCAI 2019) [22] đề xuất Template2Vec, trích xuất vector ngữ nghĩa cho từng mẫu log thông qua Word2Vec/FastText kết hợp trọng số d-IDF; (2) Logsy (Nedelkoski et al., ICDM 2020) [23] sử dụng hàm mất mát phân loại ngoại lai (Outlier Classification Loss) trên dữ liệu log từ các hệ thống phụ trợ để định hình biên giới phân tách cho lớp bình thường; (3) LogBERT (Guo et al., IJCNN 2021) [20] khai thác kiến trúc Transformer hai chiều dựa trên cơ chế Self-Attention của Vaswani et al. [34]. Trong kiến trúc Transformer [34], cơ chế chú ý tích vô hướng tỉ lệ (Scaled Dot-Product Attention) sử dụng các ma trận Query, Key và Value cho phép mỗi vị trí trong chuỗi tương tác trực tiếp với tất cả các vị trí khác mà không bị hạn chế bởi nút thắt tuần tự

của mạng hồi quy recurrent, kết hợp mã hóa vị trí (Positional Encoding) để duy trì trật tự chuỗi. LogBERT áp dụng cơ chế này cho hai tác vụ tự giám sát: Dự đoán sự kiện log bị che (Masked Log Event Prediction) và Dự đoán phân bố khối lượng log; (4) Nhóm tiếp cận không dùng Parser (Parsing-Free, NeuralLog [21]) bỏ qua bước phân tích cú pháp bằng cách sử dụng các mô hình ngôn ngữ tiền huấn luyện để trực tiếp mã hóa chuỗi văn bản log thô thành các vector nhúng liên tục. Trong các kiến trúc học tự giám sát (Self-Supervised Learning - SSL) này, một rủi ro phương pháp luận nghiêm trọng là hiện tượng sụp đổ biểu diễn (Representation Collapse), khi bộ mã hóa sinh ra các vector biểu diễn tầm thường giống nhau cho mọi đầu vào. Để kiểm soát hiện tượng này, kỹ thuật chính quy hóa VICReg (Bardes et al., ICLR 2022) [10] phân rã mục tiêu thành ba thành phần: Phương sai (Variance - duy trì độ phân tán theo chiều và chống collapse về một điểm), Bất biến (Invariance - giống hàng biểu diễn) và Hiệp phương sai (Covariance - phi tương quan hóa các chiều đặc trưng, chống sụp đổ chiều). Việc áp dụng VICReg trong chuyên đề đóng vai trò là một cơ chế chính quy hóa hình học không gian, trong khi hiệu quả giảm tỷ lệ cảnh báo sai/bỏ sót trong viễn trắc an ninh là giả thuyết thích ứng của đề tài cần kiểm chứng thực nghiệm [10].

Mặc dù đạt kết quả tốt trên các tập dữ liệu phân mềm, nhóm phương pháp Semantic-Sequential đối mặt với ba rào cản khi áp dụng vào an ninh mạng [8], [3]: (1) Nguy cơ rò rỉ và thiên lệch từ dữ liệu tiền huấn luyện (Pretraining-Data Advantage): các mô hình sử dụng Transformer tiền huấn luyện trên kho văn bản tổng quát có nguy cơ tận dụng tri thức ngoài miền; khi đánh giá trong điều kiện phân vùng nghiêm ngặt, năng lực phân tách thực tế cần được kiểm chứng cẩn trọng [8]; (2) Chi phí tài nguyên tính toán: cơ chế Self-Attention trong Transformer [34] có độ phức tạp tính toán và bộ nhớ bậc hai theo độ dài chuỗi hoặc kích thước cửa sổ, đòi hỏi tài nguyên tính toán đáng kể khi triển khai trên luồng dữ liệu thời gian thực có lưu lượng lớn; (3) Giới hạn phạm vi quan sát đơn luồng: mô hình chuỗi chủ yếu theo dõi các sự kiện trên một dòng thời gian cục bộ, gặp khó khăn khi mô hình hóa trực tiếp các mối liên hệ phụ thuộc đan xen đa tiến trình, đa thực thể và vượt ranh giới máy chủ.

1.2.3. Đồ thị nguồn gốc và Graph Representation Learning

Khắc phục hạn chế về phạm vi quan sát của mô hình chuỗi, hướng tiếp cận dựa trên đồ thị nguồn gốc hệ thống (System Provenance Graph) mô hình hóa toàn bộ lịch sử thực thi và tương tác trong hệ điều hành dưới dạng một đồ thị có hướng, không đồng nhất và gán nhãn thời gian [1], [5]:

$$\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{T}_v, \mathcal{T}_e, \phi, \psi, \tau)$$

Trong đó $\mathcal{V}$ là tập các đỉnh đại diện cho các thực thể hệ thống thuộc tập kiểu $\mathcal{T}_v = \{\text{Process, File, Socket, Registry, User, Host}\}$; $\mathcal{E}$ là tập các cạnh có hướng mô tả các tương tác luồng phụ thuộc thuộc tập kiểu $\mathcal{T}_e = \{\text{fork, execve, read, write, connect, bind, send, recv}\}$; và τ gán nhãn mốc thời gian xảy ra tương tác [1].

Các hệ thống phát hiện xâm nhập dựa trên đồ thị nguồn gốc (PIDS) tiêu biểu bao gồm [1], [5]: (1) UNICORN [9] (Han et al., NDSS 2020) xây dựng đồ thị nguồn gốc luồng thời gian thực, áp dụng thuật toán băm cây con Weisfeiler-Lehman (WL-subtree kernel) để chuyển đổi đồ thị động thành vector đặc trưng đếm histogram; (2) KAIROS [24] (Cheng et al., IEEE S&P 2024) tích hợp mạng nơ-ron đồ thị nhận biết thời gian (Time-Aware GNN encoder-decoder), mã hóa đồng thời thông tin cấu trúc và sự tiến triển thời gian của đồ thị nguồn gốc để chấm điểm bất thường và tái dựng dấu vết tấn công APT; (3) NODLINK [25] (Li et al., NDSS 2024) mô hình hóa bài toán phát hiện thành cây Steiner trực tuyến (Online Steiner Tree Problem) kết hợp cơ chế bộ nhớ đệm để khôi phục đồ thị con tấn công nhỏ gọn; (4) MAGIC [26] (Jia et al., USENIX Security 2024) khai thác kiến trúc tự mã hóa đồ thị che (Masked Graph Autoencoder) kết hợp cơ chế thích ứng mô hình (model adaptation) để học biểu diễn đa độ hạt và chống trôi khái niệm (concept drift); (5) ORTHRUS [27] (Jiang et al., USENIX Security 2025) tích hợp cơ chế học biểu diễn nguồn gốc chống chịu kỹ thuật lẫn tránh. Mặc dù đạt nhiều bước tiến, nhóm phương pháp đồ thị đối mặt với ba thách thức lý thuyết và thực tiễn cốt lõi: *Một là*, hiện tượng bùng nổ phụ thuộc (Dependency Explosion): các tiến trình hệ thống chạy dài hạn liên tục tương tác với nhiều tệp tin và


socket, khiến đồ thị phát triển dày đặc và tạo ra nhiều liên kết phụ thuộc xa làm loãng tín hiệu bất thường [1], [28]; *Hai là*, ranh giới giữa quan hệ phụ thuộc cấu trúc và tác động nhân quả (Dependency $\neq$ Causal Effect): kết quả khảo sát thực nghiệm của Bilot et al. [29] (USENIX Security 2025) và Guerra et al. [30] chỉ ra rằng nhiều mô hình GNN phức tạp có nguy cơ khai thác các đặc trưng đường tắt thông kê (như phân bố bậc của nút hoặc tính mới của đường dẫn); trong đó Bilot et al. [29] chứng minh một mô hình mạng nơ-ron đơn giản (simple neural network) đạt hiệu năng cạnh tranh vượt trội trên 5/7 tập dữ liệu DARPA, còn Guerra et al. [30] chỉ ra hiệu quả của các baseline danh sách cho phép / thông kê sự kiện, khẳng định một cạnh phụ thuộc trong đồ thị không đồng nghĩa với tác động nhân quả an ninh; *Ba là*, hai bệnh lý mạng nơ-ron đồ thị về mặt cấu trúc: khi tăng số lớp truyền tin (message passing), hiện tượng làm mịn quá mức (Over-smoothing), được Oono & Suzuki [44] chứng minh về mặt toán học tại ICLR 2020, khiến vector biểu diễn của các đỉnh mất dần năng lực biểu đạt theo hàm mũ và hội tụ về các vector khó phân biệt; trong khi đó hiện tượng nghiền cổ chai thông tin (Over-squashing), được Alon & Yahav [31] phân tích tại ICLR 2021, xuất hiện khi thông tin từ vùng lân cận tăng theo hàm mũ bị ép vào một vector kích thước cố định. Hai hiện tượng này mang bản chất toán học độc lập và cần được xử lý bằng các cơ chế kiến trúc riêng biệt.

Tại Việt Nam, các nghiên cứu chuyên sâu của ThS. Nguyễn Thị Thu Thủy (Khoa An toàn thông tin, Học viện Kỹ thuật Mật mã) [32] cũng đã hệ thống hóa toàn diện phương pháp luận ứng dụng Graph Learning và mạng nơ-ron đồ thị (Graph Neural Network, GNN) trên đồ thị nguồn gốc (provenance graph) để phát hiện các chiến dịch tấn công APT đa giai đoạn; đồng thời phân tích sâu sắc các thách thức về hiện tượng bùng nổ phụ thuộc, tính đa góc nhìn và yêu cầu bảo toàn tính nhân quả khi phân tích luồng sự kiện kiểm toán hệ thống.

Bảng 1.3: So sánh đối chiếu ba nhóm phương pháp biểu diễn đặc trưng log chủ đạo

Tiêu chí đánh giá	Nhóm Thống kê / Cú pháp (Drain, PCA)	Nhóm Chuỗi Semantic (DeepLog, LogBERT)	Nhóm Đồ thị Nguồn gốc (UNICORN, MAGIC)
Cơ chế biểu diễn cốt lõi	Vector đếm tần suất Event ID trên cửa sổ trượt	Vector nhúng ngữ cảnh từ chuỗi sự kiện tuần tự	Vector nhúng cấu trúc đồ thị luồng phụ thuộc dị thể
Độ phức tạp thời gian	$O(N)$: Tuyến tính theo số lượng sự kiện	$O(N \cdot L)$ đến $O(N \cdot L^2)$: Phụ thuộc độ dài cửa sổ L	Phụ thuộc $ E $, số tầng và chiều ẩn; chi phí lưu trữ đồ thị phụ thuộc $ V + E $
Bảo toàn tham số an ninh	Hạn chế (Tham số biến động thường bị thay thế bởi parser)	Trung bình (Tham số được rời rạc hóa hoặc nhúng từ)	Tốt (Lưu trữ trực tiếp trên thuộc tính của nút/cạnh)
Mô hình hóa chuỗi quan hệ	Không hỗ trợ	Cục bộ trên dòng thời gian tuần tự đơn luồng	Toàn diện trên quan hệ tương tác đa thực thể
Khả năng triển khai thực tế	Thuận lợi nhờ tính toán nhanh và tài nguyên thấp	Đòi hỏi tài nguyên GPU và thời gian suy luận lớn	Thách thức do đồ thị tăng trưởng và bùng nổ phụ thuộc
Điểm nghẽn phương pháp luận	Mất mát tham số động, nhạy cảm với sai số phân tách	Chi phí tính toán cao, hạn chế góc nhìn đa thực thể	Bùng nổ phụ thuộc, Over-smoothing, Over-squashing

Tổng kết lại, phân tích so sánh đối chiếu chỉ ra rằng mỗi nhóm phương pháp đều sở hữu những ưu thế và giới hạn riêng biệt (Bảng 1.3). Mối quan hệ tương tác và sự chuyển tiếp từ các rào cản kỹ thuật của ba nhóm phương pháp tới năm khoảng trống nghiên cứu trọng tâm được tổng hợp trực quan trên bản đồ quan hệ trong Hình 1.4:



Hình 1.4: Bản đồ đối chiếu ba nhóm phương pháp biểu diễn log và nguồn gốc hình thành năm khoảng trống nghiên cứu cốt lõi (Nguồn: Tác giả tổng hợp)

1.3. Các khoảng trống nghiên cứu cốt lõi

Từ kết quả khảo sát và phân tích đối chiếu ba nhóm phương pháp biểu diễn đặc trưng log tại Mục 1.2, có thể nhận thấy rằng mặc dù các kỹ thuật thống kê, mô hình chuỗi ngữ nghĩa và học biểu diễn đồ thị nguồn gốc đã đạt được nhiều bước tiến quan trọng, việc ứng dụng chúng vào môi trường phát hiện tấn công mạng doanh nghiệp thực tế vẫn đối mặt với những rào cản nền tảng chưa được giải quyết thấu đáo [8], [6], [1], [3]. Nhằm thiết lập cơ sở khoa học vững chắc và định hình phạm vi nghiên cứu, chuyên đề tổng kết năm khoảng trống nghiên cứu cốt lõi tương ứng với năm câu hỏi nghiên cứu (RQ) định hướng cho toàn bộ các đề xuất phương pháp luận tiếp theo.

1.3.1. Khoảng trống 1: Mất mát ngữ nghĩa an ninh trong quá trình trừu tượng hóa tham số

Dữ liệu thực nghiệm từ các nghiên cứu tiền nhiệm chỉ ra rằng các bộ phân tích cú pháp đóng vai trò then chốt trong việc giảm chiều không gian văn bản log thành các mẫu định dạng tĩnh [6], [7]. Tuy nhiên, cơ chế trừu tượng hóa tham số phụ thuộc vào từng thuật toán phân tích cú pháp; nhiều pipeline tiền xử lý thay thế hoặc khái quát hóa một phần các tham số biến động (như địa chỉ IP, tên tài khoản, đường dẫn tệp tin, cổng

mạng, tham số dòng lệnh) thành các biến đại diện (wildcard/template variables) nhằm tạo ra các mẫu log dùng chung.

Giới hạn quan trọng chưa được giải quyết là: Sự tương đương về mặt cú pháp mẫu log (Template Equivalence) không đồng nghĩa với sự tương đương về mặt ngữ nghĩa an ninh (Security Semantic Equivalence) [2], [3]. Ví dụ, cùng một mẫu thông điệp xác thực thất bại nhưng xuất phát từ một tài khoản quản trị viên đặc quyền root trong mạng nội bộ mang mức độ nghiêm trọng an ninh hoàn toàn khác so với từ một tài khoản người dùng thông thường; hoặc hai dòng lệnh powershell.exe thực thi lệnh quản trị hợp lệ và tải mã độc mã hóa base64 đều bị ánh xạ về cùng một Event ID tiến trình. Khi bộ trích xuất đặc trưng triệt tiêu toàn bộ các tham số động này, không gian biểu diễn bị mất đi phần lớn các tín hiệu ngữ cảnh quan trọng để phân biệt hành vi độc hại với hành vi thông thường.

Khoảng trống nghiên cứu này đặt ra thách thức: Làm thế nào để thiết lập một cơ chế trích xuất đặc trưng có khả năng lọc bỏ các nhiễu cú pháp vô hại nhưng vẫn bảo toàn các tham số động mang ngữ nghĩa an ninh trọng yếu (dưới sự kiểm soát rò rỉ đường tắt và rủi ro quyền riêng tư) trong không gian vector biểu diễn? Từ đó, câu hỏi nghiên cứu thứ nhất được xác lập:

- Câu hỏi nghiên cứu 1 (RQ1, Representation Fidelity): Có thể xây dựng representation loại bỏ nhiễu cú pháp nhưng vẫn bảo toàn các dynamic parameters có ý nghĩa an toàn quan trọng (dưới sự kiểm soát rò rỉ và quyền riêng tư) hay không?

1.3.2. Khoảng trống 2: Bất đồng bộ và suy thoái trong giống hàng biểu diễn đa góc nhìn

Các công trình nghiên cứu hiện đại đã chỉ ra rằng dữ liệu log sở hữu tính đa góc nhìn nội tại: góc nhìn thống kê tần suất phản ánh mật độ hoạt động [6], góc nhìn chuỗi sự kiện phản ánh trật tự thời gian cục bộ [14], [20], và góc nhìn đồ thị nguồn gốc phản

ánh luồng phụ thuộc cấu trúc đa thực thể $\mathcal{G}$ [1], [5], [9]. Việc kết hợp các góc nhìn này được kỳ vọng sẽ cung cấp bức tranh toàn cảnh về chiến dịch tấn công.

Tuy nhiên, khi tiến hành hợp nhất hoặc giống hàng (Cross-view Alignment) các không gian biểu diễn dị thể này trong không gian vector tiềm ẩn, các mô hình học biểu diễn tự giám sát đối mặt với nguy cơ sụp đổ chiều biểu diễn (Representation Collapse), vốn đòi hỏi các kỹ thuật điều hòa phương sai và hiệp phương sai hoặc giảm dư thừa đặc trưng để duy trì tính đa dạng (như các nguyên lý được gợi mở trong VICReg [10] và Barlow Twins [11]). Đồng thời, trong phạm vi bài toán biểu diễn an ninh mạng doanh nghiệp, quá trình giống hàng đa góc nhìn còn đặt ra các thách thức chuyên biệt: (1) Nguy cơ chuyển giao tiêu cực (Negative Transfer), khi sự kết hợp giữa các góc nhìn làm suy giảm độ chính xác tổng thể do nhiễu từ một góc nhìn lấn át tín hiệu hữu ích của góc nhìn khác; và (2) Vấn đề góc nhìn bị khuyết hoặc tương ứng từng phần (Missing-view & Partial Correspondence), nảy sinh khi một số luồng telemetry bị chậm trễ, thất thoát gói tin hoặc không có liên kết 1-1 đồng thời giữa chuỗi sự kiện và đồ thị nguồn gốc.

Khoảng trống nghiên cứu cốt lõi ở đây là: Việc giống hàng đồng thời các góc nhìn dị thể đòi hỏi thiết lập một cơ chế toán học phù hợp để ngăn ngừa sụp đổ biểu diễn và kiểm soát chuyển giao tiêu cực, đồng thời vẫn bảo tồn được các thông tin đặc thù hữu ích của từng góc nhìn riêng biệt. Do đó, câu hỏi nghiên cứu thứ hai được xác lập:

- Câu hỏi nghiên cứu 2 (RQ2, Cross-View Alignment): Có thể căn chỉnh các view dị thể mà không gây representation collapse, negative transfer, đồng thời vẫn bảo toàn thông tin hữu ích đặc thù của từng view hay không?

1.3.3. Khoảng trống 3: Rò rỉ thông tin quy trình, học đường tắt và trôi dạt biểu diễn

Công trình tổng kết của Arp et al. (USENIX Security 2022) [8] và Liu et al. (IEEE S&P 2025) [3] đã cảnh báo sâu sắc về tình trạng sai lệch phương pháp luận

trong nghiên cứu học máy áp dụng cho an ninh mạng. Trong bài toán trích xuất đặc trưng log, các mô hình rất dễ học phải các đặc trưng đường tắt giả định (Dataset Shortcuts) có tương quan ngẫu nhiên với nhãn độc hại trong tập huấn luyện nhưng không phản ánh bản chất tấn công thực tế.

Phân tích hệ thống chỉ ra sáu kênh rò rỉ thông tin tiềm tàng thường xuất hiện trong quy trình thực nghiệm: (1) Rò rỉ từ vựng/bộ phân tích cú pháp, khi bộ parser được học trên toàn bộ dữ liệu gồm cả tập kiểm thử; (2) Rò rỉ chuẩn hóa thống kê, khi các tham số trung bình/phương sai hoặc trọng số TF-IDF được tính toán xuyên qua ranh giới tập train và test; (3) Rò rỉ thực thể/máy chủ thử nghiệm, khi dữ liệu tấn công trên cùng một máy chủ xuất hiện ở cả hai tập; (4) Rò rỉ điều chỉnh ngưỡng và siêu tham số; (5) Rò rỉ dữ liệu tiền huấn luyện ngoài miền; và (6) Rò rỉ thời gian tương lai, khi mô hình vô tình sử dụng sự kiện ở thời điểm tương lai để trích xuất biểu diễn cho hiện tại.

Khoảng trống nghiên cứu quan trọng là: Làm thế nào để phân định tường minh giữa tín hiệu an ninh hợp lệ và đặc trưng đường tắt nhân tạo, đồng thời đảm bảo không gian biểu diễn duy trì được năng lực phân tách khi dữ liệu vận hành bị trôi dạt phân phối theo thời gian? Chuyên đề xác lập câu hỏi nghiên cứu thứ ba:

- Câu hỏi nghiên cứu 3 (RQ3, Validity Without Shortcuts): Representation có còn hữu ích sau khi loại bỏ shortcut của dataset và khi phân phối dữ liệu thay đổi hay không?

1.3.4. Khoảng trống 4: Gán nhãn mức thô, phân bổ bằng chứng yếu và nhiều quản trị viên

Trong thực tế giám sát an ninh mạng doanh nghiệp, dữ liệu nhãn thực tế thường chỉ được ghi nhận ở mức độ hạt rất thô (Coarse Labels), chẳng hạn như gán nhãn một phiên làm việc kéo dài nhiều giờ hoặc toàn bộ một máy chủ bị xâm nhập trong một khoảng thời gian [3], [12], [13]. Bên trong phiên làm việc đó, phần lớn các dòng log

vẫn là các thao tác hệ thống bình thường, và chỉ có một số lượng rất nhỏ sự kiện thực sự phản ánh kỹ thuật tấn công.

Thách thức này càng trở nên phức tạp do sự xuất hiện liên tục của hành vi quản trị viên hệ thống (Admin-Noise / LOLBins) [1], [3]. Các kỹ sư quản trị thường xuyên thực thi các lệnh bảo trì, chẩn đoán mạng hoặc sao lưu dữ liệu bằng các công cụ dòng lệnh hợp lệ (như PowerShell, WMI, SSH, vssadmin). Các hành vi này sở hữu cấu trúc cú pháp và quyền hạn thực thi tương đồng với kỹ thuật của kẻ tấn công, nhưng hoàn toàn mang mục đích hợp pháp (Benign-but-risky). Một hành vi bất thường hoặc hiếm gặp không tự thân đồng nghĩa với hành vi tấn công độc hại (Unusual $\neq$ Malicious, Anomaly $\neq$ Attack).

Khoảng trống nghiên cứu ở đây là: Làm thế nào để phân bổ chính xác bằng chứng tấn công yếu (Weak Evidence Attribution) từ các nhãn mức thô mà không học nhầm các hành vi quản trị hợp pháp thành độc hại? Đây là cơ sở để xác lập câu hỏi nghiên cứu thứ tư:

- Câu hỏi nghiên cứu 4 (RQ4, Weak Evidence Attribution): Có thể gán đúng attack evidence dưới coarse labels mà không học nhầm các hành vi quản trị hợp pháp thành malicious hay không?

1.3.5. Khoảng trống 5: Đánh đổi giữa bảo toàn liên kết an ninh và rủi ro quyền riêng tư

Nhiệm vụ phát hiện và điều tra các cuộc tấn công APT kéo dài đòi hỏi mô hình học biểu diễn phải duy trì khả năng liên kết có kiểm soát giữa các chuỗi hành vi của cùng một thực thể (người dùng, máy chủ, tiến trình) qua nhiều mốc thời gian khác nhau [1], [5].

Tuy nhiên, việc lưu giữ khả năng liên kết này trong không gian vector biểu diễn trực tiếp làm nảy sinh các nguy cơ nghiêm trọng về quyền riêng tư và an toàn thông tin [16], [33], [17]. Các vector biểu diễn đặc trưng tiềm ẩn có nguy cơ bị kẻ tấn công khai thác thông qua các kỹ thuật tấn công suy luận thành viên (Membership Inference

Attacks - MIA [16]) để xác định xem dữ liệu của một thực thể có nằm trong tập huấn luyện hay không. Về mặt lý thuyết nguồn gốc, nghiên cứu kinh điển của Fredrikson et al. [33] đã chứng minh tấn công nghịch đảo mô hình (Model Inversion Attacks) có thể khai thác thông tin đầu ra và độ tin cậy để suy diễn lại các đặc trưng nhạy cảm của dữ liệu đầu vào. Trong bối cảnh mô hình biểu diễn nhật ký của đề tài (Mô hình đe dọa do nghiên cứu đề xuất / Threat Model Adaptation), các định danh như tên người dùng, tên máy chủ và chuỗi đối số dòng lệnh là các thuộc tính nhạy cảm tiềm năng cần phải kiểm thử thực nghiệm trước nguy cơ bị khôi phục hoặc xấp xỉ từ không gian vector biểu diễn. Một mô hình được thiết kế có nhận thức về quyền riêng tư (Privacy-Aware) không tự động đồng nghĩa với việc đã đạt được khả năng bảo vệ quyền riêng tư vững chắc (Privacy-Preserving) nếu chưa trải qua các kiểm thử thực nghiệm tấn công nghiêm ngặt [17].

Khoảng trống nghiên cứu này đòi hỏi phải phân tích tường minh mối quan hệ đánh đổi: Đây là điểm cân bằng giữa năng lực duy trì liên kết thực thể phục vụ phân tích an ninh và mức độ rò rỉ thông tin riêng tư của không gian vector đặc trưng? Từ đó, câu hỏi nghiên cứu thứ năm được xác lập:

- Câu hỏi nghiên cứu 5 (RQ5, Privacy-Security Trade-Off): Đây là sự cân bằng chấp nhận được giữa entity continuity và privacy leakage để representation vẫn hữu ích cho phân tích an toàn?

CHƯƠNG 2. PHƯƠNG PHÁP BIỂU DIỄN ĐẶC TRƯNG LOG ĐA GÓC NHÌN BẢO TOÀN NGŨ CẢNH AN TOÀN

2.1. Hình thức hóa bài toán và giới hạn xử lý dòng

2.1.1. Về mặt nhận thức luận khoa học, các hàm mất mát (loss) là các tín hiệu tối ưu hóa nội tại của quá trình huấn luyện, không phải bằng chứng khoa học tự thân chứng minh năng lực an ninh trực tiếp. Việc giảm một hàm mất mát phụ trợ (auxiliary loss) chỉ chứng minh mô hình tối ưu tốt hơn trên tác vụ đại diện (surrogate task) và dữ liệu được quan sát; mọi kết luận về năng lực phát hiện xâm nhập downstream, tính vững chắc hay độ an toàn quyền riêng tư bắt buộc phải được thẩm định độc lập qua các phép đo thực nghiệm tương ứng. **Biểu diễn đa góc nhìn và ranh giới Extractor–Detector**

Trên cơ sở các khoảng trống phương pháp luận được xác lập tại Chương 1, Chương 2 đề xuất khung phương pháp biểu diễn đặc trưng log đa góc nhìn bảo toàn ngũ cảnh an toàn, vận hành trực tuyến trong môi trường xử lý dòng (Streaming Environment). Quá trình biểu diễn bắt đầu bằng việc hình thức hóa luồng nhật ký kiểm toán hệ thống thành một chuỗi sự kiện được gán nhãn thời gian: $\mathcal{L}_{1:t} = \langle e_1, e_2, \dots, e_t \rangle$, trong đó mỗi sự kiện $e_i = (t_i, \tau_i, v_i, o_i, a_i, p_i)$ tuân thủ thống nhất lược đồ bộ sáu kiểu hóa (Typed Six-tuple, đặc tả chi tiết tại Mục 2.2.1), bao gồm mốc thời gian xuất hiện sự kiện $t_i \in \mathbb{R}_{\geq 0}$ (Event-Time), định danh kiểu sự kiện $\tau_i \in \mathcal{T}$, thực thể tác nhân chủ động $v_i \in \mathcal{V}$ (Actor Entity như tiến trình gốc, tài khoản người dùng), thực thể đối tượng đích chịu tác động $o_i \in \mathcal{O} \cup \{\perp\}$ (Object Entity như tệp tin, cổng mạng, tiến trình con), hành động/thao tác thực hiện $a_i \in \mathcal{A}$ (Action như fork, execve, read, write, connect, registry_set), và tập hợp các tham số động có cấu trúc $p_i = \{(k_j, v_j)\}_{j=1}^m$ (đường dẫn tệp tin, tham số dòng lệnh thực thi, cổng mạng và địa chỉ IP kết nối) [1].

Bài toán học biểu diễn đặc trưng log được phát biểu chính thức là việc tìm kiếm một ánh xạ tham số hóa f_θ biến đổi lịch sử sự kiện quan sát được $\mathcal{L}_{1:t}$ thành một vector biểu diễn tiềm ẩn liên tục $z_t \in \mathbb{R}^d$:

$$z_t = f_\theta(\mathcal{S}_t), \mathcal{S}_t = \text{Update}(\mathcal{S}_{t-1}, e_t)$$

Trong đó $\mathcal{S}_t$ là trạng thái bộ nhớ nội bộ hữu hạn tại thời điểm t , được cập nhật theo cơ chế đơn lượt theo chiều thời gian, không nhìn trước (Strictly Causal Single-pass Update) khi tiếp nhận sự kiện mới e_t . Quá trình học biểu diễn và đánh giá được tổ chức chặt chẽ theo ba giai đoạn giám sát độc lập (Supervision Contract):

1. Giai đoạn A (Stage A, Pretraining Tự giám sát Ngoại tuyến): Huấn luyện bộ trích xuất f_θ hoàn toàn theo cơ chế tự giám sát trên dữ liệu nền tảng lịch sử $\mathcal{D}_{\text{train}}$ mà không tiếp cận bất kỳ nhãn tấn công hay tín hiệu phân loại hạ nguồn nào, học các bất biến cấu trúc và trật tự thời gian nội tại.

2. Giai đoạn B (Stage B, Thích ứng Bằng chứng Yếu / Tùy chọn): Khi môi trường giám sát cung cấp các nhãn mức thô (Coarse/Bag-level Labels), một mục tiêu học đa thể hiện có trọng số chú ý (Attention-based Multiple Instance Learning) có thể được kích hoạt trong pha thích ứng riêng biệt nhằm tinh chỉnh phân bố trọng số cho các bằng chứng thừa thớt mà không làm sai lệch tính chất tự giám sát của Stage A.

3. Giai đoạn C (Stage C, Đánh giá Đóng băng Hạ nguồn): Khóa cố định toàn bộ tham số θ^* của bộ trích xuất biểu diễn. Đánh giá chất lượng biểu diễn thông qua giao thức đóng băng tham số (Frozen Linear Probe: $\hat{y}_t = \sigma(W^\top z_t + b)$) phục vụ phân loại và quy kết chiến thuật/kỹ thuật theo phân loại MITRE ATT&CK [4], hoặc quy trình chấm điểm bất thường không giám sát tùy chọn (Optional Downstream Zero-Shot Anomaly Scoring Protocol). Trong đó, hàm tính điểm bất thường, phép đo khoảng cách/năng lượng, phân bố nền chuẩn, phương pháp hiệu chuẩn và chính sách ngưỡng/ngân sách cảnh báo đều được đăng ký trước và khóa cố định trên tập Train/Validation tại Chương 3 trước khi mở tập Test. Bộ trích xuất Extractor tuyệt đối độc lập và không phụ thuộc vào bất kỳ bộ dò Detector cụ thể nào.

Trên cơ sở định nghĩa bài toán và ranh giới phương pháp luận, chuyên đề hình thức hóa năm giả thuyết khoa học cốt lõi (Hypotheses H1–H5 (Đóng góp Độc lập của Chuyên đề)):

Giả thuyết H1 (Parameter Semantic Fidelity, Đóng góp Độc lập): Biểu diễn nhận biết tham số X_{param} (chuỗi lệnh, đường dẫn tệp tin, địa chỉ IP) vào không gian vector z bảo tồn lượng thông tin tương hỗ về ngữ nghĩa an ninh tiềm ẩn Y_{sec} cao hơn có ý nghĩa so với biểu diễn chỉ dựa trên mẫu tĩnh hoặc bị trừu tượng hóa tham số $X_{\text{abstracted}}$:

$$\mathcal{I}(z; Y_{\text{sec}}) > \mathcal{I}(z_{\text{abstracted}}; Y_{\text{sec}})$$

Trong đó Y_{sec} là biến ngẫu nhiên đại diện cho mục tiêu ngữ nghĩa an ninh tiềm ẩn (như nhãn hành vi độc hại, ý định thực thi tiến trình, phân loại quyền hạn truy cập); $\mathcal{I}(\cdot; \cdot)$ là thước đo thông tin tương hỗ, với bộ ước lượng (Estimator) và giao thức thực nghiệm sẽ được thiết lập và khóa chặt chẽ tại Chương 3; giả thuyết chỉ kiểm tra tính trung thực ngữ nghĩa an ninh và không suy diễn tuyệt đối sang việc triệt tiêu súp đổ biểu diễn.

Giả thuyết H2 (Multi-View Alignment & Negative Transfer Prevention, Đóng góp Độc lập): Cơ chế giống hàng có kiểm soát giữa góc nhìn chuỗi sự kiện $z^{(\text{seq})}$ và góc nhìn đồ thị nguồn gốc $z^{(\text{graph})}$ được kỳ vọng nâng cao hiệu năng biểu diễn tổng thể vượt trên các góc nhìn đơn lẻ, đồng thời thỏa mãn các điều kiện kiểm chứng định lượng:

$$\begin{aligned} \text{Utility}(z) &> \max(\text{Utility}(z^{(\text{seq})}), \text{Utility}(z^{(\text{graph})})) - \epsilon_{\text{margin}}, \text{Var}(z) \geq \tau_{\text{var}}, \mathcal{I}(z; X_{\text{view}}) \\ &\geq \tau_{\text{info}} \end{aligned}$$

Trong đó $\tau_{\text{var}} > 0$ là ngưỡng phương sai duy trì độ đa dạng không gian (ngăn ngừa súp đổ biểu diễn), τ_{info} là ngưỡng bảo toàn thông tin đặc thù từng góc nhìn, và mức độ suy giảm do chuyển giao tiêu cực được khống chế $\Delta_{\text{neg}} \leq \epsilon_{\text{neg}}$ theo các ngưỡng xác lập trước thực nghiệm (các kỹ thuật cụ thể như InfoNCE, VICReg hay Barlow Twins được xem xét là ứng viên kỹ thuật tại Mục 2.4).

Giả thuyết H3 (Anti-Drift & Shortcut Invariance Robustness, Đóng góp Độc lập): Lợi ích biểu diễn của không gian vector z duy trì tính ổn định sau khi loại bỏ các đặc trưng đường tắt giả định $S \in \mathcal{E}_{\text{exclude}}$ ($\mathcal{I}(z; S) \leq \epsilon_{\text{short}}$) và dưới sự biến động phân

phối thực tế ($P_t(X, Y) \neq P_{t+1}(X, Y)$), đồng thời thỏa mãn ràng buộc ổn định khoảng cách hình học trước các biến đổi cú pháp vô hại $T \in \mathcal{T}_{\text{benign}}$:

$$\|z(T(X)) - z(X)\|_2 \leq \epsilon_{\text{inv}}, J(z; S) \leq \epsilon_{\text{short}}$$

Giả thuyết H4 (Bounded Operational Budget Feasibility, Đóng góp Độc lập): Quá trình trích xuất và cập nhật biểu diễn dòng vận hành ổn định trong giới hạn ngân sách độ trễ và bộ nhớ xác định trước, đáp ứng yêu cầu độ trễ xử lý mỗi sự kiện $\Delta t(e_t) \leq T_{\text{budget}}$ và dung lượng trạng thái bộ nhớ $\text{Mem}(\mathcal{S}_t) \leq M_{\text{max}}$ trên toàn bộ dòng thời gian vận hành dài hạn:

$$\Delta t(e_t) \leq T_{\text{budget}}, \text{Mem}(\mathcal{S}_t) \leq M_{\text{max}}, \forall t \geq 1$$

Giả thuyết H5 (Controlled Linkability & Utility–Privacy Frontier, Đóng góp Độc lập): Cơ chế duy trì liên kết có kiểm soát được kỳ vọng sẽ thiết lập sự vượt trội theo nghĩa Pareto (Pareto-dominance) so với các đường cơ sở giữ nguyên định danh thô hoặc ẩn danh hóa quá mức tại ít nhất một điểm vận hành thực tế dưới các thước đo hiệu năng an ninh (Utility) và tổn thất quyền riêng tư (Privacy Loss) đã định nghĩa trước:

$$\exists z: \text{Utility}(z) \geq \text{Utility}(z_{\text{baseline}}) \wedge \text{PrivacyLoss}(z) \leq \text{PrivacyLoss}(z_{\text{baseline}})$$

Trong đó lý thuyết Quyền riêng tư Vi sai (DP) đóng vai trò định lượng và chặn trên tổn thất lý thuyết (ϵ, δ) dưới các giả định toán học xác định, còn rủi ro thực tế được kiểm chứng thực nghiệm độc lập thông qua các tấn công suy luận thành viên (MIA) [16], [17] và tấn công nghịch đảo/tái định danh thực thể [33].

2.1.2. Độ phức tạp xử lý dòng với trạng thái hữu hạn

Trong môi trường giám sát an ninh SOC thời gian thực, luồng telemetry liên tục đổ về với lưu lượng rất lớn. Việc duy trì toàn bộ lịch sử tương tác của hệ thống trên bộ nhớ là bất khả thi về mặt tài nguyên. Do đó, chuyên đề thiết lập hợp đồng xử lý dòng với trạng thái hữu hạn (Bounded-State Streaming Contract), được quy định bởi ngân sách bộ nhớ trần M_{max} và tập thực thể hoạt động $\mathcal{V}_{\text{active}}(t)$:

$$\mathcal{V}_{\text{active}}(t) = \{v \in \mathcal{V} \mid t - t_{\text{last}}(v) \leq \tau_{\text{TTL}}, |\mathcal{S}_t| \leq M_{\text{max}}\}$$

Trong đó τ_{TTL} là ngưỡng thời gian sống (Time-To-Live). Một thực thể v (tiến trình, socket, tệp tin) không phát sinh bất kỳ tương tác nào trong khoảng thời gian τ_{TTL} sẽ hết hạn và đủ điều kiện loại bỏ (Eviction) khỏi bộ đệm trạng thái $\mathcal{S}_t$. Khi kích thước trạng thái tiếp cận ngưỡng ngân sách M_{max} , hệ thống kích hoạt yêu cầu thu dọn và nén tóm tắt dữ liệu. Để hiện thực hóa hợp đồng này, các kỹ thuật như chính sách Least Recently Updated (LRU), cấu trúc phác thảo Count-Min Sketch và hàm suy giảm trọng số cạnh theo hàm mũ $\omega(e_{uv}, t) = \exp(-\lambda(t - t_{uv}))$ được đề xuất như các ứng viên kỹ thuật hiện thực hóa (Proposed Implementation Choices) có thể thay thế hoặc tùy biến linh hoạt.

Xử lý hiện tượng sự kiện đến muộn hoặc xáo trộn thứ tự (Out-of-Order Events) phát sinh từ độ trễ mạng thu thập telemetry [1], [25], chuyên đề đề xuất nguyên tắc xử lý theo thời gian sự kiện kết hợp cơ chế mốc ngắt thời gian (Event-Time Watermark):

$$t_{\text{wm}} = \max_{1 \leq i \leq t} (t_{\text{event}}(e_i)) - \delta_{\text{delay}}$$

Mốc thời gian t_{wm} xác lập ranh giới trễ cho phép δ_{delay} ; các sự kiện đến muộn trong phạm vi δ_{delay} được tự động điều hòa vào trạng thái dòng. Các sự kiện đến trễ hơn δ_{delay} được chuyển tiếp vào bộ đệm tái điều chỉnh (Reconciliation Buffer) theo giao thức ghi nhận thất thoát thông tin xác định (Explicit Information-Loss Protocol) mà không làm gián đoạn luồng suy luận thời gian thực.


Khi hệ thống gặp hiện tượng đột biến lưu lượng (Traffic Spike), cơ chế kiểm soát áp lực ngược (Backpressure Control) dựa trên thuật toán Token-Bucket điều tiết tốc độ nạp dữ liệu. Nếu lưu lượng vượt quá giới hạn chịu tải tối đa, việc loại bỏ gói tin (Shedding) được thực hiện hoàn toàn độc lập với kết quả phát hiện của mô hình (dựa trên hạn ngạch băng thông nguồn thu thập hoặc mức độ ưu tiên của phân vùng telemetry, tuyệt đối không dựa vào điểm số an ninh chưa kiểm chứng) nhằm tránh rủi

ro rò rỉ vòng lặp (Detector Leakage) và loại bỏ nhằm các bằng chứng APT yếu thừa thớt.

Xét theo lý thuyết tính toán, mô hình dòng thiết lập hợp đồng ngân sách độ phức tạp cho từng thành phần xử lý ký hiệu tổng quát: $\mathcal{C}_{\text{step}} = \mathcal{C}_{\text{seq}}(L, d, \text{arch}) + \mathcal{C}_{\text{graph}}(\text{card}(\mathcal{V}_{\text{active}}), \text{card}(\mathcal{E}_{\text{window}}), \text{arch}) + \mathcal{C}_{\text{state}}(\text{idx}, M_{\text{max}}) + \mathcal{C}_{\text{align}}$. Trong đó các hàm chi phí phụ thuộc vào kiến trúc và cấu trúc dữ liệu cụ thể (ví dụ chi phí tự chú ý $\approx \mathcal{O}(L^2 \cdot d)$ nếu dùng Transformer chuẩn hoặc $\mathcal{O}(L \cdot d)$ nếu dùng biến thể tuyến tính, chi phí truyền tin đồ thị lân cận phụ thuộc số lớp và bậc đỉnh $\mathcal{O}(\deg_{\text{max}} \cdot d)$, chi phí cập nhật chỉ mục trạng thái $\mathcal{O}(\log \text{card}(\mathcal{V}_{\text{active}}))$ nếu sử dụng cây cân bằng). Các mức chặn Big-O cụ thể được đặc tả chặt chẽ cho từng nhánh tại Mục 2.3, Mục 2.4 và tổng hợp tại Bảng 2.2 và Bảng 2.4. Chuyên đề chỉ rõ bản chất đánh đổi cốt lõi (Long-Horizon Context Trade-off): các chiến dịch APT kéo dài nhiều tuần đòi hỏi duy trì ngữ cảnh tương tác sâu, trong khi bộ nhớ thực tế bị giới hạn bởi M_{max} , và thiết kế dòng giải quyết mâu thuẫn này bằng cơ chế nén ngữ cảnh có kiểm soát thay vì lưu trữ toàn bộ dữ liệu thô.

2.1.3. *Kiến trúc tổng thể và giao diện vào/ra*

Kiến trúc tổng thể của khung biểu diễn đặc trưng log đa góc nhìn dòng được thiết kế theo nguyên tắc phân tách độc lập giữa hai mặt phẳng vận hành: Mặt phẳng Huấn luyện (Training Plane) và Mặt phẳng Suy luận Dòng (Streaming Inference Plane), được minh họa chi tiết trong Hình 2.1:



Hình 2.1: Kiến trúc hai mặt phẳng (Training Plane & Inference Plane) của khung biểu diễn đặc trưng log đa góc nhìn dòng (Nguồn: Tác giả đề xuất)

1. Mặt phẳng Huấn luyện: Vận hành ngoại tuyến (Offline) trên kho dữ liệu telemetry lịch sử $\mathcal{D}_{\text{train}}$. Mặt phẳng này thực hiện trích xuất song song hai góc nhìn (chuỗi sự kiện và đồ thị nguồn gốc), tối ưu hóa hàm mất mát giống hàng đa góc nhìn kết hợp các số hạng điều hòa bất biến để tìm kiếm bộ trọng số tối ưu θ^* tại Giai đoạn A, đồng thời hỗ trợ pha thích ứng bằng chứng yếu Giai đoạn B (nếu có nhãn mức thô). Quá trình tiền huấn luyện hoàn toàn không sử dụng nhãn tấn công và không can thiệp vào luồng vận hành thời gian thực.

2. Mặt phẳng Suy luận Dòng: Vận hành trực tuyến (Online) trên luồng sự kiện đang diễn ra $e_t \in \mathcal{L}_{1:t}$. Mặt phẳng này tiếp nhận trọng số đã đóng băng hoàn toàn θ^* , cập nhật trạng thái bộ nhớ hữu hạn S_t theo các chính sách TTL, Eviction và Watermarking, sau đó trích xuất vector đóng gói $z_t = f_{\theta^*}(S_t) \in \mathbb{R}^d$ theo cơ chế đơn lượt đơn hướng (Strictly Causal, Zero Lookahead), cung cấp đầu vào tức thời cho các bộ dò tuyến tính đóng băng Giai đoạn C phục vụ phát hiện và quy kết chiến thuật/kỹ thuật MITRE ATT&CK.

2.2. Tiền xử lý và bảo vệ dynamic parameters

Mục 2.2 xác lập cơ sở tiền xử lý phục vụ toàn bộ pipeline trích xuất đặc trưng đa góc nhìn: từ luồng nhật ký thô đến các sự kiện đã được chuẩn hóa, phân loại tham số an ninh và bảo vệ quyền riêng tư có kiểm soát; tất cả đều tuân thủ nghiêm ngặt ranh giới Extractor–Detector và hợp đồng biểu diễn đã thiết lập tại Mục 2.1. Ba thành phần cốt lõi được trình bày theo thứ tự phụ thuộc logic: (1) Parsing và chuẩn hóa có nhận thức an ninh (2.2.1); (2) Mô hình đe dọa quyền riêng tư và cơ chế liên kết có kiểm soát (2.2.2); (3) Đồng bộ thời gian và cửa sổ ngữ cảnh đa tỷ lệ (2.2.3).

2.2.1. *Parsing, Typed Canonicalization, Entity Resolution và Security-aware Parameter Retention*

Điểm khởi đầu của pipeline là luồng nhật ký thô không đồng nhất từ nhiều nguồn thu thập: nhật ký kiểm toán hệ điều hành (auditd, Windows Event Log, Sysmon), nhật ký mạng, nhật ký xác thực. Mỗi nguồn sử dụng định dạng cú pháp riêng và ký pháp tham số đặc thù. Mục tiêu của giai đoạn tiền xử lý là ánh xạ tất cả sự kiện về một lược đồ bộ sáu có kiểu hóa (Typed Six-tuple Schema) trong khi bảo toàn mọi thông tin có giá trị an ninh nằm trong các tham số động.

2.2.1.1. **Typed Schema và Security-aware Parameter Retention**

Mỗi sự kiện thô sau khi qua bước parsing được biểu diễn dưới dạng bộ sáu có kiểu hóa (Typed Six-tuple) như sau:

$$\tilde{e}_i = (t_i, \tau_i, v_i, o_i, a_i, p_i)$$

Trong đó: $t_i \in \mathbb{R}_{\geq 0}$ là mốc thời gian sự kiện theo đồng hồ hệ thống nguồn; $\tau_i \in \mathcal{T}$ là kiểu hành vi kiểm toán (syscall, registry op, network op, auth op,...); $v_i \in \mathcal{V}$ là thực thể chủ thể (Actor) gồm tiến trình, người dùng, dịch vụ; $o_i \in \mathcal{O}$ là thực thể đối tượng (Object) gồm tệp tin, socket, registry key, tiến trình con; $a_i \in \mathcal{A}$ là hành động cụ thể (read, write, execute, connect, create, delete,...); $p_i = \{(k_j, v_j)\}_{j=1}^{m_i}$ là tập các tham số động có kiểu hóa cụ thể: đường dẫn tệp tin, địa chỉ IP và cổng đích, chuỗi đối

số dòng lệnh, giá trị registry, tên người dùng đích, mã trả về, đáp ứng đúng yêu cầu của Hợp đồng Biểu diễn yêu cầu bảo toàn.

Tập kiểu sự kiện $\mathcal{T}$ và tập hành động $\mathcal{A}$ được định nghĩa tĩnh theo đặc tả nguồn thu thập (auditd syscall table, Windows Event ID taxonomy, Sysmon event types) và không phụ thuộc vào dữ liệu huấn luyện, do đó không phát sinh rủi ro rò rỉ vocabulary từ tập kiểm tra (CTRL-LEAK-001). Ngược lại, từ vựng tham số động (đặc biệt là chuỗi đường dẫn tệp tin và đối số lệnh) phụ thuộc vào môi trường và được học hoàn toàn trên phân vùng huấn luyện $\mathcal{D}_{\text{train}}$ theo cơ chế fit-only: mọi thống kê, ánh xạ từ vựng và bảng chuẩn hóa đều được fit trên $\mathcal{D}_{\text{train}}$ và áp dụng ở trạng thái đóng băng (frozen state) lên phân vùng Validation và Test, qua đó bảo đảm không có thông tin ngược từ Val/Test nào được đưa vào quá trình fit.

2.2.1.2. Typed Canonicalization và Entity Resolution

Hạt nhân của giai đoạn chuẩn hóa là hai vị từ ngữ nghĩa bổ sung cho nhau, được áp dụng lên từng trường của bộ sáu kiểu hóa:

$$\text{Retain}(x) = \mathbf{1}[\text{Type}(x) \in \mathcal{T}_{\text{security}} \vee x \text{thỏa đặc tả an ninh tiên nghiệm}]$$

$$\text{Normalize}(x) = \phi(x) \text{ với } \phi \text{ loại bỏ biến thể định dạng, giữ nguyên ngữ nghĩa}$$

Vị từ $\text{Retain}(\cdot)$ được xác lập dựa trên kiểu ngữ nghĩa trường (field semantic type) và tính phù hợp an ninh xác định tiên nghiệm (a priori security relevance) hoặc được cấu hình độc quyền trên phân vùng $\mathcal{D}_{\text{train}}/\mathcal{D}_{\text{val}}$ theo đặc tả miền, tuyệt đối không phụ thuộc vào nhãn tấn công hay thống kê tập kiểm tra (loại trừ hoàn toàn rủi ro test leakage). Cụ thể, $\text{Retain}(\cdot)$ đánh giá $\mathbf{1} = \text{True}$ đối với các trường mang thông tin tương tác hệ thống trọng yếu: địa chỉ IP và cổng mạng, đường dẫn tệp tin thực thi/cấu hình, chuỗi đối số dòng lệnh, khóa registry, định danh tiến trình cha và con và tài khoản người dùng đích. Các quy tắc như kiểm tra dải IP mạng, khóa registry khởi động, hay cờ đặc quyền nếu được áp dụng chỉ đóng vai trò là các đặc trưng chính sách miền tùy chọn (optional domain-policy features) hỗ trợ chuẩn hóa biểu diễn, tuyệt đối không phải là bộ phán quyết tiên tri (oracle) để phân biệt hành vi độc hại; ranh giới Extractor–

Detector được duy trì nghiêm ngặt (Extractor không phải là rule-based detector). Ngược lại, các trường metadata môi trường cục bộ không mang ngữ nghĩa an ninh (như PID tạm thời, timestamp mili-giây nội bộ không phải Event-Time, số sequence kernel) được phân loại là KNOWN EXCLUDE FIELD và bị loại bỏ (DROP) trước khi đưa vào Extractor. Đối với các tham số chưa từng thấy hoặc chưa rõ ngữ nghĩa (UNSEEN / UNCERTAIN), hệ thống áp dụng chính sách UNKNOWN-SAFE (bảo toàn nhãn kiểu trường và cấu trúc, gán typed placeholder), không thực hiện loại bỏ mặc định.

Hàm chuẩn hóa $\phi(\cdot)$ Áp dụng các phép biến đổi định dạng tường minh: chuẩn hóa đường dẫn, các ký hiệu separator, junction thừa, chuẩn hóa phân cách; chuẩn hóa địa chỉ IP về dạng chính tắc (loại bỏ zero-padding, khai triển IPv6 viết tắt); chuẩn hóa timestamp về UTC epoch; lower-casing không phân biệt hoa thường với tên lệnh trên Windows. Quan trọng là hàm $\phi(\cdot)$ không được phép loại bỏ thông tin ngữ nghĩa an ninh dưới danh nghĩa “nhiều cú pháp”: ví dụ, khoảng trắng trong đối số lệnh không được thu gọn nếu điều đó phá vỡ khả năng tái tạo ý định lệnh. Ranh giới giữa nhiều định dạng và tham số an ninh được ghi nhận tường minh và không thay đổi trong suốt quá trình thực nghiệm.

Bảng 2.1 tóm tắt chính sách xử lý cho từng trường của bộ sáu kiểu hóa:

Bảng 2.1: Chính sách RETAIN / NORMALIZE / PRIVACY-PROTECT / UNKNOWN-SAFE cho các trường của bộ sáu kiểu hóa

Trường	Vai trò ngữ nghĩa	Chính sách giữ/chuẩn hóa	Xử lý quyền riêng tư và An toàn
t_i	Event-Time	NORMALIZE → UTC epoch	Quasi-ID khi kết hợp dữ liệu ngoài; đánh giá theo CTRL-PRIV-001
τ_i	Kiểu hành vi kiểm toán	RETAIN (tĩnh, không học)	Kiểu thấp, không PII trực tiếp

Trường	Vai trò ngữ nghĩa	Chính sách giữ/chuẩn hóa	Xử lý quyền riêng tư và An toàn
v_i	Thực thể chủ thể (Actor)	PRIVACY-PROTECT $\rightarrow \pi_\psi(v_i)$	Direct identifier; bắt buộc pseudonymize
o_i	Thực thể đối tượng	PRIVACY-PROTECT $\rightarrow \pi_\psi(o_i)$	Direct/quasi-ID; bắt buộc pseudonymize
a_i	Hành động	RETAIN (tĩnh)	Kiểm thấp
p_i (Retain=1)	Tham số an ninh được xác nhận	RETAIN + NORMALIZE $\rightarrow$ tokenize	Tokenize trên từ vựng $\mathcal{D}_{\text{train}}$; OOV $\rightarrow$ UNKNOWN-SAFE
p_i (KNOWN EXCLUDE)	Trường xác định không mang ngữ nghĩa an ninh (PID, timestamp cục bộ, sequence kernel)	DROP trước Extractor	Loại bỏ hoàn toàn trước khi đưa vào f_θ
p_i (UNSEEN / UNCERTAIN)	Tham số ngoài từ vựng $\mathcal{D}_{\text{train}}$ hoặc chưa rõ an ninh	UNKNOWN-SAFE (bảo toàn cấu trúc cú pháp)	Giữ nguyên field-type tag (PATH, IP, CMD, REG, USER) và vị trí cấu trúc; thay giá trị chuỗi bằng typed placeholder (<UNK-PATH>, <UNK-IP>, <UNK-CMD>)

2.2.1.3. Leakage-safe Preprocessing

Tất cả các thành phần tiền xử lý có trạng thái học được (bao gồm từ vựng tokenizer tham số động, bảng chuẩn hóa tên tiến trình theo môi trường, thống kê tần suất sự kiện phục vụ outlier filtering, và ngưỡng phân ngưỡng tham số) đều được fit độc quyền trên phân vùng huấn luyện $\mathcal{D}_{\text{train}}$ theo thứ tự nhân quả thời gian (causal-time order), tức là chỉ sử dụng dữ liệu quan sát trước thời điểm phân cắt huấn luyện. Phân vùng Validation và Test chỉ nhận các phép biến đổi (transform) từ trạng thái đóng băng đã fit, không có bất kỳ thông tin thống kê nào từ Val/Test được đưa trở lại (CTRL-LEAK-001: Anti-Leakage Temporal Split). Cụ thể:

Một là, phân vùng thời gian tuyến tính theo Event-Time: $\mathcal{D}_{\text{train}} < \mathcal{D}_{\text{val}} < \mathcal{D}_{\text{test}}$ trong đó ký hiệu $<$ biểu thị quan hệ xảy ra trước nghiêm ngặt theo thứ tự thời gian. Không có xáo trộn ngẫu nhiên (random shuffle) theo thời gian ở bất kỳ giai đoạn nào.

Hai là, tất cả preprocessor (tokenizer, normalizer, entity resolver, vocabulary builder) đều có trạng thái fit-freeze: quá trình fit chỉ chạy một lần trên $\mathcal{D}_{\text{train}}$.

Ba là, chính sách xử lý tham số chưa xác định (UNSEEN / UNCERTAIN SECURITY SEMANTICS) tuân thủ nghiêm ngặt nguyên tắc an toàn UNKNOWN-SAFE: tuyệt đối không áp dụng quy tắc mặc định hủy bỏ (không thực hiện UNCONFIRMED $\rightarrow$ DROP). Hệ thống phân định rạch ròi: (a) Các trường KNOWN EXCLUDE FIELD (metadata môi trường như PID, timestamp cục bộ mili-giây, số sequence nội bộ) được loại bỏ hoàn toàn trước khi đưa vào Extractor; (b) Các tham số UNSEEN hoặc chưa xác định rõ ngữ nghĩa an ninh xuất hiện trong tập Validation hoặc Test được giữ nguyên nhãn kiểu trường (field-type tag: PATH, IP, CMD, REG, USER) và bảo toàn vị trí cấu trúc của tham số trong bộ sáu, đồng thời thay thế giá trị chuỗi cụ thể bằng typed placeholder tương ứng (<UNK-PATH>, <UNK-IP>, <UNK-CMD>). Kỹ thuật này bảo đảm không sụp đổ (collapse) thông tin cấu trúc cú pháp cần thiết cho Extractor và không làm rò rỉ từ vựng.

Bốn là, ranh giới leakage-safe được kiểm tra tự động trong pipeline thực nghiệm: mọi phép fit nào truy cập dữ liệu ngoài $\mathcal{D}_{\text{train}}$ đều bị phát hiện và báo lỗi trước khi chạy thực nghiệm (xem CTRL-LEAK-001).

2.2.2. *Mô hình đe dọa quyền riêng tư và Controlled Linkability*

Các vector biểu diễn đặc trưng z_t và các sự kiện đã được chuẩn hóa $\tilde{e}_i$ tất yếu mang thông tin nhận dạng thực thể, xem đây là điều kiện cần thiết để duy trì ngữ cảnh hành vi và phục vụ phân tích tấn công đa giai đoạn (kế thừa H5 từ Mục 2.1). Tuy nhiên, việc lưu giữ thông tin nhận dạng thô trong không gian vector tạo ra bề mặt tấn công quyền riêng tư không cần thiết. Mục 2.2.2 hình thức hóa mô hình đe dọa và xác lập cơ chế liên kết có kiểm soát như một hợp đồng kỹ thuật. Cơ chế này được kỳ vọng thiết lập sự vượt trội Pareto theo H5 nhưng phải được kiểm chứng thực nghiệm tại Chương 3 (BOUNDARY-06: Privacy Claim Requires Attack-Based Empirical Evaluation).

2.2.2.1. **Data/Entity Adversary**

Lớp đe dọa thứ nhất là đối nghịch dữ liệu/thực thể (Data/Entity Adversary). Đối nghịch này có quyền truy cập trực tiếp hoặc gián tiếp vào các sự kiện đã chuẩn hóa $\tilde{e}_i$ hoặc các trạng thái trung gian trong pipeline tiền xử lý. Hai mối đe dọa chính:

Tấn công liên kết thực thể (Entity Linkage Attack): đối nghịch sử dụng các trường nhận dạng thô (tên người dùng, PID, hostname) để liên kết sự kiện giữa các phân đoạn thời gian, các hệ thống, hoặc giữa log nguồn và dữ liệu bên ngoài nhằm xác định danh tính cá nhân.

Tấn công tái định danh (Re-identification Attack): đối nghịch sử dụng các đặc trưng hành vi đặc trưng (pattern thao tác tệp tin, chuỗi lệnh đặc thù) kết hợp với thông tin bên ngoài để tái định danh thực thể đã bị ẩn danh hóa.

2.2.2.2. Model Adversary

Lớp đe dọa thứ hai là đối nghịch mô hình (Model Adversary). Đối nghịch này không truy cập trực tiếp dữ liệu thô mà tương tác với mô hình đã được triển khai hoặc với các vector biểu diễn z_t đã xuất ra. Hai mối đe dọa chính:

Tấn công suy luận thành viên (Membership Inference Attack, MIA): đối nghịch xác định xem một bản ghi dữ liệu cụ thể của một thực thể có nằm trong tập huấn luyện của mô hình hay không, thông qua quan sát hành vi đầu ra hoặc các đặc trưng của vector z ([16]).

Tấn công nghịch đảo biểu diễn (Representation/Model Inversion Attack): Về mặt nguyên lý, Fredrikson et al. [33] chứng minh tấn công nghịch đảo có thể khai thác thông tin đầu ra/độ tin cậy để tái cấu trúc thuộc tính dữ liệu; trong mô hình đe dọa thích ứng của đề tài (Threat-Model Adaptation), đối nghịch cố gắng khôi phục hoặc xấp xỉ các thuộc tính nhạy cảm tiềm năng (như tên người dùng, hostname, chuỗi lệnh) từ vector nhúng z .

Lưu ý quan trọng: sự tồn tại của hai lớp đe dọa trên không đồng nghĩa với việc mọi thiết kế đều bị tổn thương ở mức độ như nhau. Mức độ tổn thương thực tế phụ thuộc vào kiến trúc cụ thể của f_θ và cơ chế liên kết được chọn; mức độ này được xác định qua kiểm thử tấn công thực nghiệm tại Chương 3 (CTRL-PRIV-001).

2.2.2.3. Controlled Linkability Mechanism Contract

Trước hai lớp đe dọa nêu trên trong khi vẫn bảo toàn ngữ cảnh hành vi cần thiết cho phân tích tấn công, chuyên đề xác lập Cơ chế Liên kết Có Kiểm soát như một hợp đồng kỹ thuật với ba thành phần:

Một là, cơ chế pseudonymization thực thể theo phiên (Session-scoped Pseudonymization): mỗi thực thể thực sự $v \in \mathcal{V}$ được ánh xạ về một mã định danh giả danh $\hat{v} = \pi_\psi(v)$ thông qua hàm ánh xạ xác định có kiểm soát $\pi_\psi: \mathcal{V} \rightarrow \hat{\mathcal{V}}$. Hàm π_ψ bảo toàn quan hệ đồng nhất thực thể (tức là $v_i = v_j \Rightarrow \pi_\psi(v_i) = \pi_\psi(v_j)$) để cho phép

liên kết hành vi theo thời gian (điều kiện cần để phát hiện APT đa giai đoạn), nhưng không giữ lại thông tin nhận dạng thô v không cần thiết cho mục đích phát hiện.

Hai là, cơ chế tokenization tham số động có chọn lọc (Security-selective Parameter Tokenization): các tham số động đã được $\text{Retain}(\cdot)$ xác nhận là mang ngữ nghĩa an ninh được tokenize thành các đơn vị học được theo kho từ vựng fit trên $\mathcal{D}_{\text{train}}$. Các trường KNOWN EXCLUDE FIELD được loại bỏ hoàn toàn trước khi đưa vào f_θ ; trong khi các tham số UNSEEN / UNCERTAIN được xử lý theo chính sách UNKNOWN-SAFE (bảo toàn nhãn kiểu trường và vị trí cấu trúc, gán typed placeholder), không bị loại bỏ tùy tiện.

Ba là, về phạm vi liên kết và rotation (Linkability Scope): hàm π_ψ xác lập bốn ranh giới tường minh: (a) Linkable within scope: trong cùng phiên, π_ψ nhất quán để hành vi đa giai đoạn của cùng thực thể vẫn liên kết được; (b) Unlinkable across rotation boundary: khi rotation xảy ra, cùng thực thể nhận mã giả danh mới, làm gián đoạn cross-session linkage; (c) Remains linkable: kiểu hành vi, thời gian tương đối và tham số an ninh giúp duy trì behavioral fingerprint; (d) Becomes unlinkable: tên thực sự v , o và các direct identifier. Rotation boundary phải được xác lập theo predefined operational policy hoặc được lựa chọn dựa trên tập Train/Validation, tuyệt đối không sử dụng thông tin từ true Test attack/campaign duration (loại trừ rủi ro test leakage). Tại Chương 3, chuyên đề đánh giá nhiều mốc rotation horizon cố định (fixed horizons) để xây dựng đường biên Utility–Privacy frontier. Trường hợp rotation horizon quá ngắn so với thời lượng chiến dịch APT thực tế sẽ dẫn tới việc cùng một thực thể nhận các mã giả danh khác nhau qua từng giai đoạn, làm phân mảnh khả năng liên kết chuỗi hành vi cross-phase nếu không có cơ chế tái liên kết an toàn; đây là failure case tường minh cần được định lượng trong đánh giá thực nghiệm. Thiết kế phạm vi cụ thể (session-scope vs. global scope) là quyết định thực nghiệm phụ thuộc vào đánh đổi này.

Hợp đồng kỹ thuật tổng quát của cơ chế Controlled Linkability được phát biểu như sau: với mọi sự kiện đã được chuẩn hóa $\tilde{e}_i$, sự kiện được biến đổi quyền riêng tư $\tilde{e}_i^{\text{priv}}$ được tạo ra bằng cách thay thế các trường nhận dạng thực thể bằng mã giả danh và áp dụng toán tử bảo vệ tham số an toàn ParamProtect(p_i) tuân thủ nguyên tắc: (i) các trường KNOWN EXCLUDE FIELD bị loại bỏ hoàn toàn; (ii) các tham số được Retain($\cdot$) xác nhận được tokenize trên $\mathcal{D}_{\text{train}}$; (iii) các tham số UNSEEN / UNCERTAIN được xử lý theo chính sách UNKNOWN-SAFE :

$$\tilde{e}_i^{\text{priv}} = (t_i, \tau_i, \pi_\psi(v_i), \pi_\psi(o_i), a_i, \text{ParamProtect}(p_i))$$

Lưu ý rằng các tham số thời gian và kiểu hành vi được bảo toàn nguyên vẹn vì chúng không phải direct identifier, tuy nhiên các tham số này có thể hoạt động như quasi-identifier khi kết hợp với dữ liệu bên ngoài; rủi ro liên kết tương ứng cần được đánh giá theo CTRL-PRIV-001. Cơ chế này được kỳ vọng thiết lập sự vượt trội Pareto theo nghĩa của H5 so với hai đường cơ sở: (a) giữ nguyên định danh thô không có pseudonymization; và (b) ẩn danh hóa quá mức xóa bỏ cả liên kết thực thể cần thiết cho phân tích hành vi. Tuy nhiên, khẳng định sự vượt trội này yêu cầu kiểm thử thực nghiệm tường minh tại Chương 3 thông qua CTRL-PRIV-001: đánh giá MIA ([16]), tấn công nghịch đảo (theo nguyên lý Fredrikson et al. [33] áp dụng cho các thuộc tính nhạy cảm của log), và tấn công tái định danh; không thể đưa ra kết luận chỉ từ lý thuyết DP hoặc thiết kế pseudonymization.

2.2.3. Đồng bộ thời gian và cửa sổ ngữ cảnh đa tỷ lệ

Sau khi các sự kiện được chuẩn hóa và bảo vệ quyền riêng tư theo Mục 2.2.1–2.2.2, bước tiếp theo là tổ chức chúng thành các đơn vị ngữ cảnh phục vụ các bộ trích xuất đặc trưng hạ nguồn tại Mục 2.3. Mục 2.2.3 giải quyết hai vấn đề liên quan chặt chẽ: (1) đảm bảo tính nhất quán Event-Time khi sự kiện đến từ nhiều nguồn có đồng hồ không đồng bộ; và (2) xây dựng cấu trúc cửa sổ ngữ cảnh đa tỷ lệ phù hợp với bản chất đa giai đoạn của chiến dịch APT. Cơ chế móc ngắt thời gian và tham số δ_{delay} đã

được xác lập tại Mục 2.1.2; Mục 2.2.3 kế thừa và áp dụng các định nghĩa đó mà không tái định nghĩa lại.

2.2.3.1. Event-Time, Clock Skew, Watermark và Late Events

Môi trường SOC thực tế thu thập log từ nhiều nguồn có đồng hồ hệ thống khác nhau, phát sinh hiện tượng lệch pha đồng hồ (Clock Skew). Lệch pha đồng hồ khiến các bản ghi telemetry tương ứng của cùng một sự kiện/tương tác quan sát được lại mang nhãn thời gian không nhất quán khi so sánh xuyên nguồn, làm xáo trộn thứ tự thời gian sự kiện dùng để xây dựng chuỗi và đồ thị hạ nguồn (lưu ý nguyên lý bất biến: quan hệ phụ thuộc ghi nhận trong log không đồng nhất với quan hệ nhân quả (nguyên lý: dependency $\neq$ causal effect)). Giai đoạn đồng bộ thời gian áp dụng một chuỗi bước xử lý có thứ tự:

(i) Chuẩn hóa múi giờ: tất cả nhãn thời gian được chuyển về UTC epoch trước khi so sánh xuyên nguồn.

(ii) Ước lượng và hiệu chỉnh lệch pha đồng hồ: với mỗi cặp nguồn có thể quan sát được sự kiện chung (ví dụ: cùng một kết nối mạng được ghi nhận bởi cả endpoint log và network log), offset lệch pha Δ_{skew} được ước lượng và hiệu chỉnh. Phương pháp ước lượng cụ thể (crystal-synced event matching, NTP-based correction,...) là quyết định triển khai phụ thuộc môi trường và không ảnh hưởng đến hợp đồng tiền xử lý.

(iii) Áp dụng cơ chế Watermark kế thừa từ Mục 2.1.2: tham số δ_{delay} xác lập cửa sổ dung sai cho sự kiện đến muộn sau đồng bộ thời gian. Các sự kiện đến trong cửa sổ $[t_{\text{wm}}, t_{\text{wm}} + \delta_{\text{delay}}]$ được tích hợp vào trạng thái dòng; các sự kiện đến trễ hơn được chuyển vào Reconciliation Buffer theo Explicit Information-Loss Protocol.

2.2.3.2. Multi-scale Context Windows

Đặc điểm của chiến dịch APT là hoạt động trải dài nhiều tỷ lệ thời gian khác nhau đồng thời: hành động tức thời (milliseconds đến seconds), chuỗi hành vi ngắn hạn (minutes đến hours), và chiến dịch dài hạn (days đến weeks). Một cửa sổ ngữ cảnh duy nhất không thể bao phủ đầy đủ tất cả tỷ lệ này mà không vi phạm ràng buộc bộ

nhớ hữu hạn $M_{\max}$ từ Mục 2.1.2. Chuyên đề đề xuất cấu trúc cửa sổ ngữ cảnh ba tỷ lệ (Multi-scale Context Windows) như một giải pháp phân cấp:

$$\mathcal{W} = \{W_s, W_m, W_L\}$$

Cửa sổ ngắn hạn W_s (Short-term Window): bao phủ chuỗi sự kiện gần nhất trong phạm vi thời gian ngắn (hyperparameter, ví dụ: vài phút đến hàng chục phút; khóa bằng Validation/operational budget tại Mục 2.3), cung cấp ngữ cảnh thực thi tức thời cho một tiến trình hoặc phiên làm việc. Cửa sổ này cung cấp dữ liệu đầu vào chính cho Bộ trích xuất tuần tự (Sequential Extractor) tại Mục 2.3. Kích thước $\text{card}(W_s)$ bị chặn trên bởi độ dài chuỗi tối đa $L_{\max}$ của kiến trúc encoder, với giá trị cụ thể sẽ được xác lập tại Mục 2.3 khi kiến trúc được khóa.

Cửa sổ trung hạn W_m (Medium-term Window): bao phủ lịch sử hành vi của thực thể trong phạm vi thời gian trung (hyperparameter, ví dụ: vài giờ đến một ngày; khóa bằng Validation budget), phản ánh các pattern hành vi đặc trưng của người dùng/tiến trình và cung cấp ngữ cảnh phát hiện leo thang đặc quyền hoặc lateral movement. Cửa sổ này được duy trì trong trạng thái hữu hạn $\mathcal{S}_t$ thông qua cơ chế nén trạng thái (state summary/sketch) đã xác lập tại Mục 2.1.2.

Cửa sổ dài hạn/Tóm tắt trạng thái W_L (Long-term State Summary): thay vì lưu trữ toàn bộ lịch sử thô (vi phạm $M_{\max}$), trạng thái dài hạn được duy trì dưới dạng các sketch thống kê nén gọn (ví dụ: Count-Min Sketch về tần suất hành vi loại sự kiện, hàm suy giảm trọng số cạnh theo thời gian). Đây chính là đánh đổi cốt lõi Long-Horizon Context Trade-off đã được xác lập tại Mục 2.1.2: chi phí tính toán và bộ nhớ cụ thể của W_L phụ thuộc vào lựa chọn cấu trúc sketch tại Mục 2.3–2.4.

Ba cửa sổ W_s, W_m, W_L không độc lập mà có quan hệ phân cấp: $W_s \subset W_m$ theo thứ tự thời gian, và W_L là tóm tắt nén của lịch sử trước W_m . Phân cấp này đảm bảo cùng một evidence có thể xuất hiện ở nhiều scale (W_s, W_m, W_L) dưới dạng bài biểu diễn khác nhau, nhưng không có thông tin tương lai nào bị nạp vào cửa sổ hiện tại (nguyên lý Strictly Causal / Zero Lookahead từ Mục 2.1.3). Sơ đồ phân cấp cụ thể và

giao diện đầu ra từ $\mathcal{W}$ sang các bộ trích xuất tại Mục 2.3 sẽ được hình thức hóa khi kiến trúc được xác lập.

2.3. Trích xuất đặc trưng đa góc nhìn

Sau giai đoạn tiền xử lý và đồng bộ thời gian tại Mục 2.2, luồng sự kiện kiểu hóa $\tilde{e}_i^{\text{priv}}$ được đưa vào hai bộ trích xuất đặc trưng song song nhằm khai thác hai góc nhìn bổ trợ cho nhau: góc nhìn tuần tự ngữ nghĩa (Semantic-Sequential View) và góc nhìn cấu trúc phụ thuộc (Dependency-Temporal Graph View). Mỗi bộ trích xuất hoạt động độc lập trên không gian đầu vào tương ứng và xuất ra một vector biểu diễn đặc trưng riêng biệt: $z_{\text{seq}} \in \mathbb{R}^{d_{\text{seq}}}$ và $z_{\text{graph}} \in \mathbb{R}^{d_{\text{graph}}}$. Hai vector này là đầu vào của tầng giống hệt và học biểu diễn thống nhất tại Mục 2.4.

2.3.1. Bộ trích xuất tuần tự ngữ nghĩa Transformer

Bộ trích xuất tuần tự ngữ nghĩa tiếp nhận chuỗi các sự kiện kiểu hóa trong cửa sổ ngắn hạn W_s gồm $L \leq L_{\text{max}}$ sự kiện liên tiếp, kế thừa kiến trúc Self-Attention tiêu chuẩn [34]. Nhiệm vụ của bộ trích xuất là mô hình hóa các phụ thuộc ngữ cảnh cục bộ, thứ tự gọi hàm hệ thống và tương tác tham số động mà không dựa trên bất kỳ nhãn phân loại tấn công nào ở hạ nguồn.

2.3.1.1. Biểu diễn sự kiện kiểu hóa và mã hóa ngữ cảnh

Mỗi sự kiện kiểu hóa $\tilde{e}_i^{\text{priv}} = (t_i, \tau_i, \pi_\psi(v_i), \pi_\psi(o_i), a_i, \text{ParamProtect}(p_i))$ được chiếu vào không gian vector liên tục $\mathbb{R}^{d_{\text{model}}}$ thông qua hàm nhúng kết hợp các thành phần thông tin theo cấu trúc:

$$\begin{aligned} \mathbf{x}_i = & \mathbf{e}_\tau(\tau_i) + \mathbf{e}_a(a_i) + \mathbf{e}_v(\pi_\psi(v_i)) + \mathbf{e}_o(\pi_\psi(o_i)) + \sum_{(k_j, v_j) \in p_i^{\text{priv}}} \mathbf{e}_p(k_j, v_j) \\ & + \mathbf{e}_{\text{time}}(t_i) + \mathbf{e}_{\text{pos}}(i) \end{aligned}$$

Trong đó: $\mathbf{e}_\tau, \mathbf{e}_a$ là các ma trận nhúng kiểu sự kiện và hành động tĩnh; $\mathbf{e}_v, \mathbf{e}_o$ là nhúng thực thể chủ thể và đối tượng theo không gian giả danh có kiểm soát; $\mathbf{e}_p$ là

những các token tham số an ninh được giữ lại; $e_{\text{pos}}(i)$ là mã hóa vị trí rời rạc; và $e_{\text{time}}(t_i)$ là hàm mã hóa thời gian liên tục điều hòa (Harmonic Time Encoding) dạng $e_{\text{time}}(t_i) = [\cos(\omega_1 t_i + \phi_1), \dots, \cos(\omega_k t_i + \phi_k)]^T$, kế thừa nguyên lý mã hóa thời gian liên tục trên đồ thị động [35], cung cấp biểu diễn học được của khoảng thời gian tương đối Δt giữa các hành vi liên tiếp. Toàn bộ các siêu tham số cấu trúc như số tầng encoder N_{layers} , số đầu chú ý N_{heads} , số chiều ẩn d_{model} , số chiều lan truyền d_{ff} và tỷ lệ dropout p_{drop} đều được xác lập dựa trên tập huấn luyện và kiểm định (Train/Validation), không sử dụng nhân kiểm tra.

2.3.1.2. Mục tiêu huấn luyện tự giám sát

Quy trình huấn luyện bộ trích xuất tuần tự mà không gây rò rỉ nhãn tấn công hay phụ thuộc vào tri thức chuyên gia định trước được tối ưu hóa qua ba mục tiêu tự giám sát (Self-supervised Objectives) với đầu dự đoán phụ trợ (Auxiliary Heads) và tiêu chuẩn tối ưu hóa rõ ràng:

1. Tác vụ dự đoán sự kiện bị che (Masked Event Prediction, $\mathcal{L}_{\text{MEP}}$): Thích ứng từ phương pháp LogBERT [20], che ngẫu nhiên tập chỉ số sự kiện $\mathcal{M}_{\text{event}} \subset \{1, \dots, L\}$ theo tỷ lệ che $r_{\text{mask}}^{\text{event}} \in (0,1)$ (trong đó đề tài lựa chọn giá trị 15% làm điểm khởi tạo tham chiếu và được khóa cố định trên tập Train/Validation trước khi đánh giá trên tập Test). Đầu dự đoán phụ trợ $\phi_{\text{seq}}^{\text{event}}: \mathbb{R}^{d_{\text{model}}} \rightarrow \mathbb{R}^{\text{card}(\mathcal{V}_{\text{event}})}$ ánh xạ trạng thái ẩn h_i sang không gian xác suất kiểu sự kiện. Mục tiêu (target) là nhãn kiểu sự kiện và hành động thực tế $y_i^{\text{event}} \in \{1, \dots, \text{card}(\mathcal{V}_{\text{event}})\}$, tối ưu hóa qua hàm mất mát Categorical Cross-Entropy trung bình trên tập bị che, cung cấp gradient cập nhật trực tiếp cho θ_{seq} và $\phi_{\text{seq}}^{\text{event}}$:

$$\mathcal{L}_{\text{MEP}} = -\frac{1}{\text{card}(\mathcal{M}_{\text{event}})} \sum_{i \in \mathcal{M}_{\text{event}}} \log[\text{softmax}(\phi_{\text{seq}}^{\text{event}}(\mathbf{h}_i^{\text{seq}}))]_{\tau_i}$$

2. Tác vụ dự đoán tham số an ninh bị che (Masked Parameter Prediction, $\mathcal{L}_{\text{MPP}}$): Thiết kế đóng góp riêng của chuyên đề nhằm che ngẫu nhiên tập tham số bảo toàn an ninh $\mathcal{M}_{\text{param}} \subset \{1, \dots, L\}$ theo tỷ lệ $r_{\text{mask}}^{\text{param}} \in (0,1)$ (khởi tạo tham chiếu

15% và được khóa cố định trên tập Validation trước khi thử nghiệm). Đầu dự đoán phụ trợ $\phi_{\text{seq}}^{\text{param}}: \mathbb{R}^{d_{\text{model}}} \rightarrow \mathbb{R}^{\text{card}(\mathcal{V}_{\text{param}})}$ dự đoán token tham số mục tiêu y_i^{param} . Mục tiêu tái dựng được định nghĩa chuẩn xác là token đã qua chuẩn hóa và biến đổi bảo vệ quyền riêng tư π_{ψ} tại Mục 2.2 (gồm token thực thể giả danh hóa, token tham số an ninh chuẩn hóa hoặc token kiểu hóa UNKNOWN-SAFE), tuyệt đối không đặt mục tiêu là chuỗi nhạy cảm thô. Hàm mất mát Categorical Cross-Entropy tính trung bình trên $\mathcal{M}_{\text{param}}$, truyền gradient cho θ_{seq} và $\phi_{\text{seq}}^{\text{param}}$:

$$\mathcal{L}_{MPP} = \frac{1}{\text{card}(\mathcal{M}_{\text{param}})} \sum_{i \in \mathcal{M}_{\text{param}}} \sum_{(k_j, v_j) \in \mathbf{p}_i^{\text{priv}}} \mathcal{L}_{\text{param}}(\phi_{\text{seq}}^{\text{param}}(\mathbf{h}_i^{\text{seq}}), (k_j, v_j))$$

3. Tác vụ dự đoán khoảng thời gian tương đối (Relative Time Gap Prediction, $\mathcal{L}_{\text{time}}$): Thiết kế đóng góp riêng của chuyên đề nhằm dự đoán khoảng cách thời gian giữa hai sự kiện kề nhau $\Delta t_{i,i+1} = t_{i+1} - t_i \geq 0$. Đầu hồi quy phụ trợ $\phi_{\text{seq}}^{\text{time}}: \mathbb{R}^{2d_{\text{model}}} \rightarrow \mathbb{R}$ tiếp nhận vector ghép $[h_i; h_{i+1}]$ để dự đoán giá trị logarit $\log(1 + \Delta t_{i,i+1})$. Tiêu chuẩn tối ưu hóa là hàm Smooth L1 (Huber criterion, $\delta = 1.0$) trung bình trên toàn bộ $L - 1$ cặp sự kiện liên kề, truyền gradient cho θ_{seq} và $\phi_{\text{seq}}^{\text{time}}$:

$$\mathcal{L}_{\text{time}} = \frac{1}{\text{card}(\mathcal{M}_{\text{time}})} \sum_{i \in \mathcal{M}_{\text{time}}} \mathcal{L}_{\delta}(\phi_{\text{seq}}^{\text{time}}(\mathbf{h}_i^{\text{seq}}), \log(1 + \Delta t_i))$$

Hàm mất mát tổng thể của Bộ trích xuất tuần tự trong Giai đoạn A1 là tổng kết hợp có trọng số: $\mathcal{L}_{\text{seq}}^{\text{self}} = \alpha_1 \mathcal{L}_{\text{MEP}} + \alpha_2 \mathcal{L}_{\text{MPP}} + \alpha_3 \mathcal{L}_{\text{time}}$, trong đó các hệ số $\alpha_1, \alpha_2, \alpha_3 > 0$ được tinh chỉnh trên tập Validation.


2.3.1.3. Giao diện đầu ra của bộ trích xuất tuần tự

Sau khi đi qua N_{layers} khối Transformer Encoder, chuỗi biểu diễn ẩn $H_{\text{seq}} = [h_1, \dots, h_L] \in \mathbb{R}^{L \times d_{\text{model}}}$ được tổng hợp thành vector biểu diễn ngữ cảnh tuần tự z_{seq} thông qua toán tử tổng hợp có trọng số chú ý (Attention-weighted Readout):

$$\alpha_i = \text{softmax} \left(\frac{w_{\text{seq}}^T h_i}{\sqrt{d_{\text{model}}}} \right)$$

$$z_{\text{seq}} = \sum_{i=1}^L \alpha_i W_{\text{proj}} h_i \in \mathbb{R}^{d_{\text{seq}}}$$

Đầu ra của Bộ trích xuất tuần tự là một gói biểu diễn chuẩn hóa mang vector $z_{\text{seq}} \in \mathbb{R}^{d_{\text{seq}}}$ đại diện cho toàn bộ chuỗi hành vi trong cửa sổ ngắn hạn W_s , kèm theo siêu dữ liệu tương ứng (Correspondence Metadata) bao gồm: khoảng thời gian sự kiện $[t_{\text{start}}, t_{\text{end}}]$, phạm vi thực thể hoặc phiên tương ứng, mặt nạ sẵn sàng của góc nhìn $m_{\text{seq}} \in \{0,1\}$, và định danh cửa sổ. Giao diện này cung cấp đầy đủ thông tin để Tầng giống hàng tại Mục 2.4 xác định quan hệ tương ứng giữa các góc nhìn mà không thực hiện dung hợp sớm hay sử dụng nhãn kiểm tra. Giả định kiến trúc gồm N_{layers} tầng Transformer Encoder, độ dài chuỗi đầu vào L , số chiều mô hình d_{model} và số chiều tầng truyền thẳng d_{ff} , độ phức tạp tính toán của bộ trích xuất tuần tự là $C_{\text{seq}} = \mathcal{O}(N_{\text{layers}} \cdot (L^2 \cdot d_{\text{model}} + L \cdot d_{\text{model}} \cdot d_{\text{ff}}))$, trong đó số hạng bậc hai phản ánh chi phí tính toán ma trận chú ý theo độ dài chuỗi.



Hình 2.2: Kiến trúc Bộ trích xuất tuần tự ngữ nghĩa Transformer và cơ chế học tự giám sát trên cửa sổ ngắn hạn (Nguồn: Tác giả đề xuất)

2.3.2. Xây dựng đồ thị nguồn gốc phụ thuộc thời gian và đảm bảo độ chân thực đồ thị

Song song với bộ trích xuất tuần tự, luồng sự kiện được chuyển hóa thành đồ thị nguồn gốc phụ thuộc thời gian (Dependency-Temporal Provenance Graph). Đồ thị này biểu diễn các quan hệ tương tác và luồng thông tin cấu trúc giữa các thực thể hệ thống. Quá trình xây dựng đồ thị tuân thủ quy trình ba bước: tiếp nhận sự kiện kiểu hóa, áp dụng các cơ chế ứng viên kiểm soát độ chân thực đồ thị (Graph-Fidelity Candidates), và nạp cấu trúc đã tinh lọc vào mô hình Temporal GNN.

2.3.2.1. Định kiểu hóa, cạnh có hướng và thuộc tính thời gian

Đồ thị nguồn gốc phụ thuộc thời gian tại thời điểm t được hình thức hóa dưới dạng đồ thị dị thể động $\mathcal{G}_t = (\mathcal{V}_t, \mathcal{E}_t, \phi_V, \phi_E, \tau_E)$, trong đó:

- Tập đỉnh kiểu hóa $\mathcal{V}_t$: phân loại thông qua hàm ánh xạ kiểu $\phi_V: \mathcal{V}_t \rightarrow \{\text{Process, File, Socket, User, Host}\}$, phân định ranh giới ngữ nghĩa giữa các loại tài nguyên hệ thống.
- Tập cạnh có hướng $\mathcal{E}_t$: mỗi cạnh $e = (u, v, r, t_e) \in \mathcal{E}_t$ thể hiện một tương tác quan sát được với kiểu quan hệ $r = \phi_E(e) \in \{\text{fork, exec, read, write, connect, bind}\}$ và mốc thời gian sự kiện $t_e = \tau_E(e)$.

- Thuộc tính cạnh: tích hợp các tham số an ninh đã được chuẩn hóa và bảo vệ quyền riêng tư (như số byte truyền nhận, cờ truy cập, mã trạng thái), gắn kèm vector thuộc tính $x_e \in \mathbb{R}^{d_{\text{edge}}}$.

Nguyên tắc cốt lõi: cạnh chỉ được tạo ra khi có sự kiện nhật ký kiểm toán ghi nhận tường minh tương tác giữa hai thực thể. Hệ thống không tự ý tạo cạnh nối chỉ dựa trên sự gần nhau về mặt thời gian giữa hai sự kiện rời rạc.

2.3.2.2. Quan hệ phụ thuộc quan sát được và ranh giới với quan hệ nhân quả

Một ranh giới phương pháp luận căn bản cần được duy trì xuyên suốt chuyên đề là sự phân định giữa quan hệ phụ thuộc quan sát được (Observable Dependency) và quan hệ nhân quả thực sự (Causal Effect). Các cạnh trong đồ thị nguồn gốc phản ánh luồng dữ liệu và quan hệ kiểm toán do hệ điều hành ghi lại, biểu thị khả năng có sự truyền dẫn thông tin (Information Flow Potential). Tuy nhiên, việc một tiến trình đọc tệp tin A rồi sau đó ghi vào tệp tin B không khẳng định một cách chắc chắn rằng nội dung trong B bị chi phối nhân quả bởi A (nguyên lý bất biến: dependency $\neq$ causal effect). Chuyên đề không sử dụng thuật ngữ đồ thị nhân quả trừ khi các giả định nhận dạng nhân quả chặt chẽ được thỏa mãn, tránh các suy diễn sai lầm trong việc truy vết nguồn gốc tấn công.

2.3.2.3. Các cơ chế ứng viên kiểm soát độ chân thực đồ thị và bùng nổ phụ thuộc

Trong môi trường thực tế, đồ thị nguồn gốc thường đối mặt với hiện tượng bùng nổ phụ thuộc và ô nhiễm liên kết từ các thực thể tồn tại lâu (Long-lived Entities như dịch vụ hệ thống, tiến trình nền). Để xử lý các thách thức này trước khi nạp đồ thị vào mô hình học máy, chuyên đề đề xuất bốn cơ chế ứng viên kiểm soát độ chân thực đồ thị (Proposed Graph-Fidelity Candidates) hoạt động độc lập với bộ phát hiện:

1. Phân rã thực thể theo đơn vị công việc (Unit-of-work Node Splitting): các tiến trình hệ thống chạy dài ngày được phân tách thành các đỉnh phiên dựa trên luồng thực thi (thread) hoặc ranh giới phiên xử lý, nhằm hạn chế việc một tiến trình duy nhất tạo liên kết ảo giữa các tác vụ không liên quan.

2. Hàm suy giảm trọng số cạnh theo thời gian (Temporal Edge Weight Decay): trọng số ảnh hưởng của cạnh suy giảm theo hàm mũ $w(e) = \exp(-\lambda(t - t_e))$, trong đó $\lambda > 0$ là hệ số suy giảm được xác định theo ngân sách trạng thái tại Mục 2.1.2, làm giảm độ ưu tiên của các tương tác cũ.
3. $t_{\text{first}} t_{\text{last}}$ Khi áp dụng mạng nơ-ron đồ thị trên đồ thị nguồn gốc có đường kính lớn, hai rủi ro kiến trúc phổ biến là hiện tượng làm mịn quá mức (Over-smoothing, Oono & Suzuki [44]) khiến biểu diễn các đỉnh hội tụ về các vector khó phân biệt, và hiện tượng nghẽn cổ chai thông tin (Over-squashing, Alon & Yahav [31]) khi thông tin từ vùng lân cận mở rộng theo hàm mũ bị ép vào một vector kích thước cố định. Chuyên đề đề xuất hai cơ chế ứng viên giảm thiểu (Mitigation Candidates):
4. Tính độc lập và đánh giá thực nghiệm: các cơ chế trên hoàn toàn dựa trên quy tắc cấu trúc và thời gian, không sử dụng điểm số tấn công hay nhãn kiểm tra để quyết định giữ hay xóa cạnh. Mức độ đóng góp và hiệu quả thực tế của từng cơ chế ứng viên được đánh giá định lượng thông qua phân tích triệt tiêu (Ablation Study) tại Chương 3.

2.3.2.4. Xử lý thực thể khởi động lạnh và thực thể mới

Hệ thống log thường xuyên xuất hiện các thực thể mới (tiền trình mới tạo, kết nối mạng tạm thời, máy chủ mới kết nối) chưa có lịch sử tương tác trong đồ thị, dẫn đến thách thức khởi động lạnh (Cold-start). Để xử lý hiện tượng này trong không gian biểu diễn:

- Khởi tạo vector trạng thái dựa trên kiểu thực thể: đỉnh mới v được khởi tạo vector đặc trưng ban đầu thông qua hàm nhúng kiểu thực thể học được (Entity-type-conditioned learnable initialization): $h_v^{(0)} = e_{\text{type}}(\phi_V(v))$. Cơ chế kế thừa ngữ cảnh từ tiền trình cha chỉ được kích hoạt như một tùy chọn hỗ trợ khi quan hệ cha con thực sự quan sát được trong luồng nhật ký kiểm toán và thỏa mãn

hợp đồng riêng tư, tuyệt đối không sử dụng thông tin nhân kiểm tra hay giả định mở rộng miền định danh.

- Toán tử tự kết nối điều hòa (Self-loop Regularization): nhằm hỗ trợ việc truyền thông điệp khi cấu trúc lân cận thừa thớt, mạng GNN có thể áp dụng toán tử tự kết nối điều hòa trong đồ thị tính toán của mô hình. Toán tử này chỉ tồn tại trong quá trình thực thi lan truyền thông điệp và không được ghi nhận vào đồ thị nguồn gốc G_t như một quan hệ quan sát được.

2.3.3. Bộ trích xuất đồ thị động Temporal GNN

Sau khi đồ thị nguồn gốc được xây dựng và áp dụng các cơ chế ứng viên kiểm soát độ chân thực, cấu trúc đồ thị động được đưa vào Bộ trích xuất Temporal GNN. Kế thừa khung xử lý bộ nhớ và truyền thông điệp thời gian động [36] cùng các nguyên lý thiết kế từ các hệ thống đồ thị nguồn gốc tiêu biểu [24], [25], [26], [27], chuyên đề hình thức hóa cơ chế truyền thông điệp thời gian có kiểu hóa (Typed Temporal Message Passing) phù hợp với dữ liệu log bảo toàn ngữ cảnh an ninh.

2.3.3.1. Truyền thông điệp thời gian có kiểu hóa

Tại mỗi sự kiện tương tác $e = (v, u, r, t)$, thông điệp truyền từ đỉnh nguồn v sang đỉnh đích u được tính toán dựa trên trạng thái bộ nhớ của các đỉnh ngay trước mốc thời gian sự kiện, khoảng thời gian tương đối, vector nhúng kiểu quan hệ và thuộc tính cạnh an toàn:

$$m_{v \rightarrow u}(t) = \text{Msg}(h_{v,pre}, h_{u,pre}, \delta_v(t), e_r, x_e)$$

Trong đó $h_{v,pre}$ và $h_{u,pre}$ là trạng thái bộ nhớ của v và u ngay trước event-time t ; e_r là vector nhúng của loại quan hệ r ; x_e là vector thuộc tính cạnh; $\delta_v(t) = t - t_{last}(v)$ là độ lệch thời gian so với tương tác gần nhất của v . Các thông điệp gửi đến đỉnh u trong cùng bước thời gian được tổng hợp qua hàm gom cụm:

$$m_{u,agg}(t) = \text{Agg}(\{m_{v \rightarrow u}(t) : (v, u) \in N_t(u)\})$$

Trạng thái bộ nhớ của thực thể u được cập nhật qua tế bào hồi quy (như GRU Cell) từ trạng thái trước đó và thông điệp tổng hợp:

$$h_u(t) = \text{Update}\left(h_{u,pre}, m_{u,agg}(t)\right)$$

2.3.3.2. Học biểu diễn tự giám sát trên đồ thị nguồn gốc động

Mục tiêu tối ưu hóa các tham số θ_{graph} của mạng Temporal GNN trong Giai đoạn A1 mà không sử dụng nhãn tấn công hay thông tin tương lai, chuyên đề thiết lập hàm mục tiêu tự giám sát đồ thị động $\mathcal{L}_{\text{graph}}^{\text{self}}$. Kế thừa cảm hứng từ mô hình MAGIC [26] về học biểu diễn qua cơ chế che giấu (Masked Graph Representation Learning) và mở rộng cho đồ thị nguồn gốc động theo thời gian (Adapted / Ours), hàm mục tiêu tự giám sát đồ thị được cấu thành từ ba tác vụ phụ trợ với đầu dự đoán riêng biệt:

$$\mathcal{L}_{\text{graph}}^{\text{self}} = \beta_1 \mathcal{L}_{\text{mask-node}} + \beta_2 \mathcal{L}_{\text{mask-edge}} + \beta_3 \mathcal{L}_{\text{time-gap}}$$

- Tác vụ tái tạo thuộc tính thực thể bị che (Masked Node Attribute Reconstruction, $\mathcal{L}_{\text{mask-node}}$): Che ngẫu nhiên một tỷ lệ $r_{\text{mask-node}} \in (0,1)$ thuộc tính kiểu hóa của các thực thể hoạt động $\mathcal{V}_{\text{mask}} \subset \mathcal{V}_{\text{active}}$ (trong đó $r_{\text{mask-node}}$ là siêu tham số được kiểm soát, tinh chỉnh và khóa cố định trên tập Validation). Đầu giải mã phụ trợ $\phi_{\text{graph}}^{\text{node}}: \mathbb{R}^{d_{\text{GNN}}} \rightarrow \mathbb{R}^{d_{\text{node-attr}}}$ tái tạo lại vector thuộc tính an toàn quyền riêng tư x_v^{priv} từ trạng thái ẩn $h_v(t)$ theo tiêu chuẩn hồi quy Mean Squared Error (MSE). Mục tiêu tái dựng được khóa chuẩn xác là x_v^{priv} , tức vector đặc trưng đỉnh kiểu hóa thu được SAU KHI đã áp dụng toàn diện quy trình chuẩn hóa, kiểm soát liên kết danh tính / giả danh hóa (Controlled Linkability / Pseudonymization) và chính sách UNKNOWN-SAFE tại Mục 2.2; tuyệt đối không đặt mục tiêu là tên người dùng thô, tên máy chủ thô, mã tiến trình thô, định danh đối tượng thô hay bất kỳ giá trị nhạy cảm nào trước biến đổi, bảo đảm tác vụ tự giám sát đồ thị tuân thủ

nghiêm ngặt cùng hợp đồng bảo vệ quyền riêng tư như tác vụ MPP của chuỗi; truyền gradient cập nhật cho θ_{graph} và $\phi_{\text{graph}}^{\text{node}}$:

$$\mathcal{L}_{\text{mask-node}} = \frac{1}{\text{card}(\mathcal{V}_{\text{mask}})} \sum_{v \in \mathcal{V}_{\text{mask}}} \|\phi_{\text{graph}}^{\text{node}}(\mathbf{h}_v(t)) - \mathbf{x}_v^{\text{priv}}\|_2^2$$

- Tác vụ dự đoán kiểu quan hệ cạnh bị che (Masked Edge Relation Prediction, $\mathcal{L}_{\text{mask-edge}}$): Che nhãn quan hệ tương tác trên tập cạnh $\mathcal{E}_{\text{mask}} \subset \mathcal{E}$ theo tỷ lệ $r_{\text{mask-edge}} \in (0,1)$ (siêu tham số được kiểm soát, tinh chỉnh và khóa cố định trên tập Validation trước khi đánh giá Test). Đầu phân loại phụ trợ $\phi_{\text{graph}}^{\text{edge}}: \mathbb{R}^{2d_{\text{GNN}}} \rightarrow \mathbb{R}^{\text{card}(\mathcal{R})}$ tiếp nhận vector ghép $[h_v(t); h_u(t)]$ và tối ưu hóa hàm Categorical Cross-Entropy đối với nhãn quan hệ thực tế $r_{(v,u)} \in \{1, \dots, \text{card}(\mathcal{R})\}$, truyền gradient cho θ_{graph} và $\phi_{\text{graph}}^{\text{edge}}$:

$$\begin{aligned} \mathcal{L}_{\text{mask-edge}} &= -\frac{1}{\text{card}(\mathcal{E}_{\text{mask}})} \sum_{(v,u) \in \mathcal{E}_{\text{mask}}} \log[\text{softmax}(\phi_{\text{graph}}^{\text{edge}}([h_v(t); h_u(t)]))_{r_{(v,u)}}] \end{aligned}$$

- Tác vụ dự đoán khoảng cách thời gian tương đối (Relative Temporal Gap Prediction, $\mathcal{L}_{\text{time-gap}}$): Dự đoán độ lệch thời gian tương tác $\Delta t_{v,u} = |t_v - t_u|$ giữa các cặp đỉnh tương tác trong tập cạnh hoạt động $\mathcal{E}_{\text{active}}$. Đầu hồi quy phụ trợ $\phi_{\text{graph}}^{\text{time}}: \mathbb{R}^{2d_{\text{GNN}}} \rightarrow \mathbb{R}$ tiếp nhận $[h_v(t); h_u(t)]$ và tối ưu hóa hàm Smooth L1 $\delta = 1.0$ đối với đích $\log(1 + \Delta t_{v,u})$, truyền gradient cho θ_{graph} và $\phi_{\text{graph}}^{\text{time}}$ (giúp mô hình học cấu trúc thứ tự và khoảng thời gian quan sát được giữa các sự kiện mà không hàm ý tác động nhân quả, tuân thủ nguyên tắc temporal order != causal effect và dependency != causal effect):

$$\begin{aligned} \mathcal{L}_{\text{time-gap}} &= \frac{1}{\text{card}(\mathcal{E}_{\text{active}})} \sum_{(v,u) \in \mathcal{E}_{\text{active}}} \mathcal{L}_{\delta}(\phi_{\text{graph}}^{\text{time}}([h_v(t); h_u(t)]), \log(1 \\ &\quad + \Delta t_{v,u})) \end{aligned}$$

Các trọng số $\beta_1, \beta_2, \beta_3 > 0$ là các siêu tham số cân bằng giữa các tác vụ phụ trợ. Hàm mục tiêu $\mathcal{L}_{\text{graph}}^{\text{self}}$ trực tiếp tối ưu hóa tập tham số θ_{graph} cùng các đầu phụ trợ trong Giai đoạn A1 và trở thành thành phần bảo toàn cấu trúc đồ thị trong hàm $\mathcal{L}_{\text{preserv}}$ tại Mục 2.4.

2.3.3.3. Kiểm soát hiện tượng làm mịn quá mức và nghẽn cổ chai thông tin

Khi áp dụng mạng nơ-ron đồ thị trên đồ thị nguồn gốc có đường kính lớn, hai rủi ro kiến trúc phổ biến là hiện tượng làm mịn quá mức (Over-smoothing, Oono & Suzuki [44]) khiến biểu diễn các đỉnh hội tụ về các vector khó phân biệt, và hiện tượng nghẽn cổ chai thông tin (Over-squashing, Alon & Yahav [31]) khi thông tin từ vùng lân cận mở rộng theo hàm mũ bị ép vào một vector kích thước cố định. Chuyên đề đề xuất hai cơ chế ứng viên giảm thiểu (Mitigation Candidates):


- Giảm thiểu Over-smoothing: giới hạn số lớp truyền thông điệp ở mức thấp ($K \leq 2$) kết hợp cơ chế kết nối tắt phần dư (Residual Skip-connections): $h_u^{(l)}(t) = h_u^{(l-1)}(t) + \text{GNN}(h_u^{(l-1)}(t), \dots)$, hỗ trợ duy trì tính phân biệt giữa các thực thể.
- Giảm thiểu Over-squashing: áp dụng cơ chế lấy mẫu lân cận có chọn lọc theo trọng số thời gian (Top-k Temporal Attention Sampling), ưu tiên tổng hợp thông điệp từ các đỉnh lân cận có hoạt động gần nhất thay vì mở rộng toàn bộ cây phụ thuộc nhiều bước. Cơ chế này được thiết kế để đánh giá đối sánh với các chính sách lấy mẫu toàn bộ lân cận (Full Neighborhood) và lấy mẫu theo độ mới (Recency Sampling) tại Chương 3, nhằm kiểm tra thực nghiệm liệu chính sách sampling có gây mất mát các bằng chứng APT dài hạn (long-range evidence) hay không.

2.3.3.4. Giao diện đầu ra của bộ trích xuất đồ thị

Vector biểu diễn đặc trưng đồ thị $\mathbf{z}_{\text{graph}}$ trên cửa sổ trung hạn W_m được tạo ra bằng cách tổng hợp trạng thái của tất cả các thực thể đang hoạt động trong cửa sổ:

$$\begin{aligned}\mathbf{z}_{\text{graph}} &= \text{Readout}_{\text{graph}}(\{\mathbf{h}_u(t) : u \in \mathcal{V}_{\text{active}}(W_m)\}) \\ &= \sum_{u \in \mathcal{V}_{\text{active}}} \text{softmax}\left(\frac{\mathbf{w}_{\text{graph}}^T \mathbf{h}_u(t)}{\sqrt{d_{\text{GNN}}}}\right) \mathbf{w}_{\text{proj}} \mathbf{h}_u(t) \in \mathbb{R}^{d_{\text{graph}}}\end{aligned}$$

Đầu ra của Bộ trích xuất đồ thị là một gói biểu diễn mang vector $\mathbf{z}_{\text{graph}} \in \mathbb{R}^{d_{\text{graph}}}$ tóm tắt cấu trúc đồ thị và sự lan truyền thông tin qua lại giữa các thực thể trong cửa sổ trung hạn W_m , đi kèm siêu dữ liệu tương ứng: khoảng thời gian $[t_{\text{start}}, t_{\text{end}}]$, tập thực thể hoạt động $\mathcal{V}_{\text{active}}$, mặt nạ sẵn sàng $m_{\text{graph}} \in \{0,1\}$, và định danh đồ thị con. Về mặt khung đa tỷ lệ, cửa sổ dài hạn W_L đã thiết lập tại Mục 2.2.3.2 đóng vai trò cung cấp ngữ cảnh trạng thái dài hạn có chặn (Bounded Long-term Context Summary) cho hệ thống mà không làm phát sinh bộ trích xuất thứ ba độc lập. Chi phí tính toán của nhánh đồ thị được phân lập giữa chi phí xây dựng cửa sổ và chi phí xử lý gia số theo từng sự kiện: xây dựng đồ thị $\mathcal{C}_{\text{build}} = \mathcal{O}(\text{card}(\mathcal{E}_W))$, tạo thông điệp $\mathcal{C}_{\text{msg}} = \mathcal{O}(\text{card}(\mathcal{E}_W) \cdot (d_{\text{GNN}} \cdot d_{\text{msg}} + d_{\text{attr}}))$, cập nhật trạng thái bộ nhớ với tập đỉnh nhận thông điệp $\mathcal{V}_{\text{upd}}(t) \subseteq \mathcal{V}_t$ là $\mathcal{C}_{\text{update}} = \mathcal{O}(\text{card}(\mathcal{V}_{\text{upd}}) \cdot d_{\text{GNN}}^2)$, và tổng hợp đầu ra $\mathcal{C}_{\text{readout}} = \mathcal{O}(\text{card}(\mathcal{V}_{\text{active}}) \cdot d_{\text{GNN}} + d_{\text{GNN}} \cdot d_{\text{graph}})$.



Hình 2.3: Kiến trúc xây dựng đồ thị nguồn gốc phụ thuộc thời gian và Bộ trích xuất Temporal GNN (Nguồn: Tác giả đề xuất)

Bảng 2.2: Đặc tả kiến trúc và độ phức tạp tính toán của hai bộ trích xuất đặc trưng đa góc nhìn

Thành phần trích xuất	Góc nhìn biểu diễn	Cấu trúc đầu vào	Mục tiêu biểu diễn	Độ phức tạp tính toán
Bộ trích xuất tuần tự (Transformer)	Tuần tự ngữ nghĩa	Cửa sổ ngắn W_s (L sự kiện)	Tự giám sát (MEP, MPP, Time Gap)	$\mathcal{O}(N_{\text{layers}} \cdot (L^2 \cdot d + L \cdot d \cdot d_{\text{ff}}))$
Xây dựng đồ thị nguồn gốc	Cấu trúc phụ thuộc	Luồng sự kiện $\tilde{e}_i^{\text{priv}}$	Độ chân thực đồ thị (Fidelity candidates)	$\mathcal{O}(\text{card}(\mathcal{E}_W))$
Bộ trích xuất đồ thị (Temporal GNN)	Đồ thị động	Đồ thị dị thể $\mathcal{G}_t$	Tự giám sát động (L_{graph})	$\mathcal{O}(\text{card}(\mathcal{E}_W) \cdot d + \text{card}(\mathcal{V}_{\text{upd}}) \cdot d^2)$
Giao diện biểu diễn đầu ra	Không gian ẩn đa góc nhìn	Vector z_{seq} & z_{graph}	Đầu vào cho tầng giống hàng (Mục 2.4)	$\mathcal{O}(d_{\text{seq}} + d_{\text{graph}})$

2.4. Gióng hàng và học biểu diễn thống nhất đa góc nhìn

Sau khi hai bộ trích xuất độc lập tại Mục 2.3 sản sinh hai vector đặc trưng ẩn $z_{\text{seq}} \in \mathbb{R}^{d_{\text{seq}}}$ (nắm bắt thứ tự vi mô, tham số an ninh và nhịp điệu thời gian trên cửa sổ ngắn hạn W_s) và $z_{\text{graph}} \in \mathbb{R}^{d_{\text{graph}}}$ (nắm bắt cấu trúc phụ thuộc quan sát được, luồng truyền lan thông tin và quan hệ phụ thuộc cấu trúc, thời gian trên cửa sổ trung hạn W_m), thách thức khoa học trung tâm là làm thế nào để dung hợp và gióng hàng hai nguồn thông tin dị thể này thành một vector biểu diễn thống nhất canonical $z_{\text{mv}} \in \mathbb{R}^{d_{\text{mv}}}$. Tầng gióng hàng đa góc nhìn (Multi-View Alignment Plane) xây dựng cơ chế phương pháp luận giải quyết câu hỏi nghiên cứu RQ2 và RQ4, thiết lập nền tảng kỹ thuật nhằm phục vụ kiểm định giả thuyết H2 và H4 tại Chương 3. Để đạt được mục tiêu này, chuyên đề thiết lập một quy trình tối ưu hóa đa tầng chặt chẽ: (1) thiết lập không gian ngữ nghĩa chung mà không gây sụp đổ biểu diễn; (2) bảo toàn đối xứng thông tin đặc thù nội góc nhìn (Symmetric Multi-View Preservation); (3) kiểm soát nhiễu đặc quyền và hành vi quản trị viên thông qua ngữ cảnh hóa đa chiều (Risk-aware Admin-Noise Control); (4) cung cấp cơ chế phân bổ bằng chứng yếu qua mô hình học đa thể hiện (Multiple Instance Learning, MIL) tùy chọn; và (5) thích ứng linh hoạt với hiện tượng khuyết góc nhìn (Missing-View) trong môi trường phân tán mà không vi phạm nguyên tắc nhân quả thời gian.

2.4.1. Gióng hàng đa góc nhìn dị thể

Mục 2.4.1 thiết lập Hợp đồng Tương ứng (Correspondence Contract), phân định ranh giới giữa Không gian Biểu diễn (Representation Space) và Không gian Chiếu (Projection Space), cùng các cơ chế điều hòa chống sụp đổ biểu diễn.

2.4.1.1. Hợp đồng tương ứng ngữ cảnh và siêu dữ liệu liên kết

Một cặp biểu diễn đa góc nhìn $(z_{\text{seq}}, z_{\text{graph}})$ được xem là một cặp tương ứng hợp lệ (Valid Correspondence Pair) nếu và chỉ nếu chúng thỏa mãn Hợp đồng Tương ứng

dựa trên bộ siêu dữ liệu liên kết $\mathcal{M} = \langle [t_{\text{start}}, t_{\text{end}}], \mathcal{E}_{\text{scope}}, m_{\text{seq}}, m_{\text{graph}} \rangle$ đã thiết lập tại Mục 2.3:

- Giao thoa khoảng thời gian quan sát (Temporal Interval Overlap): Khoảng thời gian hiệu lực của cửa sổ chuỗi ngắn hạn $[t_{\text{start}}^{\text{seq}}, t_{\text{end}}^{\text{seq}}]$ phải là tập con hoặc có giao thoa thực dương với khoảng thời gian của cửa sổ đồ thị trung hạn $[t_{\text{start}}^{\text{graph}}, t_{\text{end}}^{\text{graph}}]$, tức $[t_{\text{start}}^{\text{seq}}, t_{\text{end}}^{\text{seq}}] \cap [t_{\text{start}}^{\text{graph}}, t_{\text{end}}^{\text{graph}}] \neq \emptyset$.
- Giao thoa phạm vi thực thể (Entity Scope Overlap): Tập các thực thể hệ thống quan sát trong chuỗi $\mathcal{E}_{\text{scope}}^{\text{seq}}$ (tiền trình, người dùng, tài nguyên) phải chia sẻ ít nhất một đỉnh thực thể chung với tập đỉnh đồ thị $\mathcal{E}_{\text{scope}}^{\text{graph}} = \mathcal{V}_{\text{active}}(W_m)$, tức $\mathcal{E}_{\text{scope}}^{\text{seq}} \cap \mathcal{E}_{\text{scope}}^{\text{graph}} \neq \emptyset$.
- Tính đầy đủ của mặt nạ khả dụng (Availability Mask Completeness): Cả hai góc nhìn đều tồn tại dữ liệu đo kiểm thực tế trong khoảng quan sát, biểu thị bởi $m_{\text{seq}} = 1$ và $m_{\text{graph}} = 1$.

Tuyệt đối không sử dụng nhãn tấn công (Attack Labels) hay bất kỳ tín hiệu từ tập kiểm thử nào để định nghĩa cặp tương ứng trong Stage A. Các cặp tương ứng được hình thành hoàn toàn tự nhiên từ tiến trình vận hành hệ thống thực tế. Các trường hợp chỉ giao thoa một phần thực thể hoặc thời gian được xếp vào nhóm Tương ứng Cục bộ (Partial Correspondence), trong khi các trường hợp thiếu hụt một trong hai nguồn được xử lý qua cơ chế Góc nhìn Khuyết.

2.4.1.2. Phân tách không gian biểu diễn và không gian chiếu

Tránh hiện tượng mất mát thông tin cấu trúc đặc thù khi ép hai vector biểu diễn gốc z_{seq} và z_{graph} phải hội tụ về cùng một điểm, chuyên đề áp dụng nguyên lý phân tách không gian theo SimCLR [37] và VICReg [10]. Chúng ta đưa mỗi vector biểu diễn qua một đầu chiếu phi tuyến riêng biệt (Non-linear Projection Heads):

$$p_{\text{seq}} = g_{\text{seq}}(z_{\text{seq}}) = W_{p2} \cdot \text{GELU}(\text{LayerNorm}(W_{p1} z_{\text{seq}})) \in \mathbb{R}^{d_{\text{proj}}}$$

$$p_{\text{graph}} = g_{\text{graph}}(z_{\text{graph}}) = W_{g2} \cdot \text{GELU}(\text{LayerNorm}(W_{g1} z_{\text{graph}})) \in \mathbb{R}^{d_{\text{proj}}}$$

Trong đó g_{seq} và g_{graph} là các mạng MLP hai tầng có chuẩn hóa LayerNorm và hàm kích hoạt phi tuyến GELU; d_{proj} là số chiều của Không gian Chiếu. Việc phân tách này thiết lập một ranh giới phương pháp luận nghiêm ngặt: Không gian Chiếu $\mathbb{R}^{d_{\text{proj}}}$ chỉ phục vụ việc tính toán các hàm mất mát giống hàng tự giám sát và sẽ bị loại bỏ sau khi kết thúc Stage A; trong khi Không gian Biểu diễn $\mathbb{R}^{d_{\text{seq}}}$, $\mathbb{R}^{d_{\text{graph}}}$ và không gian biểu diễn thống nhất $\mathbb{R}^{d_{\text{mv}}}$ được bảo toàn nguyên vẹn để cung cấp đặc trưng cho các tác vụ hạ nguồn ở Stage C.

2.4.1.3. Phân tích đối sánh các cơ chế tự giám sát đa góc nhìn

Trong học biểu diễn tự giám sát, ba hướng tiếp cận tiêu biểu bao gồm: InfoNCE / Contrastive Learning [38], [37], Barlow Twins [11], và VICReg [10]. Bảng 2.3 phân tích đối sánh chi tiết các đặc tính lý thuyết từ các công bố gốc và các giả thuyết nghiên cứu của chuyên đề đối với dữ liệu telemetry an ninh:

Bảng 2.3: So sánh đối sánh các cơ chế tự giám sát đa góc nhìn trong bài toán an ninh mạng

Tiêu chí phương pháp luận	InfoNCE / Contrastive	Barlow Twins	VICReg (Ứng viên đề xuất)
Cơ chế điều hòa chống sụp đổ	Sử dụng phân bố mẫu âm (Negative pairs) để đẩy xa các phiên khác nhau [38], [37]	Ép ma trận tương quan chéo giữa hai view về ma trận đơn vị I [11]	Phân tách độc lập: Duy trì phương sai từng chiều + Phạt hiệp phương sai [10]
Yêu cầu mẫu âm (Negative pairs)	Bắt buộc (phụ thuộc vào cơ chế lấy mẫu âm trong batch)	Không yêu cầu mẫu âm tường minh	Không yêu cầu mẫu âm tường minh
Đặc tính phân tích trên telemetry	Rủi ro False Negatives tiềm tàng khi phạt các phiên bình thường độc lập có hành vi tương đồng (Giả thuyết chuyên đề, kiểm chứng tại Chương 3)	Độ ổn định phụ thuộc vào việc ước lượng tương quan chéo; rủi ro nhảy cảm thang đo chuỗi và đồ thị (Giả thuyết chuyên đề, kiểm chứng tại Chương 3)	Điều hòa độc lập phương sai và hiệp phương sai; kỳ vọng duy trì cấu trúc phân phối telemetry an ninh (Giả thuyết chuyên đề, kiểm chứng tại Chương 3)

Tiêu chí phương pháp luận	InfoNCE / Contrastive	Barlow Twins	VICReg (Ứng viên đề xuất)
Đặc tính phụ thuộc kích thước lô	Hiệu năng thường hưởng lợi khi kích thước lô đủ lớn để bao quát phân bố mẫu âm	Độ ổn định phụ thuộc vào việc ước lượng ma trận tương quan chéo trên batch	Ước lượng phương sai và hiệp phương sai trực tiếp trên phân bố lô huấn luyện
Vai trò trong đề tài	Phương pháp đối sánh (Ablation baseline) tại Chương 3	Phương pháp đối sánh (Ablation baseline) tại Chương 3	Ứng viên chính (Primary candidate), kiểm chứng thực nghiệm tại Chương 3

Từ phân tích phương pháp luận trên, chuyên đề lựa chọn VICReg (Variance-Invariance-Covariance Regularization) [10] làm ứng viên giống hàng cốt lõi (Primary Candidate). Theo Bardes et al. [10], VICReg thiết lập cơ chế tự giám sát không tương phản dựa trên điều hòa phương sai và hiệp phương sai (variance/covariance regularization) để ngăn ngừa sụp đổ biểu diễn mà không cần khai thác các cặp mẫu âm (negative pairs). Dựa trên đặc tính lý thuyết này của công bố gốc, nghiên cứu đề xuất giả thuyết thích nghi (Author Adaptation Hypothesis): việc loại bỏ nhu cầu lấy mẫu âm tường minh trong không gian telemetry log sẽ giúp giảm thiểu rủi ro âm tính giả (False Negatives), hạn chế việc ép các phiên telemetry bình thường độc lập nhưng có đặc trưng tương đồng ra xa nhau một cách nhân tạo. Giả thuyết này sẽ được kiểm chứng thực nghiệm độc lập tại Chương 3 trong mối tương quan với hai phương pháp đối chứng (Ablation Baselines) là InfoNCE [38], [37] và Barlow Twins [11].

2.4.1.4. Hàm mục tiêu giống hàng VICReg trên không gian chiếu

Hàm mục tiêu giống hàng VICReg trên một lô huấn luyện kích thước B gồm các cặp chiếu hợp lệ $\{(p_{\text{seq}}^{(i)}, p_{\text{graph}}^{(i)})\}_{i=1}^B$ được phân rã thành ba thành phần điều hòa tường minh:

- Số hạng Bất biến (Invariance Term, $\mathcal{L}_{\text{inv}}$): Đo lường khoảng cách sai số toàn phương trung bình giữa hai góc nhìn biểu diễn của cùng một thực thể hoặc khoảng thời gian:

$$\mathcal{L}_{inv}(\mathbf{P}_{seq}, \mathbf{P}_{graph}) = \frac{1}{B} \sum_{i=1}^B \left\| \mathbf{p}_{seq}^{(i)} - \mathbf{p}_{graph}^{(i)} \right\|_2^2$$

- Số hạng Phương sai (Variance Regularization, $\mathcal{L}_{var}$): Sử dụng hàm bản lề để duy trì độ lệch chuẩn của từng chiều đặc trưng trên toàn bộ lô huấn luyện lớn hơn một ngưỡng tối thiểu $\gamma > 0$ (giá trị khởi tạo tham chiếu $\gamma = 1$, được tối ưu hóa trên tập xác thực), kiểm soát nguy cơ sụp đổ điểm (Point Collapse):

$$\mathcal{L}_{var}(\mathbf{P}) = \frac{1}{d_{proj}} \sum_{j=1}^{d_{proj}} \max\left(0, \gamma - \sqrt{\text{Var}(\mathbf{p}_{:,j})} + \epsilon\right)$$

Trong đó công thức phương sai mẫu từng chiều đặc trưng $\text{Var}(\mathbf{p}_{:,j})$ và hằng số ổn định số học $\epsilon = 10^{-4}$ được xác định tường minh:

$$\text{Var}(\mathbf{p}_{:,j}) = \frac{1}{B-1} \sum_{i=1}^B (p_{i,j} - \bar{p}_j)^2$$

- Số hạng Hiệp phương sai (Covariance Regularization, $\mathcal{L}_{cov}$): Phạt tổng bình phương các phần tử nằm ngoài đường chéo chính của ma trận hiệp phương sai $\mathbf{C}(\mathbf{P}) \in \mathbb{R}^{d_{proj} \times d_{proj}}$, điều hòa các chiều đặc trưng theo hướng giảm tương quan tuyến tính giữa các chiều và giảm tính dư thừa thông tin (Redundancy Reduction), hạn chế hiện tượng sụp đổ số chiều (Dimensional Collapse):

$$\mathbf{C}(\mathbf{P}) = \frac{1}{B-1} \sum_{i=1}^B (\mathbf{p}^{(i)} - \bar{\mathbf{p}})(\mathbf{p}^{(i)} - \bar{\mathbf{p}})^T$$

$$\mathbf{C}_{off}(\mathbf{P}) = \mathbf{C}(\mathbf{P}) - \text{Diag}\left(\text{diag}(\mathbf{C}(\mathbf{P}))\right)$$

$$\mathcal{L}_{cov}(\mathbf{P}) = \left(\frac{1}{d_{proj}}\right) \left\| \mathbf{C}_{off}(\mathbf{P}) \right\|_F^2$$

Trong đó $\mathbf{C}_{off}(\mathbf{P})$ là ma trận hiệp phương sai $\mathbf{C}(\mathbf{P})$ sau khi đặt toàn bộ phần tử đường chéo chính bằng 0.

2.4.1.5. Cơ chế thích ứng góc nhìn khuyết và tương ứng từng phần

Trong thực tế giám sát an ninh phân tán, các cảm biến thu thập telemetry có thể gặp sự cố cục bộ, gây ra hiện tượng khuyết góc nhìn (Missing-View, Incomplete Telemetry). Chuyên đề xử lý vấn đề này theo khung tiếp cận của CPM-Nets [39] kết hợp cơ chế mặt nạ khả dụng và suy thoái duyên dáng (Graceful Degradation) do chuyên đề đề xuất:

- Trường hợp đầy đủ hai góc nhìn ($m_{\text{seq}} = 1, m_{\text{graph}} = 1$): Hệ thống kích hoạt toàn bộ luồng huấn luyện giống hàng và dung hợp đa góc nhìn.
- Trường hợp chỉ có chuỗi sự kiện ($m_{\text{seq}} = 1, m_{\text{graph}} = 0$): Vô hiệu hóa số hạng $\mathcal{L}_{\text{inv}}$ và các thành phần liên quan đến đồ thị; biểu diễn thống nhất tự động suy thoái duyên dáng về nhánh chuỗi thông qua phép chiếu thích ứng: $z_{\text{mv}} = f_{\text{adapt}}^{\text{seq}}(z_{\text{seq}}) = \text{LayerNorm}(W_{\text{out}}^{\text{seq}} z_{\text{seq}})$.
- Trường hợp chỉ có đồ thị nguồn gốc ($m_{\text{seq}} = 0, m_{\text{graph}} = 1$): Tương tự, hệ thống vô hiệu hóa $\mathcal{L}_{\text{inv}}$ và chuyển hướng biểu diễn thống nhất về nhánh đồ thị: $z_{\text{mv}} = f_{\text{adapt}}^{\text{graph}}(z_{\text{graph}}) = \text{LayerNorm}(W_{\text{out}}^{\text{graph}} z_{\text{graph}})$.
- Trường hợp tương ứng cục bộ: Khi hai góc nhìn chỉ giao nhau một phần về thời gian hoặc thực thể, hệ thống tính toán hệ số giao thoa Jaccard $0 < \rho_{\text{overlap}} \leq 1$ và điều tiết trọng số giống hàng tương thích: $\mathcal{L}_{\text{inv}}^{\text{partial}} = \rho_{\text{overlap}} \cdot \mathcal{L}_{\text{inv}}$.

Nguyên tắc bất biến: Hệ thống tuyệt đối không tự bịa đặt dữ liệu (Data Hallucination) cho góc nhìn bị thiếu, không sử dụng dữ liệu tương lai để nội suy và không sử dụng nhãn tấn công để bù đắp, tuân thủ nguyên tắc nhân quả thời gian của mặt phẳng suy luận dòng.

Lưu ý phương pháp luận về tính nhân quả: Khái niệm “Strictly Causal / Zero Lookahead” được định nghĩa chính xác theo nghĩa: hệ thống chỉ sử dụng dữ liệu đo kiểm trong quá khứ và hiện tại tại thời điểm suy luận dòng, tuyệt đối không sử dụng thông tin tương lai hay nhãn kiểm thử; khái niệm này KHÔNG hàm ý suy diễn quan

hệ nhân quả (Causal-effect Inference) theo nghĩa thống kê can thiệp. Trong an ninh mạng, sự phụ thuộc quan sát được không đồng nhất với tác động nhân quả.

2.4.2. *Nhận thức hành vi quản trị viên và điều hòa rủi ro*

Một yếu tố gây nhiễu quan trọng trong giám sát an ninh là sự chồng lấn giữa hoạt động quản trị hợp thức và hành vi tấn công. Mục 2.4.2 thiết lập khung phương pháp luận nhận thức hành vi quản trị (Risk-aware Administrative Behavior) và các cơ chế kiểm soát nhiễu đặc quyền (Admin-Noise Controls, Đề xuất của đề tài / Ours) nhằm giải quyết trực tiếp câu hỏi nghiên cứu RQ4.

2.4.2.1. **Nguyên tắc bất biến: Bất thường không đồng nhất với Độc hại**

Trong môi trường vận hành công nghệ thông tin thực tế, các hoạt động quản trị viên (System Administration), ví dụ như cài đặt bản vá hàng loạt, sao lưu cơ sở dữ liệu định kỳ, bảo trì từ xa thông qua PowerShell, SSH, WMI, PsExec hay các kịch bản script tự động hóa phức tạp, thường xuyên tạo ra các chuỗi sự kiện có tần suất cao đột biến, quyền hạn cao (Privileged Execution) và cấu trúc lệnh khác lạ so với người dùng thông thường. Tuy nhiên, các hoạt động này hoàn toàn hợp thức. Chuyên đề xác lập nguyên tắc khoa học cốt lõi: Hành vi bất thường không đồng nhất với hành vi độc hại (Unusual != Malicious).

Bộ trích xuất đa góc nhìn không đóng vai trò bộ phân loại dựa trên luật (Rule-based Detector) để gán nhãn cứng hoạt động quản trị là an toàn hay độc hại. Thay vào đó, bộ trích xuất có nhiệm vụ mã hóa toàn diện các đặc trưng ngữ cảnh quan sát được (Observable Context Features) vào không gian vector biểu diễn liên tục z_{mv} dựa trên 4 chiều thông tin an ninh:

- Ngữ cảnh đặc quyền (Privilege Context): Định lượng mức độ leo thang và phân cấp đặc quyền hệ thống theo thang đo liên tục, phản ánh đúng quyền hạn thực thi tại thời điểm quan sát mà không xem quyền hạn cao mặc định là mối đe dọa.
- Ngữ cảnh công cụ và tham số (Tool & Parameter Structure): Biểu diễn cấu trúc cú pháp câu lệnh, tham số thực thi động và trạng thái chữ ký số

(Signed/Unsigned State nếu quan sát được), phản ánh trung thực bản chất công cụ thực thi vào không gian vector.

- Ngữ cảnh thời gian và chu kỳ (Temporal & Cadence Regularity): Mô hình hóa tính chu kỳ của các tác vụ tự động (Cronjobs, Scheduled Tasks, Maintenance Windows) thông qua hàm phân phối nhịp điệu thời gian Δt , mã hóa các hoạt động định kỳ theo lịch trình và các hành vi tương tác thủ công vào biểu diễn thời gian.
- Ngữ cảnh lan truyền thực thể (Entity Footprint & Neighborhood Breadth): Biểu diễn luồng kết nối quản trị diện rộng và cấu trúc phân nhánh lân cận của đồ thị nguồn gốc trung hạn, tạo cơ sở cho các mô hình hạ nguồn phân biệt hành vi quản trị thông thường với các chuỗi lây lan ngang (Lateral Movement).

Toàn bộ các đặc trưng trên chỉ được mã hóa vào vector biểu diễn. Việc đưa ra quyết định độc hại hay an toàn (Malicious-vs-Benign Decision) được bàn giao hoàn toàn cho các mô hình đánh giá hạ nguồn ở Stage C và các kịch bản thực nghiệm tại Chương 3.

2.4.2.2. Kiểm soát biến gây nhiễu và ngăn chặn học đường tắt

Bảo đảm tính vững chắc (Robustness) của không gian vector biểu diễn, chuyên đề thiết lập các cơ chế kiểm soát biến gây nhiễu (Confounder Controls):

- Cấm học đường tắt định danh (No Identity / Role Shortcuts): Hệ thống tuyệt đối không sử dụng tên người dùng thô hoặc chuỗi ký tự chức danh làm đặc trưng đầu vào trực tiếp. Mọi định danh thực thể đều được chuẩn hóa và bảo vệ qua cơ chế Kiểm soát Liên kết Danh tính (Controlled Linkability, Mục 2.2.2), ngăn chặn mô hình học mối liên hệ giả tạo rằng “tài khoản Admin luôn an toàn” hoặc “tài khoản Guest luôn đáng ngờ”.
- Cấm rò rỉ nhãn kiểm thử và đặc quyền giám sát (No Privileged Test Knowledge): Trong toàn bộ quá trình tiền xử lý và huấn luyện tự giám sát, hệ thống tuyệt đối không sử dụng bất kỳ thông tin nào về nhãn tấn công tương lai hay danh sách

phân loại tĩnh từ tập kiểm thử, ngăn rò rỉ thông tin kiểm thử qua các kênh đã định nghĩa (Data Leakage Prevention).

2.4.3. Hàm mục tiêu thống nhất và phân bổ bằng chứng yếu

Mục 2.4.3 tổng hợp toàn bộ đồ thị tối ưu hóa (Optimization Graph) của chuyên đề, thiết lập hàm mục tiêu tự giám sát thống nhất trong Stage A, đóng kín các luồng gradient cho toàn bộ tập tham số, và tích hợp mô đun Phân bổ Bằng chứng Yếu qua mô hình học đa thể hiện (MIL) tùy chọn trong Stage B.

2.4.3.1. Đóng kín đồ thị tối ưu hóa và kiểm toán tham số huấn luyện

Theo nguyên tắc kiểm toán tham số có gradient (Zero Orphan Parameters), Bảng 2.4 tổng hợp toàn bộ tập tham số huấn luyện của hệ thống, xác định rõ giai đoạn huấn luyện, hàm mục tiêu sinh gradient, thời điểm đóng băng và vai trò khi suy luận trực tuyến:

Bảng 2.4: Kiểm toán toàn diện các khối tham số và đồ thị tối ưu hóa trong hệ thống

Khối tham số	Giai đoạn	Hàm mục tiêu sinh Gradient	Thời điểm đồng băng / Vòng đời	Dùng khi suy luận?
θ_{seq} (Transformer Encoder)	Stage A1 (Chuỗi)	$\mathcal{L}_{\text{seq}}^{\text{self}} = \alpha_1 \mathcal{L}_{\text{MEP}} + \alpha_2 \mathcal{L}_{\text{MPP}} + \alpha_3 \mathcal{L}_{\text{time}}$	Đồng băng sau A1; Tinh chỉnh ở A2	CÓ (Trích $\mathbf{Z}_{\text{seq}}$)
$\phi_{\text{seq}}^{\text{event}}, \phi_{\text{seq}}^{\text{param}}, \phi_{\text{seq}}^{\text{time}}$	Stage A1 (Chuỗi)	$\mathcal{L}_{\text{MEP}}, \mathcal{L}_{\text{MPP}}, \mathcal{L}_{\text{time}}$	Duy trì ở A2 cho $\mathcal{L}_{\text{preserv}}$; Hủy sau A2	KHÔNG (Ngắt bỏ)
θ_{graph} (Temporal GNN)	Stage A1 (Đồ thị)	$\mathcal{L}_{\text{graph}}^{\text{self}} = \beta_1 \mathcal{L}_{\text{mask-node}} + \beta_2 \mathcal{L}_{\text{mask-edge}} + \beta_3 \mathcal{L}_{\text{time-gap}}$	Đồng băng sau A1; Tinh chỉnh ở A2	CÓ (Trích $\mathbf{Z}_{\text{graph}}$)
$\phi_{\text{graph}}^{\text{node}}, \phi_{\text{graph}}^{\text{edge}}, \phi_{\text{graph}}^{\text{time}}$	Stage A1 (Đồ thị)	$\mathcal{L}_{\text{mask-node}}, \mathcal{L}_{\text{mask-edge}}, \mathcal{L}_{\text{time-gap}}$	Duy trì ở A2 cho $\mathcal{L}_{\text{preserv}}$; Hủy sau A2	KHÔNG (Ngắt bỏ)
$\mathcal{G}_{\text{seq}}, \mathcal{G}_{\text{graph}}$ (Projection Heads)	Stage A2 (Giống hàng)	$\mathcal{L}_{\text{align}} = \mathcal{L}_{\text{VICReg}}(P_{\text{seq}}, P_{\text{graph}})$	Đồng băng & Hủy sau Stage A2	KHÔNG (Ngắt bỏ)
w_r, b_r, w_g, b_g (Gating Weights)	Stage A2 (Dung hợp)	$\mathcal{L}_{\text{fuse-rec}}$ (Tái tạo tự giám sát)	Đồng băng sau Stage A2	CÓ (Tính $\mathbf{W}_{\text{rel}}$)
$P_{\text{fuse}}^{\text{seq}}, P_{\text{fuse}}^{\text{graph}}$ (Cross Proj)	Stage A2 (Dung hợp)	$\mathcal{L}_{\text{fuse-rec}}$ (Tái tạo tự giám sát)	Đồng băng sau Stage A2	CÓ (Chiều $\mathbb{R}^{d_{\text{cross}}}$)
$W_{\text{out}}^{\text{seq}}, W_{\text{out}}^{\text{graph}}, W_{\text{out}}^{\text{cross}}$	Stage A2 (Dung hợp)	$\mathcal{L}_{\text{fuse-rec}}$ (Tái tạo tự giám sát)	Đồng băng sau Stage A2	CÓ (Gộp $\mathbf{Z}_{\text{mv}}$)
$D_{\text{seq}}, D_{\text{graph}}$ (Linear Decoders)	Stage A2 (Dung hợp)	$\mathcal{L}_{\text{fuse-rec}}$ (Tái tạo tự giám sát)	Đồng băng & Hủy sau Stage A2	KHÔNG (Ngắt bỏ)
$w_{\text{mil}}, V_{\text{mil}}, U_{\text{mil}}, W_{\text{mil}}^{\text{cls}}, b_{\text{mil}}^{\text{cls}}$	Stage B (Tùy chọn)	$\mathcal{L}_{\text{MIL}}$ (Coarse Bag BCE)	Đồng băng sau Stage B (chỉ bản mở rộng)	TÙY CHỌN (Bản MIL)

2.4.3.2. Hàm mục tiêu tự giám sát thống nhất Stage A và Bảo toàn Đối xứng

Trong Stage A, chuyên đề áp dụng chiến lược Bảo toàn Đối xứng kết hợp hàm mất mát tái tạo dung hợp tự giám sát (Self-Supervised Fusion Reconstruction). Hàm mất mát bảo toàn đối xứng duy trì năng lực biểu diễn nội góc nhìn cho cả chuỗi và đồ thị thông qua việc tái sử dụng các mục tiêu tự giám sát nội tại:

$$\mathcal{L}_{\text{preserv}} = \mathcal{L}_{\text{seq}}^{\text{self}}(\mathbf{z}_{\text{seq}}) + \mathcal{L}_{\text{graph}}^{\text{self}}(\mathbf{z}_{\text{graph}})$$

Vòng đời và vai trò của các đầu dự đoán phụ trợ (Auxiliary SSL Heads Lifecycle): Trong Stage A1, các đầu phụ trợ $\phi_{\text{seq}}^{\text{event}}$, $\phi_{\text{seq}}^{\text{param}}$, $\phi_{\text{seq}}^{\text{time}}$ và $\phi_{\text{graph}}^{\text{node}}$, $\phi_{\text{graph}}^{\text{edge}}$, $\phi_{\text{graph}}^{\text{time}}$ được tối ưu hóa đồng thời cùng backbone tương ứng. Trong Stage A2, để tính toán hàm mất mát bảo toàn đối xứng $\mathcal{L}_{\text{preserv}} = \mathcal{L}_{\text{seq}}^{\text{self}} + \mathcal{L}_{\text{graph}}^{\text{self}}$ được thiết kế nhằm hạn chế nguy cơ trôi dạt biểu diễn (Representation Drift) và quên thảm họa (Catastrophic Forgetting) trong khi giống hàng đa góc nhìn (việc đánh giá định lượng hiệu quả thực tế được thực hiện tại Chương 3), các đầu phụ trợ này tiếp tục được duy trì để cung cấp gradient điều hòa. Ngay sau khi Stage A2 kết thúc, toàn bộ các đầu phụ trợ này cùng 2 đầu chiều phi tuyến g_{seq} , g_{graph} và 2 bộ giải mã tái tạo D_{seq} , D_{graph} đều bị ngắt bỏ. Tại thời điểm suy luận dòng (Stage C), chỉ các backbone θ_{seq} , θ_{graph} và các ma trận dung hợp chuẩn tắc được nạp để tính toán vector z_{mv} , bảo đảm nguyên tắc Zero Orphan Parameters và tối ưu tài nguyên thực thi trực tuyến.

Cung cấp tín hiệu học trực tiếp cho các ma trận dung hợp $P_{\text{fuse}}^{\dots}$, $W_{\text{out}}^{\dots}$, vector trọng số gating w_r, w_g và các ma trận giải mã tuyến tính $D_{\text{seq}} \in \mathbb{R}^{d_{\text{seq}} \times d_{\text{mv}}}$, $D_{\text{graph}} \in \mathbb{R}^{d_{\text{graph}} \times d_{\text{mv}}}$, chuyên đề thiết lập hàm mất mát tái tạo đa góc nhìn tự giám sát $\mathcal{L}_{\text{fuse-rec}}$:

$$\begin{aligned} \mathcal{L}_{\text{fuse-rec}} = & \|D_{\text{seq}}z_{\text{mv}} - \text{stopgrad}(z_{\text{seq}})\|_2^2 \\ & + \|D_{\text{graph}}z_{\text{mv}} - \text{stopgrad}(z_{\text{graph}})\|_2^2 \end{aligned}$$

Định tuyến luồng gradient: Để ngăn chặn hiện tượng co-adaptation không kiểm soát khiến vector đích tự trôi dạt, chuyên đề thiết lập toán tử chặn gradient tường minh $z_{\text{seq}}^{\text{target}} = \text{stopgrad}(z_{\text{seq}})$ và $z_{\text{graph}}^{\text{target}} = \text{stopgrad}(z_{\text{graph}})$. Hàm mất mát $\mathcal{L}_{\text{fuse-rec}}$ chỉ truyền gradient cập nhật cho các tham số tầng dung hợp và bộ giải mã ($w_r, b_r, w_g, b_g, P_{\text{fuse}}^{\dots}, W_{\text{out}}^{\dots}, D_{\text{seq}}, D_{\text{graph}}$) mà TUYỆT ĐỐI KHÔNG cập nhật ngược lại các trọng số backbone θ_{seq} và θ_{graph} . Trong quá trình tinh chỉnh liên hợp ở Stage A2, hai bộ trích xuất backbone θ_{seq} và θ_{graph} chỉ nhận luồng gradient duy nhất từ hàm giống hàng $\mathcal{L}_{\text{align}}$ kết hợp với hàm bảo toàn đối xứng $\mathcal{L}_{\text{preserv}}$.

Hàm mục tiêu tối ưu hóa thống nhất toàn bộ Stage A được xác lập:

$$\begin{aligned}\mathcal{L}_{Stage-A} = & \lambda_{inv}\mathcal{L}_{inv} + \lambda_{var}\left(\mathcal{L}_{var}(\mathbf{P}_{seq}) + \mathcal{L}_{var}(\mathbf{P}_{graph})\right) \\ & + \lambda_{cov}\left(\mathcal{L}_{cov}(\mathbf{P}_{seq}) + \mathcal{L}_{cov}(\mathbf{P}_{graph})\right) + \lambda_{spec}\mathcal{L}_{preserv} \\ & + \lambda_{rec}\mathcal{L}_{fuse-rec}\end{aligned}$$

Các hệ số siêu tham số $\lambda_{inv}, \lambda_{var}, \lambda_{cov}, \lambda_{spec}, \lambda_{rec}$ là các trọng số điều hòa được thiết lập giá trị khởi tạo tham chiếu $\{25.0, 25.0, 1.0, 1.0, 1.0\}$ và sẽ được tối ưu hóa, kiểm định độ nhạy thực nghiệm trên tập xác thực tại Chương 3.

2.4.3.3. Công độ tin cậy động và Phần thuật Gradient PCGrad

Đánh giá chất lượng góc nhìn và điều hòa xung đột gradient trong quá trình tối ưu hóa Stage A, hệ thống tích hợp vector chất lượng đo kiểm quan sát được q_{seq} và q_{graph} :

$$\begin{aligned}\mathbf{q}_{seq} &= [m_{seq}, Cov_{event}, \Delta t_{span}]^T \in \mathbb{R}^3, \mathbf{q}_{graph} \\ &= [m_{graph}, Cov_{graph}, Density_{edge}]^T \in \mathbb{R}^3 \\ s_{seq} &= \mathbf{w}_r^T [z_{seq}; \mathbf{q}_{seq}] + b_r, s_{graph} = \mathbf{w}_g^T [z_{graph}; \mathbf{q}_{graph}] + b_g \\ w_{rel}^{seq} &= \tau + (1 - 2\tau) \frac{\exp(s_{seq})}{\exp(s_{seq}) + \exp(s_{graph})}, w_{rel}^{graph} = 1 - w_{rel}^{seq}\end{aligned}$$

Trong đó $\tau = 0.05$ là siêu tham số ngưỡng chặn dưới an toàn, ngăn ngừa việc hạ trọng số về 0 (tính nhạy cảm của τ sẽ được kiểm chứng thực nghiệm tại Chương 3). Khi tối ưu hóa liên hợp, chuyên đề đề xuất áp dụng kỹ thuật phần thuật gradient PCGrad [40] trên tập tham số nhận đồng thời hai luồng gradient:

$$\theta_{PCGrad} = \text{dom}(\nabla \mathcal{L}_{align}) \cap \text{dom}(\nabla \mathcal{L}_{preserv})$$

Trong đó $g_{align} = \nabla_{\theta_{PCGrad}} \mathcal{L}_{align}$ và $g_{preserv} = \nabla_{\theta_{PCGrad}} \mathcal{L}_{preserv}$. Các gradient từ hàm tái tạo $\mathcal{L}_{fuse-rec}$ không tham gia vào phép chiếu PCGrad vì chúng chỉ cập nhật độc lập các tham số tầng dung hợp. Khi xảy ra xung đột hướng $\langle g_{align}, g_{preserv} \rangle < 0$, gradient giống hệt được chiếu vuông góc:

$$\mathbf{g}_{align} \leftarrow \mathbf{g}_{align} - \frac{\langle \mathbf{g}_{align}, \mathbf{g}_{preserv} \rangle}{\|\mathbf{g}_{preserv}\|_2^2} \mathbf{g}_{preserv}$$

Kỹ thuật chiếu trực giao PCGrad giúp giảm thiểu xung đột gradient giữa mục tiêu giống hàng liên góc nhìn và mục tiêu bảo toàn đặc thù nội góc nhìn theo tiêu chuẩn cosine; hiệu quả thực tế trong việc hạn chế hiện tượng chuyển giao tiêu cực sẽ được kiểm định qua phân tích triết tiêu tại Chương 3.

2.4.3.4. Stage B (Tùy chọn): Phân bổ bằng chứng yếu qua Attention-MIL

Trong các kịch bản an ninh thực tế, nhãn tấn công thường chỉ sẵn có ở mức độ thô, ví dụ: một phiên làm việc, một máy chủ, hoặc một cửa sổ chiến dịch kéo dài được xác định là bị xâm nhập (nhãn túi $Y_{\text{bag}} \in \{0,1\}$), nhưng không thể xác định chính xác sự kiện log đơn lẻ nào là hành vi tấn công. Để giải quyết thách thức này, chuyên đề thiết lập mô đun Phân bổ Bằng chứng Yếu tùy chọn ở Stage B dựa trên khung tiếp cận Học Đa Thể Hiện.

Chuyên đề áp dụng cơ chế Attention-based Deep MIL của Ilse et al. [15], nhưng thiết kế cơ chế ánh xạ Túi, Thực thể đặc thù cho bài toán an ninh mạng (Cybersecurity Bag-Instance Mapping, Đề xuất của đề tài / Ours):

- Định nghĩa Túi quan sát ($\text{Bag}, \mathcal{X}_{\text{bag}} = \{z_{\text{mv}}^{(1)}, z_{\text{mv}}^{(2)}, \dots, z_{\text{mv}}^{(K)}\}$): Một túi gồm K vector biểu diễn đa góc nhìn liên tiếp tương ứng với một phiên làm việc hoặc một cửa sổ giám sát của máy chủ.
- Định nghĩa Thực thể thành phần ($\text{Instance}, z_{\text{mv}}^{(i)}$): Mỗi vector biểu diễn đa góc nhìn tại thời điểm t_i đóng vai trò là một thể hiện bên trong túi.

Cơ chế Gated Attention-MIL với không gian chú ý ẩn kích thước d_{att} tính toán trọng số chú ý thích ứng $a_i \in [0,1]$ cho từng thể hiện:

$$a_i = \frac{\exp\left(\mathbf{w}_{mil}^T \left(\tanh\left(\mathbf{v}_{mil}\mathbf{z}_{mv}^{(i)}\right) \odot \sigma\left(\mathbf{u}_{mil}\mathbf{z}_{mv}^{(i)}\right)\right)\right)}{\sum_{j=1}^K \exp\left(\mathbf{w}_{mil}^T \left(\tanh\left(\mathbf{v}_{mil}\mathbf{z}_{mv}^{(j)}\right) \odot \sigma\left(\mathbf{u}_{mil}\mathbf{z}_{mv}^{(j)}\right)\right)\right)}$$

$$\mathbf{z}_{bag} = \sum_{i=1}^K a_i \mathbf{z}_{mv}^{(i)}$$

$$\hat{Y}_{bag} = \sigma(W_{mil_cls}\mathbf{z}_{bag} + b_{mil_cls})$$

$$\mathcal{L}_{MIL} = -Y_{bag} \log(\hat{Y}_{bag}) - (1 - Y_{bag}) \log(1 - \hat{Y}_{bag})$$

Phân định ranh giới giữa Khung trích xuất chuẩn tắc và Đầu phân lớp phụ trợ MIL: Cơ chế Gated Attention-MIL trang bị một đầu phân lớp túi phụ trợ W_{mil_cls}, b_{mil_cls} . Trong quy trình chuẩn hóa của chuyên đề:

- Giai đoạn Stage B: Chỉ sử dụng nhãn thô trên tập Huấn luyện và Xác thực (Train/Validation only) để huấn luyện đầu phân lớp phụ trợ và tùy chọn tinh chỉnh nhẹ không gian vector đặc trưng.
- Giai đoạn Stage C chuẩn tắc: Hệ thống hoàn toàn loại bỏ đầu phân lớp W_{mil_cls}, b_{mil_cls} cùng cấu trúc phân loại túi, đóng băng bộ trích xuất đặc trưng thuần túy để chỉ xuất gói biểu diễn chuẩn tắc $\mathcal{B}_{mv}$ chứa vector canonical $\mathbf{z}_{mv}$ cho các mô hình hạ nguồn độc lập.
- Biến thể tùy chọn hỗ trợ MIL (Optional MIL-Assisted Variant): Nếu kịch bản triển khai thực tế có nhu cầu giám sát trực quan điểm bằng chứng a_i , hệ thống định nghĩa riêng một biến thể hỗ trợ MIL, hoàn toàn phân định với Extractor chuẩn tắc. Tại Chương 3, chuyên đề sẽ báo cáo độc lập kết quả giữa ba cấu hình: SSL thuần túy (SSL-only), SSL kết hợp thích ứng MIL (SSL + MIL Adaptation), và Biến thể hỗ trợ MIL khi triển khai (MIL-assisted variant).

Ý nghĩa phương pháp luận của trọng số chú ý a_i : Trọng số a_i phản ánh mức độ đóng góp bằng chứng yếu (Weak Evidence Attribution Score) của cửa sổ quan sát thứ

i đối với trạng thái bất thường chung của toàn bộ túi. Chuyên đề nhấn mạnh ranh giới khoa học: Trọng số a_i là tín hiệu gợi ý điều tra, TUYỆT ĐỐI KHÔNG PHẢI là xác suất tấn công độc hại và KHÔNG PHẢI là bằng chứng giải thích nhân quả.

2.4.4. Biểu diễn thống nhất, giao diện đầu ra và độ phức tạp

Mục 2.4.4 xác lập công thức tổng hợp biểu diễn thống nhất canonical, định nghĩa giao diện chuẩn cho các mô hình hạ nguồn ở Stage C và phân tích chi phí tính toán.

2.4.4.1. Vector biểu diễn thống nhất canonical z_{mv} và giao diện Extractor

Kết hợp sức mạnh biểu diễn vi mô từ chuỗi và quan hệ cấu trúc vĩ mô từ đồ thị mà không áp đặt giả định đồng nhất số chiều tùy tiện, chuyên đề thiết lập các ánh xạ tuyến tính chuẩn hóa sang không gian tương tác chung $\mathbb{R}^{d_{cross}}$:

$$u_{seq} = P_{fuse}^{seq} z_{seq} \in \mathbb{R}^{d_{cross}}, u_{graph} = P_{fuse}^{graph} z_{graph} \in \mathbb{R}^{d_{cross}}$$

$$u_{cross} = u_{seq} \odot u_{graph} \in \mathbb{R}^{d_{cross}}$$

Trong đó $P_{fuse}^{seq} \in \mathbb{R}^{d_{cross} \times d_{seq}}$ và $P_{fuse}^{graph} \in \mathbb{R}^{d_{cross} \times d_{graph}}$ là các ma trận chiếu tuyến tính phục vụ dung hợp; ký hiệu $\odot$ biểu thị tích Hadamard trên không gian cùng số chiều $\mathbb{R}^{d_{cross}}$ nhằm nắm bắt tương tác phi tuyến bậc hai giữa hai góc nhìn. Vector biểu diễn thống nhất canonical $z_{mv} \in \mathbb{R}^{d_{mv}}$ được tổng hợp thông qua cơ chế Dung hợp có Công thức ứng:


$$z_{mv} = LayerNorm(m_{seq} w_{rel}^{seq} W_{out}^{seq} z_{seq} + m_{graph} w_{rel}^{graph} W_{out}^{graph} z_{graph} + m_{seq} m_{graph} W_{out}^{cross} u_{cross}) \in \mathbb{R}^{d_{mv}}$$

Trong đó $W_{out}^{seq} \in \mathbb{R}^{d_{mv} \times d_{seq}}$, $W_{out}^{graph} \in \mathbb{R}^{d_{mv} \times d_{graph}}$, $W_{out}^{cross} \in \mathbb{R}^{d_{mv} \times d_{cross}}$ là các ma trận trọng số đầu ra. Gói biểu diễn đầu ra đa góc nhìn được đóng gói chuẩn mực:

$$\mathcal{B}_{mv} = \langle z_{mv}, [t_{start}, t_{end}], \mathcal{E}_{scope}, m_{seq}, m_{graph}, w_{rel} \rangle$$

Gói biểu diễn $\mathcal{B}_{mv}$ tạo thành giao diện đầu ra duy nhất của toàn bộ Khung Trích xuất Đặc trưng Đa góc nhìn. Phù hợp với ranh giới phân định tầng tại Mục 1.1.3, Extractor tuyệt đối không chứa logic phát hiện bất thường hay ngưỡng phân lớp an

ninh. Gói biểu diễn được bàn giao nguyên vẹn sang Stage C phục vụ các đầu dò tuyến tính đồng bằng và quy trình chấm điểm bất thường không giám sát tùy chọn (Optional Downstream Zero-Shot Anomaly Scoring Protocol, trong đó hàm đo khoảng cách/năng lượng, phân bố nền và chính sách ngưỡng được tiền đăng ký và khóa cố định trên tập Train/Validation tại Chương 3).



Hình 2.4: Sơ đồ kiến trúc Gióng hàng đa góc nhìn, Kiểm soát sụp đổ và Tổng hợp biểu diễn thống nhất (Nguồn: Tác giả đề xuất)

2.4.4.2. Phân tích độ phức tạp tính toán và ngân sách streaming

Chi phí tính toán của Tầng Gióng hàng và Biểu diễn Thống nhất được phân định rõ ràng giữa giai đoạn huấn luyện tự giám sát và giai đoạn suy luận trực tuyến:

- Chi phí huấn luyện gióng hàng và tái tạo dung hợp: Trong mỗi bước huấn luyện lô B , chi phí chiếu phi tuyến qua MLP là $\mathcal{O}(B \cdot (d_{seq} + d_{graph})d_{proj})$. Chi phí tính toán hàm mất mát VICReg trên không gian chiếu là $\mathcal{O}(B \cdot d_{proj}^2)$, hàm tái tạo dung hợp là $\mathcal{O}(B \cdot (d_{seq} + d_{graph} + d_{cross})d_{mv})$, và chi phí phẫu thuật gradient PCGrad bổ sung trên tập tham số chia sẻ Θ_{PCGrad} sau khi đã tính các gradient thành phần là $\mathcal{O}(\text{card}(\Theta_{PCGrad}))$. Nếu kích hoạt mô đun Attention-MIL ở Stage B với không gian ẩn chú ý d_{att} , chi phí tính toán cho mỗi túi kích thước K bao gồm chi phí chiếu công chú ý $\mathcal{O}(K \cdot d_{mv} \cdot d_{att})$ và chi phí phân lớp túi $\mathcal{O}(K \cdot d_{att} + d_{mv})$, cho chi phí tổng thể mỗi túi là $\mathcal{O}(K \cdot d_{mv} \cdot d_{att} + d_{mv})$ (tuyến

tính theo quy mô túi $\mathcal{O}(K)$ khi các tham số chiều được cố định). Toàn bộ chi phí này chỉ phát sinh trong quá trình huấn luyện ngoại tuyến.

- Chi phí suy luận trực tuyến: Trong giai đoạn vận hành dòng, các đầu chiếu g_{seq}, g_{graph} và các mô đun mất mát được ngắt bỏ hoàn toàn. Chi phí dung hợp và tổng hợp đầu ra đa góc nhìn tăng thêm (Incremental Fusion/Readout Cost), sau khi đã có z_{seq} và z_{graph} , chỉ bao gồm các phép nhân ma trận, vector tuyến tính và cổng gating.

$$C_{fusion} = O(d_{seq}d_{cross} + d_{graph}d_{cross} + d_{seq}d_{mv} + d_{graph}d_{mv} + d_{cross}d_{mv})$$

Với kích thước các không gian vector đặc trưng được cố định, chi phí dung hợp cục bộ này không phụ thuộc vào độ dài toàn bộ luồng telemetry hoặc kích thước toàn đồ thị. Nhận định này chỉ áp dụng cho incremental fusion/readout sau khi z_{seq} và z_{graph} đã được tạo; không phải End-to-End Budget.

Chi phí tính toán toàn trình của toàn bộ hệ thống bao gồm: tiền xử lý sự kiện thô, trích xuất chuỗi ngắn hạn, cập nhật đồ thị động, lan truyền thông điệp Temporal GNN, quản lý trạng thái bộ nhớ hữu hạn và tổng hợp dung hợp đa góc nhìn. Các chỉ số đo kiểm thực nghiệm toàn trình (thông lượng sự kiện/giây, độ trễ p50/p95, dung lượng RAM, VRAM và kích thước trạng thái trên mỗi thực thể) sẽ được đo lường thực nghiệm chi tiết tại Chương 3 nhằm kiểm định toàn diện giả thuyết $H4$.

CHƯƠNG 3. THỰC NGHIỆM, ĐÁNH GIÁ VÀ ỨNG DỤNG

Chương này trình bày chi tiết công tác thực nghiệm, phương pháp luận đánh giá và các kết quả định lượng thu được nhằm kiểm chứng mô hình biểu diễn đồ thị sự kiện theo dòng thời gian liên tục (Temporal Graph View Encoder) đã đề xuất tại Chương 2. Mọi quy trình thực nghiệm đều tuân thủ các nguyên tắc kiểm toán độc lập: môi trường phần cứng và phần mềm được ghi nhận chính xác theo khóa môi trường, dữ liệu phân tách nhân quả chống rò rỉ thông tin, và kết quả được đối soát nguồn gốc độc lập trên từng hạt giống ngẫu nhiên. Toàn bộ các phân tích trong chương này được dẫn xuất trực tiếp từ các bằng chứng thực nghiệm máy đọc được, phân định rõ ràng giữa kết quả quan sát thực tế, suy diễn khoa học và các giới hạn kỹ thuật nội tại.

3.1. Thiết lập thực nghiệm và dữ liệu

3.1.1. *Môi trường tính toán, tính tái lập và kiểm định độ bất định thống kê*

Bảo đảm tính minh bạch và khả năng tái lập thực nghiệm, toàn bộ quá trình tiền huấn luyện được thực thi trên môi trường máy trạm độc lập với thông số kỹ thuật được xác định theo đúng khóa môi trường thực thi STAGE-A2-LOCAL-EXECUTION-ENVIRONMENT-V1.5.json. Hệ thống phần cứng trang bị card đồ họa NVIDIA GeForce RTX 3050 Ti Laptop GPU (dung lượng bộ nhớ 4.0 GB, Compute Capability 8.6, phiên bản driver 595.95, mã định danh UUID: GPU-3f4d825d-63ad-0695-1b32-466308a00b8c). Bộ xử lý trung tâm là Intel Core i5-12500H (12 Cores / 16 Threads) với bộ nhớ RAM hệ thống ghi nhận 15.71 GB.

Môi trường phần mềm vận hành trên nền tảng hệ điều hành Windows-11-10.0.26200-SP0, phiên bản Python 3.12.8, thư viện PyTorch 2.6.0+cu124 với CUDA runtime 12.4. Nhằm kiểm soát tối đa tính ngẫu nhiên của các phép toán trên nhân GPU, hệ thống cấu hình biến môi trường CUBLAS_WORKSPACE_CONFIG=:4096:8 và kích hoạt chế độ tính toán xác định torch.use_deterministic_algorithms(True). Đặc tả môi trường được niêm phong trong tệp bằng chứng experiments/evidence/stage-a2/preexecution/STAGE-A2-LOCAL-EXECUTION-ENVIRONMENT-V1.5.json với

mã băm SHA-256: 81d3ca4865a95c75cc2345695091265f948ad58e705865a3f8f780a9bf09f362.

Bảng 3.1: Thông số kỹ thuật môi trường thực nghiệm và khóa xác thực mật mã

Thành phần	Thông số kỹ thuật phần cứng / phần mềm	Khóa xác thực mật mã / Ghi chú
GPU phần cứng	NVIDIA GeForce RTX 3050 Ti Laptop GPU (4.0 GB, CC 8.6)	UUID: GPU-3f4d825d-63ad-0695-1...
Driver GPU	NVIDIA Display Driver 595.95	Khóa phiên bản cố định
Bộ vi xử lý	Intel Core i5-12500H (12 Cores / 16 Threads)	12 nhân vật lý, 16 luồng
Bộ nhớ hệ thống	RAM 15.71 GB	Ghi nhận từ môi trường lock
Hệ điều hành	Windows-11-10.0.26200-SP0	Nền tảng thực thi cục bộ
Phần mềm tính toán	Python 3.12.8, PyTorch 2.6.0+cu124, CUDA 12.4	cuBLAS :4096:8
Mã băm môi trường	STAGE-A2-LOCAL-EXECUTION-ENVIRONMENT-V1.5.json	SHA256: 81d3ca4865a95c75cc234569...

3.1.2. Hai tầng benchmark và giao thức phân chia nhân quả chống rò rỉ

Trong khuôn khổ nghiên cứu chuyên đề, thực nghiệm Stage A2 tập trung đánh giá trên tập dữ liệu chuẩn HDFS (Hadoop Distributed File System). Tập dữ liệu gốc HDFS_1.tar.gz (dung lượng 44.7 GB chưa nén) chứa tổng cộng 11,175,629 sự kiện log hệ thống được phân nhóm thành 575,061 phiên khối (Block Session ID), có mã băm toàn vẹn SHA-256: 6ca6c5bc2671c66afecee9369a2fdac606bf33997a2494ac66aa411fe3e95169.

Khác với các phương pháp xáo trộn ngẫu nhiên truyền thống có nguy cơ rò rỉ thông tin thời gian, nghiên cứu đề xuất và áp dụng quy trình phân chia dữ liệu theo thứ tự thời gian nhân quả nghiêm ngặt (Strict Causal Temporal Split), tuân thủ khuyến nghị

tránh rò rỉ thời gian (temporal snooping) của Arp et al. [8]. Toàn bộ các phân vùng dữ liệu được phân định theo thứ tự thời gian và xác thực bằng chữ ký mật mã:

1. Phân vùng Huấn luyện: Bao gồm đúng 35,000 phiên khối đầu tiên theo dòng thời gian thực tế, tương ứng với 586,577 sự kiện log, được tổ chức thành 2,292 cửa sổ ngữ cảnh (độ dài $W = 256$ sự kiện). Danh sách thành viên phiên khối huấn luyện có mã băm xác thực: 65b76694b0a3cf5c6d684a26899b1e5dca634cfd0985560149feddc12ca8ccfc.

2. Phân vùng Kiểm định: Gồm 7,500 phiên khối tiếp theo trên trục thời gian, tương ứng 119,531 sự kiện log, tổ chức thành 467 cửa sổ ngữ cảnh ($W = 256$). Mã băm xác thực danh sách phiên khối kiểm định: 14cf689f9682a354e104463b9f02806629a683dfdf36d72d88daf5b407b0609a.

3. Phân vùng Kiểm thử Niêm phong: Được niêm phong cách ly mật mã thông qua cơ chế Tường lửa Dữ liệu Kiểm thử (SEALED_CRYPTO_FIREWALL). Toàn bộ quá trình tối ưu hóa trọng số và kích hoạt điều kiện dừng sớm chỉ được thực hiện trên tập Train và Validation; chỉ số `test_opened` luôn được bảo toàn ở trạng thái false với 0 lượt truy cập, đảm bảo dữ liệu kiểm thử hoàn toàn chưa bị truy cập cho đến giai đoạn đánh giá hạ nguồn.

Bảng 3.2: Phân chia tập dữ liệu HDFS theo giao thức nhân quả chống rò rỉ

Phân vùng dữ liệu	Số phiên khối (Sessions)	Số sự kiện log (Events)	Số cửa sổ ngữ cảnh ($W=256$)	Mã băm tập hợp (Membership SHA-256)
Train Split	35,000	586,577	2,292	65b76694b0a3cf5c6d68...
Validation Split	7,500	119,531	467	14cf689f9682a354e104...
Sealed Test Split	Niêm phong cách ly	Niêm phong cách ly	Niêm phong cách ly	e07999decc7164e639a7...
Toàn bộ ngữ liệu	575,061	11,175,629	43,654	6ca6c5bc2671c66afece...

3.1.3. Hệ thống thang đo ba tầng và hàm mục tiêu huấn luyện

Theo khung đánh giá của luận văn, năng lực của vector biểu diễn đặc trưng log được kiểm chứng qua hệ thống thang đo ba tầng: (1) Thang đo Bản chất (Intrinsic Metrics) đo lường sai số dự đoán và độ phân kỳ phân phối trên không gian tự giám sát; (2) Thang đo Đầu dò (Probe Metrics) đánh giá năng lực phân tách tuyến tính các thuộc tính an ninh; và (3) Thang đo Vận hành (Operational Metrics) kiểm tra hiệu năng tính toán, độ trễ và thông lượng dòng sự kiện.

Kiến trúc thực nghiệm trong Stage A2 là mô hình TemporalGraphViewEncoder, bao gồm: bộ nhớ trạng thái thực thể động dựa trên tế bào GRUCell (d_mem=128), cơ chế chú ý thời gian đa đầu (Multi-Head Temporal Attention over causal event window), và phép chiếu thời gian liên tục điều hòa (Continuous Sinusoidal Time Projection phi(Delta t)). Mô hình xử lý đồ thị di thể với 4 loại nút thực thể và 8 loại quan hệ cạnh. Mô hình được tối ưu hóa bằng thuật toán AdamW (lr=5e-4, betas=(0.9, 0.98), eps=1e-8, weight_decay=0.01) kết hợp bộ lập lịch Linear Warmup (343 steps) + Cosine Annealing to min_lr=1e-5. Kích thước lô hiệu dụng là 1,024 events (4 windows x 256 events per optimizer step), tương ứng 573 bước cập nhật trọng số trên mỗi epoch (tổng số bước tối ưu hóa tối đa là 6,876 bước trên 12 epochs, trong đó giai đoạn khởi động kéo dài 343 bước).

Mục tiêu huấn luyện tự giám sát đa nhiệm (Multi-task Self-supervised Objective) trong Stage A2 được xây dựng từ ba thành phần tổn thất cục bộ:

- Mất mát Dự đoán Quan hệ Che giấu (Masked Relation Prediction Loss, L_{rel}): Đo lường sai số phân loại quan hệ cạnh giữa các thực thể dựa trên hàm mất mát cross-entropy:

$$\mathcal{L}_{mask-edge} = -\frac{1}{card(\mathcal{E}_{mask})} \sum_{(v,u) \in \mathcal{E}_{mask}} \log[softmax(\varphi_{graph}^{edge}([\mathbf{h}_v(t); \mathbf{h}_u(t)])_{r(v,u)})]$$

- Mất mát Tái cấu trúc Đặc trưng Nút (Masked Node Attribute Reconstruction Loss, L_{node}): Sử dụng sai số toàn phương trung bình để khôi phục vector thuộc tính nút bị che giấu:

$$\mathcal{L}_{mask-node} = \frac{1}{card(\mathcal{V}_{mask})} \sum_{v \in \mathcal{V}_{mask}} \|\varphi_{graph}^{node}(\mathbf{h}_v(t)) - \mathbf{x}_v^{priv}\|_2^2$$

- Mất mát Hồi quy Khoảng thời gian Sự kiện (Continuous Time Interval Regression Loss, L_{time}): Hồi quy độ lệch thời gian liên tục $\log(1 + \Delta t)$ bằng hàm mất mát Smooth L1:

$$\mathcal{L}_{time-gap} = \frac{1}{card(\mathcal{E}_{active})} \sum_{(v,u) \in \mathcal{E}_{active}} \mathcal{L}_{\delta}(\varphi_{graph}^{time}([\mathbf{h}_v(t); \mathbf{h}_u(t)]), \log(1 + \Delta t_{v,u}))$$

Hàm mất mát đồ thị tổng hợp Stage A2 (L_{graph}) là tổ hợp tuyến tính cố định giữa ba thành phần trên:

$$L_{graph} = 1.0 L_{rel} + 1.0 L_{node} + 0.1 L_{time}$$

3.2. Kết quả thực nghiệm và benchmarking

3.2.1. Kết quả huấn luyện Stage A2 trên 5 hạt ngẫu nhiên thực nghiệm

Đánh giá tính ổn định thống kê và loại trừ hiện tượng thiên lệch chọn lọc, chiến dịch thực nghiệm được tiến hành trên 5 hạt giống khởi tạo ngẫu nhiên độc lập: 999, 42, 7, 1337, và 2024. Dựa trên cấu hình Stage A2 chính thức hiện hành theo văn bản thẩm quyền `experiments/plans/STAGE-A2-FINAL-12-EPOCH-AUTHORITY.json` (trần 12 epochs, 6.876 bước tối ưu hóa, 343 bước khởi động tuyến tính) kết hợp kiểm toán nguồn gốc thực thi độc lập từ nhật ký Git và các tệp bằng chứng máy đọc được, các đợt chạy được phân loại khoa học và minh bạch như sau: (1) Nhóm Lệch Giao thức (Protocol Deviation): Seed 999 (hoàn thành 12 epochs với mất mát kiểm định 0,6095 nhưng có sai lệch giao thức tiền thi hành khi văn bản ủy quyền commit 244e81a5 ràng buộc kế hoạch chứa 573 bước khởi động trong khi mã nguồn thực thi sử dụng 343

bước), Seed 42 (quỹ đạo chạy theo bộ lập lịch cũ và dừng sớm tại Epoch 4 theo quy tắc dừng sớm đã tiền đăng ký), và Seed 7 (khớp lịch trình 12 epochs nhưng tệp ủy quyền chỉ được commit lên Git sau thời điểm khởi chạy); và (2) Nhóm Đợt chạy Không chuẩn (Noncanonical): Seed 1337 (chạy theo lịch trình cũ, dừng tại Epoch 12 và thiếu các tệp biên bản thực thi bắt buộc METRICS.json, RUN-MANIFEST.json, TEST-FIREWALL.json) và Seed 2024 (chứa sai lệch mã băm commit và điều chỉnh lịch học giữa chừng). Bảng 3.3 tổng hợp chi tiết số liệu đo đạc thực tế trên từng hạt giống từ các tệp nhật ký thực thi được xác minh; Bảng 3.4 ghi nhận trạng thái hồ sơ và điều kiện kết thúc từng đợt chạy.

Bảng 3.3: Kết quả huấn luyện Stage A2 trên 5 hạt ngẫu nhiên thực nghiệm

Hạt giống	Epoch	Số bước	Train loss	Best epoch	Best val loss	Val loss cuối	L_{rel}	L_{node}	L_{time}
Seed 999	12	6,876	0.1590	12	0.609500	0.609500	0.1943	0.4063	0.088 ₇
Seed 42	4	2,292	0.3083	1	6.081352	7.150944	4.9266	2.1803	0.440 ₇
Seed 7	12	6,876	0.1609	12	0.550259	0.550259	0.1833	0.3584	0.085 ₇
Seed 1337	12	6,876	0.1848	10	0.917827	1.205658	0.3063	0.8317	0.677 ₁
Seed 2024	12	6,876	0.1671	12	0.553257	0.553257	0.1974	0.3472	0.086 ₇
TB lệch thủ tục (3 seed)	-	-	0.2094	-	2.413704	2.770234	1.7681	0.9817	0.205 ₀

Ghi chú: Các trạng thái hồ sơ phản ánh mức độ tuân thủ quy trình ủy quyền, cấu hình và khả năng truy vết của từng đợt thực nghiệm; chúng không đồng nghĩa với lỗi tính toán hoặc checkpoint không sử dụng được. Các đợt có sai lệch được giữ lại để báo cáo minh bạch và được tách biệt khi tổng hợp kết quả chuẩn. Chi tiết trạng thái hồ sơ và điều kiện kết thúc từng đợt chạy được ghi nhận tại Bảng 3.4.

Bảng 3.4: Trạng thái hồ sơ và điều kiện kết thúc các đợt thực nghiệm
Stage A2

Hạt giống	Trạng thái hồ sơ	Lý do kết thúc
Seed 999	Có sai lệch thủ tục	Đạt trần epoch
Seed 42	Có sai lệch thủ tục	Dừng sớm
Seed 7	Có sai lệch thủ tục	Đạt trần epoch
Seed 1337	Ngoài tập chuẩn	Dừng giữa chừng
Seed 2024	Ngoài tập chuẩn	Đạt trần epoch
TB lệch thủ tục (3 seed)	Có sai lệch thủ tục	-

Từ kết quả Bảng 3.3, toàn bộ 5 hạt giống thực nghiệm được bóc tách và đối soát nguồn gốc độc lập. Trong khuôn khổ kiểm toán hợp đồng tiền thi hành nghiêm ngặt, không có đợt chạy nào thỏa mãn đầy đủ các điều kiện đạt chuẩn (Canonical) do xuất hiện độ lệch giao thức (protocol deviation) giữa kế hoạch tiền thi hành và quá trình thực thi thực tế; độ lệch này là yêu cầu kiểm toán thủ tục, không đồng nhất với lỗi hỏng huấn luyện (training failure). Đối với nhóm quan sát lệch thủ tục (Seed 999, Seed 42, Seed 7), mức mất mát kiểm định tốt nhất ghi nhận trung bình là 2.413704 và mất mát kiểm định cuối trung bình đạt 2.770234. Trong đó, Seed 999 hoàn thành 12 epochs với mất mát kiểm định 0,609500 nhưng mang sai lệch về số bước khởi động so với văn bản ủy quyền; Seed 7 đạt mức mất mát kiểm định tốt nhất 0,550259 nhưng văn bản ủy quyền được commit sau khi khởi chạy; Seed 42 dừng sớm tại Epoch 4 theo quy tắc dừng sớm đã tiền đăng ký. Các thành phần mất mát kiểm định cuối (L_{rel} , L_{node} , L_{time}) tuân thủ chặt chẽ công thức phân rã thành phần L_{graph} cho từng đợt chạy. Việc công khai các sai lệch nguồn gốc và duy trì trạng thái niêm phong của tập kiểm thử giúp tăng tính minh bạch và khả năng kiểm toán của quy trình thực nghiệm.

3.2.2. *Đổi sánh đặc tính phương pháp luận so với các nghiên cứu cơ sở*

Làm rõ vị trí đóng góp học thuật của khung biểu diễn đề xuất, Bảng 3.5 tiến hành đổi sánh định tính về đặc tính phương pháp luận giữa mô hình của luận văn và các phương pháp trích xuất đặc trưng log tiêu biểu được công bố trên các diễn đàn bảo mật quốc tế. Đối chiếu này dựa trên phân tích thiết kế kiến trúc lý thuyết và thực nghiệm tiên huấn luyện Stage A2, không cấu thành tuyên bố thực nghiệm so sánh hơn về độ chính xác phát hiện bất thường downstream khi chưa tiến hành đánh giá end-to-end có gắn nhãn.

Bảng 3.5: Đổi sánh đặc tính phương pháp luận giữa khung biểu diễn đề xuất và các phương pháp cơ sở

Phương pháp cơ sở	Mô hình biểu diễn	Xử lý tham số & thời gian	Đặc tính cấu trúc & Phân tích khoảng trống
DeepLog (Du et al., CCS 2017) [14]	Mô hình chuỗi LSTM trên mã định danh mẫu (Template ID)	Mô hình hóa chuỗi log key và vector giá trị tham số qua các LSTM tách rời; thời gian chỉ phản ánh qua thứ tự bước rời rạc	Nhận xét trong phạm vi đổi sánh của nghiên cứu: Thiếu cấu trúc liên kết đồ thị giữa các thực thể hệ thống; nhạy cảm với biến động log ngoài từ điển
LogBERT (Guo et al., IJCNN 2021) [20]	Mô hình ngôn ngữ tự chú ý Transformer 2 chiều	Mô hình hóa chuỗi mã mẫu; không bảo toàn ngữ nghĩa số học của tham số dòng lệnh	Nhận xét trong phạm vi đổi sánh của nghiên cứu: Không khai thác cấu trúc quan hệ nhân quả đồ thị; chi phí tính toán bậc hai theo độ dài chuỗi
UNICORN (Han et al., NDSS 2020) [9]	Đồ thị nguồn gốc tĩnh với cấu trúc phức họa đồ thị động (Graph Sketching)	Thời gian chia theo khoảng (Histogram/Bucketing); không hỗ trợ tham số biến đổi liên tục	Nhận xét trong phạm vi đổi sánh của nghiên cứu: Dễ gặp hiện tượng bùng nổ phụ thuộc (Dependency Explosion) trong các tiến trình dài ngày
KAIROS (Cheng et al., IEEE S&P 2024) [24]	Mạng đồ thị nguồn gốc theo thời gian (Temporal Provenance Graph)	Sử dụng khoảng thời gian rời rạc giữa các sự kiện kiểm toán kernel	Nhận xét trong phạm vi đổi sánh của nghiên cứu: Tập trung vào log kiểm toán hệ điều hành cấp thấp; chi phí bộ nhớ lớn khi theo vết toàn bộ dòng dữ liệu
MAGIC (Jia et al., USENIX Security 2024) [26]	Mô hình tự mã hóa đồ thị có mặt nạ (Masked Graph Autoencoder)	Phân chia cửa sổ sự kiện tĩnh; không mô hình hóa luồng thời gian liên tục cục bộ	Nhận xét trong phạm vi đổi sánh của nghiên cứu: Quy trình xử lý đồ thị offline, khó triển khai cho các luồng log streaming tốc độ cao
Khung nghiên cứu đề xuất (Temporal Graph View)	TemporalGraphViewEncoder kết hợp bộ nhớ GRU động và Temporal Attention	Hàm nhúng thời gian liên tục phi(Delta t) bảo toàn trọn vẹn khoảng trễ thực tế	Mô hình hóa quan hệ đồ thị dị thể (4 loại nút, 8 loại quan hệ) kết hợp tự giám sát đa nhiệm

3.3. Phân tích triệt tiêu, động thái tối ưu hóa và kiểm chứng giả thuyết

3.3.1. Phân tích động thái tối ưu hóa và hiện tượng dừng sớm

Kết quả thực nghiệm trong chiến dịch huấn luyện Stage A2 ghi nhận sự phân hóa rõ nét giữa các quỹ đạo hội tụ. Trong khi Seed 7 và Seed 999 đạt được mức mất mát kiểm định thấp quanh 0,550–0,609 sau 12 epochs, thì Seed 42 đã kích hoạt cơ chế dừng sớm (Early Stopping) ngay tại Epoch 4 với giá trị mất mát kiểm định ghi nhận ở mức 6.081352 (do thỏa mãn điều kiện kiên nhẫn patience = 3/3 epochs không cải thiện so với Epoch 1).

Phân tích nhật ký huấn luyện (TRAIN-LOG.jsonl) ghi nhận tại Epoch 1, Seed 42 có mất mát kiểm định ban đầu là 6.081352. Sau đó, mất mát trên tập kiểm định không tiếp tục giảm mà tăng lên 6.3761 ở Epoch 2, duy trì ở mức cao ở Epoch 3 (7.0354) và Epoch 4 (7.1509). Dữ liệu thực nghiệm hiện có chưa đủ bằng chứng để xác định chính xác nguyên nhân nội tại của hiện tượng này (chẳng hạn như liệu bề mặt tối ưu có dạng yên ngựa hay gradient của nhánh quan hệ có bị suy giảm hay không), do trong quá trình chạy chưa thực hiện đo đạc trực tiếp phổ giá trị riêng hay chuẩn gradient của từng tầng trọng số. Tuy nhiên, hiện tượng này cho thấy quá trình tối ưu hóa mô hình đồ thị thời gian có thể chịu ảnh hưởng đáng kể từ trạng thái khởi tạo trọng số ngẫu nhiên ban đầu.

Việc báo cáo trung thực kết quả của Seed 42 thể hiện sự tuân thủ nghiêm túc quy trình nghiên cứu khoa học: mọi quan sát thực tế đều được ghi nhận đầy đủ, không thực hiện hành vi loại bỏ kết quả bất lợi để làm đẹp số liệu. Đồng thời, sự biến thiên giữa các hạt giống khẳng định sự cần thiết của việc đánh giá đa seed nhằm lượng hóa độ bất định trước khi đưa ra các kết luận khái quát.

3.3.2. Kiểm chứng các giả thuyết khoa học tiên đăng ký

Đối chiếu kết quả tiền huấn luyện Stage A2 với năm giả thuyết khoa học xác lập tại Chương 2:

1. Giả thuyết H1 (Parameter Semantic Fidelity): Trong Stage A2 trên tập HDFS, nhánh đồ thị tập trung học quan hệ thực thể; mất mát dự đoán cạnh (L_{rel}) giảm từ ~ 0.59 xuống 0.1833, cung cấp bằng chứng bước đầu cho năng lực biểu diễn cấu trúc trước khi đánh giá mức độ bảo toàn tham số động ở các tác vụ hạ nguồn.

2. Giả thuyết H2 (Multi-View Alignment): Nhánh đồ thị ghi nhận mất mát hồi quy thời gian (L_{time}) giảm về 0,0857–0,0887 trên các đợt chạy 12 epochs, phù hợp với kỳ vọng hàm chiếu phi(Δt) biểu diễn khoảng trễ; việc kiểm chứng giống hàng đồng bộ với chuỗi Transformer được định vị cho các giai đoạn tiếp theo.

3. Giả thuyết H3 (Anti-Drift & Shortcut Robustness): Stage A2 tập trung vào nhiệm vụ tự giám sát nội tại, chưa thử nghiệm loại bỏ đặc trưng đường tắt hoặc kiểm tra trôi dạt phân phối; giả thuyết này được bảo lưu kiểm chứng định lượng tại giai đoạn đánh giá đóng băng hạ nguồn.

4. Giả thuyết H4 (Bounded Operational Budget Feasibility): Kích thước lô hiệu dụng 1,024 sự kiện tiêu tốn dưới 550 MB bộ nhớ GPU, gợi ý tiềm năng bước đầu về dung lượng bộ nhớ. Tuy nhiên, cần thêm các phép đo thực nghiệm về độ trễ streaming và thông lượng thực tế trước khi kết luận về khả năng triển khai vận hành SOC.

5. Giả thuyết H5 (Controlled Linkability & Utility–Privacy Frontier): Stage A2 áp dụng chính sách chuẩn hóa danh tính và mã giả danh theo Mục 2.2; các đánh giá tấn công suy luận thành viên và ranh giới Pareto giữa độ chính xác và quyền riêng tư được bảo lưu kiểm chứng ở mô hình hạ nguồn.

3.4. Khả năng ứng dụng thực tế, giới hạn và hướng phát triển

3.4.1. Khả năng tích hợp vận hành trong trung tâm điều hành an ninh mạng SOC

Mô hình biểu diễn đồ thị thời gian mở ra hai tiềm năng ứng dụng cụ thể trong công tác giám sát an ninh mạng:

Thứ nhất, hỗ trợ giảm tải cảnh báo. Việc biểu diễn các thực thể hệ thống theo chuỗi tương tác thời gian liên tục mở ra khả năng gom cụm các sự kiện cảnh báo đơn

lẽ có liên hệ nhân quả, hỗ trợ chuyên viên phân tích theo dõi ngữ cảnh sự cố theo đồ thị tương tác.

Thứ hai, hỗ trợ truy vết sự cố. Vector biểu diễn trạng thái động của các nút thực thể có thể được sử dụng để đối chiếu thứ tự tương tác theo thời gian, hỗ trợ công tác truy vết nguồn gốc trong các tình huống phân tích điều tra số.

3.4.2. Các giới hạn thực nghiệm và hướng nghiên cứu tiếp theo

Nghiên cứu ghi nhận ba giới hạn thực nghiệm cụ thể cần được hoàn thiện trong các giai đoạn tiếp theo:

Thứ nhất, về quy mô thực nghiệm cục bộ. Thực nghiệm Stage A2 được tiến hành trên môi trường máy trạm đơn GPU với độ dài cửa sổ $W = 256$ sự kiện; cần tiếp tục đánh giá khả năng mở rộng trên các đồ thị quy mô lớn hơn với các tập dữ liệu như DARPA TC.

Thứ hai, về chiến lược khởi tạo trọng số. Hiện tượng dừng sớm ở Seed 42 gợi ý sự cần thiết của việc nghiên cứu sâu hơn về các cơ chế khởi tạo trọng số hoặc kỹ thuật khởi động (warmup) thích nghi nhằm cải thiện độ ổn định tối ưu hóa.

Thứ ba, về phạm vi đánh giá hạ nguồn. Giai đoạn Stage A2 mới hoàn thành tiền huấn luyện tự giám sát trên tập Train và Validation; nhiệm vụ tiếp theo là tiến hành đánh giá năng lực phát hiện tấn công trên tập dữ liệu kiểm thử niêm phong khi có ủy quyền chính thức.

KẾT LUẬN

Báo cáo chuyên đề nghiên cứu chuyên sâu đã hoàn thành việc xây dựng khung phương pháp luận và bước đầu kiểm chứng thực nghiệm mô hình biểu diễn đặc trưng nhật ký sự kiện hệ thống dựa trên đồ thị theo dòng thời gian liên tục. Các nội dung chính được tổng hợp theo ba trục nghiên cứu cụ thể:

Một là, về công tác khảo sát và xác lập bài toán (Chương 1). Nghiên cứu đã hệ thống hóa các phương pháp trích xuất đặc trưng log truyền thống (thống kê tần suất, nhúng từ vựng, trích xuất mẫu template tĩnh và đồ thị nguồn gốc tĩnh). Qua đó, chuyên đề chỉ ra các điểm nghẽn then chốt trong các tiếp cận hiện hữu, đặc biệt là sự mất mát ngữ nghĩa tham số biến đổi và sự thiếu hụt thông tin về khoảng trễ thời gian liên tục giữa các sự kiện an ninh mạng.

Hai là, về phương pháp luận và thiết kế kiến trúc (Chương 2). Chuyên đề đề xuất khung kiến trúc biểu diễn đặc trưng, trong đó nhánh đồ thị sự kiện theo thời gian (TemporalGraphViewEncoder) tích hợp tế bào bộ nhớ GRU động và cơ chế chú ý thời gian đa đầu nhằm theo vết trạng thái biến đổi của thực thể. Mô hình tích hợp hàm nhúng thời gian liên tục phi(Delta t) và hàm mục tiêu tự giám sát đa nhiệm, cho phép học biểu diễn cấu trúc quan hệ mà không phụ thuộc dữ liệu gán nhãn.

Ba là, về thực nghiệm và kiểm toán khoa học (Chương 3). Dựa trên cấu hình 12 epochs hiện hành, quá trình kiểm toán độc lập đã phân loại minh bạch toàn bộ 5 hạt giống thực nghiệm. Nhóm quan sát lệch giao thức (Seed 999 hoàn thành 12 epochs với mất mát kiểm định 0,609500 nhưng mang sai lệch về số bước khởi động so với văn bản ủy quyền tiền thi hành; Seed 7 đạt mất mát kiểm định tốt nhất 0,550259 nhưng văn bản ủy quyền commit sau khi khởi chạy; Seed 42 dừng sớm tại Epoch 4) ghi nhận mức mất mát kiểm định trung bình là 2.413704. Cùng với các đợt chạy không chuẩn (Seed 1337, Seed 2024), các kết quả cung cấp dữ liệu đối chiếu khách quan trong khi toàn bộ dữ liệu kiểm thử được duy trì niêm phong sau tường lửa mật mã (test_opened = false).

Các kết quả đạt được cung cấp cơ sở kỹ thuật ban đầu để phục vụ các giai đoạn nghiên cứu tiếp theo, hướng tới việc hoàn thiện mô hình biểu diễn đa góc nhìn toàn phần và thử nghiệm đánh giá phát hiện tấn công trên dữ liệu kiểm thử khi được ủy quyền.

TÀI LIỆU THAM KHẢO

- [1] M. A. Inam, Y. Chen, A. Goyal, J. Liu, J. Mink, N. Michael, S. Gaur, A. Bates and W. U. Hassan, "SoK: History is a Vast Early Warning System: Auditing the Provenance of System Intrusions," in 2023 IEEE Symposium on Security and Privacy (SP), San Francisco, CA, USA, 2023, pp. 2620-2638, doi: 10.1109/SP46215.2023.10179405.
- [2] N. Michael, J. Mink, J. Liu, S. Gaur, W. U. Hassan and A. Bates, "On the Forensic Validity of Approximated Audit Logs," in Proceedings of the 36th Annual Computer Security Applications Conference (ACSAC 2020), Austin, TX, USA, 2020, pp. 189-202, doi: 10.1145/3427228.3427272.
- [3] J. Liu, M. A. Inam, A. Goyal, A. Riddle, K. Westfall and A. Bates, "What We Talk About When We Talk About Logs: Understanding the Effects of Dataset Quality on Endpoint Threat Detection Research," in 2025 IEEE Symposium on Security and Privacy (SP), San Francisco, CA, USA, 2025, pp. 112-129, doi: 10.1109/SP61157.2025.00112.
- [4] MITRE Corporation, "MITRE ATT&CK: Enterprise Tactics and Techniques Matrix (v19.1)," Tech. Rep., 12/05/2026. [Online]. Available: <https://attack.mitre.org/>
- [5] M. Zipperle, F. Gottwalt, E. Chang and T. S. Dillon, "Provenance-based Intrusion Detection Systems: A Survey," ACM Computing Surveys, vol. 55, no. 7, pp. 1-36, 2023, doi: 10.1145/3539605.
- [6] J. Zhu, S. He, J. Liu, P. He, Q. Xie, Z. Zheng and M. R. Lyu, "Tools and Benchmarks for Automated Log Parsing," in 2019 IEEE/ACM 41st International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP), Montreal, QC, Canada, 2019, pp. 121-130, doi: 10.1109/ICSE-SEIP.2019.00021.
- [7] Z. Jiang, J. Liu, J. Huang, Y. Li, Y. Huo, J. Gu, Z. Chen, J. Zhu and M. R. Lyu, "A Large-Scale Evaluation for Log Parsing Techniques: How Far Are We?," in Proceedings of the 33rd ACM SIGSOFT International Symposium on Software Testing and Analysis (ISSTA 2024), Vienna, Austria, 2024, pp. 223-234, doi: 10.1145/3650212.3652123.
- [8] D. Arp, E. Quiring, F. Pendlebury, A. Warnecke, F. Pierazzi, C. Wressnegger, L. Cavallaro and K. Rieck, "Dos and Don'ts of Machine Learning in Computer Security," in Proceedings of the 31st USENIX Security Symposium, Boston, MA, USA, 2022, pp. 3971-3988.
- [9] X. Han, T. Pasquier, A. Bates, J. Mickens and M. Seltzer, "UNICORN: Runtime Provenance-Based Detector for Advanced Persistent Threats," in Proceedings of the Network and Distributed System Security Symposium (NDSS 2020), San Diego, CA, USA, 2020, doi: 10.14722/ndss.2020.24046.
- [10] A. Bardes, J. Ponce and Y. LeCun, "VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning," in Proceedings of the 10th International Conference on Learning Representations (ICLR 2022), 2022.
- [11] J. Zbontar, L. Jing, I. Misra, Y. LeCun and S. Deny, "Barlow Twins: Self-Supervised Learning via Redundancy Reduction," in Proceedings of the 38th International Conference on Machine Learning (ICML 2021), PMLR 139, 2021, pp. 12310-12320.
- [12] Defense Advanced Research Projects Agency (DARPA/I2O), "Transparent Computing Engagement 3 Data Release," original release 30 Aug. 2018, official DARPA-I2O repository / README-E3.md.
- [13] A. D. Kent, "Comprehensive, Multi-Source Cyber-Security Events," Los Alamos National Laboratory (LANL), Dataset, 2015, doi: 10.17021/1179829.
- [14] M. Du, F. Li, G. Zheng and V. Srikumar, "DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning," in Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS '17), Dallas, TX, USA, 2017, pp. 1285-1298, doi: 10.1145/3133956.3134015.
- [15] M. Ilse, J. M. Tomczak and M. Welling, "Attention-based Deep Multiple Instance Learning," in Proceedings of the 35th International Conference on Machine Learning (ICML 2018), Stockholm, Sweden, PMLR 80, 2018, pp. 2127-2136.
- [16] R. Shokri, M. Stronati, C. Song and V. Shmatikov, "Membership Inference Attacks Against Machine Learning Models," in Proceedings of the 38th IEEE Symposium on Security and Privacy (S&P 2017), San Jose, CA, USA, 2017, pp. 3-18, doi: 10.1109/SP.2017.41.
- [17] J. P. Near, D. Darais, N. Lefkovitz and G. S. Howarth, "Guidelines for Evaluating Differential Privacy Guarantees," National Institute of Standards and Technology, NIST Special Publication (SP) 800-226, Mar. 2025, doi: 10.6028/NIST.SP.800-226.
- [18] W. Xu, L. Huang, A. Fox, D. Patterson and M. I. Jordan, "Detecting Large-Scale System Problems by Mining Console Logs," in Proceedings of the ACM SIGOPS 22nd Symposium on Operating Systems Principles (SOSP '09), Big Sky, MT, USA, 2009, pp. 117-132, doi: 10.1145/1629575.1629587.
- [19] J.-G. Lou, Q. Fu, S. Yang, Y. Xu and J. Li, "Mining Invariants from Console Logs for System Problem Detection," in Proceedings of the 2010 USENIX Annual Technical Conference (USENIX ATC 10), Boston, MA, USA, 2010. [Online]. Available: <https://www.usenix.org/conference/usenix-atc-10/mining-invariants-console-logs-system-problem-detection>

- [20] H. Guo, S. Yuan and X. Wu, "LogBERT: Log Anomaly Detection via BERT," in Proceedings of the International Joint Conference on Neural Networks (IJCNN 2021), Shenzhen, China, 2021, pp. 1-8, doi: 10.1109/IJCNN52387.2021.9534113.
- [21] V.-H. Le and H. Zhang, "Log-based Anomaly Detection Without Log Parsing," in Proceedings of the 36th IEEE/ACM International Conference on Automated Software Engineering (ASE 2021), Melbourne, Australia, 2021, pp. 492-504, doi: 10.1109/ASE51524.2021.9678773.
- [22] W. Meng, Y. Liu, Y. Zhu, S. Zhang, D. Pei, Y. Liu, Y. Chen, R. Zhang, S. Tao, P. Sun and R. Zhou, "LogAnomaly: Unsupervised Detection of Sequential and Quantitative Anomalies in Unstructured Logs," in Proceedings of the 28th International Joint Conference on Artificial Intelligence (IJCAI 2019), Macao, China, 2019, pp. 4739-4745, doi: 10.24963/ijcai.2019/658.
- [23] S. Nedelkoski, J. Bogatinovski, A. Acker, J. Cardoso and O. Kao, "Self-Attentive Classification-Based Anomaly Detection in Unstructured Logs," in Proceedings of the 2020 IEEE International Conference on Data Mining (ICDM 2020), Sorrento, Italy, 2020, pp. 1196-1201, doi: 10.1109/ICDM50108.2020.00148.
- [24] Z. Cheng, Q. Lv, J. Liang, Y. Wang, D. Sun, T. Pasquier and X. Han, "KAIROS: Practical Intrusion Detection and Investigation using Whole-system Provenance," in Proceedings of the 45th IEEE Symposium on Security and Privacy (S&P 2024), San Francisco, CA, USA, 2024, pp. 3533-3551, doi: 10.1109/SP54263.2024.00005.
- [25] S. Li, F. Dong, X. Xiao, H. Wang, F. Shao, J. Chen, Y. Guo, X. Chen and D. Li, "NODLINK: An Online System for Fine-Grained APT Attack Detection and Investigation," in Proceedings of the Network and Distributed System Security Symposium (NDSS 2024), San Diego, CA, USA, 2024, doi: 10.14722/ndss.2024.23204.
- [26] Z. Jia, Y. Xiong, Y. Nan, Y. Zhang, J. Zhao and M. Wen, "MAGIC: Detecting Advanced Persistent Threats via Masked Graph Representation Learning," in Proceedings of the 33rd USENIX Security Symposium, Philadelphia, PA, USA, 2024, pp. 5197-5214.
- [27] B. Jiang, T. Bilot, N. E. Madhoun, K. A. Agha, A. Zouaoui, S. Iqbal, X. Han and T. Pasquier, "ORTHRUS: Achieving High Quality of Attribution in Provenance-based Intrusion Detection Systems," in Proceedings of the 34th USENIX Security Symposium, Seattle, WA, USA, 2025, pp. 7173-7192.
- [28] J. Zeng, C. Zhang and Z. Liang, "PalanTir: Optimizing Attack Provenance with Hardware-enhanced System Observability," in Proceedings of the 2022 ACM SIGSAC Conference on Computer and Communications Security (CCS '22), Los Angeles, CA, USA, 2022, pp. 3135-3149, doi: 10.1145/3548606.3560570.
- [29] T. Bilot, B. Jiang, Z. Li, N. E. Madhoun, K. A. Agha, A. Zouaoui and T. Pasquier, "Sometimes Simpler is Better: A Comprehensive Analysis of State-of-the-Art Provenance-Based Intrusion Detection Systems," in Proceedings of the 34th USENIX Security Symposium, Seattle, WA, USA, 2025, pp. 7193-7212.
- [30] L. Guerra, T. Chapuis, G. Duc, P. Mozharovskiy and V.-T. Nguyen, "How Benchmarks and Evaluation Protocols Shape Conclusions in Provenance-Based Intrusion Detection," arXiv preprint arXiv:2608.01454, 2026.
- [31] U. Alon and E. Yahav, "On the Bottleneck of Graph Neural Networks and its Practical Implications," in Proceedings of the 9th International Conference on Learning Representations (ICLR 2021), 2021.
- [32] Nguyễn Thị Thu Thủy, "Phát hiện tấn công APT dựa trên Graph Learning (Phần 2)," Tạp chí An toàn thông tin, 2026. [Online]. Available: <https://antoanthongtin.vn/tin/phat-hien-tan-cong-apt-dua-tren-graph-learning-phan-2>
- [33] M. Fredrikson, S. Jha and T. Ristenpart, "Model Inversion Attacks that Exploit Confidence Information and Basic Countermeasures," in Proceedings of the 22nd ACM SIGSAC Conference on Computer and Communications Security (CCS '15), Denver, CO, USA, 2015, pp. 1322-1333, doi: 10.1145/2810103.2813677.
- [34] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser and I. Polosukhin, "Attention Is All You Need," in Advances in Neural Information Processing Systems 30 (NeurIPS 2017), 2017, pp. 5998-6008.
- [35] D. Xu, C. Ruan, E. Korpeoglu, S. Kumar and K. Achan, "Inductive Representation Learning on Temporal Graphs," in Proceedings of the 8th International Conference on Learning Representations (ICLR 2020), 2020.
- [36] E. Rossi, B. Chamberlain, F. Frasca, D. Eynard, F. Monti and M. Bronstein, "Temporal Graph Networks for Deep Learning on Dynamic Graphs," arXiv preprint arXiv:2006.10637, 2020.
- [37] T. Chen, S. Kornblith, M. Norouzi and G. Hinton, "A Simple Framework for Contrastive Learning of Visual Representations," in Proceedings of the 37th International Conference on Machine Learning (ICML 2020), PMLR 119, 2020, pp. 1597-1607.
- [38] A. van den Oord, Y. Li and O. Vinyals, "Representation Learning with Contrastive Predictive Coding," arXiv preprint arXiv:1807.03748, 2018.
- [39] C. Zhang, Z. Han, Y. Cui, H. Fu, J. T. Zhou and Q. Hu, "CPM-Nets: Cross Partial Multi-View Networks," in Advances in Neural Information Processing Systems 32 (NeurIPS 2019), 2019, pp. 557-567.
- [40] T. Yu, S. Kumar, A. Gupta, S. Levine, K. Hausman and C. Finn, "Gradient Surgery for Multi-Task Learning," in Advances in Neural Information Processing Systems 33 (NeurIPS 2020), 2020, pp. 5824-5836.
- [41] M. Russinovich and T. Garnier, "Sysmon (System Monitor) - Sysinternals," Microsoft Learn, Tech. Doc., 17/06/2026. [Online]. Available: <https://learn.microsoft.com/en-us/sysinternals/downloads/sysmon>

- [42] J. Zhu, S. He, P. He, J. Liu and M. R. Lyu, "Loghub: A Large Collection of System Log Datasets for AI-driven Log Analytics," in 2023 IEEE 34th International Symposium on Software Reliability Engineering (ISSRE), Florence, Italy, 2023, pp. 355-366, doi: 10.1109/ISSRE59848.2023.00071.
- [43] Defense Advanced Research Projects Agency (DARPA/I2O), "Transparent Computing Engagement 5 Data Release," original release 29 Apr. 2020, official DARPA-I2O repository / README.md.
- [44] K. Oono and T. Suzuki, "Graph Neural Networks Exponentially Lose Expressive Power for Node Classification," in Proceedings of the 8th International Conference on Learning Representations (ICLR 2020), 2020.